

第049讲 学习理论的第一组保证

从“这一次误差不大”到“哪些随机实验中有大概率出错”

先修与路线。先修008讲的函数代数与数学表达、018讲的概率事件与条件信息、022讲的抽样与极限定理，以及048讲的风险与泛化分解。先完成六行五规则的计算，再读Hoeffding界和union bound；指数矩推导可留到第二遍。最后用一个失败率接近一半的反例检查你是否真的理解“固定模型”。建议三次学习，每次60–90分钟。

本讲研究有限规则集合，不假装每个机器学习任务都要梯度下降。数据、规则、风险、选择过程全部能逐格列出，因此可以把概率界与真实误差分开核对。所有实验为预声明合成机制，无真实个人数据，也不是现实任务的性能保证。

1. 先分清三个风险和两种概率

一个假设 h 就是一个预测规则。给定输入 x ，它输出预测 $h(x)$ ；损失 $\ell(h(x), y)$ 衡量预测与真实 y 的差异。总体风险和样本经验风险分别是

$$R(h) = E_{(X,Y) \sim P}[\ell(h(X), Y)], \quad \hat{R}_S(h) = \frac{1}{n} \sum_{i=1}^n \ell(h(x_i), y_i).$$

这里 P 是数据生成分布， $S = ((x_1, y_1), \dots, (x_n, y_n))$ 是抽到的样本。对一个固定 h ， $R(h)$ 是固定但通常未知的数， $\hat{R}_S(h)$ 随 S 变化。学习算法从样本选择 $\hat{h}(S)$ ，所以 $R(\hat{h})$ 也会随训练集变化。

目标可以是控制某一个 h 的估计误差，也可以控制所有 $h \in \mathcal{H}$ ，或者控制选中规则相对于类内最佳规则的超额风险。三个对象不同，不能在公式中省掉下标后混用。

ϵ 表示允许的误差幅度， δ 表示允许的坏样本概率。例如“以至少0.95概率偏差不超过0.1”，是对重新抽取整份样本的随机实验作陈述。它不是说每个预测都有95%概率正确，也不是说真实风险本身是一个均匀随机数。

2. 一个能精确知道总体风险的小世界

令 X 取 $(-2, -1, 1, 2)$ ，概率为 $(1, 3, 3, 1)/8$ 。正类概率依次是 $(1/8, 1/4, 3/4, 7/8)$ 。完整联合分布有八个结果：

输入 x	真实 y	联合概率
-2	0	7/64
-2	1	1/64
-1	0	9/32

输入x	真实y	联合概率
-1	1	3/32
1	0	3/32
1	1	9/32
2	0	1/64
2	1	7/64

预先固定五个向右递增的阈值规则。按四个输入顺序，预测向量为 $H_0 = (1, 1, 1, 1)$, $H_1 = (0, 1, 1, 1)$, $H_2 = (0, 0, 1, 1)$, $H_3 = (0, 0, 0, 1)$, $H_4 = (0, 0, 0, 0)$ 。本讲用0-1损失：预测等于标签时0，否则1。

以 H_2 为例，它在 $(-2, 1), (-1, 1), (1, 0), (2, 0)$ 上出错，所以

$$R(H_2) = \frac{1}{64} + \frac{6}{64} + \frac{6}{64} + \frac{1}{64} = \frac{7}{32} = 0.21875.$$

H_1 只在 $x = -1$ 处与 H_2 不同，把原先的正类错误质量6/64换成负类错误质量18/64，风险增加12/64 = 3/16。所以 $R(H_1) = 13/32$ 。其余规则也逐项累加，不用大型测试集近似。




图1 事前固定的五个预测向量，以及对八种结果精确求和得到的真实风险。

读图问题。 为什么 H_2 最好但风险仍不为0？标签本身有随机性。这个主实验属于有噪声、一般的学习场景，不满足“类内有一个零风险规则”的可实现假设。

3. 六行样本：前向、损失、汇总、选择

以下纸笔样本是事先写定的教学例子，不冒充随机抽样结果。每行先读取 x ，查每个规则的预测，再与 y 比较，得到五个损失。每个损失除以6后，才是该行对平均风险的贡献。

行	x	y	五规则预测 H0...H4	五个0-1损失
S1	-2	0	1,0,0,0,0	1,0,0,0,0
S2	-1	1	1,1,0,0,0	0,0,1,1,1
S3	-1	0	1,1,0,0,0	1,1,0,0,0
S4	1	1	1,1,1,0,0	0,0,0,1,1
S5	2	1	1,1,1,1,0	0,0,0,0,1
S6	2	0	1,1,1,1,0	1,1,1,1,0

第2行 $x = -1, y = 1$: $H_2(x) = 0$, 故损失 $1\{0 \neq 1\} = 1$, 对平均风险贡献 $1/6$ 。第3行同样 $x = -1$ 但 $y = 0$, H_2 的贡献是0。不能先对标签取整或把重复输入当作同一观测而合并掉标签噪声。

将整批六行汇总后, 错误次数为(3, 2, 2, 3, 3), 经验风险为(1/2, 1/3, 1/3, 1/2, 1/2)。并列集合是 $\{H_1, H_2\}$; 预先约定按列表顺序选第一个, 因此选择 H_1 , 其真实风险13/32, 比类内最佳高3/16。

这里没有光滑参数和局部导数。对离散规则列表作精确枚举, 找到最小经验风险, 称经验风险最小化(ERM)。若随意对0-1指示函数求一个不存在的全局普通梯度, 再宣称完成“反向传播”, 反而掩盖了真实算法。

4. 追加整批观测, 再做下一次前向

接着把事先声明的两条追加训练观测 $(-1, 0), (1, 1)$ 一起加入。它们不是封存测试集, 算法允许使用它们更新选择。两行分别产生损失向量(1, 1, 0, 0, 0)和(0, 0, 0, 1, 1)。

同步加入整批后, 八行总错误次数为(4, 3, 2, 4, 4), 经验风险为(1/2, 3/8, 1/4, 1/2, 1/2), 这次唯一最优是 H_2 。再执行所选规则的下一前向, 四个输入的预测从(0, 1, 1, 1)变为(0, 0, 1, 1), 只有 $x = -1$ 改变。

阶段	H0	H1	H2	H3	H4	选中
初始六行	0.500000	0.333333	0.333333	0.500000	0.500000	H1
追加后八行	0.500000	0.375000	0.250000	0.500000	0.500000	H2
总体风险	0.500000	0.406250	0.218750	0.406250	0.500000	总体最优H2




图2 六行损失矩阵与两次完整选择。参数更新在这里表现为离散规则选择改变，而不是梯度步。

读图问题。 如果起初并列时选择 H_2 ，这份六行样本的真实风险会不同，为什么不违背“两个规则经验风险相同”？因为经验风险只描述当前六行；总体对未见结果的权重不同。

5. 固定规则：Hoeffding界究竟用了什么

先固定一个不依赖这份样本的 h ，令 $Z_i = \ell(h(X_i), Y_i)$ 。假设观测独立同分布，并且损失位于 $[0, 1]$ 。则 Z_i 也是独立同分布的有界变量，均值为 $R(h)$ 。

Hoeffding型双侧结论为

$$P\{|\hat{R}_S(h) - R(h)| > \epsilon\} \leq 2 \exp(-2n\epsilon^2).$$

若右侧大于1，可以截到1，因为概率本来不超过1；这叫没有提供额外信息的平凡界，不是概率“大于100%”。以 δ 为允许失败概率，反解得

$$\epsilon_{\text{fixed}}(n, \delta) = \sqrt{\frac{\log(2/\delta)}{2n}}.$$

于是对这个固定规则，以至少 $1 - \delta$ 的概率，真实风险位于 $[\hat{R} - \epsilon_{\text{fixed}}, \hat{R} + \epsilon_{\text{fixed}}] \cap [0, 1]$ 。不等式允许比 δ 小得多的实际失败率。

假设检查。 独立同分布针对观测行，不是针对不同规则。0-1损失满足范围；无界平方误差、未截断对数损失不能直接代入这个 $[0, 1]$ 公式。若损失在 $[a, b]$ ，可归一化，偏差尺度乘 $b - a$ ；若不同时间分布发生变化，则估计的目标也需要重新定义。

6. 选读推导：为什么出现指数和 $n\epsilon^2$

先看一个 $Z \in [0, 1]$ 。定义 $K(\lambda) = \log E[e^{\lambda(Z - EZ)}]$ 。这是对指数变换再取对数，不是新的预测模型。 $K(0) = 0$ 、 $K'(0) = 0$ ；再求一次导数， $K''(\lambda)$ 是在按指数权重重新加权后的分布中的方差。

重新加权不改变 $Z \in [0, 1]$ 。对任意这种变量，因 $Z^2 \leq Z$ ，若均值为 μ ，方差不超过 $\mu - \mu^2 \leq 1/4$ 。所以 $K'' \leq 1/4$ ，从0积分两次得到 $K(\lambda) \leq \lambda^2/8$ 。即

$$E[e^{\lambda(Z-EZ)}] \leq e^{\lambda^2/8}.$$

对独立的 n 个损失，指数和的期望能分解为期望乘积。这一步才是独立性进入证明的地方。对非负随机变量使用Markov不等式：

$$P\left\{\sum_i (Z_i - EZ_i) > n\epsilon\right\} \leq e^{-\lambda n\epsilon} \prod_i E[e^{\lambda(Z_i - EZ_i)}] \leq e^{-\lambda n\epsilon + n\lambda^2/8}.$$

取 $\lambda = 4\epsilon$ 使指数最小，得到 $e^{-2n\epsilon^2}$ 。对负方向重复，再把两个坏事件概率相加，得到前面的系数2。若独立性不存在，乘积分解不能随便写下去；这比记住一个根号更重要。

7. 为什么训练后不能直接把选中规则当作固定规则

对每个事前固定的 h ，上面的结论都成立，并不意味着把 h 换成用同一份数据挑出来的 $\hat{h}$ 就自动成立。筛选偏好经验误差偶然偏小的规则，规则索引携带了样本信息。

一个常见错误是：“我最终只交付一个模型，所以 $M = 1$ 。”如果这一个模型是比较几百个候选后选出来的，选择发生之前的候选集合和选择过程不能被删除。后面我们会给出真实失败概率接近一半的例子。

解决办法之一是让同一个好事件同时保护整个事前固定集合。另一个办法是只在完全独立、没有反馈选择的留出集上评价已冻结规则。

8. Union bound：不要求规则之间独立

定义每个规则的坏事件 $A_h = \{|\hat{R}(h) - R(h)| > \epsilon\}$ 。至少一个规则出问题的事件是 $\bigcup_{h \in \mathcal{H}} A_h$ 。指示函数满足

$$1\{\bigcup_h A_h\} \leq \sum_h 1\{A_h\}.$$

两边取期望，就有 $P(\bigcup_h A_h) \leq \sum_h P(A_h)$ 。这里没有使用坏事件互相独立。五个阈值规则的损失高度相关，但仍可以用这条界。

若事前固定有限类大小为 M ，得到

$$P\{\max_{h \in \mathcal{H}} |\hat{R}(h) - R(h)| > \epsilon\} \leq 2Me^{-2n\epsilon^2}.$$

反解为

$$\epsilon_{\text{unif}}(n, M, \delta) = \sqrt{\frac{\log(2M/\delta)}{2n}}.$$

在这个同时成立的好事件上，无论你根据当前样本如何选择类中的规则，选中者也受同一个偏差界保护。关键是它属于已经被保护的集合，而不是选择算法必须独立于样本。

9. 三项相加：从一致收敛走到ERM保证

令 $h^* \in \arg \min_{h \in \mathcal{H}} R(h)$, $\hat{h} \in \arg \min_h \hat{R}(h)$ 。在所有规则的偏差都不超过 ϵ 时，插入并减去经验风险：

$$R(\hat{h}) - R(h^*) = [R(\hat{h}) - \hat{R}(\hat{h})] + [\hat{R}(\hat{h}) - \hat{R}(h^*)] + [\hat{R}(h^*) - R(h^*)].$$

第一项最多 ϵ ，中间项因ERM最多0，最后一项最多 ϵ 。所以 $R(\hat{h}) - R(h^*) \leq 2\epsilon$ 。这就是近似“训练好”如何变成“总体上接近类内最好”的桥梁。

若只找到经验目标距离最小值不超过 ζ 的规则，中间项最多 ζ ，保证就变成 $2\epsilon + \zeta$ 。本讲是精确有限搜索， $\zeta = 0$ 。该结论不解决模型类本身的近似误差，也不消除标签噪声；它与048讲的误差分解衔接。

10. 精确枚举：界真的压住了实际尾概率吗

每次抽样只会落在八种结果之一。若计数为 $(c_1, \dots, c_8)$ 、和为 n ，其概率为

$$P(c_1, \dots, c_8) = \frac{n!}{\prod_i c_i!} \prod_i p_i^{c_i}.$$

计算每种计数的五个经验风险、固定规则偏差与最大偏差，再把坏事件的概率相加。所有 p_i 分母是64，因此可以用整数与有理数精确累计，而不依赖Monte Carlo。

对 $n = 8$ 共有 $\binom{15}{7} = 6435$ 种计数组合；它们代表 8^8 种有序样本。独立核验还对 $n = 4$ 逐个遍历全部4096个有序样本，与组合计数方法逐项一致。

$n=8, \epsilon$	固定H2坏事件	同时坏事件	同时上界截断到1
1/8	0.384492355	0.815579853	1.000000000
1/4	0.075113166	0.316424976	1.000000000
3/8	0.015402707	0.060545543	1.000000000
1/2	0.002027565	0.003492207	0.183156389




图3 $n=8$ 的完整精确枚举与理论上界。纵轴为对数轴，不能把竖向距离当作概率相减。

读图问题。 当 $\epsilon = 1/2$ 时，同时坏事件概率约0.003492，而上界约0.183156。界很松，但没有声称实际概率等于这个上界。它只使用范围、样本数和类大小，舍弃了具体分布与规则相关性。

固定阈值的实际尾概率也不必随每个整数 n 严格单调。比如固定 H_2 、 $\epsilon = 1/8$ 时， $n = 6$ 尾概率约0.350621， $n = 8$ 约0.384492；经验误差格点跨过严格阈值会产生跳变。不要为了画单调线而改结果。

11. 14000次独立重复：把真实误差与界放在一起

主种子4905，样本数为8、16、32、64、128、256、512，每个 n 独立重复2000次。按八类别的多项分布直接抽计数，与抽IID有序样本后计数具有相同分布；顺序不影响这些风险。每次保留完整计数、选中规则、经验/真实风险、带符号差、最大绝对差和超额风险。

n	同时半径	实测最大偏差均值	超额风险均值	同时界违约次数/2000
8	0.575452	0.228969	0.078797	3
16	0.406906	0.158078	0.042797	2
32	0.287726	0.111156	0.012516	2
64	0.203453	0.078508	0.001781	1
128	0.143863	0.055129	0.000000	2
256	0.101726	0.039678	0.000000	1
512	0.071931	0.027733	0.000000	5




图4 实际偏差的分布与保守界同时画出；右侧原始 2ϵ 有时大于1，虚线截断只使用已知风险范围。

这里真实违约次数不是全零，也远少于 0.05×2000 。 δ 是上限而非必须达到的比例。图左阴影是重复结果的5%至95%分位带，不是均值置信区间；图右曲线为平均超额风险，不是每次实验最大值。

$n = 256$ 的带符号乐观差 $R(\hat{h}) - \hat{R}(\hat{h})$ 样本均值为 -0.000378906 ，照实保留。有限次Monte Carlo均值可以因为抽样波动为负；不能强制截成0。零观测违约也不证明真实概率为0：若2000次独立重复均未违约，单侧95%二项上限是 $1 - 0.05^{1/2000} \approx 0.001497$ 。

12. 纯噪声候选：错误使用单模型界的反例

现在换一个预声明机制。标签恒为0，输入有 M 个彼此独立的公平二元特征，每个规则 $h_j(x) = x_j$ 。所以所有规则真实风险都是1/2，不存在真正更有预测力的候选。

n 行训练数据中，第 j 个规则的错误数 $K_j \sim \text{Binomial}(n, 1/2)$ ，并且这些错误数相互独立。ERM选择最小的 K_j 。增加候选越容易碰到“偶然训练错误很少”的规则，但真实风险仍为1/2。这一特别构造中的候选独立只用于计算精确最小值分布，不是union bound的普遍要求。

$n = 20, \delta = 0.05$ 时，固定模型半径约0.303681；若选中错误数不超过3，则 $0.5 - K_{\min}/20$ 超过半径。单个规则出现至多3错的概率为

$$q = \frac{\binom{20}{0} + \binom{20}{1} + \binom{20}{2} + \binom{20}{3}}{2^{20}} = \frac{1351}{1048576}.$$

至少一个候选出现这个事件的概率是 $1 - (1 - q)^M$ 。双侧违约还包括所有候选都至少17错的极小概率 q^M 。所以误用单模型界的真实违约概率是 $1 - (1 - q)^M + q^M$ 。 $M = 512$ 时约0.483196884，大于声称的0.05。

M	误套单模型界：解析	误套：实测/2000	正确同时界：解析	同时界：实测/2000
1	0.002576828	6	0.002576828	6
8	0.010260951	17	0.001608669	1

M	误套单模型界：解析	误套：实测/2000	正确同时界：解析	同时界：实测/2000
64	0.079199301	156	0.001280930	0
512	0.483196884	960	0.000488162	0




图5 n=20的纯噪声筛选。左侧训练误差下降不代表总体预测能力提高；右侧误套单模型界产生高失败率。

读图问题。如果有人只展示左图的下降曲线，并把最终模型称作“优秀模型”，还缺哪一个总体事实？若按同样逻辑把512写成1，右图哪个实际结果直接否定这一做法？

13. 分布而不只是平均值

独立候选的最小错误数满足

$$P(K_{\min} > k) = [1 - F_{\text{Binomial}(n, 1/2)}(k)]^M.$$

相邻尾概率相减就得到最小值的概率质量。程序先用精确整数二项系数构建CDF，再以100位Decimal计算这些概率；这些是高精度解析公式求值，不称为无限精度的有理数输出。Monte Carlo按相同二项计数分布抽样，不伪装成训练了神经网络。




图6 n=20时最小错误率分布随M左移；M=512的2000次实际频率与解析概率质量并列。

核验时也遇到一个普通数值问题：直接对接近1的生存概率取512次方再相减，在 $n = 100$ 某个小概率格点有约 3.59×10^{-14} 绝对差。改用互补CDF、 $\log 1p$ 和 $\exp m1$ 进行独立SciPy参照后，最大差约 10^{-15} ；没有扩大验收容差或改科学结果。

读图问题。 每条分布的总概率质量是多少？选中训练误差0.2的模型，真实风险仍可能是多少？这里答案恰好是0.5，因为所有候选的总体表现都已由机制确定。

14. 独立留出集为什么能重新使用单模型界

训练数据先选索引 $\hat{j}$ ，保存选择摘要。再取独立100行留出数据，不根据留出结果反向修改索引。条件于全部训练数据， $\hat{j}$ 已经固定；留出损失仍是独立的伯努利1/2，因此可以在留出样本数100上使用单模型界。

这不是把训练时的512个比较抹掉，而是换了一份与选择独立的样本来评价。训练样本数20、50、100时，独立留出违约频率分别是0.0070、0.0075、0.0060，均为2000次重复的实际频率。




图7 选择阶段与独立评价阶段的数据角色；同一数据复用的失败率与独立留出评价分开报告。

读图问题。 左图两个柱形使用的是同一个半径吗？训练侧半径按训练 n ，留出侧按100计算，所以不是。若用留出分数再从512个候选挑最好者，哪个条件随之失效？

15. 边缘分布相同，并不等于独立

另取一个公平伯努利变量 B ，把它复制20次作为损失，即 $Z_1 = \dots = Z_{20} = B$ 。每一行的边缘分布都是伯努利1/2，真实风险也为1/2；但经验均值只能为0或1，绝对偏差始终0.5。

如果错误地按 $n = 20$ 套用半径0.303681，就会每次都违约，失败概率为1。多保存19份相同观测没有增加19份独立信息。这个反例不靠随机种子；两种可能结果已经枚举完。




图8 独立20次与同一变量复制20次的精确分布。两边每一行边缘相同，但均值集中性完全不同。

读图问题。 为什么这不是“样本量20所以理论失效”的反例？被破坏的是独立性前提。真实群组和时间数据不一定完全复制，但同样需要先识别有效独立单位；050讲将具体处理划分与评价对象。

16. PAC：把 ϵ 、 δ 与样本量连起来

在统计学习意义下，PAC的核心是：对指定的分布/任务范围，样本足够多时，以至少 $1 - \delta$ 概率得到误差不超过目标 ϵ 的规则。可实现场景以真实错误率为目标，一般有噪声场景通常以相对类内最优的超额风险为目标。量词是对允许的分布与目标条件成立，而不是只在一个随机种子上成功。

令一般ERM保证中的 $2\epsilon_{\text{unif}}$ 不超过目标 ϵ ，平方整理：

$$2\sqrt{\frac{\log(2M/\delta)}{2n}} \leq \epsilon \iff n \geq \frac{2\log(2M/\delta)}{\epsilon^2}.$$

这是充分条件，不是必要样本数，也不保证我们能高效搜索所有规则。统计可学习性与计算效率需要区分。

如果另外知道类内有一个零风险规则，且算法返回训练集上零错的一致规则，可以得到更强的可实现结论。真实风险大于 ϵ 的固定坏规则在 n 行上全对的概率不超过 $(1 - \epsilon)^n \leq e^{-n\epsilon}$ ；对 M 个候选求 union bound，令 $Me^{-n\epsilon} \leq \delta$ ，得到 $n \geq \log(M/\delta)/\epsilon$ 。




图9 两种不同假设下的充分样本量公式，横轴只取预声明的三个目标值并连线。可实现公式不适用于本讲有噪声总体。

读图问题。 为什么右图样本数较少？它增加了零风险可实现性及一致学习器要求。不能只因右图更漂亮，就用它替换左图对有噪声数据的结论。

17. 从有限数量走向VC维

实数阈值有无穷多个，不能直接把 $M = \infty$ 代入有限类公式后得到有用界。一个新思路是看这些规则能在有限点集上制造多少种标签模式，而不只数参数有多少取值。

一个假设类能**打散**一组 m 个点，表示这 2^m 种二元标签分配都能由类中某个规则实现。VC维是存在可被打散点集的最大大小。注意“存在某种点的摆放能打散”和“任意摆放都能打散”不同。

对于固定向右的阈值，任一单点能标0或1；对两个有序不同点，标签10永远做不到，因此VC维1。这里没有允许阈值方向随意翻转；若换了类，维数结论可能改变。

对于实数轴上的区间内标1，两个点四种标签都能实现；三个有序点的101做不到，因为区间包含两端就必须包含中间，所以VC维2。对 m 个有序不同点，阈值模式数 $m + 1$ ，区间模式数 $m(m + 1)/2 + 1$ ，后者还包括全0模式。




图10 完整标签模式表展示缺失模式。左表有四种标签分配但只有三种阈值可实现；右表区间缺少101。

读图问题。 右侧101行被画出来，是否表示它可实现？看行标签“缺少”；图列出了全部可能的标签需求，然后标记类不能实现的那一种。

VC理论用增长函数、对称化与额外论证处理无限类。不能直接把当前样本上观察到的模式数，替换固定类union bound里的 M 而不证明。模式可能由当前样本决定，而相同样本内行为的规则在总体上仍不同。本讲介绍这一入口，不把有限实验冒充一般VC定理证明。

18. 如何读界、复现以及继续研究

先写清损失范围、独立单位、数据分布、候选集合确定时间、选择与评价的数据角色，再谈界的数值。界很松可能因为舍弃了方差、相关性或算法结构，可以寻找更精细理论；但“松”本身不等于错误。反过来，某次实验的差距小也不能补上缺失前提。

`experiment.py`保存全部14000次主实验计数和6000次纯噪声重复的选择记录；`audit.py`独立做4096条有序样本枚举、固定规则的精确二项尾概率、事件union核对、Decimal半径、实际SciPy分布、所有随机流重建及数据角色变换测试。普通和-0都用显式检查，Notebook首格先核验源与数据。详见独立实验手册。

数值工具有公开的有限资源范围，不接受布尔、复数、非有限值冒充数值。精确组合枚举限 $n \leq 8$ ；大规模部分用明确标注的Monte Carlo。概率小到浮点下溢时，指数上界同时保留对数值，不声称输出0就是数学概率0。完整输入域与失败契约见README。

原始来源

1. Hoeffding (1963) , [Probability Inequalities for Sums of Bounded Random Variables](#), 核对原论文Theorem1/2与指数矩方法；本讲自行展开适用于学习损失的推导，没有复制论文图。
2. Balcan, [Foundations of Machine Learning and Data Science](#), 2015-09-16, 核对可实现有限类样本复杂度、PAC及阈值/区间打散定义。
3. Póczos, [CMU 10-715 VC Theory](#), 核对有限类与无限类处理的区别。未把课程图作为本讲插图。

核对日期2026-10-05。所有八状态分布、六行手算、追加批次、纯噪声选择及十图为原创教学构造。学完后请解释：为什么数据依赖的选择可以被同时界保护，却不能自动被固定单模型界保护？