

第050讲练习详解 数据划分与评价对象

1 使用本答案前的约定

本答案覆盖讲义E1至E16、图G1至G10和实验L1至L8。主实验60台设备、48天，标签在t+2可用；第32天结束冻结时，只能训练 $t \leq 30$ ；测试从33日开始并逐日读取当日x。纸笔四行表与两设备权重表是独立的精确教学例，不应误当主面板的子样本。

优化目标用半平方损失加岭惩罚并除以n；主报告用没有1/2的测试MSE。任何数值核对先检查这两种尺度。近似数允许合理浮点容差，不能为了匹配末位而调整随机数据。

2 讲义练习完整解答

E1 同一个人两种任务

“在周五冻结模型，使用截止周五已取得的登记者历史与当次可用输入，预测这些登记者下一周的结果，以每人等权的损失汇总。”这允许同人跨训练和测试，但必须训练早于评价、标签已成熟；若每周重训，还要在每个预测起点重新建立合法训练窗口。

“使用开发阶段见过的人的记录训练，评价从未参与训练的新登记者首次预测，以每人等权损失汇总。”这需要整人留出；若还要模拟未来新登记者，应同时保持时间方向。如果新登记者先有几次校准观测，须明确它们何时取得、哪些可用于适应以及哪些才算最终测试。

两句的目标总体与可用历史不同。随机按周记录切分无法同时证明两者；只删姓名列也不改变其他稳定个人特征和重复记录的关联。

E2 相关结构与总均值方差

$\bar{Z} = G^{-1} \sum_g a_g + (Gm)^{-1} \sum_{g,t} \varepsilon_{gt}$ 。两部分独立，第一部分方差为 $G\tau^2/G^2 = \tau^2/G$ ；第二部分为 $Gm\sigma^2/(Gm)^2 = \sigma^2/(Gm)$ ，相加得所需式。

同组两行协方差为 $\text{Var}(a)=1.44$ ，单行方差1.69，所以 $\rho=1.44/1.69 \approx 0.852071$ 。方差放大因子为 $1+47\rho \approx 41.047337$ 。Gm=2880时，按这一均值的方差等效换算约70.16个独立观察。

推导针对去掉已知信号后Z的总体均值，依赖等组大小、同方差和指定相关结构。MSE是拟合残差的平方，通常有不同相关结构；训练参数又依赖整张数据。因此这个有效样本量不能直接移植到MSE区间、AUC或神经网络的泛化分析。

E3 标签成熟日

训练条件是label_available_day ≤ 32 。第30天标签到32天，可使用；第31天到33天，不可使用；第32天到34天，也不可使用。只因为输入与事件日期早于截止，不代表标签已知。

若延迟5天，条件 $t+5 \leq 32$ 给 $t \leq 27$ 。若某些记录延迟不同，应逐行检查实际可用日，而非所有记录统一减一个平均延迟。事后回填的最终标签还需历史快照或明确版本，不能把最后文件状态冒充过去系统状态。

E4 逐样本完整链

$\theta=0$ 时四行预测0，残差依次-1、-3、-2、-4。半平方损失依次1/2、9/2、2、8，均值 $15/4=3.75$ 。

局部导数由残差乘设计行： $H1=(-1,0,-1,0)$ ， $H2=(-3,-3,-3,0)$ ， $H3=(-2,0,0,-2)$ ， $H4=(-4,-4,0,-4)$ 。按列合计 $(-10,-7,-4,-6)$ ，除4得到 $(-5/2,-7/4,-1,-3/2)$ 。这是平均目标的梯度，不能再除4。

初始化正则梯度为0。 $\eta=1/5$ 同步更新 θ 为 $(1/2,7/20,1/5,3/10)$ 。下一前向： $H1$ 为 $1/2+1/5=7/10$ ； $H2$ 再加 $7/20$ 得到 $21/20$ ； $H3$ 为 $1/2+3/10=4/5$ ； $H4$ 再加 $7/20$ 得到 $23/20$ 。

从这个非零参数开始，正则目标和下一次梯度的正则部分都非零。下一梯度为数据梯度加 $(0,w,vA,vB)/4$ ，截距仍不惩罚。更新时不能先改某个参数再用其新值算其他参数梯度，否则不再是本题同步全批量GD。

E5 下一目标与最优值

下一残差为 $-3/10$ 、 $-39/20$ 、 $-6/5$ 、 $-57/20$ 。残差平方和为13.455，除8得到1.681875。惩罚平方和为 $(7/20)^2+(1/5)^2+(3/10)^2=101/400=0.2525$ ，除8为 $101/3200=0.0315625$ 。总值 $5382/3200+101/3200=5483/3200=1.7134375$ 。

最优参数 $(2,1,-1/3,1/3)$ 下，训练预测为 $5/3$ 、 $8/3$ 、 $7/3$ 、 $10/3$ ，残差 $2/3$ 、 $-1/3$ 、 $1/3$ 、 $-2/3$ 。残差平方和 $10/9$ ；非截距系数平方和 $1+1/9+1/9=11/9$ 。目标为 $(10/9+11/9)/8=7/24$ 。

验证一阶条件：残差和0，对 x 的残差和-1加 $w=1$ 得到0；设备A残差和 $1/3$ 加 $vA=-1/3$ 得到0；设备B残差和 $-1/3$ 加 $vB=1/3$ 得到0。正惩罚与非空截距列保证本增广目标唯一，故该驻点就是最优。

$H5$ 已知A、 $x=2$ ，预测 $2+2-1/3=11/3$ ； $H6$ 未知C，专属项0，预测 $2+2=4$ 。它们的 y 分别5、7仅用于后续评价，不会改变模型。一次GD时这两个预测是1.4与1.2，不能把最优预测误写成第一步输出。

E6 划分计数与未使用记录

random: $2880 \times 75\%=2160$ 训练、720测试、0未用，当前固定索引中60设备都同时出现。group: $45 \times 48=2160$ 训练、 $15 \times 48=720$ 测试，设备交集0，0未用。

time: 训练日0至30共31天， $60 \times 31=1860$ ；测试33至47共15天， $60 \times 15=900$ ；未用31、32两天共120行。设备交集60，这是已知设备未来目标所允许的历史共享。

group_time: $45 \times 31=1395$ 训练、 $15 \times 15=225$ 测试。45个训练设备的31至47日共765行不评价；15个留出设备的0至32日共495行不训练；合计1260未用，正好补齐2880。未用原因是目标定义与标签时序，不是按照误差挑选。

E7 修正随机分数陈述

可以写：“在第0份60设备48天合成面板的观察期结束后，随机保留720行作为测试，用其余2160行训练带设备偏置的Personalized，测试行属于已见设备，覆盖同一日历期，按行平方损失平均得到MSE约0.636795。这是回顾性缺失记录评价。”

改成“新设备未来风险”就缺少设备身份隔离与时间可用性两种边界。模型训练看过这些测试设备的其他天，也看过较晚日期标签。不能用同一数值改标题而不重新设计评价。随机方案计算正确不等于部署声称正确。

E8 有限测试与噪声期望

0.25是本机制独立测量噪声的方差。对固定预测和测试设计重新抽噪声时，期望平方误差为信号偏差平方平均加0.25，不能低于0.25。但一次有限样本的噪声平方均值和交叉项都有波动，实际MSE可以更小。

Trend时间协议当前实际MSE约0.237188，oracle_conditional_mse约0.258967。后者用测试位置的模拟真均值 μ 计算，已经包含新标签噪声0.25，不代表对所有可能设备、日期、训练集和分布漂移完成积分。前者已与含噪 y 比较，也不能再加0.25。

低于0.25的某一次成绩不是泄漏的充分证据，更不是突破不可约噪声的证明。应检查独立性、数量、结果波动及信息路径，而非凭一条数值不等式给结论。

E9 三种重复及三种离散量

80份面板每次重抽 a 、 u 、 ε 并重训，反映此指定生成机制下整个学习和测试流程的变化。同一张现有表反复shuffle共享观测和设备效应，只反映划分条件下的一部分不稳定性，不能当成80份独立总体数据。

标准差描述一份新面板结果的离散；MC标准误 $SD/\sqrt{80}$ 描述80份均值估计的蒙特卡洛精度；10%至90%范围包住这80个结果的中间80%，不是均值置信区间。这里同设备未来Personalized的数值分别约0.051584、0.005767、[1.456109,1.580299]。

同份面板不同模型是配对，统计比较应保留这个关系。不同协议也共享面板但目标不同，不应该把12条结果摊成12个独立重复。固定划分seed只是使位置可重复，随机性的主要来源是新面板。

E10 权重翻转

按行抽样时抽到U概率8/10、V概率2/10。A的 $MSE=(8 \times 1 + 2 \times 9)/10=2.6$ ， $B=4$ ，所以A好。按设备抽样时两台各1/2， $A=(1+9)/2=5$ ， $B=4$ ，所以B好。

哪个更适合取决于目标。服务成本按每条记录计算可能倾向行权重；要代表每个设备的平均体验可能倾向设备权重。权重必须事先说清，不能看完结果后挑让某模型赢的一项。

随机测试每个设备留出记录数不等，所以主例Personalized行MSE0.636795与设备MSE0.631142不同；整组、时间、联合每台测试数相同，两项恰好相等。相等是这个样本设计的代数事实，不是二者永远相同。

E11 Bootstrap的边界

同一设备的残差损失共享未学到的偏置，720行并非720个独立设备。行级重采样打散了这层依赖，分布过窄；组级每次抽15台并保留各自48行，较好对应固定拟合模型下独立新设备抽样。

当前行SD约0.097790、组SD约0.423647。百分位区间分别约[1.666194,2.042607]与[1.085891,2.720594]。组方法更匹配机制不等于已经证明95%覆盖；仅15组、非线性损失和有限Bootstrap重复都会影响近似质量。

未包括的因素至少有：训练集重新采集与再拟合；模型和超参数选择；未来日期漂移形式变化；设备间共同冲击；标签选择性缺失。固定日历、固定拟合时把组Bootstrap称为“整个算法所有不确定性”是不成立的。

E12 两种截止的推导

样本 t 的标签要等 $t+2$ 结束可用。32日训练时有 $t+2 \leq 32$ ，因此 $t \leq 30$ 。首个测试 $t=33$ 特征为[30,33]，目标为34、35，完整支持[30,35]。

若要求训练完整支持 $[t-3, t+2]$ 与[30,35]无交集，且训练位于之前，则 $t+2 < 30$ ，因此 $t \leq 27$ 。 $t=28$ 末端30仍与测试首端相交，不能用 ≤ 30 代替严格小于。

合法向前预测可以复用已经观测的历史 x ；没有未来信息越界并不保证损失之间独立。严格无支持重叠是另一种更强的设计要求，会改变训练样本与目标。不能一见重叠就叫作弊，也不能因历史可用而把相关窗口当独立样本算窄区间。

E13 同人交叉与删除ID

已登记者未来预测允许同人历史进入训练，前提是时间和标签成熟合法、模型不会利用未来答案，评价声明也确实只覆盖已知人。新受试者预测则不应把该受试者其他记录放在训练，因此同人交叉构成目标错配或泄漏风险。

删除ID不能移除体征、设备指纹、固定背景和近重复记录中的身份信息。例如同一人照片的背景、同一传感器长期偏置都可能让模型识别来源。应按原始采集单位切分并检查衍生记录，而非仅删除显眼的ID列。

反过来，不能因设备ID本身可识别就禁止合法个性化模型。可否利用历史由部署任务与隐私授权等另行决定，本讲只论统计评价设计。

E14 全数据目标均值泄漏

设备平均 y 若在全记录上计算，测试 y 会影响该设备均值，均值作为特征再进入训练与预测。信息路径为“测试答案→全数据目标统计→训练特征/测试特征→预测”，索引文件不交叠也挡不住。

修正应先划分，再仅用允许的训练历史构造统计。时间任务还需逐预测时点确认标签成熟，不能用该时点以后的同设备 y 。新设备没有历史时用预先定义的训练总体回退或单独的校准协议，不能从测试标签估设备均值。

若均值要用于训练本身的目标编码，还需避免每个训练样本直接看到自己的答案，通常要有训练内折外或适当留一策略；实现细节在后续流水线课程展开。最终测试集不能参与学习这些映射。

E15 gap单位

TimeSeriesSplit的gap数的是它收到的样本行，而不是自动识别日历。每天60行时gap=2通常只去掉两条设备记录，既不是两天，也未必让同一天完整归入一侧。若输入按设备排序，顺序更不代表全局时间。

先对已排序的唯一日期数组切分，明确日历间距和标签延迟，再用isin将日期集合映射回所有设备记录。课程示例48天、n_splits=3、test_size=8、gap=2得到边界(21,24,31)、(29,32,39)、(37,40,47)。

若日期不规则，按固定数量日索引的gap也不自动等于固定时长，应直接比较实际时间戳和可用时刻。不应机械以窗口长度当唯一gap，更要画原始支持并明确目标。

E16 一个现实方案范例

假定目标是已登记设备未来服务，以及新设备首次服务，两者分别报告。每月最后一天冻结模型，用标签已复核完成的记录拟合，次月逐日读当日x预测，月内不重训。未知设备专属偏置归0，不能在其测试期累计标签后悄悄更新。

把开发资料中的较早月份用于训练，较晚但仍属开发期的月份用于选择是否加趋势；新设备评价需要同时按设备留出，并固定设备加入时间规则。所有预处理和组类别集合只fit训练；主指标可选设备等权MSE，同时给行MSE和支持度，不看完结果再改权重。

锁定模型、时间项、惩罚、失败和缺失处理后，在后来一个未用月份进行一次最终测试。对已知与新设备分别给结果、组级不确定性及主要失败情境。若测试后改模型，就将这一批标为探索，另留新评价数据。若真实部署是每日重训，应将每个预测日合法重训作为被评价算法，不能拿月度冻结结果代替。

该方案仍需检查样本来源、设备共用环境、标签缺失与干预。日期趋势只是候选特征，不能因为合成实验表现好就预先断言现实趋势线性。没有唯一正确日期长度，关键是与实际使用一致且未使用未来信息。

3 十幅图的完整解读

G1 划分地图

random与time允许同设备两边出现。random是观察结束后对已见设备的留出记录插值，time是同设备合法历史到未来；二者的时间信息不同。仅有设备交集不能统一判泄漏，必须看声称任务。

联合图灰色大块是“训练设备晚期不评价”和“测试设备早期不训练”，另有标签延迟造成的灰列。它描述新设备未来冷启动，而不是随意舍弃数据提高分数。每个格子都可从split_membership.csv核对。

G2 可用性

第30日输入在30日、标签32日到达，可训练。第31、32日标签在33、34日到达，截止时不可训练。若表中只保留事件日并回填最终标签，只按 $\text{day} \leq 32$ 筛选会偷读未来已知的结果。

图上的连线是标签延迟，不是预测器在使用未来 x 。主任务在未来每一天到来后读取当天 x ；没有声称32日已经掌握33至47日所有输入。

G3 一步目标

目标1.7134375包含平均半平方损失1.681875及惩罚0.0315625。下一训练MSE是 $2 \times 1.681875 = 3.36375$ ，二者尺度和组成均不同。忘惩罚会少0.0315625。

未知C没有训练历史，按协议 $v_C = 0$ 。用测试标签给C补偏置会让“新设备初次预测”变成“看过答案后的拟合”，改变被评价算法。H5与H6只是评价行，不参与这一步梯度。

G4 主例成绩

联合测试中Personalized约2.938758，Pooled约2.920942。测试组未知，设备偏置不给直接帮助；训练中增加组参数仍会改变共享系数估计，有限样本下可轻微变差。应如实保留。

Trend的时间MSE0.237188略低于随机0.243271，是当前面板有限噪声与拟合差异的结果。原则是协议是否模拟使用信息，而非要求某种划分一定给更差分数。这个数值不允许用未来标签训练过去模型。

G5 重复面板

每个点完整重抽并重训，菱形均值，粗线经验10%至90%。同设备未来Personalized的SD约0.05158描述单个面板结果波动；MCSE约0.00577描述80面板均值的估计精度，后者小不代表下一面板一定接近均值。

每个rep内三个模型和四份协议共享原始抽样，是配对设计。不能把所有点不分模型协议混成独立重复。左右坐标尺度不同，须读实际刻度，不能凭图上线段长度比较绝对方差。

G6 偏移和残差

x 直方图相似不排除 $P(Y | X)$ 随时间变化，也不排除标签流程或未观察变量变化。本机制除了 x 均值漂移，还有独立的0.045t目标漂移。

残差定义 $y - \text{预测}$ ，为正说明低估，为负说明高估。右侧Pooled和Personalized向上表示模型落后于上升的响应基线，Trend接近零与其包含日期项有关。图只描述当前机制，不能证明日期项在任意现实环境可靠。

G7 设备错误

a仅模拟器可见，不是现实可用特征。将它加入模型会改写信息边界，至多作为知道真实潜变量的理想参照，不能声称仍是原冷启动算法的可实施成绩。

删掉最大误差设备只会得到“条件于排除这些困难设备”的另一个总体。若实际有事先规定的拒绝服务或转人工规则，可以评价该完整规则及拒绝比例和成本；不能事后按错误大小过滤后隐去选择。

G8 Bootstrap图

橙色更宽说明保留设备内依赖改变了抽样变异估计，不是95%覆盖率检验。要验证覆盖率，需要在规定总体机制下重复生成评价样本并检查区间包含真实目标的频率，且说明真实目标如何得到。

若评价整个重训算法，需要在训练抽样层级也重采样或独立采集、重新拟合，再使用独立测试；还须纳入合法模型选择流程。当前两个直方图都固定训练结果，不能捕捉这一层。

G9 权重图

若V再增加8条同质量记录，U有8、V有10，A行平均变成 $(8 \times 1 + 10 \times 9) / 18 = 49 / 9 \approx 5.4444$ ，B仍4，行排名也翻转。设备等权A仍5、B4，因为各组内平均保持。

这些若只是高度相关的重复测量，不会按记录数比例增加独立设备证据。计数、权重和信息量是三个概念，不能把多行等同多位独立对象。

G10 窗口图

首个测试支持从30到35，训练 $t \leq 27$ 才满足末端 $t+2 < 30$ ； $t=28$ 恰在30接触，因此不满足严格无交集。仅要求截止32时标签可用，则 $t \leq 30$ 已经合法。

重用已观察过去x可以符合服务过程，例如滚动窗口预测每天都会重用昨天读数。它仍使相邻错误有关联。待评价目标答案经另一个重叠窗口进入训练、或输入包含未来读数，则是不同性质的信息越界，需要排除。

4 八项实验的完整参考

L1 评价协议卡

random: 49日所有标签已到齐后拟合，训练2160行，评价全期720行，已见60设备，回顾插值。

group: 同样观察期结束后拟合，训练45设备2160行，评价另15设备720行，同期新设备迁移。

time: 32日冻结，训练所有60设备0至30日1860行，评价同设备33至47日900行，逐日读x且不重训。

group_time: 32日冻结，训练45设备早期1395行，评价15个未见设备未来225行，未知设备偏置0。四者主报告均按行MSE，另给设备等权MSE。

标签到达都是 $t+2$ ，不因划分改变。模型只有pooled、personalized、trend三个固定选择、alpha1；未查看分数后挑最好协议。协议卡必须包含这些信息，而非只写train_test_split参数。

L2 手算验收

完整数值见E4、E5。最低应有四行局部导数、求和 $(-10, -7, -4, -6)$ 、除4、减 η 梯度、四行下一预测与两行测试预测。正则为非截距系数平方之和除8；截距0.5不包含在内。

若把测试H5、H6加入梯度，聚合样本量与目标都改变；若把未知C编码为A或B，会错误借用设备历史；若用每行梯度立即更新下一行，则变成SGD而不是本题一次同步批量更新。这三种错误可能都运行不报错，所以必须对齐逐行结果。

L3 划分验收

完整计数见E6。时间与联合检查 $\max(\text{label_available_day}[\text{train}])=32$ 和 $\min(\text{day}[\text{test}])=33$ ；random与group的前一项49，不能拿来模拟32日上线。

索引不交叠只能排除同一表行重复使用；无法排除同设备相关、重复事件、衍生窗口重叠和全数据预处理。设备交集为0也不保证时间合法：group覆盖整期，晚标签仍不能用于过去预测。

L4 结果解释

四协议Personalized第0份MSE分别约0.636795、1.847585、1.496320、2.938758。随机利用同设备记录估计偏置，整组未知设备不能；时间可利用早期设备历史但受到未建模漂移，联合同时面对新设备与未来。

80次负面计数为整组34次Personalized差于Pooled，联合38次；Trend联合3次差于Personalized。报告这些结果不会削弱复现性，反而避免“所有种子都一定改善”的不实推断。全体960次拟合保留，作者检查最大一阶最优性梯度约 9.65×10^{-15} 。

同一协议内模型比较是固定评价集下的比较。跨协议并未控制训练量、组数和目标，所以不能据其差额严格识别“只由时间”或“只由泄漏”造成的效应。需要另做预声明消融才能进一步归因。

L5 独立参照

独立OneHotEncoder只fit训练groups，整组测试one-hot全部0；Ridge使用不惩罚截距、alpha1，SVD解。NumPy用自己的完整指示设计与增广系统；SciPy带列主元QR走另一求解路径。

12组主例的最大sklearn预测差约 6.75×10^{-14} ，最大SciPy QR预测差约 1.42×10^{-14} ，说明当前数值目标和编码对齐。手算Fraction解为精确值，中心差分误差约 1.47×10^{-10} ，与小步长浮点近似相符。

这些参照比重新调用同一待测函数更能发现编码或求解错误；它们仍不证明数据代表性。若所有路线都使用同一个错误评价总体，即使预测完全一致，科学结论仍会错。

L6 权重与区间

两设备手算见E10，区间见E11。主面板组等长时整组测试行平均与组平均相同，但Bootstrap单位仍不同：按行和按组即使平均公式给同一个点估计，也会给不同不确定性。

这是很重要的区分：点估计相同不能用来证明抽样设计等价。15个设备的潜在偏置在48行中重复出现；按行重采样将它当成被重复观察到的独立新偏置，低估设备构成变化。

L7 时间接口

在48个日索引上切分，再映射成面板行，三组边界(21,24,31)、(29,32,39)、(37,40,47)。以第一组为例训练0至21日共22天，1320行；测试24至31日8天，480行。第二组训练1800行、第三组2280行，测试均480行。

这是额外接口演示，主实验截止仍固定32、测试33至47，没有把三个库折结果拿来重新选择模型。训练行数增加是TimeSeriesSplit扩展窗语义；若实际只用最近固定时长，需要另设max_train_size或明确时间戳窗口。

L8 示例报告

“在预声明的60设备48天合成机制中，标签延迟两天到达。我们分别构造回顾随机记录、同期整组、同设备未来和新设备未来评价；后两者在第32日仅用已到达标签拟合，之后逐日读x预测33至47日，不重训。第0份同设备未来中Personalized的MSE为1.496320，含日期模型为0.237188；后者与本模拟线性漂移匹配，不能外推为通用优势。80份独立重抽面板中，联合目标下Personalized有38次差于Pooled，Trend有3次差于Personalized，均完整保留。主指标按行MSE并辅以设备等权结果；固定模型测试误差用整设备Bootstrap描述，未验证百分位区间覆盖率。Fraction、SciPy和sklearn的独立计算一致，但模拟没有标签缺失、共同冲击或非线性突变，不构成现实部署保证。”

报告可有其他结构，但不能省掉“何时知道什么”和“评价谁”。最漂亮的一根柱不能代替整个实验定义；真实可实施的协议比解释一个事后挑出的高分更重要。