

第051讲 练习详解

交叉验证与模型选择

本文件逐题回答独立实验手册二十二题。默认数字来自随包科学结果；公式说明为什么这样算，而不只给出API调用。

1. 验证选择也是学习

验证标签被用于比较候选，最优候选的索引因此依赖这些标签。即使每个候选验证分数单独估计得合理，选择最低者也会偏爱负的估计噪声。最后只输出一个候选，并不能消除比较其他候选的历史。

嵌套CV将这一整套选择纳入每次外层训练程序，再用没有参与该轮选择的外层标签评价。它解决数据角色问题，不保证每一份数据的估计更接近真实值。

2. 合并MSE

三个折的平方误差和分别为 $3 \times 0 = 0$ 、 $2 \times 1 = 2$ 、 $2 \times 4 = 8$ ，合计10。总验证样本数7，因此合并MSE为10/7。

直接平均三个折MSE得到5/3，对每个折等权而非每行等权。通常关心逐样本风险时，应使用前者；如果目标本来是组/折等权，则应明确声明另一种加权对象。

3. 各层样本数

80行分外层5折，每次外层训练64、测试16。64行内部4折，每次内层训练48、验证16。内层选定候选后重新用64行拟合，再在外层16行评价。

最终模型另在全部80行上运行事先约定的选参并重拟合，最后用独立4000行测试。48、64、80三个训练规模对应不同拟合对象，不能省略。

4. 两候选完整验证链

λ	内层拟合行	w	验证x	验证y	预测	平方损失
0	1,2	1	-2	-1	-2	1
0	1,2	1	2	3	2	1
0	0,3	1	-1	-1	-1	0
0	0,3	1	1	1	1	0

λ	内层拟合行	w	验证x	验证y	预测	平方损失
1	1,2	1/2	-2	-1	-1	0
1	1,2	1/2	2	3	1	4
1	0,3	4/5	-1	-1	-4/5	1/25
1	0,3	4/5	1	1	4/5	1/25

λ_0 合并MSE为 $(1 + 1 + 0 + 0)/4 = 1/2$ 。 λ_1 为 $(0 + 4 + 1/25 + 1/25)/4 = 51/50$ 。所以选择 λ_0 。
验证损失不含 λw^2 项，否则就在改变评价指标。

5. 重拟合与外测

内折模型只看了两行，不能利用完外层训练集的全部信息。选择 λ_0 后，四行 $\sum xy = 10, \sum x^2 = 10$ ，所以重拟合 $w=1$ 。

外测x3、4对应预测3、4，与设定标签一致，MSE为0。这是两个事先构造的纸笔点，未说明任何真实总体误差为零；外测标签没有参与选择。

6. 第0次前向的局部链

固定 λ_1 、 w_0 ，预测全部0。半平方损失对预测的导数就是残差，预测对 w 的导数就是 x ，连乘再除以4为平均数据梯度贡献。

x	y	预测	残差及局部导数	半平方损失	对平均梯度贡献
-2	-1	0	1	1/2	-1/2
-1	-1	0	1	1/2	-1/4
1	1	0	-1	1/2	-1/4
2	3	0	-3	9/2	-3/2

平均数据目标1.5，梯度-2.5，正则梯度 λw 为0。整批更新 $w_1 = 0 - 0.1(-2.5) = 0.25$ 。

7. 两次更新后的重新前向

$w_1=0.25$ 时：

x	预测	残差	半平方损失	平均数据梯度贡献
-2	-0.5	0.5	0.125	-0.25
-1	-0.25	0.75	0.28125	-0.1875

x	预测	残差	半平方损失	平均数据梯度贡献
1	0.25	-0.75	0.28125	-0.1875
2	0.5	-2.5	3.125	-1.25

平均数据目标0.953125，正则项0.03125，总目标0.984375。数据梯度-1.875，加 $\lambda w=0.25$ ，总梯度-1.625。同步更新 $w_2 = 0.25 - 0.1(-1.625) = 0.4125$ 。

第三次前向：

x	预测	残差	半平方损失	平均数据梯度贡献
-2	-0.825	0.175	0.0153125	-0.0875
-1	-0.4125	0.5875	0.172578125	-0.146875
1	0.4125	-0.5875	0.172578125	-0.146875
2	0.825	-2.175	2.3653125	-1.0875

数据目标0.6814453125，正则项0.085078125，总目标0.7665234375；数据梯度-1.46875，加0.4125后总梯度-1.05625。仍未到最优 $w^* = 5/7$ 。所有行必须用同一个当前w计算，不能逐行修改后混成整批结果。

8. 正则项的计数

目标定义是平均数据损失加一个正则项 $\lambda w^2/2$ ，导数是平均数据梯度加一个 λw 。把 λw 直接加到每个已除以m的行贡献中再求和，会放大m倍。

等价写法有两种：在每行尚未平均的数据损失中都加 $\lambda w^2/2$ ，再把这些行整体取平均；或者对已经除以m的每行损失贡献各加 $\lambda w^2/(2m)$ ，最后直接求和。不能先把正则项除以m，加到每行后再取平均，否则会多除一次m。验证MSE只计算预测误差，不加训练惩罚，因为我们评价的是新响应预测表现。

9. Ridge缩放

本讲目标乘以2m后为 $\sum (y - Xw)^2 + m\lambda \|w\|^2$ ，正好对应sklearn Ridge的 $\alpha=m\lambda$ 。 $\lambda 0.01$ 在m48、64、80时分别对应0.48、0.64、0.8。

固定alpha也可以定义另一套合法协议，但那不再是本讲各层固定同一个平均惩罚 λ 的目标。比较独立实现时必须先统一目标。

10. 局部与全局索引

外层训练子集是原始数据的一部分，例如包含原始索引1、4、9等。该子集的局部索引0对应原始索引1，而不是原始索引0。

内层划分首先在64行子集的位置上定义，再通过外层训练索引映射回80行全局位置。直接把局部索引用在完整数组上可能读入外测标签，即使数组形状仍然正确，也已经泄漏。

11. 为什么逐外折重选

“选参程序”本身会利用标签。若先在80行上找到一个最优候选，再固定它做外5折，每个外测折的标签早已通过全数据选择影响了候选。

正确做法是在每轮64行里独立完成内层搜索，再重新拟合64行。不同外折选出不同候选是程序对数据变化的响应，不应为了统一结果强行固定。

12. Oracle总体MSE

真响应为 $f^*(X) + \epsilon$ ，噪声均值0、方差0.64，且与X独立。给定已拟合函数，平方误差期望等于0.64加 $E[(\hat{f}(X) - f^*(X))^2]$ ，交叉噪声项为0。

在均匀[-1,1]下，Legendre基正交且 $E[P_j^2] = 1/(2j+1)$ ，因此积分误差为 $\sum_j (\hat{\theta}_j - \theta_j^*)^2/(2j+1)$ 。不同次数的系数补0后比较。

这需要已知真函数和分布，是合成实验的诊断工具，不能用于正式选择候选，也不是现实数据免费提供的测试分数。

13. 配对对象

非嵌套分数0.580613481应与其选中候选的五个折训练模型平均总体风险0.658596943配对。嵌套分数0.610719723应与五轮各自重新选参并重拟合的模型平均总体风险0.703331028配对。

它们都不是最终80行模型的0.653490839总体风险。训练规模和选择流程不同，错配会把其他差异混入“乐观偏差”。

14. 单次差更大不推翻原则

主数据非嵌套差约0.077983463，嵌套差约0.092611305，后者更大。嵌套只保证外测标签未参与该轮选择；当前有限测试样本仍有随机误差，不保证逐份数据都更准。

在适当IID与可积条件下，讨论的是重复抽样下对外层训练规模的整套程序的期望评价。不能用一次正负差决定协议有效性，也不能删除不符合预期的结果。

15. 80次汇总

非嵌套差均值0.044208443，跨独立数据集SD0.106522895，MCSE为
 $0.106522895/\sqrt{80} = 0.011909622$ 。

嵌套差均值0.019856313，SD0.105931772，MCSE约0.011843532。这里独立单位是一份全新生成的80行开发数据及完整重做的选择流程，不是五折中的一折。

16. 约1.68MCSE的解释

$0.019856313/0.011843532 \approx 1.68$ 。可以说有限80次模拟的均值偏离0，但近似 ± 2 MCSE范围包含0，不能把它当作明显系统性偏差的证据，也不能宣称数据已证明严格无偏。

理论条件和有限模拟误差分别检查。不能通过换种子或删除某些重复，把均值调到恰好0。

17. 反向与相同

80次中非嵌套CV低于嵌套CV73次，相同5次，高于嵌套CV2次。这比较的是两个报告分数，不等同于各自oracle减CV的差。

非嵌套乐观差有27次负值，嵌套有34次负值；负值说明那一次分数高于它对应模型的总体风险，不应被裁成0。

18. 重叠不是相关系数

不同外层训练集各有64行，共享48行，因此共享比例 $48/64=75\%$ 。它是集合相交的比例，不是随机误差的Pearson相关系数。

共享训练信息可能导致折分数相关，所以不能把五折看成五次独立训练实验直接套普通t检验。相关系数大小还取决于模型、损失和数据分布，不能只从重叠比例读出来。

19. 三种划分

分层保持各验证折类别比例尽量接近，但不防止同一个人的多条记录跨折，也不尊重未来信息。分组把同组记录放在一起，面向新组评价，但不自动保证时间顺序。

时间划分沿时序用过去训练、之后验证，并可留gap处理边界间隔；它不自动消除组重叠，gap大小也必须来自真实标签延迟和窗口定义。主实验是IID回归，另外12行例子仅展示真实索引约束，不比较四种模型分数。

20. 为什么只要求该轮不变

在第k轮外层评价中， V_k 标签不能进入该轮选择，所以改变它们不应改变该轮内层结果。但这些行会成为其他轮的训练数据，其他轮的选择可以改变。

如果要求所有轮都完全不变，就误解了交叉验证的数据复用方式。检查信息流必须明确“当前是哪一轮”。

21. 最终模型

评价完成后，按照事先定义的选择流程在全部开发数据上选参，再用全部开发数据重拟合。不要从五个外折模型中挑外层分数最低者，因为那又用外层标签选择了一次。

本讲最终选择次数3、 $\lambda 0.01$ ，用80行拟合。选择摘要锁定后才生成独立测试数据，并且不再根据测试成绩改变候选。如果改变，就需要新的诚实评价。

22. 最终测试及不确定性

独立4000行测试MSE为0.645598668，其条件均值标准误约0.013965358；这个固定最终模型的精确总体MSE为0.653490839。两者差异处于普通测试抽样变化范围，但不构成对所有未来分布的保证。

条件标准误把当前模型视为固定，只考虑新的测试响应抽样；80份数据的MCSE则描述重新训练和选参后某种汇总量的模拟误差。它们不是同一种不确定性。