

第052讲完整答案 无泄漏的数据处理流水线

1 使用约定

本册完整对应讲义E1至E16、G1至G10及实验L1至L8。A为整设备新对象评价，B/C为独立行机制。纸笔四行使用训练最小最大界和一次无正则GD；主实验A用5%与95%界和Ridge。主报告是全平方MSE，小例优化目标是平均半平方损失，不要混淆倍数。

2 E1 每个处理步骤都可能学习参数

中位数插补学各列非缺值中位数；分位截断学上下界；标准化学均值和ddof=0方差；独热学类别词表、列顺序；监督筛选学保留哪些列；目标编码学类别计数、标签和与整体均值。每一个都应标注拟合行集合。

摄氏度到开尔文按定义加273.15，不从样本估计，可在划分前执行。全表分位点截断的阈值依赖验证X；若协议只允许训练fit，就越界。若规则是看了验证图后才选出来，连规则选择本身也参与开发，不能只把最终阈值重新在训练计算就抹去这段历史。

3 E2 缺失机制相对于信息集合

若设备型号A丢包率10%、B为40%，型号已观测，且给定型号后丢包独立于读数，那么这是相对于该观测集合的MAR例。边际上读数可能与缺失相关，因为型号也影响读数；这不违背条件独立定义。

若型号未记录，不能继续把它当作已知条件。观测数据中剩余变量是否足以解释依赖需另论，机制可能无法从现有表识别。不能单凭空白分布看起来随机或某个检验不显著，证明MNAR不存在。真实饱和值不返回的机制可能对未见值有依赖，需要采集知识和敏感性分析。

4 E3 四行训练统计与六行设计

非缺训练x为1、3、5，中位数3。填补1、3、3、5； $q=0$ 、1给界1、5；均值3。偏差-2、0、0、2，平方和8，除 $n=4$ 得2，所以标准化值 $-\sqrt{2}$ 、0、0、 $\sqrt{2}$ 。

含截距设计行依次为： $H1=(1, -\sqrt{2}, 1, 0, 0)$ ， $H2=(1, 0, 1, 0, 1)$ ， $H3=(1, 0, 0, 1, 0)$ ， $H4=(1, \sqrt{2}, 0, 1, 0)$ 。 $H5$ 原值7截到5、C未知，故 $(1, \sqrt{2}, 0, 0, 0)$ ； $H6$ 缺失用3、B已知，故 $(1, 0, 0, 1, 1)$ 。

$H5$ 不能提供7去重估界或尺度，也不能用C扩列； $H5/H6$ 标签6和3不能进任何训练梯度。 $H6$ 缺失指示1可在预测时从原始输入读取，不是标签泄漏。填补值是预测算法的回退，不是声称找到了真实缺失值。

5 E4 从局部链到同步更新

初始预测全0，残差-1、-2、-2、-5；半平方损失1/2、2、2、25/2，平均17/4。由 $\partial \ell / \partial \theta_j = r a_j$ 得四行：

- H1: $(-1, \sqrt{2}, -1, 0, 0)$
- H2: $(-2, 0, -2, 0, -2)$
- H3: $(-2, 0, 0, -2, 0)$
- H4: $(-5, -5\sqrt{2}, 0, -5, 0)$

求和 $(-10, -4\sqrt{2}, -3, -7, -2)$ ，除4得 $(-5/2, -\sqrt{2}, -3/4, -7/4, -1/2)$ 。 $\eta=1/5$ ，减去 η 梯度得到 $(1/2, \sqrt{2}/5, 3/20, 7/20, 1/10)$ 。不能先改一个参数再用新预测求其他参数梯度。

下一前向H1为 $1/2 - 2/5 + 3/20 = 1/4$ ；H2为 $1/2 + 3/20 + 1/10 = 3/4$ ；H3为 $17/20$ ；H4为 $1/2 + 2/5 + 7/20 = 5/4$ 。残差 $-3/4, -5/4, -23/20, -15/4$ 。

平方和为 $9/16 + 25/16 + 529/400 + 225/16 = 1751/100$ 。除以 $2n=8$ 得到 $1751/800 = 2.18875$ 。逐行半平方损失0.28125、0.78125、0.66125、7.03125，平均一致。

H5预测 $1/2 + 2/5 = 9/10$ ，H6预测 $1/2 + 7/20 + 1/10 = 19/20$ 。训练损失下降只验证一步优化，不推出验证性能必然改善。实际A用Ridge完整求解，此GD不是主实验的训练循环。

6 E5 全缺 常数与未知值

全缺数值训练列在`keep_empty_features=True`下保留并填0；插补后分位上下界都为0，训练均值0、方差0、`scale=1`。验证首次出现7仍按已学界截到0；它没有训练支持来估计这个方向。验证缺失和非缺失仍可由原始缺失指示区别。

常数训练列例如全为2，界为2、2，中心2、方差0、`scale=1`，变换输出0。`scale`设1避免除零，不声称方差变为1。这里额外截断使验证偏离常数的数值也回到常数；只有`StandardScaler`而无截断时，验证非同值会有非零结果，不能混同。

未知站点用训练词表编码为零，不新增列。全零是预定回退，不是证明未知站点完全等于某个已有站点或总体平均效应。

7 E6 Pipeline仍可被错误使用

正确伪代码：for每个合法外折，创建新的完整Pipeline，仅`fit(X[tr], y[tr])`，再`predict(X[val])`，最后才用`y[val]`评分。可选预处理与参数的选择应在tr内部另层进行。

错误伪代码：`Z=target_encoder.fit_transform(X_all, y_all)`，然后`cross_val_score(Pipeline([Ridge]), Z, y)`。表面有Pipeline和`cross_val_score`，但Z已包含全表监督统计，越界发生在外折之前。另一种错误是`pipeline.fit(X_all, y_all)`之后仅切出验证预测，显然也不成立。

如果固定文档规定-999是坏码，先转换NaN可以是无学习规则；但先看全表才决定哪些码或阈值异常，已引入数据依赖。正确性取决于实际信息路径，而非API名称。

8 E7 缩放不变与惩罚变化

$z = (x - \mu)/s$ ，则 $b + wz$ 等于 $b - w\mu/s + (w/s)x$ 。 $s > 0$ 时反向关系也存在。带截距无惩罚OLS在两个坐标中优化相同残差平方和与相同线性函数族；满秩确保对应函数唯一，因此新 x 预测相同。

本例原始训练均值 $x = -0.5$ 、 $y = 2$ ，协方差和为4、 x 离均平方和5，所以斜率0.8，截距2.4。 $x = 2$ 和4的预测4、5.6。全表缩放改变坐标但不会改变这个函数。

加 λw^2 时，原坐标斜率 $a = w/s$ ，因此惩罚变为 $\lambda s^2 a^2$ 。 s 变化而 λ 数值不变，就改变对原函数的惩罚。两个函数类相同不等于目标相同。截断则不是可逆仿射变换，也不满足证明前提。

9 E8 如实报告微小泄漏差

合理表述：“在固定12份设备模拟中，仅将两数值列缩放fit范围扩大到训练加验证，四折MSE平均从2.037497变为2.037060，差-0.000437；8份稍低、4份更高。该做法违背预定新设备归纳协议，但此有限实验未显示巨大或单向性能增益。”

不应说“全表缩放总提高分数”，也不应因4份变差就说“泄漏不存在”。四折共享训练数据，不是独立重复；12份重新抽设备与观察的数据才是本机制的独立重复。未给现实效果或精确置信覆盖保证。

10 E9 纯噪声选列

300个噪声列中，总有若干与有限标签偶然相关。先用全部标签排序，就偏好同时在验证中也碰巧相关的列。之后回归器虽只fit训练，验证已通过“列集合”影响了训练。这是选择偏差的信息通路。

真实无信号并不让每次有限MSE恰好1。1是已知生成机制下用真均值0预测的新标签期望平方误差；训练均值有估计误差，验证样本有波动。均值基线提供不利用噪声列的参照。正确选择路线更差并不说明应改成泄漏，而说明有限样本拟合噪声有代价。

11 E10 八行目标编码

内层来源5至8时 $\mu = 6.5$ 、 $m = 2$ ：A有 $q = 5, n = 1$ ，得6；B得 $19/3$ ；C得7；因此行1至4为6、 $19/3$ 、6、7。行3虽同A也用同映射，不读自身标签3。

来源1至4时 $\mu = 2.5$ ：A有 $q = 4, n = 2$ ，得 $9/4$ ；B得 $7/3$ ；D未见用 $5/2$ ；C得3。因此行5至8为 $9/4$ 、 $7/3$ 、 $5/2$ 、3。回退均值也来自该内部训练来源，不用全8行的4.5。

全训练 $\mu = 4.5$ ，A的 $q = 9, n = 3$ ，得 $18/5$ ；B的 $q = 8, n = 2$ ，得 $17/4$ ；C的 $q = 12, n = 2$ ，得 $21/4$ ；D的 $q = 7, n = 1$ ，得 $16/3$ 。验证A、C、Z对应3.6、5.25、4.5。此时允许完整8个训练标签，但不允许任何验证 y 。

12 E11 三类transform来源

`fit_transform(T)`给训练行的是内部折外特征：对属于`L_k`的行，计数、标签和、整体均值都来自`T`去掉`L_k`。它同时保存完整`T`映射供未来使用。

`fit(T).transform(T)`给训练行的是包含自身标签的完整`T`编码，没有内部`cross-fit`。它可能使下游模型过拟合自身标签痕迹。

`transform(V)`在已`fit_transform(T)`的对象上调用时，使用完整`T`映射，而非随机某个内部映射，也不会读`V`标签。训练与验证编码来源大小不同是设计，不应为追求数值相同而用完整`T`编码替换训练折外特征。

13 E12 内部自身排除仍不保证外层隔离

假设外层验证有行`a`、`b`。全表内部`cross-fit`给`a`编码时可能排除`a`，却包含`b`的标签；给外层训练行`c`编码时也可能包含`a`或`b`的标签。外层验证答案已经进入训练特征，即使每行都不直接读自身`y`。

修正是先定外层`tr/va`，再只在`tr`内构造内部编码，`va`只查`tr`完整映射。组依赖需内部按适合的组切分，时间任务需标签在每行预测时点前可用。仅把最外层改成`GroupKFold`不能让之前算好的全局特征恢复独立。

14 E13 过拟合与评价污染

训练自编码只用外层训练标签，训练算法容易利用自己的标签痕迹；外层验证未提供标签，因而较差外层分数可以诚实揭示该缺点。这与“外层评价已失效”不同。

全标签编码把验证答案纳入映射，外层分数不再评价原先可实施的预测流程。当前看似`MSE`更好，不能拿来当部署收益。两种机制一个导致真实泛化变差，一个使评价混入答案，方向相反不矛盾。

15 E14 部署诊断与结论边界

记录每列缺失率、全缺列、未知类别比例、被截到上下界的比例、原始及处理后分布、列模式与版本，以及标签到达后按相关群组和时间汇总的损失。异常应连同预测时可用性和采集改动一起解释。

输入分布变化不必然意味着性能下降；某些变化在预测无关方向。性能仍好也不代表所有未覆盖群体都安全。需要在合适标签和评价对象上验证，不能自动用新数据重`fit`后再把过去的独立评价保证继续沿用。

16 E15 有延迟标签的时间目标编码

一种可行规则是：在`t`时点给行`i`预测，仅使用实际`label_available_time < t`的历史训练标签；若目标是新设备，还要排除该设备在开发数据中的记录。类别计数、和与回退均值都遵守同样边界。没有历史的类别按预定先验或允许历史均值回退，不能使用未来总体均值。

构造训练特征时可按时间滚动起点生成历史编码，明确暖启动前缀处理；最早没有可用标签时可用固定先验或预先排除暖启动期并说明目标改变。随机内部KFold可能用未来标签编码过去行，不符合可实施信息。scikit-learn1.8 TargetEncoder默认内部折并不自动解决此问题，本包C实验因此不声称时间适用。

17 E16 完整选择与最终评价

先按人/设备/时间目标保留最终测试，固定评价指标、权重、失败处理。开发集上外层评价、内层选择：对每个外层tr，只在其中搜索候选；每个内部候选从头fit完整预处理与模型，目标编码再按其所需合法内部来源构造训练特征。复杂嵌套不必滥用名称，必须写清每个集合。

选择规则定下后，用全部允许开发集重训该完整算法。目标编码仍需为这批训练行产生内部cross-fit特征，下游拟合这些特征，保存完整开发集映射用于未来。最后只一次用封存测试transform、predict、评分。

若读最终测试后再改平滑、缺失策略、截断或模型，该集合已参与开发，不能继续称为未见最终测试；需要披露选择历史，并另设计确认性评价。外层CV也不能反复用来挑所有设计却声称从未受选择影响。

18 十幅图完整解答

G1 设备与站点

站点是可观察的普通类别，训练与验证共享S2不违反未见设备目标；不等于共享同一设备。A的同设备进行共享随机偏置，应整组留出。若目标是既有设备未来，需时间顺序、标签到达与历史信息规则，当前同制度整组图不足以回答。

G2 直方图和截断

原始图只含非缺数，处理图填完全全部216行，总数不同正常。上界堆积包括被截断的值，不代表真实测量正好在界上。按事后误差删设备改成“条件于未出大错设备”的总体，不能隐去选择后宣称原目标改善。

G3 中位数和坐标

把H5纳入尺度估计会影响训练均值方差，从而可能改变全部训练z；加入H5还可能改变截断上界，若同样错误扩大其fit范围。填3是算法替代，不是对H2真实值的证明。验证应用固定训练坐标，不要求其经验均值0。

G4 梯度热图

只有H2原值缺失、 $m=1$ ，因此对u有 -2 局部导数；其他三行0。单行损失未平均，求和除4得到J梯度，只除一次。同步GD要求所有导数在旧 θ 求值；先改b再求w使用另一个残差，属于不同更新过程。

G5 差值的两种符号

两线重合不能审计fit集合，必须查状态来源。四次错误更差不能修复协议；它们仅反驳“必然提高”。48折共享样本和训练信息，不能当48个独立总体抽样；每份四折先汇总，再描述12份独立数据的变化。

G6 OLS不变性

固定岭强度在不同尺度下对应不同原单位惩罚，允许函数相同不再代表目标相同。截断将多个不同原值压到同界，不可逆，改变了函数表达与训练信息，不满足坐标替换证明。

G7 选择后相关

Ridge虽只读训练，列选择提前读验证y，仍泄漏。有限MSE不必恰1。删除正确路线最高误差会把报告改成条件于较好运气的数据集结果，低估波动和风险；所有预声明有效重复都要保留。

G8 自身标签干预

行1内部编码来自5至8，所以改行1自身y不影响它的该编码。完整T映射会改变；第二内部折以1至4为来源，因此其他被编码行也可能改变。fit_transform与transform用不同标签集合，差异是交叉拟合设计本身。

G9 三种编码结果

自编码的自身标签痕迹使训练拟合过于乐观，在真正留出标签上表现变差。全标签路线连外层答案也读了，外层高分已污染。correct略差于简单均值是无信号机制下应保留的负结果，换seed直到胜出会添加选择偏差。

G10 完整外层隔离

排除单行自身y不代表排除整份外层验证y。全表cross-fit可能利用其他验证行标签，或将某验证标签用于编码外层训练行。正确流程先限定外层训练集合，再开展所有内部映射，验证只transform。

19 L1至L8参考验收

L1 角色卡

A：同制度未见设备， 48×6 行，四折各216/72，只有设备作为外层分组。B：200独立行、300无信号特征，150/50，监督选5列。C：360独立类别和标签，270/90，内层180/90，验证映射完整270。三者不混为同一个随机对象；A不是未来任务，C不含组效应。

L2 手算

完整过程见E3/E4。应交出六行处理后设计、四行初始损失导数、求和除4、新 θ 、下一损失和H5/H6预测。原始缺失标志须在插补前取；H5不得改训练上界，H6标签不得改变u。下一半平方平均1751/800用Fraction复核。

L3 数值来源

从当前实际tr排序计算中位数与插补后分位点，216行截断结果求均值和方差。与结果JSON的preprocessing_state逐列比，词表仅训练站点；scale_n_fit与clip_n_fit都为216。独立设计返回的列顺序为两数值、两缺失指示、训练词表独热，截距由Ridge另处理。

若独立计算和库不同，先查分位数插值、先后顺序、NaN处理、ddof和列顺序，不要调容差掩盖逻辑差。实际状态数值随数据版本确定，可直接从结果读取与原始数组重算，而非只抄答案常数。

L4 结果报告

A的两个均值及4/8负结果见E8。B的0.874681并非在无信号总体学到了规律，列选择看见了答案。C的1.263601自编码揭示过拟合，0.733944全标签成绩不能作现实泛化；1.018423正确cross-fit还略差于1.008078均值基线。

全部12份各四折，主要拟合336次。此计数表示工作量和结果完整性，不表示336次独立实验。报告保存每份分数，不从平均值反推所有重复都改善。

L5 编码来源

八行分数见E10。主实验C第0外折每份内部映射只读180个训练标签，覆盖的90个行号不参与该映射。验证映射读270训练标签。选择一行后，先找到其内部折，再数类别n和标签和q、算该子集 μ ，代 $(q+5\mu)/(n+5)$ ；类别未见则用同子集 μ 。

独立manual_folds采用RandomState置乱、按折大小分块再按原位置取训练验证，数值编码用字典计数与求和。它不调用TargetEncoder，所以能检查实际API是否符合所述cross-fit。

L6 干预证据

外层验证y加50，正确训练输入标签未变，预测逐项不变；全标签编码最大改变23.214286，表明负对照确实敏感。训练行自己y变更不影响它自身折外编码，但完整映射和其他内部行可能变化。验证X加100不影响训练处理状态，却允许该验证预测改变。

分数不变性不能代替状态不变性：OLS负对照正好显示状态改变而预测不变。应同时检查来源、状态、模型与预测各自预期，明确要发现哪类错误。

L7 可执行证据

普通与-O保存的数值JSON相同，审计通过；不同cwd按脚本位置加载输入。新核首格完整校验，全部代码格有执行计数且无error输出，十幅图重建后显示。图5纵轴保留两符号，图8不合并两类训练编码，图10的90个外层验证标签始终不被允许。

完整重建脚本只写outputs/rebuild；PDF版面需逐页检查。新进程InProcessKernel确实执行Notebook，但不等于浏览器Jupyter或外部网络内核也被测试。

L8 示例报告

“我们按事前固定协议分别研究三条信息路径。A以未见设备为目标，在每外折训练内完成插补、分位截断、缩放和类别编码；只将缩放扩到验证X时，12份平均MSE差为-0.000437，且4份更差，说明协议越界不保证单向提升。B在纯噪声上全标签选列获得虚低评分。C区分训练自编码过拟合与外层标签泄漏：正确cross-fit平均1.018423，自编码1.263601，全标签0.733944；正确处理并未胜过简单均值基线。逐行编码均追溯到合法内层或完整训练来源，手工统计、计数编码与SciPy QR核验一致，验证标签干预对正确路线不变。折内分数相关，我们以12份独立合成数据描述变异。该实验不验证真实缺失机制、未来时间漂移或部署效用。”

报告可有其他结构，但信息来源、负结果与边界不能省略。完成本讲意味着能审计训练算法的状态与评价隔离，不意味着任何现实数据都已被妥善处理。