

第054讲 完整答案

1 E1与E2 信息时点和交互

E1：特征必须在目标预测发生的时刻对目标对象可得到，且按训练时相同规则生成。例如用入院时的测量预测未来结果可行，用未来处置或结果回填的变量就越界。是否在表格中存在不是唯一标准；还要检查采集时间、生成过程与部署可计算性。

E2：四行 x_1 、 x_2 、 y 均值0。 x_1 与 y 内积为 $-1+1-1+1=0$ ， x_2 与 y 内积为 $-1-1+1+1=0$ ；各列平方和4，分母 $\sqrt{4} \times \sqrt{4}=4$ ，相关都是0。可是每行 x_1x_2 恰等于 y ，因此两列联合包含完整信息。

加性设计的常数列、 x_1 、 x_2 与 y 正交，所以最小二乘系数为0，预测四个0。平方误差为(1,1,1,1)， $MSE=1$ 。添加交互列后系数 $w_{12}=1$ ，预测(1,-1,-1,1)， $MSE=0$ 。机器浮点求解可能给约 $1e-31$ 的小数，数学值仍为0。

G1与L1：边际零相关只排除该有限表中单列线性关联，不排除联合信息。只观察三行时，训练完美可以对应多种对第四行不同的函数，不能由训练拟合本身证明外推正确。若先删原列再生成交互，就失去乘积原料；若先生成全部交互，则需要控制维度和选择机会。

2 E3与L2 特征计数

p 列一次项 p 个，平方项 p 个，不同列间交互 $p(p-1)/2$ 个。总数 $p+p+p(p-1)/2=p+p(p+1)/2$ 。不含常数；若加常数再加1。 $p=10$ 给65， $p=80$ 给3320；包含常数分别66和3321。

两列的五项是 x_1 、 x_2 、 x_1^2 、 x_1x_2 、 x_2^2 。不能把 x_1x_2 和 x_2x_1 当成两列不同信息；它们相同。行数仍是原来 n ，扩列没有创造独立观察，也没有自动解决欠定与过拟合。

3 E4与G2 平方距离的条件推导

两端标准正态独立，每坐标差 z 均值0、方差2。 $E[z^2]=2$ ；正态四阶矩为3乘方差平方，所以 $E[z^4]=3 \times 4=12$ 。 $\text{Var}(z^2)=12-4=8$ 。 d 个坐标独立相加后 $E[S]=2d$ 、 $\text{Var}(S)=8d$ ，标准差 $\sqrt{8d}$ ，除均值 $2d$ 得 $\sqrt{2/d}$ 。

d	理论平方距离均值	理论变异系数
2	4	1
10	20	0.447214
50	100	0.2
200	400	0.1

图变窄是相对均值更集中，原始平方距离均值反而增长。该精确公式对平方距离成立，不能把它直接套给未平方的距离。独立4000对只近似总体，有限样本误差合理；不要求模拟等于理论最后一位。

共享查询点时，各距离条件于该点可有独立结构，但无条件会共享查询点随机性，原推导的独立对设计不再相同。真实特征相关、非正态或有低维结构时，公式也需重新推导。这里没训练近邻模型，因此没有近邻准确率结论。

4 E5 三类选择与共同边界

Filter按统计量先评分，如绝对Pearson；Wrapper用指定预测器验证不同集合，如顺序前向；Embedded在模型拟合内形成稀疏或选择，如L1。它们都可能正确或错误地使用验证信息，没有一种名称能自动防泄漏。

所有基于训练数据学习的统计状态应在相应训练折内重建。k、惩罚和选择方法如果需比较，则在内层验证选择。Wrapper不一定找到全局最优；80列全部子集有2的80次方种，顺序路径只走其中很少一部分。成本需报告。

5 E6 PCA和选择

选择保留原列子集；PCA通过Vq把中心化原列组合成新坐标。主成分可能同时依赖80个测量，因此只留5个主成分不意味着只需采5项指标。PCA保留X的大方差方向，低方差预测信号可能丢失，不能把方差比例叫标签信息比例。

PCA的均值、方向要训练内fit，验证只transform。q若依据预测分数选择，也要内层。正文未实际运行PCA，不能在结果表中补上推测的PCA表现。

6 E7与L3 两层验证

360行先分160开发与200确认。一个外层折为120训练与40验证；一个内层折在120内部再分80训练与40验证。在每个内层训练80行依次计算排名、选k列、fit缩放、fit回归；内层验证只做固定变换和预测。

用三个内层分数平均选k，再对120行外层训练从头排名、缩放和拟合，评价外层40行。四折外层平均评价整个选择算法。最后用160开发做同类内部选择、最终重拟合，然后评价200确认行。

局部索引t对应原表行outer_train_ids[t]。若把内层train_local直接用到全表，就选错行。全局错误对照的排名使用160行标签，含当前外层40行验证标签；它没有使用确认标签，后者仍可用于本次固定实验外推评价。

7 E8与L4 Pearson和独立解

$x=(0,1,2)$ 、 $y=(0,1,2)$ ，中心化均为 $(-1,0,1)$ ，分子2，分母2， $r=1$ 。把 y 改成 $(2,1,0)$ 后分子-2， $r=-1$ ；绝对值相同。常数列分母0，数学相关未定义；本实现给评分0并按原编号平局裁决，是显式回退而非统计证明。

训练标准化 A 每列均值0， y 中心化 y_c 。Ridge最小化 $\|y_c - Aw\|^2 + \|w\|^2$ ，其导数为 $-2A^T(y_c - Aw) + 2w$ 。令它为0，得 $(A^T A + I)w = A^T y_c$ 。截距回到 y 的训练均值，验证使用训练均值和尺度。

这里 $\alpha=1$ 对应“平方误差和”，若改为平均平方误差又仍加 $1 \times \|w\|^2$ ，相当于原目标惩罚增大 n 倍，解会变。audit.py用SciPy的正定线性求解核对sklearn的SVD求解，路径不同但数学目标相同；不显式求逆。

8 E9与L6 Jaccard逐项算

$A=\{0,1,4\}$ 、 $B=\{0,2,4\}$ 的交集2项、并集4项，所以 $J=0.5$ 。四个集合的配对为 $(0,1)$ 、 $(0,2)$ 、 $(0,3)$ 、 $(1,2)$ 、 $(1,3)$ 、 $(2,3)$ ，共6对，逐对算再平均。训练折重叠，不能把六对当六个独立数据集。

all80每对交并都是80，所以 $J=1$ ，无论80列是否有用。global_leaky共享同一全表排名，所选前 k 集合被人为嵌套，因此也较稳定。频率0.75只意味着四折中三次选中，不是变量为原因的75%概率。

Jaccard无机会校正，随子集大小变化，不能单独排名算法。

9 E10 E12与L5 结果反例

signal中nested外层均值1.021937，global_leaky为0.987023；两者最终确认均为1.025244。每份最终选 k 和列集恰相同，在同一160行上训练得到相同预测。这说明泄漏可以改变评价而不改变最后模型，不能由最终预测相同倒推过程合法。

null中nested外层1.110172、确认1.070827；global_leaky外层0.962204、确认1.094461。没有真实信号时，全数据筛选可以利用偶然相关美化内部估计，但未带来更低确认误差。不能将外层与确认差完全视为泄漏效应，因为训练规模120与160不同。

signal all80外层3.111984、确认1.894060；null all80外层2.930717、确认2.031184。只允许说“在 $\alpha=1$ 和当前机制下这条路线更差”，不能说80维永远无法泛化。若另调正则，需计入新的选择和评价流程。

10 E11 G5 G6与L8 稳定不等于正确

稳定表示某个算法对样本变化的选择行为较一致。一个永远返回全部列的算法极稳定；一个永远返回错误列的算法也可极稳定。正确与否要看明确目标下的预测、成本、可信机制证据和外部验证，不能只看集合重叠。

x2近似x0的代理测量，它们高度相关时可能互相替代。不同训练折偏好不同列不一定导致很大预测差；反之预测稳定也不保证选出真实原因。必须分别研究函数稳定性、变量选择稳定性与因果解释，不能偷换。

只展示前15列时必须写明候选共80列，并保留完整频率；否则读者无法知道筛选机会。主结果完整保存80列、四折集合、所有k试验，图只是可读的缩略视图。

11 G3 G4和实验报告

G3：虚线是外层验证标签流向排名，违反该折训练权限。内层验证可以选k，但不能训练该内层候选的排名。k定下后，在外层训练重新fit所有步骤；不能复用某一内层模型直接当完整外层模型。

G4：蓝橙并非相同训练量下的两个重复测量，蓝模型训练120行，橙模型训练160行。看到橙更低可能部分来自更多训练行。讨论泄漏应对照同样外层划分下的两条筛选路线，并保留独立确认。图显示均值，逐份波动在JSON内，不能只依据两根柱宣布显著胜利。

L8参考结论：在两个预设合成机制、每机制六份360行80列数据上，无泄漏嵌套筛选与全局标签排名表现出不同外层误差。signal最终确认预测却完全相同，null中全局排名的更低CV未转化为更低确认误差。固定全部80列最稳定，但在本次 $\alpha=1$ 下更差。结果提醒我们将特征选择放入验证边界，同时报告子集大小和稳定性；它不是高维学习的普遍失败定律，也不是变量因果鉴定。

12 L7 执行与复现

正确执行记录应有每个代码格的实际计数、没有error输出、六张由本次result画出的PNG。Notebook重新运行主要实验与独立审计。外部浏览器和网络Jupyter内核未测试，不能仅凭命令行成功声称所有界面都正常。

一般容许约 $1e-10$ 的浮点差；折归属、选列、k、维度和协议应一致。计时可变，数据、生成式和随机种子不能偷偷改变。所有实际数值答案及第0份的k、Jaccard、频率将在Notebook中显示；也可从experiment-result.json逐项读取。

13 第0份signal实际选择

四折k分别为[5, 5, 5, 5]。四个集合依次为[[0, 2, 1, 15, 5], [0, 2, 1, 23, 32], [0, 2, 1, 32, 23], [0, 2, 1, 8, 31]]。六对Jaccard为0.428571, 0.428571, 0.428571, 1.000000, 0.428571, 0.428571，平均0.523810。前15列频率为[1.0, 1.0, 1.0, 0.0, 0.0, 0.25, 0.0, 0.0, 0.25, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0]。这些是描述性折间频率，不是独立实验的因果概率。