

第054讲 实验指南

1 实验目标和交付物

本实验不是“从80列中找出真正原因”。你要复现四行交互反例，检查独立高维距离推导，再比较无泄漏嵌套筛选、故意全表标签筛选和固定全部特征。最后同时报告误差、选择大小和稳定性，以及它们不能说明的事情。

数据完全合成，不含个人信息。主实验有signal、null两个机制，每机制6份独立数据，每份360行×80列。前160行开发，后200行独立确认。确认集不参与列排名或k选择。CPU即可，无账号、外部数据或付费API需求。

2 安装与运行

推荐Python3.12，数值依赖版本在requirements.txt，Anaconda环境在environment.yml。终端进入本讲目录后执行：

```
conda env create -f environment.yml
conda activate ml054
python experiment.py --out outputs/my-result.json
python audit.py --report outputs/my-result.json --out outputs/my-audit.json
python plots.py --report outputs/my-result.json --directory outputs/my-figures
python execute_notebook.py --out outputs/fresh-kernel.ipynb
```

已有独立环境时用python -m pip install -r requirements.txt。不要把pip对应的Python与执行脚本的Python混淆。所有默认输入相对脚本目录；显式输出相对调用位置。generate_data.py默认另存outputs/regenerated-data，供你比较数组，不自动覆盖交付数据。

完整PDF重建需另外安装build-requirements.txt及package.json里的MathJax3.2.2；系统需Node.js、Pango和Noto CJK字体。准备好后bash build_all.sh将所有重建文件放入outputs/rebuild。实验脚本本身不需要文档依赖。

3 L1 四行交互先手算

在纸上写 $x_1=(-1,-1,1,1)$ 、 $x_2=(-1,1,-1,1)$ 、 $y=(1,-1,-1,1)$ 。三列均值为0，平方和都为4。分别算 x_1 与 y 、 x_2 与 y 的内积，它们都为0，因此相关为0。

然后分别预测：加性模型全0，交互模型 x_1x_2 。逐行计算平方误差，再求平均。你应得到1与0。这里四行全用于拟合，目的在于验证代数表达能力，不是测未知真实总体上的泛化。

最后加入一项思考：若一个研究员先用相关筛掉两列，再生成交互，还能恢复乘积吗？若先生成全部交互再筛选，会增加多少候选、带来什么选择噪声？

验收：完整手算表，以及一句话区分“边际无线性相关”和“联合上无预测信息”。

4 L2 核对维度和平方距离

计算两列不含常数的二次特征 x_1 、 x_2 、 x_1^2 、 x_1x_2 、 x_2^2 。推广到 p 列，写出 $p+p(p+1)/2$ 。分别算 $p=10$ 、 80 ；说明列数变化没有增加样本行数。

读取`controls.distance`。每个 d 有4000对彼此独立的正态点，保存的是平方距离除以 $2d$ 。用`mean`与`std(ddof=1)`求变异系数，再与 $\sqrt{2/d}$ 比较。必须说明模拟不必与理论值逐位相同；理论是总体公式，4000对只给有限样本估计。

验收： $d=2$ 、 10 、 50 、 200 的理论均值 $2d$ 和变异系数；解释图2的横轴是规范化平方距离，而非原始距离或预测准确率。不要据此声称实验已经证明某个近邻算法失败。

5 L3 从外层行号追踪内层来源

在`runs`中选`signal`、`rep=0`、`method=nested`，再选第0外层折。`train_ids`有120个，`valid_ids`有40个。`inner_trials`内每个 k 有3折，每折`train_local`有80个、`valid_local`有40个。

内层索引是相对120行外层训练子表的局部位置。真正原表行号应写为`outer_train_ids[inner_train_local]`。不能直接把内层的0当原始数据第0行。独立审计通过这个映射复算每次排名与预测。

为 $k=2$ 第一内层折，取80行 X 和 y 计算排名，取前2列，再训练内标准化并拟合Ridge。在内层验证40行计算MSE。三折平均用于比较 k ，然后再在120行外层训练上重新排名和拟合，最后评价外层40行。

验收：画出 $360 \rightarrow 160+200 \rightarrow 120+40 \rightarrow 80+40$ 的边界。说明200确认行为什么没有出现在任何选择函数的输入中。

6 L4 Pearson与Ridge逐项核对

`rank_features`先减训练均值，计算各列与中心化 y 的内积，再除两边长度。使用绝对值，因此负相关也可被选。常数列分母0时本实现返回评分0；这是一条工程回退规则，相关系数本身仍是未定义的。

对一个选中列，手算其均值与 $ddof=0$ 标准差。`StandardScaler`将验证减同一训练均值、除同一尺度，不能重新`fit`验证。`Ridge`目标使用平方误差和加 α 乘系数平方和， $\alpha=1$ ，截距不惩罚。不要把它误写成平均平方误差加同样 α ，二者的惩罚相对强度不同。

审计独立实现：训练标准化后，令 A 为设计矩阵、 yc 为中心化 y ，计算 $w=(A^T A + I)$ 逆乘 $A^T yc$ ，再在验证坐标上预测。实际代码用线性求解器，不显式求逆，以减少数值开销和误差。

验收：能解释`audit.py`为什么用另一种线性代数路线核对库模型，而不是原样再调同一个`fit`。常数列与NaN、标签长度错三种检查应按预期处理。

7 L5 比较全表筛选和独立确认

global_leaky的排名一次使用160行开发标签，其中包含当前外层验证行。这样生成的列集合会迎合外层验证噪声。注意：它没有用后200行确认标签，因此确认集仍可显示真实外推表现。

按signal与null分别汇总外层MSE、确认MSE。不要把两机制混成一个“平均改进百分比”。signal中两种筛选最终确认结果相同，是因为各份最终k与最终列集一致；确认模型都使用160行，允许合法重新学习排名。外层评价却不同，所以相同最终模型不是无泄漏证明。

null中标签与输入独立，理论最佳总体MSE为噪声方差1。全表筛选CV更低，但独立确认并未更低。CV与确认模型的训练样本数又不同，分别120与160，因此不能把它们差值全部解释为泄漏量。

验收：完整六行汇总表，逐份结果，以及一段保留相同最终预测这一反例的解释。

8 L6 稳定性需要同时报告选择大小

四个外层折得到四个集合，共六对。先用 $A=\{0,1,4\}$ 、 $B=\{0,2,4\}$ 手算交并， $J=2/4$ 。再从真实结果的selected字段重算六个J并平均。

查看每折k以及selection_frequency。不同k、不同候选总数会改变随机重叠机会。all_features全部80列一直保留，所以 $J=1$ ；它没有告诉你这80列每一列有用。global_leaky因各折共用同一排名，也显得更稳定，但这是共享标签信息造成的依赖。

验收：报告每份四个k、六个J、平均J和前15列频率；强调整整80列结果仍保留。不能将四折频率称为某变量是原因的概率。

9 L7 执行Notebook并检查输出

Notebook的主要实验单元重新运行experiment.run，不读取交付结果冒充计算。后续审计和绘图也使用这次result，所有图再生成后嵌入。你可以在JupyterLab中Restart Kernel and Run All，或使用第二节的命令行执行器。

命令行执行器使用新Python进程中的真实IPython进程内内核，逐格保留stream和图像。检查所有代码格有执行计数，无error，六张图有实际PNG内容。这不代表测试了浏览器界面或远程Jupyter连接。

如果数值不匹配，先检查numpy、scipy、scikit-learn版本、数据SHA、种子、折索引与选列顺序。浮点求解可有很小数值差，不应将 $1e-12$ 差异解释为新的科学结果。若频率或k不同，则需要认真追查排名平局、数据或流程。

10 L8 写研究结论与局限

结论必须明确：这是合成signal/null，固定Ridge $\alpha=1$ ，比较的是特征流程而非等训练预算算法竞赛；相同独立确认不为泄漏辩护；all80高稳定但预测差；Pearson可能遗漏交互；PCA只作原理说明未实测。

提出后续研究时，可预先比较正则强度网格、不同相关代理结构或外部数据，但应重新规划验证与预算。不要在现有确认结果上反复决定下一特征再继续叫封存确认。若目标是机制解释，应另外考虑混杂、干预与采集设计，预测筛选本身不够。

提交L1至L8完整记录。所有题目对应答案在answers.pdf，原始来源与核查范围在sources.md及source-checks.json。

11 结果核查与常见失败

以下数字应从你的新result汇总得到，保留到六位仅为阅读；审计使用更高精度。不要只检查一条路线成功。

机制与方法	外层MSE	确认MSE
signal nested	1.021937	1.025244
signal global_leaky	0.987023	1.025244
signal all80	3.111984	1.894060
null nested	1.110172	1.070827
null global_leaky	0.962204	1.094461
null all80	2.930717	2.031184

如果确认误差相同但外层不同，不要把它当作程序错误；本次signal确有这一结果。若all80稳定性不是1，先检查集合是否始终包含0至79；若常数列产生NaN，检查相关分母为0的处理；若所有k试验都恰等同，检查是否误把同一组预测复制到不同候选。

审计文件应报告144个外层、1152个内层和36个确认预测核对通过。Notebook应有14代码格和6张实际嵌入图。独立审计不会把高分作为通过标准；正确保存“不如基线”同样合格。若你的修改改变了数据机制、k候选、模型或划分，应另标实验版本，不与原包结果混合冒称完全复现。