

第055讲 完整答案

1 E1 稀有类与标签问题

自然不平衡是目标总体正类本来少；抽样偏差是进入训练的分布与目标不同；选择性标注是只有 $S=1$ 对象得到标签；标签噪声是已记录的标签可能与真实目标不符。复制少数类改变训练权重，不能自动补出未知标签，也不能识别未知翻转概率。

判断哪一种存在，需要追溯数据生成、采集与标注制度。仅看一张正负数量表不够。未标注不是负类；把未知写成0会改变训练目标，即使最后准确率很高也不能证明合理。

2 E2与L1 代价阈值

$p=0.2$ 时判正成本 $1 \times (1-0.2)=0.8$ ，判负 $8 \times 0.2=1.6$ ，所以判正。 $p=0.05$ 时分别0.95与0.4，所以判负。一般要求 $C_{FP}(1-p) \leq C_{FN} p$ ，整理得 $p \geq C_{FP}/(C_{FP}+C_{FN})$ 。8比1时为1/9；误报2、漏判8时为 $2/10=0.2$ 。

$\pi=0.08$ 时全判负总体准确率 $1-\pi=0.92$ ，召回率0。准确率并没算错，但它对稀有漏判可能不敏感。0.5对应概率是目标后验、正确分类成本为0且两类错误成本相等的情形；若容量约束或其他效用存在，还需重新定义决策问题。

3 E3与L5 加权交叉熵

加权条件损失为 $-w_1 p \log q - w_0 (1-p) \log (1-q)$ 。导数为 $-w_1 p/q + w_0 (1-p)/(1-q)$ 。令0后交叉相乘： $w_0 (1-p)q = w_1 p(1-q)$ 。移项得 $q[w_0 (1-p) + w_1 p] = w_1 p$ ，所以 $q = w_1 p / [w_1 p + w_0 (1-p)]$ 。

$w_1=9$ 、 $w_0=1$ 、 $p=0.1$ 时，分子0.9，分母 $0.9+0.9=1.8$ ， $q=0.5$ 。原概率仍0.1。若再把原总体的低成本阈值直接作用于这个加权 q ，可能重复放大对少数类的偏好。

类别平衡比值 n_0/n_1 约11.5并不等于预设成本比8，因此balanced原始0.5并非本成本下唯一正确方法。推导是总体点态最优；有限LogisticRegression、正则与采样都可能偏离，所以实际加权和自然模型不是严格的截距平移复制。

4 E4 赔率修正逐步推导

Bayes公式下，源后验赔率 $q/(1-q)$ 等于类条件似然比 $P(x|1)/P(x|0)$ 乘源先验赔率 $\pi_s/(1-\pi_s)$ 。目标类条件密度若不变，只替换先验赔率，得到目标 $p/(1-p)=a q/(1-q)$ ，其中 a 是目标/源先验赔率之比。解 p 得 $a q/(1-q+a q)$ 。

$\pi_s=0.5$ 、 $\pi_t=0.1$ 时，源赔率1、目标赔率1/9，所以 $a=1/9$ 。 $q=0.5$ 代入，分子1/18，分母 $1/2+1/18=5/9$ ，商0.1。 $q=0$ 与1保持端点。若 $\pi_t=0.08$ 、 $q=0.5$ ，则映射到0.08。

假设包括类条件分布不变、源 q 有概率含义、目标先验可信。任意概念漂移、类别条件输入变化和标签翻转不由单一倍率解决。实际使用训练 $n1/n$ 估计目标先验，不使用测试标签估计它。修正概率后再按目标成本选择阈值，两步各有职责。

5 E5 G1与L2 复制和泄漏

若先复制原样本 A 多次，再把副本随机分到训练与测试，模型已经通过训练见过测试对象的信息。新行号不代表新对象。正确流程先按原始对象和任务划分，再只在训练范围重采样；如果对象有多个原始记录，还须按组划分，不能仅按单行。

实验`oversample_source_ids`每个都在0至1999。负类全部原始训练ID保留一次，正类有放回抽 $n0$ 次。总过采样行数 $2n0$ ，唯一ID不会因此超过原训练2000。自然测试约320正例只是期望，不要求每份等于320。

测试若人为平衡，会改变精确率、AP及成本对应的总体含义。应保留自然分布，或者明确报告抽样方式与所需加权，不得把平衡测试得出的数值直接当自然部署表现。

6 E6 G2与L3 指标为什么不同

`natural`前三条共用概率数组，Brier平均 $(p-y)^2$ 不含阈值，所以相同。ROC AUC和AP基于概率排序，也不由单个分类阈值决定。TP、FN、FP、TN通过 $p \geq t$ 形成，因而召回、精确率、准确率和成本会变。

`weighted`原始输出近似平衡分布后验，自然测试只有约8%正类，原始概率平均却约0.321，因而Brier变差；高召回来自更积极地报正，不代表每个概率都准确。修正后Brier接近自然模型，但再用0.5会漏掉许多成本上值得判正的对象，所以成本回升。

精确率 $TP/(TP+FP)$ 受总体正负比例影响；同样的真正率、假正率下，更低先验通常降低精确率。ROC AUC较少直接受先验改变影响的说法仍需类条件分布等条件，不能把AUC当任何偏移下的不变量。

7 E7与L6 Wilson16比20

$r=16/20=0.8$ ， $z \approx 1.959964$ ， $z^2 \approx 3.841459$ 。分母 $1+z^2/20 \approx 1.192073$ 。中心分子 $0.8+z^2/40 \approx 0.896036$ ，中心 $c \approx 0.751663$ 。根号内 $0.8 \times 0.2/20 + z^2/(4 \times 20^2) \approx 0.010401$ ；半宽约0.167680。

因此区间 $c \pm h \approx [0.583983, 0.919342]$ 。召回分母是20个真正类，不是所有正负例总数。若没有真正类，召回与区间无法估计；代码返回None，不产生假的0宽区间。

区间构造基于已固定模型和阈值的独立正例抽样。若重复设备导致相关，应按组设计评价或用适当的组重采样；不能继续把每行当独立二项试验。

8 E8与G5 不确定性的范围

单次Wilson区间不涵盖重新抽训练集、重新拟合、重新选阈值的不确定性。六份模拟的不同训练模型构成另一层变化，因此逐份给区间与逐份比较，比把所有测试正例合并成一个假装固定模型的计数更清楚。

两个95%区间重叠不能直接证明方法相同，不重叠也不能替代考虑同一对象配对结构的正式比较。多方法同时比较还涉及多重性。本课只报告逐个描述区间，没有宣布显著优胜或总体覆盖已精确验证。

9 E9 G6与L7 逆概率标注权重

给定 X, Y ， S 是均值 $s(X, Y)$ 的Bernoulli变量，损失 L 由已固定模型与 X, Y 确定。因此 $E[S L/s | X, Y] = L E[S | X, Y]/s = L$ 。再对 X, Y 取平均，得到目标期望损失。成立需要正确 s 且 $s > 0$ 。

s 很小时权重很大，方差增加。 $s=0$ 的区域没有标签，纯加权不能恢复。若 s 依赖未观察 Y 且机制未知，现实中不能由已有标签自动估出真 s 。oracle_ipw用生成器真值，是额外信息参照，不是一般可用算法。

本次完整自然标签成本0.324083，selected_only0.335375，oracle_ipw0.328083，missing_as_negative0.373792。IPW改善该模拟平均成本，但仍不比完整自然标签更好，也不证明对任意现实标注偏差无误。

10 E10 标签翻转手算

给定 x ，真正类概率 p 中有 $1-\alpha$ 保持正标签，真负类概率 $1-p$ 中有 β 被翻成正标签，因此 $q=(1-\alpha)p+\beta(1-p)$ 。 $\alpha=0.25$ 、 $\beta=0.02$ ，化为 $0.02+0.73p$ ； $p=0.1$ 时 $q=0.093$ 。

若 α 和 β 已知、和不等1，且 q 可靠，可形式上反解 $p=(q-\beta)/(1-\alpha-\beta)$ 。但未知噪声率、依赖 x 的翻转、模型失配都破坏简单解释。这里没有实施噪声概率修正算法，仅比较噪声训练的后果并给出条件代数。

本次噪声模型召回比完整自然同阈值略高，而Brier更差。召回这一项变化可以来自不同边界和有限样本，不证明噪声提高标签质量；要同时看概率误差、误报和成本。

11 E11 G3与L4 阈值选择的负结果

第0份把全部60个验证阈值算一遍，以较小阈值打破同成本平局。选择只读取1200验证标签。最低验证成本受有限样本噪声与离散网格影响，不能保证测试最优。

六份平均natural_tuned成本0.330958，高于预定1/9的0.324083，差约0.006875。必须保留这一结果；换种子或在测试上细调阈值再报告“胜利”会改变问题。它也不支持验证调阈值永远差。后续需要新的预注册评价来研究何时调阈值更有用。

12 E12 G4与G7 校准和决策

修正概率回答“在目标分布下这个分数应对应多少概率”；阈值回答“在给定代价下选择什么动作”。修正后用0.5仍相当于对称错误代价，并不适配本讲8比1。理想目标概率应对1/9决策；现实可在合法验证上选阈值。

图4理论曲线在(0.5,0.08)附近，强调先验影响；若类条件分布也变，不能保证映射。图7中weighted原始预测通常高于实际正例率，点在对角线下方；修正后接近对角线只是本样本分箱上的描述。分箱可能隐藏箱内异质性，尾部样本少也会波动，不能证明所有x条件概率精确。

13 L8 完整结论示例

我们在六份固定生成机制的自然不平衡数据中，每份训练2000、验证1200、测试4000，预设漏判代价8、误报1。自然模型从0.5改为1/9明显改变召回与成本，但概率指标不变；平衡权重与训练过采样提高原始0.5召回，同时原始概率在自然测试上失真。基于训练比例的先验修正使Brier接近自然模型，但修正后0.5阈值仍不适配8比1成本。验证调阈值没有胜过理论阈值，完整保留。选择性标签和错误填负例造成另类偏差，oracle IPW仅在机制已知的模拟中有条件解释。

结果不等于所有任务的最好方案。我们未证明现实机制可识别，未实现先验估计EM或完整噪声修正方法，也未将逐个Wilson区间冒充算法总体或同时置信区间。预测目标、数据权限、概率含义和效用定义都应与数字一起报告。

14 第0份实际计数与阈值

训练正例151，验证正例105，测试正例326。过采样总行数3698，唯一原始行数2000。验证选择阈值为0.09。

路线	TP	FN	FP	TN	召回95%区间
natural_05	76	250	43	3631	[0.190501, 0.281973]
natural_cost	229	97	541	3133	[0.650702, 0.749490]
natural_tuned	245	81	692	2982	[0.701878, 0.795330]
weighted_05	252	74	809	2865	[0.724509, 0.815144]
oversampled_05	251	75	791	2883	[0.721266, 0.812323]