

第055讲 实验指南

1 实验要回答的三个问题

第一，阈值、权重和训练过采样怎样影响自然测试上的少数类召回与误判成本？第二，加权或重采样后的输出还能否当原总体概率？第三，标签缺失或翻转与类别稀少有什么区别？不要把三个问题压成一个准确率。

本包六份独立合成数据，每份7200行4列，训练2000、验证1200、自然测试4000。类别1总体概率0.08。主实验所有路线在同一测试上评价，标签制度对照另比较选择性标注、已知机制IPW、翻转标签和错误填负类。无需账号、网络数据、GPU或付费API。

2 环境与运行

建议Python3.12。requirements.txt固定数值依赖，environment.yml给出Anaconda环境。进入本讲目录后执行：

```
conda env create -f environment.yml
conda activate ml055
python experiment.py --out outputs/my-result.json
python audit.py --report outputs/my-result.json --out outputs/my-audit.json
python plots.py --report outputs/my-result.json --directory outputs/my-figures
python execute_notebook.py --out outputs/fresh-kernel.ipynb
```

已有环境可用python -m pip install -r requirements.txt。确认pip和运行脚本使用同一解释器。默认输入相对脚本文件，显式输出相对命令调用位置。数据再生默认写outputs/regenerated-data，不覆盖交付数据。

完整PDF重建另需build-requirements.txt、Node.js和MathJax3.2.2，以及Pango与Noto CJK字体。安装好后bash build_all.sh输出到outputs/rebuild，不覆盖交付PDF和数据。没有排版依赖也能运行数值部分。

3 L1 先算决策 再看模型

假设目标概率 $p=0.2$ ，漏判成本8、误报1。计算判正的期望成本 $1 \times 0.8 = 0.8$ ，判负 $8 \times 0.2 = 1.6$ ，所以判正。再对 $p=0.05$ 重复，得0.95与0.4，所以判负。

把不等式 $1-p \leq 8p$ 整理为 $p \geq 1/9$ 。然后说明为什么全预测负类在 $\pi=0.08$ 时准确率可达0.92但召回率为0。这里概率、成本、动作是三个不同对象，不能拿平均预测概率代替准确率。

验收：上述两行成本表、阈值推导，以及一段解释0.5何时适用。若误报成本变为2、漏判仍8，先在纸上算新阈值，不要打开测试数据找答案。

4 L2 核查训练内过采样

读取data/protocol.json和第0份的oversample_source_ids。所有ID必须0至1999，负例原始ID各出现一次，正例有放回抽取到与负例相同数量。它们不是新独立观察，而是旧行的重复权重。

画出先划分、再复制训练正例的时间线。再画一个故意错误流程：先复制全表再随机划分。解释同一原始正例的副本如何同时在训练和测试出现。不能只检查行号不同，还要追踪它们是否来自同一原始对象。

本实验保留自然验证与测试分布。读取每份test_positives，不要求它都等于320；生成机制 $\pi=0.08$ 并不意味着每个4000行样本恰好8%。不要删负例把测试变成50%正例后仍声称自然场景精确率。

验收：第0份训练正例数、过采样总行数、唯一源ID数、测试正例数，以及“相同数据行的副本不是新增证据”的解释。

5 L3 重算一条混淆矩阵

选runs[0]的natural_05，取test_labels与probability，以 $p \geq \text{threshold}$ 判正。逐项计TP、FN、FP、TN，确认四项合计4000。召回分母TP+FN，精确率分母TP+FP，准确率分母4000。

再算成本 $(8\text{FN}+\text{FP})/4000$ 和Brier平均 $(p-y)^2$ 。把natural_cost也重算一遍。两者概率数组完全相同，只有阈值不同，因此Brier相同；混淆计数和成本则可改变。

验收：至少两条方法的完整计数与指标，说明为何精确率随目标类别比例改变；不能只交一张混淆图而没有分母。

6 L4 验证阈值的全部60个候选

读取validation_probability，对应的真实验证标签为原数据索引2000至3199。分别用0.01至0.60计算成本，选最小，平局取较小阈值。检查与selected_threshold一致。

接着在测试上只评价这个已冻结阈值。不要为了“检查最优”再遍历测试阈值并挑最小，然后把它叫验证选择。本实验同时预先报告理论1/9的路线，目的在于揭示有限验证选择的波动。

本次六份均值中，验证调阈值成本0.330958，理论1/9为0.324083。保留这一负结果。它不证明验证调阈值永远差，只表示当前样本、网格、模型和成本下出现了这组结果。

验收：第0份阈值曲线和最小候选；写一句为什么单次验证最低点不保证测试最低点。

7 L5 手算权重概率与先验修正

先取 $w_1=9$ 、 $w_0=1$ 、原 $p=0.1$ ，算 $q=w_1p/[w_1p+w_0(1-p)]=0.5$ 。此 q 对应加权目标，不是原总体50%风险。再用源先验0.5、目标先验0.1、 $q=0.5$ 做赔率修正，应回到 $p=0.1$ 。

实际实验的平衡权重由训练 n_1 、 n_0 计算，目标先验估计是 $n_1/2000$ ，不能从测试 $\text{test_positives}/4000$ 借用。对`weighted`与`oversampled`分别核对`prior_correct`，比较原始与修正Brier。

说明两个限制：复制训练数据改变有限样本的有效权重，且固定C下惩罚相对强度会变化；当 $P(X|Y)$ 也变时，一个先验乘数不能保证正确。因此不要期待`weighted`和`oversampled`输出逐位相同，也不要吧修正后的概率称为已经在所有人群上完全校准。

验收：手算与代码结果一致；解释为何修正后仍用0.5的成本较高不代表修正“失败”，而是阈值未适配8比1代价。

8 L6 少数类Wilson区间

用20个真阳性中命中16个的例子，先算 $r=0.8$ ，再代入 $z=1.959964$ 、分母 $1+z^2/20$ ，得到中心与半宽。答案应约 $[0.583983, 0.919342]$ 。区间分母是20，不是另有多少负例。

真实第0份按每条方法的TP与positives计算区间，核对图5右侧TP/P。区间条件于这次已经训练并固定阈值的分类器，描述独立测试正例的抽样不确定性。它没有包含重新训练、重新选择阈值的变动，也不是多方法同时区间。

验收：至少两条方法的数值区间及条件说明。若测试正例为0，写“无法估计召回”，不能伪造0宽区间。若对象有组内重复，应重新设计按组评价，而非照用独立二项公式。

9 L7 标签制度和未知标签

读取`observed`、`obs_prob`、`noisy_y`。`observed`只作用于前2000训练行。负类标注率0.6；正类中 $x_0 < 1$ 的标注率0.15，其余0.8。仅用`observed`训练所见分布可能偏离自然总体。将其他行`y`填0是故意错误对照，不是合理的缺失值清洗。

`oracle_ipw`对已标注行用 $1/\text{obs_prob}$ 。请推导 $E[S L/s | X, Y] = L$ ，并指出它依赖 s 已知、处处大于0及正确选择机制。此处真 s 来自生成器；现实选择性标签通常没有这些条件，不能把示教成功写成现实偏差自动解决。

翻转标签是另一个机制： $\alpha=0.25$ 、 $\beta=0.02$ ，故观测 $q=0.02+0.73p$ 。手算 $p=0.1$ 时 $q=0.093$ 。它与“标签缺失”不同，不能一律用类别平衡修复。主实验没有实现Natarajan论文全部噪声修正，也没运行先验估计EM。

验收：完整四条标签对照结果，保留噪声标签召回可能提高但Brier更差的事实；说明为什么只看召回会误读。

10 L8 重新执行并写结论

Notebook从当前数据重新fit、审计和作图，不读取旧结果冒充运行。命令行在新Python进程的真实IPython InProcessKernel执行；浏览器界面与外部Jupyter网络内核不在验证范围。检查所有代码格有计数、没有error、七张实际生成图嵌入。

报告包括六份数据的自然测试正例数、所有八条主要路线与四条标签制度、逐份指标和区间、验证选阈值规则、训练内复制来源以及限制。不要把六份不同训练模型的测试预测合并成一个声称固定分类器的巨大Wilson区间。

核心结论应区分三件事：概率的含义、决策阈值的成本、训练标签的观察机制。下一步若要改成本、特征或抽样制度，先写新协议并使用新的确认数据；不在已看过的测试上反复开发。

11 常见错误和验收范围

输入概率有NaN、超出[0,1]或标签长度不匹配会报错；先验0或1不满足本修正函数条件。无测试正例返回None召回及区间。LogisticRegression未收敛警告被转成错误，不能忽略后继续比较。文档字体缺失不影响数字实验，但最终PDF需要安装所列中文字体。

audit.py独立核对72组指标、60阈值账本、模型系数的logit前向、过采样来源与先验变换。它不证明现实标签机制可识别，也不验证所有可能模型或平台。完整答案见answers.pdf，来源与访问限制见sources.md。