

第056讲 答案 可信分类阶段项目

使用说明

本答案对应独立实验A至G及读图G1至G6。主指标是 $(4FN+FP)/N$ ， $p \geq t$ 判1，先验基线仅利用开发集。所有报告数字来自随包实际执行结果，不是要求算法必须达到的预设分数。

A 阈值与手算

$t=0.2$ 的预测为(0,1,1,0,1)。TP2、FN1、FP1、TN1；平均成本 $(4+1)/5=1$ 。 $t=0.5$ 的预测为(0,0,0,0,1)。TP1、FN2、FP0、TN2；平均成本 $8/5=1.6$ 。二者准确率都是 $3/5$ ，成本却不同；这说明准确率对FN与FP使用相同权重，无法表达本课的非对称成本。

第二行 $p=0.2$ 在 $t=0.2$ 时判1，因为约定为大于或等于。概率向量没有变，所以平均 $(p-y)^2$ 、AUC和AP不因改阈值而变。若重新训练产生新概率，才不能沿用这个结论。

B 填补泄漏的准确边界

仅排除最终测试仍不够。内层验证行属于开发集；如果在所有开发行上算中位数、均值、标准差，就让内层拟合使用了自己的验证分布。正确做法是每一内层折单独fit填补器和缩放器，仅用该折训练行，验证行只transform。

最终完整模型允许在全部开发行上fit，因为最终评价集是独立600行测试。相同的“开发行”在不同层具有不同职责，不能把文件名当作授权范围。

C 拟合预算

6个候选，每候选3次内层训练，共18。每次外层选择后另重拟合1次，三轮外层共 $3 \times 19=57$ 。最终全部开发集再做18次候选训练及1次重拟合，共19。总数76。

每候选的OOF概率只算一次，再试5个阈值，不增加训练。因此4个选择阶段 $\times$ 6候选 $\times$ 5阈值=120次评分，只有72次内层训练。先验基线计算均值，不计为逻辑回归拟合。记录数字必须说明口径。

D 一个错误修改

例如看外层400行的成本后，在0.1至0.5中挑一个更好的阈值，再把这400行称为“外层评价”。这样外层标签已经决定阈值，外层不再评价完整的未知选择过程。修复方式是把阈值选择留在内层800行；不是再给外层分数套一个置信区间。

另一例是外层表现不佳后增加更大的C网格，并只保留最终一次外层结果。即使每次代码内部边界正确，人工也用外层结果做了选择，研究过程需要如实标为探索。

E 故障注入应当失败

修改某个内层imputer统计后，审计的`np.nanmedian(X[tr],axis=0)`与记录状态不再一致，应首先报训练中位数不一致。如果跳过这条检查，后面的前向概率重建也可能失败。原始数据与结果不得覆盖；污染副本应保留在outputs中。

若修改的是完全没有缺失的一列中位数，该列预测可能不变，但统计审计仍会发现状态不实。这也是同时核对训练统计与最终指标的意义。只有看最终准确率会漏掉一部分错误。

F 完整描述误判

最终预测正例 $239+241=480$ ，其中241个为误报，误报占预测正例约50.2083%。真正正例250个中找出239个，召回95.6%；真正负例350个中误报241个，假阳性率约68.8571%。二者分母不同，不要把这两个比例混用。

成本 $(4 \times 11 + 241)/600 = 0.475$ ，相对于全判正基线 $350/600$ 减少 $65/600 \approx 0.108333$ 。模型用额外44个漏判成本换来减少109次误报，总成本净下降65。这个分解能解释为什么召回略降于基线的100%仍值得在既定目标下选择。

可以写：“该模型在指定4比1成本下优于先验基线，但600例测试中仍有241次误报；若实际业务无法承担480次复核，当前目标函数不足以支持部署。”这同时保留进展与不足。

G 配对区间

对每个测试行计算差损失，再抽600个行号，有放回重复2000次。结果2.5%和97.5%分位数约为-0.161667与-0.053333。两种方法在同一测试行相关，配对保留了这种相关；分别抽两份测试行会改变差值的抽样结构。

此次区间以已拟合模型为条件，不重新抽开发集、不重做内层搜索、不训练新系数。它不能反映下一批训练数据可能选中degree1或不同阈值的情况。若需要那类不确定性，必须设计更完整的重复抽样研究，并承认额外成本与假设。

读图答案

G1 测试框返回候选、阈值或预处理选择的箭头都会越界。测试后只做预定统计汇总与描述分析，不改冻结决策。

G2 每个degree/C组合先产生自己的OOF概率，再根据5个阈值选成本。因此图上点与点差异既含模型变化也含阈值选择，不能当成固定阈值下C的纯效应。

G3 外层训练集重叠且最终模型使用更多训练数据，预测对象也不同。把它们简单平均会混合不同估计目标，并虚构独立重复数。

G4 真正正类行的FN为11，而真正负类行的FP为241。低阈值让更多人被判正，两个现象完全可以共存。只显示归一化召回会遮住误报数量。

G5 差值大于0表示新模型成本更高。区间在零左侧仅支持既定合成总体中固定模型的成本改善，不说明真实数据代表性、伦理可接受性、因果正确性或上线安全。

G6 分母是该组TP+FN，也就是该组真实正类数。总组人数不是召回的试验次数。同一个0.95由20例或2000例产生时精度不同，因此必须同时报告计数和区间。

一段合格结论示例

在固定合成独立行总体、漏判成本4与误报成本1下，按三折嵌套验证选择6个预设流水线候选及5个阈值，最终冻结二阶特征、 $C=0.1$ 和阈值0.2。600行测试成本为0.475，相比先验基线降低0.108333，固定模型的配对95%百分位区间约为 $[-0.161667, -0.053333]$ 。结果支持这一限定问题上的改进，但仍有241次误报。两组召回分析只作描述，区间未包含重新训练、再次选择或现实分布漂移的不确定性。

常见不合格交付

只给最高准确率，忽略成本；只有最终模型而无失败与候选记录；在全开发集预处理后才做内层CV；把最小内层成本当作独立测试；把有哈希说成外部预注册；用三折标准差宣布精准置信区间；看到测试后删掉误报分析。每项都应具体修复，而不是增加一句“结果仅供参考”。