

第056讲 实验 可信分类项目交付

实验目的与边界

你将从固定数据完成一套分类研究报告：6个模型候选、5个阈值、三折嵌套验证、一个先验基线、一次最终测试、配对区间及两个预定子群的错误分析。本文件可独立使用，所需定义、命令与验收标准都在这里。

数据是合成的独立行，不对应真实个人。1800行中开发1200、最终测试600。输入x0、x1、x2；group只用于错误分析；y为0或1。仅x2允许NaN。漏判成本4、误报成本1。 $p \geq t$ 判1，平均成本 $(4FN+FP)/N$ 为唯一主指标。读完固定data/protocol.json后再运行，不用测试数据修改任务。

1 安装和文件定位

建议Python3.12，新建虚拟环境或使用environment.yml中的Conda环境。在本讲目录运行：

```
python -m pip install -r requirements.txt
python experiment.py --out outputs/my-result.json
python test_experiment.py --report outputs/my-result.json
python plots.py --report outputs/my-result.json --directory outputs/my-figures
python execute_notebook.py --out outputs/my-notebook.ipynb
```

CPU即可，不需要GPU、付费API、登录或联网下载数据。首次安装软件需要网络，之后数值实验离线完成。默认数据按脚本所在目录定位，显式输出路径按当前工作目录解析。Notebook执行器启动一个新的Python进程中的真实IPython进程内内核，不是只填入执行序号；它不验证浏览器Jupyter界面或外部socket传输。

requirements.txt只包含数值实验与Notebook依赖。PDF重建另需build-requirements.txt、Node.js、npm install及Noto CJK字体。bash build_all.sh写到outputs/rebuild，不替换原交付物。不要把缺少可选PDF渲染依赖误报为模型实验失败。

2 先写下你预期会看到什么

不运行模型前，回答三个问题并保存预测：二阶交互能否改善本例？标准化是否应该从全部1800行计算？较低阈值可能如何同时改变FN和FP？这些是学习者假设，不是应被实验强行满足的答案。

练习A：五行标签(1,1,0,0,1)，概率(0.1,0.2,0.3,0.0,0.9)。分别算 $t=0.2$ 和 $t=0.5$ 时的计数与成本。说明等于阈值如何处理，以及为什么概率评价不随阈值变化。

练习B：解释为什么把“用全数据填补中位数”改成“只在开发集填补”仍未完全修复内层交叉验证泄漏。精确指出内层一轮允许看到哪些行。

3 跟踪一次嵌套验证

打开experiment.py，从develop追踪到select。对外层第0折，记录train_ids与valid_ids数量；在selection.ledger第0候选中查三个内层fits。验证每个内层训练和验证集合不重叠，内层所有ID都属于外层训练。

练习C：手工计算训练次数。一个候选在一个内层三折中训练几次？选择阈值会增加训练吗？三次外层重拟合加一次最终重拟合后，总训练数是多少？请避免把候选阈值评分次数混成模型数。

OOF意为每行概率来自没有拟合该行的模型。整个候选的OOF向量仍被用于选择候选，因此其最低成本不能当作无偏最终结果。练习D：设计一个会错误使用外层验证信息的修改，并用文字指出它破坏了哪一层边界；不要修改封存数据来制造更好的分数。

4 审计而不是只读输出

运行test_experiment.py。它根据训练ID重新计算中位数、均值和尺度，并根据保存的幂次、系数和截距重新算OOF概率。报告应含72次内层参数核对、76次总拟合、120条阈值评分。

练习E：复制outputs/my-result.json到另一个输出文件，把其中一个内层训练中位数加1，再运行审计。预期应失败。保留原始交付结果，不能为了“测试通过”更改审计容差。测试失败后解释错误信息属于概率重建还是训练统计检查。

审计能发现程序中明确编码的错误，不证明无遗漏。对真实研究仍需核实数据来源、抽样、标签时间、重复实体、特征可用时间和项目动机。

5 阅读最终测试及负结果

预期所选degree=2、C=0.1、t=0.2。最终TP239、FN11、FP241、TN109；成本0.475、准确率0.58、召回0.956。基线成本0.583333。数值浮点末位可有极小差别，计数应一致。

练习F：若有人只汇报“召回95.6%”，请补一段不可省略的错误分析。再计算预测为正的行数，以及每复核一个预测正例中大约有多少比例实际为负。不要把教学成本单位写成人民币。

练习G：从test里的bootstrap_distribution求2.5%和97.5%分位点，与保存的paired_bootstrap_95核对。说明为何必须配对，以及这个区间没有重新训练模型。

6 独立读图任务

G1 协议图中，哪一条箭头如果从测试返回选择框，就会破坏确认性评价？

G2 候选曲线每个点为什么标有自己的阈值？两个点之间的差是否只由C造成？

G3 为什么不能把三个外层成本与最终测试成本平均后当作四次独立实验？

G4 混淆图为什么可以同时支持“漏判少”和“误报多”？

G5 bootstrap零线右侧代表什么？区间未跨零能否证明现实部署安全？

G6 子群召回区间的分母是什么？为什么样本量必须和比例一起报告？

7 写出能被质疑的结论

交付一段150至250字研究结论，必须包含：目标总体、成本定义、固定候选、测试差值与区间、误报负结果、分组分析的描述性质、未覆盖的训练不确定性。不要使用“彻底解决”“证明公平”或“可以直接上线”。

如果做探索性扩展，例如改变漏判成本或增加候选，请放在新的outputs目录，并标为探索。原始测试已看过，不能再把新最优方案的同一测试分数称为全新确认性证据。这个练习到固定项目结果为止。

验收清单

- 三份数据角色清楚，预处理和阈值没有越界
- 基线与主指标在看测试前固定
- 76次训练及全部候选记录完整，失败未被静默删除
- 审计正常运行和Python -O运行均通过
- Notebook从新内核实际执行，显示6张从本次结果重建的图
- 图、表、答案与JSON数值一致，负结果保留
- 结论只在证据支持的范围内成立

完整推导见lecture.pdf，手算及读图答案见answers.pdf。原始来源见sources.md，固定协议和数据字典在data目录。