

第057讲 k近邻实验答案

本答案用于复算和解释，不应代替先做实验。数值来自随包的固定数据与真实运行JSON。表中小数四舍五入，代码审计使用未舍入值。探索实验若修改种子或数据，可得到不同结果，但不应改写基准报告。

A 手算与边界

距离为1、1、4；稳定排序使位置0排在位置2之前。等权 $k=1$ 预测0， $k=2$ 预测2， $k=3$ 预测 $14/3$ 。 $k=1$ 并没有采用标签最接近的点，标签只在邻居选好后用于预测。

逆距离权重为1、1、 $1/4$ ，权重和 $9/4$ 。归一化权重为 $4/9$ 、 $4/9$ 、 $1/9$ ，预测 $0 \times 4/9 + 4 \times 4/9 + 10 \times 1/9 = 26/9$ 。所有坐标乘10后距离变成10、10、40，原始权重全部除10；归一化消去公共因子，预测不变。这个结论是“所有维一起乘同一个正数”，不意味着任意一维单独改单位都无影响。

分类标签0、1、1时， $k=2$ 的正类比例为0.5，按本包约定预测0； $k=3$ 比例 $2/3$ ，预测1。对于训练0、0、2和查询0，逆距离只让前两个零距离点投票，比例为0.5并预测0。 $k=1$ 时只取第一条重复记录；交换两个重复点标签的行顺序即可改变答案。

能接受的解释必须提到“先选 k 个，再在已选集合中处理零距离”，否则会错误地把所有重复点都纳入。生产系统如果用另一种重复处理规则，需要在说明、代码和测试中一致定义。

B 单位与训练内变换

查询(0,0)距 $A=(2,0)$ 为2，距 $B=(0,1)$ 为1，所以B更近。第二维乘40后，A距离仍为2，B距离为40，因此A更近。没有新增预测信息，纯粹是编码尺度改变了距离排序。

训练均值与标准差应从 $X[:360]$ 计算；标准差用 $ddof=0$ ，与StandardScaler一致。其变换值和JSON内`scaled`应在浮点容差内一致。验证和测试按训练参数变换，均值不必是0。若给测试单独fit，就会让同一个原始坐标在训练与测试中代表不同位置。

图3纵轴为了人眼恢复原始潜在变量 v ，将显示坐标写成 $x/40$ 。原始模型距离仍然在 $(u, 40v)$ 中计算；图的坐标标签不能代替模型计算流程。原始等权选21，错65条；标准化等权选5，错39条。第三条路线标准化后仍错74条，说明标准化没有自动删除噪声特征。

C 逐条验证选择

路线	权重	k等于1时验证错误率	k等于5	k等于21	k等于61	选择
原始	等权	0.24444	0.21667	0.18889	0.19444	21
原始	逆距离	0.24444	0.18889	0.18889	0.17222	61
标准化	等权	0.20000	0.15000	0.17222	0.19444	5
标准化	逆距离	0.20000	0.16667	0.17222	0.16667	5
标准化加噪声	等权	0.31667	0.36667	0.26667	0.20000	61
标准化加噪声	逆距离	0.31667	0.36667	0.26667	0.20556	61

原始逆距离的61有最低验证错误率0.17222；21的0.18889更大。标准化逆距离的5与61都是 $30/180=0.16667$ ，按事先规定的小k规则选5。所有计算只需要训练和验证信息，不需测试标签。

测试错误率按test_probability严格大于0.5得到类别，再对不相等布尔数组取平均。六条依次为65/360、66/360、39/360、40/360、74/360、73/360。把大于误写为大于等于在概率恰为0.5时会变结果，因此边界测试不能仅靠随机数碰巧覆盖。

D 回归与外推

权重	k等于1的验证MSE	k等于5	k等于21	k等于61	选中k	测试MSE
等权	0.15598	0.12912	0.14225	0.56003	5	0.111203
逆距离	0.15598	0.12091	0.11371	0.14480	21	0.126908

上表验证数值只作五位近似，精确值应以JSON复算。k=61跨越了正弦函数的多个变化区域，在波峰和波谷处会把异号标签混在一起。曲线平并不等于准确，它可以只是高偏差。

验证和测试是两个有限样本，抽到的位置与噪声不同；被选中的验证最低值还包含选择带来的乐观偏差。因此逆距离在验证领先、测试落后并不矛盾。正确做法是报告这一结果及证据边界，不把测试当第二轮验证。

在一维中，当查询点大于所有训练位置，等权近邻就是位置最大的k条训练记录。查询10、100、1000不会改变这个集合，因此等权输出相同。逆距离权重会随查询变动，但始终非负、和为1，预测在所选标签最小最大值之间；查询趋向无穷时各距离比趋近1，权重趋向等权。这个行为无法保证真实函数在外部区域也如此。

E 分解公式和正确的轴

设P是40乘101矩阵。可直接计算：

```

truth = np.sin(2 * np.array(result['bias_variance_grid']))
mean_prediction = P.mean(axis=0)
bias2 = np.mean((mean_prediction - truth)**2)
variance = np.mean(P.var(axis=0, ddof=0))
error = np.mean((P - truth[None, :])**2)

```

P.mean(axis=0)固定每个x跨40份训练集平均；axis=1则是对网格平均，会丢掉我们要评估的点。整体P.var()把不同x上的真函数变化也混入，回答的是另一个问题。

四组偏差平方、方差、误差分别约为(0.002453,0.090841,0.093293)、(0.002064,0.024525,0.026589)、(0.093518,0.030750,0.124268)、(0.598287,0.013317,0.611604)。逐项相加与误差一致，舍入后末位可能有一单位差异。

ddof=1把每个方差乘40/39。k=5时新方差约0.025154，总和比原误差多约0.000629；如果坚持用这个方差估计，应在恒等式中乘39/40。这里审计的是有限重复的代数恒等式，不是说统计上永远不能使用无偏方差估计。

新的标签噪声方差0.09未被加入，因为比较目标是真实均值 $\sin(2x)$ 。训练标签仍然有噪声，其影响已经反映在40条预测的变动里。别把“误差目标不含新观测噪声”误读成“训练数据完全无噪声”。40次只能近似总体学习算法的偏差与方差，不能把它们当无限重复的精确参数。

F 维度对照

添加噪声维数	固定k为21的测试错误率	首条查询最近距 除以中位距
0	0.113889	0.109497
2	0.152778	0.288444
5	0.183333	0.417565
10	0.200000	0.541588
20	0.216667	0.648882

同一噪声矩阵前缀避免了比较“2维”和“5维”时把原来两列也重新抽掉，固定k避免模型复杂度选择同时改变。仍然不能从一次实验推出普遍单调性。若换数据种子，某一步错误率可能不升反降；若新增特征真的包含信号，结果也可能改善。

右列只包含首条测试查询的描述量，不是所有查询均值、置信区间或定理。即使它接近1，也要结合样本量、分布和特征意义分析。高维数据的内在维度可以很低，合适距离或表示学习也能改变几何结构。这里为展示固定欧氏距离的风险，不对所有高维方法作结论。

G 输入检查与测试强度

九个标准失败例都应返回ValueError。k为布尔值要单独拦截，NaN不得让排序产生一个貌似合理的输出，查询维度不匹配应在计算距离前说明错误。分类器限定0/1标签；如果想扩展多分类，要改投票数组、返回概率列顺序、平局规则 and 对应测试，不能只删除检查。

12项随机库对照涵盖3个k、2种权重、2种任务。概率和回归值以 10^{-9} 绝对容差比较。分类别只检查阈值两侧，不能发现同侧概率的偏差，所以概率级对照更强。测试里的np.testing和显式require在python -O下仍会执行。

参考库不是绝对真理，尤其不能拿不同距离平局规则的结果当某一方必错。本包手算的稳定排序与零距离规则先定义了语义，再用无平局随机数据核对通用路径。还应保留对训练均值、验证概率、选择和测试指标的独立重算，防止一份内部一致但错误的JSON蒙混过关。

结论示例与常见扣分

可接受的结论是：固定seed5700数据中，标准化等权路线验证选k=5，测试错39/360；原始等权错65/360，说明本次故意的单位失衡损害了近邻距离。加入20个独立噪声维后，预定路线等权错74/360。逆距离并非全面胜出。偏差方差图比较真实均值，不能直接等同含噪测试MSE。这些是合成分布的一次结果，尚无现实部署证据。

只报最佳准确率、略去原始路线或噪声负结果、把全体数据fit缩放器称为规范流程、用测试重新选k、把一个查询的距离比推广到总体、把训练集内标签方差当模型方差，都应扣分。正确答案不仅有数字，还能说清楚数字来自哪些行、哪个模型和哪个问题。