

第057讲 最近邻与局部预测

本讲回答一个很直观的问题：如果一个新样本没有标签，能不能向最相似的旧样本借答案？答案是可，但“相似”由特征、单位、距离和邻居个数共同决定。我们将从三条数据的手算，走到可执行的分、回归和偏差方差实验，并逐项解释标准化、噪声维度、重复点与验证集怎样改变结论。

目录直接先修第009、046、050至052、054讲；实现还会用到第005讲数组与第007讲可复现实验。实验使用原创合成数据，CPU即可离线运行。读完后应能独立写出一个小数据kNN，说明每个边界约定，复算图中一个点，并给出适用范围而不是只报最高准确率。

1 从找相似例子开始

设训练数据为 (x_i, y_i) ，其中 $i = 1, \dots, n$ 。特征 x_i 是一行 d 个数；分类的 y_i 是类别，回归的 y_i 是连续量。查询点 x 只有特征。kNN先计算 x 与每个训练点的距离，再保留最近的 k 个训练行，最后投票或平均。这里 k 是我们在训练前后通过验证选择的超参数，不是拟合得到的一组回归系数。

例如训练位置为0、2、5，对应回归标签0、4、10，查询位置为1。距离依次为1、1、4。取最近两个标签，平均得到 $(0 + 4)/2 = 2$ 。取三个标签并等权平均，得到 $14/3$ 。两次计算都没有更新训练标签，差别来自我们允许“多远的经验”影响答案。




图1 一维手算例子。星形为查询点，圆点为训练位置。图中标签和距离共同决定答案，不能只平均特征坐标。

kNN常被叫作惰性学习：最简单的fit只是保存训练数据，主要计算放在预测时。这不等于没有训练过程或没有复杂度。决定特征、拟合缩放器、选择距离与 k 都属于学习方案；索引实现还会在fit时建搜索结构。训练数据本身也是模型的一部分，删除或泄露训练数据会影响模型。

2 把邻居集合写成可计算的定义

本讲只实现欧氏距离：

$$d(x, x_i) = \sqrt{\sum_{j=1}^d (x_j - x_{ij})^2}.$$

先算每一维差值，再平方、求和和开根号。为了找最近点，仅比较平方距离也能得到相同次序；为了逆距离加权，仍需真实距离。把距离按从小到大排序，前 k 个训练行的索引集合记为 $N_k(x)$ 。合法条件是 $1 \leq k \leq n$ 。

距离不是标签相似度。新样本的标签未知，所以找邻居时只能用预测时可获得的特征。把标签附加到特征、把未来信息作为输入、先查看测试标签再决定距离，都使离线分数失去原本含义。一个特征与任务是否相关，必须由领域知识和训练验证过程判断。

距离相同也要有约定。本实现采用稳定排序：同距点保持训练行顺序。如果第 k 和第 $k+1$ 个点同距，只有前者进入集合。这使同一输入可复现，但交换训练行顺序可能改变边界处的答案。不能把这种实现细节误说成模型发现了真实差别。若应用需顺序无关的行为，应该定义“纳入所有边界同距点”等另一套规则，并重新验证。

3 同一个邻域怎样产生两种答案

3.1 分类是局部类别比例

本讲教学分类器支持标签0和1。等权邻域中的正类比例为：

$$\hat{p}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y_i.$$

例如五个邻居的标签为1、1、0、1、0，正类比例是 $3/5$ ，预测为1。实现明确使用 $\hat{p} > 0.5$ 预测1，等于0.5时预测0。偶数 k 可能产生票数平局；奇数 k 在等权二分类且每个邻居都纳入时不会有票数平局，但仍可能有距离平局。逆距离加权时，奇数 k 也不能保证加权票数不平局。

局部比例位于0到1之间，因此库接口称它为predict_proba。但“能输出比例”不保证校准。 $k=1$ 只给出0或1，邻居标签中的随机误差会被完全继承。即使训练集独立同分布，有限样本、错误距离和分布变化也会使这个比例偏离真实条件概率。需要概率决策时，应继承前面关于校准和独立验证的要求。

3.2 回归是局部标签均值

等权回归把同一个公式用于连续标签：

$$\hat{f}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y_i.$$

为什么平均有意义？对一个固定邻域，如果我们想用常数 a 代表这些标签，并最小化 $\sum_i (y_i - a)^2$ ，对 a 求导后得到 $2ka - 2 \sum_i y_i = 0$ ，所以最优 a 就是均值。因此局部平均与平方损失相匹配。如果评价目标是绝对误差，局部中位数可能更合适，但那已经是另一个明确的模型方案。

3.3 让更近的点有更大权重

逆距离方案先令 $w_i = 1/d(x, x_i)$ ，再归一化：

$$\tilde{w}_i = \frac{w_i}{\sum_{\ell \in N_k(x)} w_\ell}, \quad \hat{f}(x) = \sum_{i \in N_k(x)} \tilde{w}_i y_i.$$

分类也用这个加权均值来估计正类比例。图1的三个距离是1、1、4，归一化权重为 $4/9, 4/9, 1/9$ ，回归预测为 $26/9 \approx 2.8889$ 。不要把 $1/d_i$ 直接乘标签后相加而忘记除权重和，否则答案会随距离单位整体改变。

如果距离恰好为0，直接取倒数会除零。本实现先选出 k 个邻居；只要其中存在零距离点，就只让这些零距离点等权投票，其他点权重归零。两个完全相同输入的标签分别为0和1，预测比例就是0.5，并按约定预测0。若重复点多于 k ，仍只使用选中的 k 个，因此重复和排序都应被审计。

4 标准化是在改变距离的含义

假设两个特征分别记录长度与质量。某维的数值范围是另一维的40倍，欧氏距离中的平方差可能被放大1600倍。这不是“该特征被证明更重要”，只是单位进入了模型。把米改为厘米也能改变邻居顺序，说明原始欧氏距离没有单位不变性。

常见做法是对每一列，用训练集均值和标准差变换：

$$z_j = \frac{x_j - \mu_j}{s_j}, \quad \mu_j = \frac{1}{n} \sum_i x_{ij}, \quad s_j^2 = \frac{1}{n} \sum_i (x_{ij} - \mu_j)^2.$$

在变换后的空间用欧氏距离，相当于原空间中每维平方差除以 s_j^2 。它让训练集中波动尺度相近，但不会自动证明各维同等有用。无关噪声列也会获得单位尺度，相关列可能重复计算同一信息，极端异常值会影响均值和标准差。常数列在StandardScaler中使用尺度1，避免除零。

只在训练行上fit。 本实验分类前360行用于拟合缩放器，随后对验证180行和测试360行使用同一组参数。不能分别把验证或测试重新标准化到自己的均值，也不能用900行共同fit。前者改变了坐标系，后者把未来分布信息提前交给模型。交叉验证时，每个训练折都必须重新拟合缩放器。

本实验的潜在特征 u, v 独立均匀分布于 $[-2, 2]$ ；无噪声标签由 $v > 0.55 \sin(2u)$ 决定，再以10%概率翻转。真正输入保存为 $(u, 40v)$ 。因此单位差异是故意制造、能够解释的，不能据此声称真实任务一律应标准化。

5 用验证选择邻域 不用测试挑赢家

分类数据固定为360行训练、180行验证、360行测试。每条预定路线分别比较 $k \in \{1, 5, 21, 61\}$ ，只按验证错误率选择 k ；相同时选较小 k 。选好后不重拟合训练加验证集合，仍保留原360行邻居，再统一报告封存测试。这减少“重拟合后邻居数量和缩放参数改变”对教学复算的干扰，实际工作也可以预先规定重拟合步骤。

三条路线为原始二维、标准化二维、标准化二维加20个独立噪声维；每条路线都比较等权和逆距离权重。六条路线在查看测试之前固定。这里报告全部路线是教学对照，不根据测试宣布一个今后部署的赢家。若需要最终选择路线和权重，应把这些也纳入开发集搜索，并用新的未使用测试评估。




图2 横轴为k的对数刻度，纵轴为验证错误率。每个子图是一条预先固定的特征路线，曲线区分邻居权重。最低点决定该路线的k，不由测试图决定。

路线	权重	验证选出的k	测试错误数 除以360	测试错误率
原始二维	等权	21	65 / 360	0.18056
原始二维	逆距离	61	66 / 360	0.18333
标准化二维	等权	5	39 / 360	0.10833
标准化二维	逆距离	5	40 / 360	0.11111
标准化加20噪声维	等权	61	74 / 360	0.20556
标准化加20噪声维	逆距离	61	73 / 360	0.20278

标准化二维在这次固定实验中减少了错误，添加无关维度又损害了表现。逆距离权重没有在所有路线胜过等权；“更精细”不等于更准。一个测试样本改变就会使错误率变化 $1/360 \approx 0.00278$ ，所以39次和40次错误不能被夸大成稳定优劣。表中没有区间，也没有对多路线比较作显著性检验。




图3 两条等权路线的决策区域。为了可读性纵坐标恢复为 x_1 除以40，模型仍使用各自规定的输入距离。颜色为预测，散点为训练标签。

图3把“单位改变邻居”变成可见的区域。原始路线容易受纵向数值支配；标准化路线能更好保留弯曲边界。散点中仍有10%随机翻转，不能要求任何平滑边界穿过所有点。绘图是诊断模型行为，不是再次修改 k 的选模依据。

6 回归曲线为什么会变平

回归实验另生成380个独立样本， x 均匀分布于 $[-3, 3]$ ， $y = \sin(2x) + \epsilon$ ，其中 ϵ 均值为0、标准差为0.3。训练100行、验证80行、测试200行。这里只用一个特征，等比例缩放不会改变邻居次序，也不影响归一化逆距离权重，所以不另加标准化对照。




图4 同一份训练数据下的等权回归。黑虚线是真实均值，灰点是含噪标签，彩线依次增大 k 。 k 很大时局部平均会抹掉正弦结构。

$k = 1$ 的曲线随最近训练标签跳动，容易复制噪声； $k = 61$ 平均了大范围的标签，曲线比较平，但弯曲结构也被冲淡。kNN回归不是一条全局多项式，也不天然连续。等权邻居集合在边界改变时，预测可以跳跃；逆距离只是另一种平滑方式，不应未经条件证明就称为处处光滑。

验证为等权选出 $k = 5$ ，测试MSE为0.111203；为逆距离选出 $k = 21$ ，测试MSE为0.126908。逆距离在验证上的最佳MSE约0.1137，低于等权最佳约0.1291，但测试次序相反。这是一个重要负结果：有限验证集上的较低误差不保证每一份测试都更好。不能因此用测试改回另一个 k 再把同一个测试分数当新证据。

在训练范围外，kNN没有外推趋势的机制。查询点远远向右移动，最近的 k 个训练点可能不再变化，等权预测随之固定；逆距离预测仍是训练标签的非负加权平均，因此不会超出邻居标签的最小最大值。若科学问题要求外推，必须单独检验，不能把局部插值图当成外推保证。

7 偏差和方差要跨训练集来定义

同一训练集内的训练误差，不是模型方差。要观察学习算法对数据抽样的敏感程度，我们独立生成40份训练集，每份80行，保持同一个真实函数和噪声标准差；在固定的101点网格上得到40条预测曲线。记第 r 次预测为 $\hat{f}_r(x)$ ，均值为 $\bar{f}(x)$ 。

在每个网格点，有限重复的平方误差恒等式为：

$$\frac{1}{R} \sum_r [\hat{f}_r(x) - f(x)]^2 = [\bar{f}(x) - f(x)]^2 + \frac{1}{R} \sum_r [\hat{f}_r(x) - \bar{f}(x)]^2.$$

证明只需在左式中加减 $\bar{f}(x)$ 再展开。交叉项含有 $\sum_r (\hat{f}_r - \bar{f}) = 0$ ，所以消失。最后再对101个网格点取平均。这里方差必须用分母 R ，即ddof=0；若用无偏样本方差的 $R - 1$ 而不调整系数，恒等式不成立。




图5 四十份独立训练集的有限重复分解。横轴是 k ，纵轴是网格平均平方量。误差针对已知真实均值，不包含新的观测噪声。

k	有限重复平方偏差	有限重复方差	相对真实均值MSE
1	0.002453	0.090841	0.093293
5	0.002064	0.024525	0.026589
21	0.093518	0.030750	0.124268
61	0.598287	0.013317	0.611604

可以看到较大的邻域最终带来明显平方偏差，但方差并非每一步严格下降：从5到21反而增加。这既有有限重复估计波动，也有随机训练位置和局部平均行为的影响。偏差方差权衡描述趋势与机制，不是每个数据、每一对 k 都满足的单调定理。

这张表与上节测试MSE不是同一个量。上节比较含噪声的测试 y ，这里比较已知无噪声均值 $f(x)$ 。对一个新的、独立的观测噪声，在期望上还要加 $0.3^2 = 0.09$ 。不能直接把有限测试MSE减去0.09就宣布精确得到模型误差，因为有限样本还存在交叉项和抽样波动。40次重复也不是无穷总体期望，图中没有Monte Carlo误差区间。

8 为什么加更多特征可能更糟

我们保留同一组信号与同一份噪声矩阵的前缀，逐次加入0、2、5、10、20个独立噪声维。每次只在前360行拟合StandardScaler，并固定等权 $k = 21$ ，不为每个维数重新选 k 。这样对照的问题是“固定方案对增加无关维度有多敏感”，不是“各维数经过最佳调参后谁最好”。




图6 左图为固定 k 等权分类错误率，右图为第一条测试查询到训练集的最近距离除以中位距离。右图只描述这个固定查询，不能代表整个数据的定理。

错误率从0.11389增到0.21667；第一条查询的最近距离与中位距离之比从0.1095增到0.6489。对独立标准化噪声，两条独立样本每维差的平方期望约为2， q 维就贡献约 $2q$ 。信号只有少数维时，无关距离成分会稀释信号，让“最近”与“普通”不再那么悬殊。

这个实验提供机制示例，不证明所有高维数据都失败。实际数据可能位于低维结构、具有稀疏表示或有效的任务距离。维度数、样本量、噪声结构和距离设计必须一起看。PCA等降维也不能先看全部测试数据再fit；任何数据驱动变换都属于训练流程。

9 读懂实现与数值边界

knn.py把邻居索引、距离、权重、预测分别暴露出来。输入先转为有限二维浮点矩阵，检查标签长度、 k 的整数合法性和特征维数。本讲明确不实现缺失值距离；遇到NaN或无穷大就报错，提醒先在训练内拟合插补器。 k 不能是布尔值，因为Python里True虽然类似整数1，却不是这里想要的超参数输入。

逆距离实现不用直接计算极大倒数，而在非零距离行使用 d_{min}/d_i 再归一化。它与 $1/d_i$ 归一化数学等价，且所有临时权重不超过1。若输入数值大到平方距离溢出，代码显式拒绝并要求重缩放，而不是让NaN悄悄产生一个类别。

每条查询先计算 n 个 d 维距离，再稳定全排序。当前教学实现单查询时间约 $O(nd + n \log n)$ ，临时距离差矩阵约 $O(nd)$ ；保存训练集需要 $O(nd)$ 空间。并非所有kNN都必须全排序：只选前 k 可用部分选择，KD树和Ball树可利用空间结构，但高维或大 k 时加速可能下降。这里为透明性使用暴力方法，不把小例子的速度推广到大规模系统。

与scikit-learn的对照只在无距离平局的随机点上要求数值一致；距离平局时不同搜索算法、行顺序和浮点细节可能得到不同邻域。对照相同接口并不自动证明正确，本包同时保留手算例、非法输入测试、已保存结果重算和有限重复恒等式。

10 本讲能支持怎样的结论

你现在应能把一个kNN结果拆成五个可审计决定：输入特征及单位、训练行与缩放参数、距离及平局规则、 k 和权重的验证选择、测试指标及适用总体。本实验支持“在当前合成分布中，标准化减少了故意制造的尺度失衡；独立噪声维度损害固定方案；邻域平均产生可见偏差方差权衡”。它不支持“标准化永远改善”“距离加权永远更好”“高维必然失败”或“局部比例天然校准”。

继续学习树模型时，会看到另一种建立局部区域的方法：按特征阈值切分，而不是按查询点临时寻找邻居。完成独立实验和答案中的手算、负对照与边界测试后，再比较两种局部预测思想。

原始来源与阅读范围

本讲公式推导、实验数据、图和教学实现均为原创。2026-10-06核对scikit-learn官方文档的邻居算法、标准化接口、近邻分类示例与偏差方差示例；完整链接及具体核对范围见sources.md。官网stable版本可能高于实验锁定版本；本包实际使用requirements.txt列明的版本。不要将外部示例的数据或结论误认为本实验运行结果。