

第058讲 练习完整答案

题1：不同值才产生新的候选

排序并去重后是1、3、5，所以候选中点为2、4。阈值1.5和2都把两个1放左边，其余行放右边，在训练分组上完全等价。它们对训练间隙中的新查询可能不同，所以实现仍需固定一个阈值代表。

特征相同的行必须接受相同判断。若按排序位置把两个1拆开，就不存在一个只依赖该特征的数值阈值能实现这个分组。这是用标签或行号偷偷改变了模型输入语义。

题2：完整Gini候选表

父正类比例为3/6，Gini为0.5。每一行先算左右类别频率，再分别计算 $2p(1-p)$ ，最后按左右样本数占比加权。

阈值	左n / 右n	左p / 右p	加权Gini	Gini减少量
1.5	1 / 5	0 / 0.6	0.400000	0.100000
2.5	2 / 4	0 / 0.75	0.250000	0.250000
3.5	3 / 3	1/3 / 2/3	0.444444	0.055556
4.5	4 / 2	0.25 / 1	0.250000	0.250000
5.5	5 / 1	0.4 / 1	0.400000	0.100000

例如3.5两边Gini都为4/9，加权后仍为4/9，减少量为 $1/2 - 4/9 = 1/18$ 。2.5与4.5并列最好；本实现保留首先枚举到的2.5，收益差不超过 10^{-12} 视为平局。

题目没有要求两边样本数相等。只根据“看起来最平衡”选择3.5，就会错过更能分开类别的候选。

题3：信息增益与单位

父熵是1 bit。阈值2.5左边纯负，熵为0；右边正类比例3/4，熵为：

$$-\frac{3}{4}\log_2 \frac{3}{4} - \frac{1}{4}\log_2 \frac{1}{4} = 0.811278124.$$

加权后为 $(2/6) \times 0 + (4/6) \times 0.811278124 = 0.540852083$ ，信息增益为0.459147917 bit，保留6位小数得到0.459148。

自然对数的对应增益为该数乘以 $\ln 2$ ，约0.318257084。改变对数底只乘同一个正常数，在同一节点不改变最佳候选排序，但会改变报告的数值单位。

题4：回归的均值和方差

对 $\sum (y_i - c)^2$ 求导为 $2 \sum (c - y_i)$ ，零点 $c = \bar{y}$ ；二阶导数为 $2n > 0$ 。因此平方误差最优常数是均值，不是任意选择的一个代表样本。

标签均值5，平方偏差为16、9、9、9、16、9，总和68，父平均平方误差为34/3。阈值3.5左均值5/3，右均值25/3。两边平方误差和都为2/3，平均都是2/9，加权后仍2/9；减少量为100/9。

另一条核验路线：两边样本各3个，均值差20/3，代入组间公式得到 $(3 \times 3/6^2) \times (20/3)^2 = 100/9$ 。两种算法应一致。

这里要衡量每个样本平均损失，分母就是参与损失的样本数n。n-1属于另一个统计估计问题，不是本次分裂目标。若左右节点大小不同，错误分母还会改变候选排名。

题5：小纯叶子不能占一半权重

A左节点Gini为0，右节点Gini为 $2(5/8)(3/8) = 15/32 = 0.46875$ 。正确加权是 $(2/10) \times 0 + (8/10) \times 0.46875 = 0.375$ ；错误简单平均为0.234375。

B左右Gini都是 $2(4/5)(1/5) = 0.32$ 。不论加权还是简单平均都为0.32，因为样本数量相等。正确方法选择B，Gini减少量0.18；错误方法选择A。A的真正减少量仅0.125。

错误的根源是给含2行的子节点与含8行的子节点同样重要性。若目标是对每一行等权的平均训练损失，就必须让子节点贡献与行数成比例。

题6：四个叶子与两条路径

节点ID	样本数	正类数	正类概率	类别
2	45	1	0.022222222	0
3	115	14	0.121739130	0
5	87	23	0.264367816	0
6	73	66	0.904109589	1

样本总数45+115+87+73=320，正类总数1+14+23+66=104，和训练正类比例104/320=0.325一致。这是两个简单而有力的守恒检查。

查询(1,1)：在根检查 $1 \leq 0.000057382$ ，为假，进入节点4；再检查 $1 \leq 0.340766698$ ，为假，进入叶子6，返回正类概率66/73，类别1。

查询(-1,1)：根条件为真，进入节点1；再检查 $1 \leq -1.070664638$ ，为假，进入叶子3，返回14/115，类别0。预测时不读取这些查询的真实标签。

题7：局部收益与全树收益

根的局部收益约0.106953125。左子节点局部收益约0.004004001，右子节点约0.203068033。根含全部320行，两子节点各160行，所以全树训练Gini减少量为：

$$0.106953125 + \frac{1}{2}(0.004004001) + \frac{1}{2}(0.203068033) = 0.210489142.$$

根Gini为0.43875，四个叶子按样本数加权后的Gini约0.228260858，两者之差也是0.210489142。小数最后几位按实际输出舍入。

直接相加三个局部收益约0.314025159，会把各子节点当成含有全部训练样本，因此夸大目标改善。这个问题不是浮点误差，而是权重定义错误。

题8：阈值等号与浮点表示

训练输入0、2的唯一候选是1。阈值左邻数小于1，走左；1本身满足 $\leq$ ，也走左；右邻数大于1，走右。三个类别为0、0、1，对应概率向量为(1,0)、(1,0)、(0,1)。

`np.nextafter(1.0,-np.inf)`与`np.nextafter(1.0,np.inf)`取float64中相邻可表示数，而不是随使用1减或加某个十进制小数。这个测试直接检查比较运算的边界约定。

成熟库可能先把输入转成float32，三个非常靠近的float64数会舍入成同一个float32值。此时库输出不相同于手写float64边界实验，并不能单独证明树算法错了。应分别检查转换语义与路由语义。

题9：XOR说明了哪一种限制

父节点Gini为0.5。按 x_0 或 x_1 在0.5处分裂，左右子节点各含一正一负，Gini仍为0.5，所以立即收益都为0。本实现要求收益严格大于容差，因而根就停止，按类别平局规则全部判0，训练准确率0.5。

可以写如下深度2规则： $x_0 \leq 0.5$ 时，若 $x_1 \leq 0.5$ 输出0，否则输出1； $x_0 > 0.5$ 时，若 $x_1 \leq 0.5$ 输出1，否则输出0。四点均被正确预测。

反例说明严格正收益的一步贪心停止可能错过有价值的后续结构，不说明树这个模型集合表示不了XOR，也不说明所有实现都会在根停止。允许零收益分裂的实现可能继续得到正确树。

题10：篡改结果应被拒绝

把报告中`test.gini.accuracy`改成1后，独立测试会根据原测试CSV、报告里的树节点与独立路由重新计算预测。真实准确率为 $123/160=0.76875$ ，所以会在“gini held-out accuracy”检查处抛出异常并以非零状态退出。

这项测试不依赖模型给出的同一个`accuracy`字段，因此能发现指标与预测不一致。作者还实际对错误叶值、错误阈值和错误预测进行过故障注入；这并不意味着任何恶意改写都可自动发现，原始代码、数据与校验记录仍需要版本管理。

如果把生产脚本和审计脚本同时改成同一种错误公式，内部一致性可能继续成立。纸笔已知答案、独立计算与库对照的互补价值就在这里。

题11：显式失败与缩放边界

缺失值或无穷值无法在本实现定义的普通有限数排序中可靠处理；类别2超出二分类接口；特征数不匹配使分裂列语义不明确；负深度不符合路径长度定义；空数组无法定义叶频率和均值。因此均应得到清楚的ValueError，而不是无声填补、截断或默认返回0。

正线性缩放在精确算术下保留顺序，也把中点映射为对应中点，因此保留训练分组和对应查询路径。但有限精度可能合并很接近的值。一般非线性单调变换虽保留训练排序，变换后两端中点通常不等于原中点的变换，所以观测间隙内的新样本可能换边。“排序不变”不能推出所有新点的浮点实现永远一致。

题12：一份合格的简短结论

在原创合成数据上，固定深度2、最小叶样本12后再读取测试。Gini与熵树准确率均0.76875，训练多数类基线0.64375；回归MSE约0.146755，训练均值基线约1.831889。分类预测与库一致，回归差为浮点舍入量级。测试未用于选择参数。严格正收益贪心可能在XOR停止；清晰树路径也不代表因果作用。结果用于机制教学，不证明现实部署效果。

评分时应关注信息边界与可核验数字，不要求逐字复制这段话。若只写“决策树很好、准确率很高”，即使数字正确，也没有完成研究表达任务。