

第059讲 练习详解

1 三种叶数上界

深度不超过4时，每个内部节点最多有两个孩子。各层节点数最多为1、2、4、8、16，因此叶数最多16。这个界由每一层都填满的完全二叉树达到；一条很长但旁边很稀疏的树不会达到它。

450行且每叶至少15行，叶子又构成互不重叠的训练行划分，所以 $15L \leq 450$ ，即 $L \leq 30$ 。两项约束同时存在时取更紧的上界 $\min(16, 30)=16$ ，而不是把二者相乘或相加。

这些只是不可能超过的界。实际输入可能全相同，没有合法阈值；标签可能全为一类，继续分裂没有收益；其他停止规则也可能更早起作用。因此它们不能预测最终一定有多少叶子。

2 分裂前的条件和分裂后的条件

一个节点恰有10行，最小分裂样本数为10，允许尝试分裂。若某特征阈值把9行放左、1行放右，仅有这个参数时，一行叶子仍可能出现。它检查的是父节点样本数，不是两个孩子各自的样本数。

再要求最小叶样本3，则9/1候选非法，因为右边不足3。6/4或7/3仍可能合法。若父节点只有5行，即使允许尝试分裂，也不存在两边都至少3行的二分。因此实现中常能提前利用父样本数小于2倍最小叶样本的条件停止。

3 频率方差的推导与条件

固定一个区域，令区域内标签 Y_1 至 Y_m 独立，且每个都服从正类概率 p 的伯努利分布。频率为 $\hat{p} = (Y_1 + \dots + Y_m)/m$ 。每项方差 $p(1-p)$ ，独立使交叉协方差为0，因此：

$$\text{Var}(\hat{p}) = \frac{1}{m^2} \sum_{i=1}^m \text{Var}(Y_i) = \frac{p(1-p)}{m}.$$

树的区域是用同一批标签反复搜索出来的，选定区域与标签不再是独立关系；数据还可能存在群组相关。若直接拿这个固定区域公式做完整不确定性声明，就忽略了选择过程和相关性。公式仍能提供“小叶子频率不稳”的直觉，但严肃区间需要匹配抽样和建模流程。

4 四叶树的全部账目

四叶正类频率依次0.05、0.8、0.2、0.95。Gini为 $2p(1-p)$ ，得到0.095、0.32、0.32、0.095。乘根权重0.4、0.1、0.1、0.4，贡献0.038、0.032、0.032、0.038，总计0.14。

左右两个50行节点的频率为0.2和0.8，Gini均0.32，根风险各0.16。其当前子树风险各0.07。因此左右有效 α 均 $(0.16-0.07)/(2-1)=0.09$ 。

根频率0.5，Gini0.5、权重1。初始根有效 α 为 $(0.5-0.14)/(4-1)=0.12$ 。但最弱环节0.09先发生，左右同时折叠以后风险是0.32、叶数2。根的有效 α 必须更新为 $(0.5-0.32)/(2-1)=0.18$ 。路径因此是：

临界 α	叶数	风险	刚发生的动作
0	4	0.14	完整树
0.09	2	0.32	左右分支同时折叠
0.18	1	0.50	根折叠

0.12是一棵已经不再存在的四叶状态里，根与全部四叶子直接比较的交点。它不是两叶树与根叶树的交点。忽略中间竞争者会误读目标的下包络。

5 在指定 α 上比较代价

$\alpha=0.05$ 时，四叶、两叶、根叶的代价分别0.34、0.42、0.55，所以四叶树最小。 $\alpha=0.10$ 时，分别0.54、0.52、0.60，所以两叶树最小。 $\alpha=0.20$ 时，分别0.94、0.72、0.70，所以根叶树最小。

$\alpha=0.09$ 时，四叶树 $0.14+4\times0.09=0.50$ ；只剪左或只剪右的三叶树 $0.23+3\times0.09=0.50$ ；两叶树 $0.32+2\times0.09=0.50$ 。它们全部并列，根叶树为0.59而较差。本实现选择其中最小的两叶树，并将并列最弱环节一起移除。

这说明一条路径未列出每一棵并列树并不是错误。要写清在临界点的选取约定，库对照也应避免拿不同合法平局规则当成实现失败。

6 Gini与训练Brier的联系

固定叶子里，有比例 p 的标签为1，其余为0，预测概率也为 p 。该叶子的平均Brier为：

$$p(1-p)^2 + (1-p)p^2 = p - p^2 = p(1-p).$$

Gini为 $2p(1-p)$ ，恰好两倍。各叶子按训练样本数权重求和，等式仍成立，因此根归一化训练Gini风险等于两倍训练Brier。

对新标签不成立。最小反例：训练叶子只含一个正类，输出 $p=1$ ，训练Gini为0；测试来一个负类， $\text{Brier}=(1-0)^2=1$ ，并不等于0的一半。恒等式依赖评价标签就是计算叶子频率的那批标签。

7 归一化如何改变 α 的尺度

如果使用总加权Gini而不除 N ，则所有风险及风险差都变成原来的 N 倍。叶数不变，所以每个有效 α 也变成 N 倍。在本实验 $N=450$ ，原来0.01量级的 α 会相应放大450倍。

若风险放大而 α 仍保持旧值，复杂度惩罚相对变弱，倾向保留更多叶子。等价目标必须一起缩放： $NR(T)+(Na)L=N[R(T)+\alpha L]$ 。乘正数不改变最小值位置，但只乘其中一项就改变了问题。

这个分析也说明不能孤立比较不同实现的 α 数字。先问风险用和还是平均、用Gini还是熵或平方误差、有没有样本权重，再谈参数含义。

8 两条路线的搜索空间

预剪枝限制生长时哪些候选或后续步骤可用。例如深度1意味着根之后绝不再展开；最小叶样本15意味着任何产生更小叶子的候选都不合法。限制可能改变早期选择与后续结构。

后剪枝固定一棵已生长的树，只能删去部分后代，把内部节点变成叶子。它可以决定“保留根分裂”或“连根分裂一起取消”，却不能把根换成另一个特征和阈值。新根分裂不属于这棵完整树的根子树集合。

所以两者并不是对同一批候选做相同计算的两种写法。后剪枝允许先探索较深结构，再评估整段分支；预剪枝通常更节省生长成本。最终效果取决于数据、候选限制、评价和实现。

9 平局规则必须可复现

本讲按验证Brier、叶数、深度、候选顺序依次比较。B有5叶少于A的7叶，所以选B，即使B深度4大于A的3。叶数优先于深度，是事先声明的规则。

若仅在显示到小数点后三位时相同，不能自动当作精确平局。0.1568和0.1572都可能显示成0.157，却是不同值。本实现使用记录的完整浮点值比较；真实研究若希望采用一个标准误差规则或统计上可忽略的差异，应提前定义并解释，不要在看到结果后临时改变判定。

10 不同模型两两分歧的分母

25个模型中，10个预测1、15个预测0。不同模型的无序配对总数为 $25 \times 24 / 2 = 300$ ，跨类别配对数 $10 \times 15 = 150$ ，所以分歧率 $150 / 300 = 0.5$ 。

令 $f = 10 / 25 = 0.4$ ， $2f(1-f) = 0.48$ 对应的是从25个模型中独立有放回抽两次；其中可能抽到同一个模型，而这种配对不可能分歧。限定两个模型不同，需要乘 $25 / 24$ ，得到 $0.48 \times 25 / 24 = 0.5$ 。

一般式为 $2f(1-f)B / (B-1)$ 。它要求 $B > 1$ ，并以同一网格点所有模型的硬分类为对象。将它对网格位置平均，就得到本讲的两两分类分歧率。

11 稳定不等于正确

假设所有真实标签都是1，而算法无论数据怎样都输出概率0.01。它在不同扰动下完全稳定，概率方差0、类别分歧0，却每次都判错。稳定性没有检查是否保留有用信号。

另一个例子是两个模型对同一输入分别输出0.51与0.99。都判1，所以类别分歧0；概率相差0.48，可能在Brier或对数损失上有很大差异。反过来，0.49与0.51概率很接近，却落在0.5两侧而类别不同。

因此实验同时报告概率变化、硬分类分歧和独立测试表现。三者共同描绘行为，不能任意选一个替代另两个。

12 设备数据需要尊重独立单位

如果目标是预测从未见过的新设备，应该按设备标识划分，使同一设备的所有记录留在同一侧；调参时也使用保持设备分离的内部验证。若目标是预测已有设备的未来，应进一步按预测时间设计过去训练、未来验证与测试，防止未来信息进入过去。

普通随机行划分可能让同一设备的固定偏差、环境条件或近似重复记录同时出现在训练与验证中。树可以记住这些设备特征，复杂模型在验证上也显得不错；到了新设备或真正未来时，这种优势消失。剪枝参数选得再仔细，也无法补救评价目标从一开始就错了。

本讲的900行由独立随机抽样生成，因此简单固定行段划分适合这个合成设置。这是生成机制支持的条件，不是“任何CSV都可以按行随机切”的通用许可。

实验结果核对与报告示例

确认结果应有37个剪枝路径状态。预剪枝选择深度2、最小叶样本1，4叶；后剪枝选择索引34、 α 约0.010590696，3叶。三种模型测试准确率依次0.680000、0.746667、0.746667；Brier依次0.320000、0.163508、0.164178。常数基线Brier约0.238978。

一个合格结论可以这样写：本实验在固定原创合成数据上，通过验证Brier选择预剪枝和后剪枝复杂度，再在225行独立测试上比较冻结模型。两种简化树都减少了叶数、改善了相对完整树的测试Brier；同一组25次删行扰动下，概率方差和分类分歧也更小。预剪枝与后剪枝的测试差异很小，不据此判断普遍优劣。结果只适用于当前生成机制，扰动标准差不是总体置信区间，树路径也不代表因果关系。

审计失败时，应定位到具体定义：风险错常涉及归一化，路径错常涉及隐藏后代或重算，选择错常涉及排序，指标错常涉及标签或概率列。若报告被篡改而测试拒绝，故障实验成功；不要把这种预期失败写成课程本身无法运行。