

第060讲 练习详解

1 有限样本的bootstrap比例

每次不选某行的概率 $4/5$ ，五次独立抽样都不选它的概率为 $(4/5)^5=0.32768$ 。至少出现一次的概率为 0.67232 。

对五行分别定义是否出现的指标，求和得到不同对象数。期望可以逐项相加，所以预计出现 $5 \times 0.67232 = 3.3616$ 个不同对象。实际对象数必须是整数，期望可以不是整数。

36.8% 与 63.2% 来自 n 趋于无穷的近似。对 $n=5$ 直接使用近似会有明显差异。各行是否出现的指标不独立，但计算期望不需要独立；计算方差时则不能忽略它们的协方差。

2 每行的袋外资格

第1棵树袋外B和E；第2棵树袋外A和D；第3棵树袋外C。因此A的袋外树集合是 $\{2\}$ ，B是 $\{1\}$ ，C是 $\{3\}$ ，D是 $\{2\}$ ，E是 $\{1\}$ 。

这组设计恰好让每行有一票，但不是一般规律。另一组bootstrap完全可能让某行有0票，也可能有2或3票。必须保存抽样成员关系才能判断；看树的最终叶子里是否出现某个编号并不足够。

当树拟合结束后，训练行会走到某片叶子，但“走到哪片叶子”与“这一行是否参与过树训练”是两个问题。袋外判断只依赖后者。

3 硬投票与概率平均

分别阈值化， 0.49 和 0.49 判0， 0.99 判1，因此多数票为0。概率平均为 $(0.49+0.49+0.99)/3=1.97/3 \approx 0.656667$ ，超过 0.5 ，所以软投票判1。

本讲恰 0.5 时判0，因为使用 $p > 0.5$ 作为正类条件。若改为 $p \geq 0.5$ ，边界结果会改变，需要同步修改文档和测试。

概率平均保留了每棵树的概率幅度；硬投票只保留阈值两侧的信息。哪一种适合任务不能只凭名称决定，但复现时必须首先确保比较的是同一种定义。

4 平均方差的推导与数值

令平均为 B 项之和除以 B 。常数缩放使方差除以 B^2 ，和的方差包括 B 个自身方差以及每对两次出现的协方差：

$$\text{Var}(\bar{Z}) = \frac{B\sigma^2 + B(B-1)\rho\sigma^2}{B^2} = \sigma^2 \left[\rho + \frac{1-\rho}{B} \right].$$

$\sigma^2=4$ 、 $\rho=0.25$ 时， $B=1$ 得到4； $B=4$ 得到 $4(0.25+0.75/4)=1.75$ ； $B=20$ 得到 $4(0.25+0.75/20)=1.15$ ； B 趋于无穷时趋于1。

无穷棵树也保留共同变化部分。这个等相关模型是解释工具，不表示任意实际森林在所有输入位置都具有相同 σ^2 与 ρ 。一般情况下应回到完整协方差矩阵。

5 三种随机性不是同一层

设 D 代表原始训练数据， Θ_b 代表第 b 棵树的随机化。在固定 D 条件下，独立 Θ_b 可以产生条件独立的树；但各树的条件均值都依赖同一个 D 。

把训练数据 D 也视为随机时，全协方差分解为：

$$\text{Cov}(Z_b, Z_c) = \mathbb{E}[\text{Cov}(Z_b, Z_c \mid D)] + \text{Cov}(\mathbb{E}[Z_b \mid D], \mathbb{E}[Z_c \mid D]).$$

第一项可为0，第二项仍可能为正，因为同一份偏难或偏易的训练数据影响所有树。这解释了条件独立与无条件相关不矛盾。

固定已经训练好的树，跨不同测试行计算残差相关，又把输入对象的变化放进随机性中。某些对象对所有树都难，会产生共同残差。它不是固定 x 跨训练重复的相关参数，所以不能不加说明地代入上一题公式。

6 Brier平均不等式及边界

记 $e_i = p_i - y_i$ ，均值为 $\bar{e}$ 。平方和分解为：

$$\frac{1}{B} \sum_i e_i^2 = \bar{e}^2 + \frac{1}{B} \sum_i (e_i - \bar{e})^2 \geq \bar{e}^2.$$

右侧最后一项非负，所以均值预测的Brier不超过各树Brier的平均。等号在所有预测相同时成立。这个推导不需要独立假设。

若真实 $y=1$ ，两棵树分别预测1和0，最好一棵损失0，平均预测0.5损失0.25。它优于两棵树平均损失0.5，却不优于最好树。不能把“平均水平”偷换成“最好水平”。

同一不等式不直接作用于准确率，因为准确率先阈值化，再记录离散对错，不是平方函数。

7 OOB分母是本行的有效票数

只有第2、第5棵树没有见过这一行，所以OOB概率为 $(0.2+0.8)/2=0.5$ 。本讲在0.5处判0。

错误除以总树数10会得到0.1。它相当于把8棵无资格树的缺失概率都当成0，把“没有投票”变成了“强烈支持负类”。如果标签为1，正确Brier为0.25，错误版本变成0.81，评价被严重扭曲。

分母正确仍不够，分子也必须只加有资格的树。把10棵概率都相加再除以2，是另一种错误。独立审计逐行重算分子和分母。

8 袋外覆盖的有限树数概率

一棵树不是袋外的概率 $1-q=0.64$ 。五棵树都不给OOB票的概率 $0.64^5=0.1073741824$ ，所以至少一票概率为 0.8926258176 ，约89.26%。

这是对单行的随机概率，也给出覆盖率的期望。一次有限实验中，不同原始行的抽样资格互相有依赖，实际覆盖比例不必精确等于这个值。不能把89.26%直接四舍五入成固定的被评价人数，再跳过实际计数。

随着B增加，无票概率快速下降；但“有一票”只表示可计算，不表示估计已经稳定。还应该看每行票数分布。

9 节点特征随机化改变什么

每节点重新选择候选列，意味着一棵树在根可能比较 x_0 、 x_3 、 x_5 ，在下一层可能比较 x_1 、 x_2 、 x_7 。整棵树仍有机会使用所有输入特征。

每棵树永久选定一部分列，则整棵树都不能看其余列，属于另一种随机子空间方式。两者都能增加多样性，但限制发生在不同层级，结果与解释也不同。

m 过小可能经常错过有用特征，使单棵树在噪声上做分裂，增大偏差或削弱预测能力。 m 过大可能让所有树重复依赖同一强特征，提高误差同步。主实验 $m=3$ 比 $m=1$ 与 $m=8$ 更好，只支持当前样本中的平衡，不是普适最优值。

10 OOB调参也会使用评价证据

比较很多候选再挑分数最好，本身就是基于标签的选择。即使每一个OOB预测都由没有见过该行的树产生，研究者仍通过比较OOB分数利用了这些标签。因此获胜分数可能包含选择偶然性。

一个清楚的流程是：先按独立单位划出最终测试；在剩余训练部分限定候选，用OOB选择；冻结候选和报告方式；最后在测试上评价一次。若需要更复杂调参，可使用适当的嵌套或外层验证，并保持群组或时间约束。

本讲按80树OOB Brier在 $m=1$ 、3、8中选3，再首次读取测试。测试曲线是预先声明的机制比较，没有用来决定一个新最佳B。若读者根据曲线继续优化，就必须承认旧测试已经参与探索。

11 同组记录构成旁路信息

不能用这棵树的表现判断新组泛化，因为它已经通过同组记录知道该对象的输入和标签。袋外只保证“这一行”没被抽中，没有保证“这个对象”没被见过。

若目标是新组，应按组划分最终测试，并在内部验证或bootstrap中以组为抽样单位。整组bootstrap一次抽组编号，选中组携带所有记录；只有整个组未出现时，该组记录才有OOB资格。

当前反例行级OOB准确率1.0，新组测试0.55，整组OOB约0.566667。有限样本不要求后两者完全相等；关键是它们不再让同一对象的重复记录跨越训练与评价边界。

不确定性也应按组计算。每组六个副本不应让我们把60个独立标签的证据夸大为360份独立证据。

12 差异很大时的排查顺序

第一查覆盖率。小B时是否只有部分行有票，缺失是否被当成0，两个分数是否评价同一批对象。第二查成员关系和聚合：OOB资格是否按整棵树的bootstrap索引判断，分子和分母是否都只使用袋外树。

第三查泄漏和独立单位：同一人、设备、家庭或重复记录是否跨边界；预处理是否在全数据上使用标签；是否把教学真值列或未来统计放进特征。第四查选择：是否反复尝试许多配置并只报告最好OOB，或看测试后仍继续调整。

第五查分布和目标：训练与测试是否来自同一时期、群体或测量机制；部署是否预测新组，而内部评价只是已见组的新行。最后再看有限样本波动、OOB有效树数较少，以及两组实现是否真的相同。

这套顺序不能保证找到唯一原因，但能避免把一个具体编程错误、一个评价目标错位和正常抽样波动都含糊地叫成“OOB不准”。

完整实验核对

主实验训练/测试各360行，8列输入。80树OOB Brier在m=1、3、8下约为0.154854、0.140659、0.146194，因此选3。对应测试Brier约0.183413、0.169593、0.176060，准确率约0.755556、0.766667、0.758333。

单棵树测试Brier约0.266005，准确率0.7。库随机森林测试Brier约0.169538；对同一组库树重算概率平均和OOB，最大差均0。不同森林间不做不合理的逐项相等断言。

群组实验有10565个树一袋外行组合，其中10499个有同组训练记录，比例约0.993753。行级OOB、新组测试、整组OOB准确率分别1.0、0.55、0.566667。这是本讲最应记住的反例：一个漂亮分数也可能准确回答了错误的泛化问题。

普通与-O模式各通过859项显式检查。Notebook应真实执行并嵌入6图；若改坏票数、概率或选择而检查报错，这是预期的验收结果。探索性改动请另存，保留原始可复现基线。