

第062讲 习题与详细解答

1 平均损失求导中的样本数去哪了

题目：风险定义为 $\mathcal{R} = (1/n) \sum_i \ell(y_i, F_i)$ ，为什么伪残差经常写为 $-\partial \ell_i / \partial F_i$ ，而没有 $1/n$ ？这是否数学错误？

解答：如果把 $(F_1, \dots, F_n)$ 作为普通欧氏向量，平均风险对第 i 个坐标的偏导确实是 $(1/n)\ell'_i$ 。负梯度中所有坐标同时乘同一个 $1/n$ ，不改变方向，可以吸收进步长。另一种严格表述是在经验内积 $\langle a, b \rangle_n = (1/n) \sum_i a_i b_i$ 下定义梯度，则方向导数 $D\mathcal{R}[h] = (1/n) \sum_i \ell'_i h_i$ 对应梯度分量 ℓ'_i 。

因此关键不在某个写法单独是否带 $1/n$ ，而在整个损失、内积和步长是否一致。本讲使用单样本损失的负导数作为伪残差，树直接拟合这些数。独立有限差分检查扰动平均损失的一行，因此要再乘 n 恢复同一尺度。

常见错误是解析代码使用单样本导数，数值检查却使用平均损失导数而不乘 n ，然后误以为程序差一个固定倍数就是算法错。更危险的是在训练中随机漏掉或多乘样本数，使相同学习率随训练行数改变意义。

2 平方损失的初值与叶值

题目：对半平方损失推导最优常数模型，以及固定叶区域里的最优修正。解释二分之一的作用。

常数风险为 $Q(c) = \sum_i (y_i - c)^2 / 2$ ，导数为 $\sum_i (c - y_i)$ 。令其为0得 $c = \bar{y}$ ，二阶导数 n 为正，故是唯一最小值。初始化只用训练标签，不借用验证或测试均值。

已有预测 F 时，定义残差 $r_i = y_i - F_i$ 。固定叶区域 R 中的常数修正 γ 最小化 $\sum_{i \in R} (r_i - \gamma)^2 / 2$ ，同样得到 $\gamma = \sum_{i \in R} r_i / |R|$ 。所以回归树拟合残差得到的叶均值已经是这一叶的精确平方损失修正。

若去掉二分之一，最优常数和最优叶值仍相同，因为整体目标乘2不改变最小点；但直接负梯度变成2倍。若算法只按固定步长走梯度，不做重新求解或线搜索，更新会改变。本讲报告半MSE，和其他软件报告MSE比较时需乘2。

3 两轮回归的完整计算

题目：X为1、2、3、4，y为1、1、3、3，学习率 $1/2$ ，用深度1树计算两轮，并分别写原始叶值和实际新增值。

初始均值2，残差(-1,-1,1,1)。阈值2.5将两个-1和两个+1分开，叶均值为-1、+1，拟合残差的平方误差为0。实际新增值是学习率乘叶值，即左边-0.5、右边+0.5。新预测为1.5、1.5、2.5、2.5。

第二轮必须从新预测重新求残差，得到(-0.5,-0.5,0.5,0.5)。树叶值为 ± 0.5 ，实际新增值为 ± 0.25 。最终预测为1.25、1.25、2.75、2.75。

时点	残差绝对值	每行平方误差	平均半平方误差
初始	1	1	1/2
第一轮后	1/2	1/4	1/8
第二轮后	1/4	1/16	1/32

本例残差在每轮乘1/2，损失在每轮乘1/4，因为损失依赖残差平方。这种整齐比例依赖树能精确拟合所有残差，实际有噪声或树容量不足时不能普遍套用。

若把学习率既乘入叶值又在预测时再乘一次，第一轮新增值会变成±0.25，与本题标准不同。随附实现保存原始树叶值和每轮实际step，预测时只乘一次。

4 对概率与对logit的导数

题目：从 $\ell(y, p) = -y \log p - (1 - y) \log(1 - p)$ 出发，推导对p和对F的导数，其中 $p = \sigma(F)$ 。对y=1、F=2给出数值解释。

直接对p求导，第一项给 $-y/p$ ，第二项给 $(1 - y)/(1 - p)$ 。通分得 $(p - y)/[p(1 - p)]$ 。Sigmoid的导数为 $p(1 - p)$ ，所以用链式法则对F求导，分母抵消，结果为 $p - y$ 。负梯度为 $y - p$ 。

当y=1、F=2时，p约0.880797。对F的负梯度为约0.119203，表示增加F会局部降低损失。对p的负梯度为 $1/p \approx 1.135335$ 。二者都指向增大正类概率，但属于不同坐标，数值不应相同。

若使用y-F，则得到-1，方向与正确logit梯度相反。平方损失的残差不能仅因名称相同就搬到logistic损失。若使用“标签减预测”这个缩写，必须明确预测指概率p，且求导变量是F，而不是p。

在0/1标签下，完整logit的损失还可写为 $\log(1 + e^F) - yF$ 。它的一阶导数同样是sigmoid(F)-y。这提供一条独立代数检查路径；代码使用logaddexp避免显式指数溢出。

5 Newton叶值为什么是一个比值

题目：树结构固定后，为叶内所有行添加同一个gamma。推导一步Newton更新，解释它和残差均值的区别。

定义 $Q(\gamma) = \sum_{i \in R} \ell(y_i, F_i + \gamma)$ ，在gamma等于0处作二阶展开：

$Q(\gamma) \approx Q(0) + Q'(0)\gamma + Q''(0)\gamma^2/2$ 。二次式求导得到 $Q'(0) + Q''(0)\gamma$ ，令其为0即 $\gamma = -Q'(0)/Q''(0)$ 。

完整logit下 $Q'(0) = \sum_i (p_i - y_i)$ ， $Q''(0) = \sum_i p_i(1 - p_i)$ ，所以：

$$\gamma_R = \frac{\sum_{i \in R} (y_i - p_i)}{\sum_{i \in R} p_i(1 - p_i)}.$$

纯一阶残差树的叶值为 $\sum_i (y_i - p_i)/|R|$ 。Newton把分母从样本数换成曲率之和，利用损失对分数变化的敏感程度调整尺度。若每行p=0.5，Hessian为0.25，Newton叶值恰是一阶残差均值的4倍。

这不是一般意义上的精确叶内最优解，只是一次二阶局部近似。纯正类叶的精确有限最优logit通常不存在，分数可不断增加；Newton仍给一个有限步。若分母接近0，需要数值保护或阻尼。随附实现分母极小时取0，并检查实际训练损失。

6 两轮分类的数值核验

题目：对标签0、0、1、1，按学习率1/2执行两轮Newton叶值提升，计算logit与损失。再说明第一轮纯梯度模式有何不同。

初始正类比例0.5，logit0，损失 $\log 2$ 约0.693147。第一轮残差为(-0.5,-0.5,0.5,0.5)。左叶分子-1、分母0.5，叶值-2；右叶+2。乘学习率后分数为 ± 1 。对每个真实类别，错误方向概率为 $1/(1+e)$ ，损失为 $\log(1+e^{-1}) \approx 0.313262$ 。

第二轮左叶每行 p 为 $s = 1/(1+e) \approx 0.268941$ ，残差 $-s$ ，Hessian为 $s(1-s)$ 。两行的2相消，Newton叶值为 $-1/(1-s) = -(1+e^{-1}) \approx -1.367879$ 。右叶相反。新分数绝对值 $a = 1 + (1+e^{-1})/2 \approx 1.683940$ ，损失 $\log(1+e^{-a}) \approx 0.170284$ 。

纯梯度模式第一轮叶值只是残差均值 ± 0.5 ，乘1/2之后分数 ± 0.25 。若看最终类别，两种模式都分对四行；若只测试准确率，就看不出算法尺度差异。必须测试原始分数、概率与损失。

本讲Notebook和独立测试分别保存两种模式的输出，不将它们混为“同一种实现的小浮点差”。这也是和sklearn对齐时必须说明Newton叶值的原因。

7 为什么小学习率不等于最后统一缩放

题目：有人先用学习率1训练40轮，最后把所有树输出乘0.1，声称等于学习率0.1训练40轮。指出错误。

第一轮后，两种流程的当前F已经不同。第二轮伪残差依赖F：平方损失中是 $y-F$ ，logistic中是 $y-\text{sigmoid}(F)$ 。因此后续树的训练目标、分裂位置、叶值乃至整条路径都可能不同。最后统一缩放只能缩放已学好的树，无法回到每一轮重新训练这些方向。

在四行回归例子中，学习率1的一棵树就完全拟合标签，后续残差为0。若最后把树贡献乘0.1，只从初始均值走向标签的10%。学习率0.1训练多轮则会不断拟合剩余残差，预测随轮数继续靠近标签。两者显然不等价。

小步长可能改善拟合路径的稳定性，但固定轮数预算下也可能欠拟合。比较时要同时说明学习率、轮数、树深与选择方式，不能只说“某个学习率更好”。

8 怎样设计可靠的有限差分检查

题目：给定平均风险函数loss，构造单行原始分数的中心有限差分，并说明乘 n 、步长与测试点选择的理由。

对第 i 行构造 $F^+ = F + he_i$ 和 $F^- = F - he_i$ 。中心差分 $[\mathcal{R}(F^+) - \mathcal{R}(F^-)]/(2h)$ 近似平均风险的偏导。为了与单样本伪残差比较，取负号并乘 n ，即 $-n[\mathcal{R}(F^+) - \mathcal{R}(F^-)]/(2h)$ 。

测试点应包括不同正负logit和两类标签，不能只用 $F=0$ 、 $y=0.5$ 这类容易使错误表达式偶然相等的对称点。本讲采用 $F=(-0.7, 0.2, 1.1, -1.3)$ ， h 为 $1e-5$ ，按约 $1e-8$ 容差比较。平方损失与logistic都检查。

h 太大，二阶以上项影响明显； h 太小，两次几乎相同的浮点损失相减会损失有效位数。因此有限差分是数值近似，需要合理容差与多个测试点。解析手算、有限差分 and 库对照互补，不能认为其中任何一种单独覆盖所有错误。

9 对齐sklearn需要哪些约定

题目：自写GBDT最终指标接近库，就能宣称完全等价吗？列出本讲真正对齐的内容与未承诺的范围。

不能。两个不同模型可在有限测试集上给出近似指标，甚至完全相同类别。严格对照应比较初始化、每轮伪残差、树结构或方向、实际步长及原始分数。本讲明确对齐半平方损失、0/1标签与完整logit、分类Newton叶值、40轮、学习率0.1、最大深度1、最小叶样本数3和squared_error分裂准则。

正式数据上，回归与分类最大训练阶段分数差分别约 $2.22e-16$ 和 $4.44e-16$ ，属于机器浮点尺度；测试损失也一致。这是对该冻结数据和配置的强证据。若切点平局、重复特征、极小Hessian或浮点舍入路径改变，两份实现可能采用不同规则，不能从这一次对照推出所有输入都逐位相同。

本讲还增加回溯下降检查，并使用自己的极小分母阈值。正式数据未触发步长减半，故对照成立；极端输入下保护策略可能不同。正确报告应披露这些约定，而不是把任何差异都归为“误差”。

10 训练下降究竟证明了什么

题目：本讲检查每轮训练损失非增。它是否证明泛化改善？如果使用测试曲线选择轮数，会发生什么？

训练下降说明实际数值更新确实改善或保持了所定义的训练目标，排除了部分符号、步长和累加错误。它没有证明目标恰好适合任务，也没有证明训练样本代表未来数据，更没有保证验证或测试损失同样下降。

模型方向来自训练样本，可能逐步拟合其中的随机波动。验证集用来判断这些额外拟合是否帮助新样本。若查看测试曲线后选最低点，测试标签通过选择轮数进入模型决策，独立性已被破坏，即使fit函数从未读取测试文件也一样。

合理流程是预先固定候选、验证指标和停止规则；选择结束后才使用封存测试评估。若当前测试集已经多次用于调整，应在报告中标为探索性结果，并另取独立数据验证。随附图中的测试轨迹只是冻结方案的教学解释，不授予反复利用它调参的统计独立性。

最后，数据摘要、重建输入、报告全字段核验和篡改测试解决的是“文件是否对应同一实验”的问题。它们与泛化评估是不同层次。良好的研究记录需要同时有算法正确性证据、数据隔离证据和结论边界。