

第063讲 提升树的实际训练详解

1 L2为2时完整重算

仍有 $G_L = 1, H_L = 1/2, G_R = -1, H_R = 1/2$ 。代入叶值公式：

$$w_L = -\frac{1}{1/2 + 2} = -\frac{2}{5}, \quad w_R = \frac{2}{5}.$$

父叶梯度之和为0，所以父叶得分项为0。增益为 $\frac{1}{2}(1/(5/2) + 1/(5/2)) = 2/5 = 0.4$ 。若学习率为0.1，加入模型的分数为左侧负0.04、右侧正0.04。

此时新增概率不是负0.04或正0.04。分数需经过sigmoid，初始logit为0，所以左侧新概率为 $\sigma(-0.04) \approx 0.490001$ ，右侧为0.509999。常见错误是把叶值、缩放后的logit变化和概率变化混为一谈。

2 损失尺度与正则化一起改变

损失整体乘2时，每个梯度和Hessian也都乘2。保持 λ 数值不变，叶值变成：

$$w' = -\frac{2G}{2H + \lambda} = -\frac{G}{H + \lambda/2}.$$

它等价于在原损失下把L2惩罚减半，一般不会保持不变。只有 $\lambda = 0$ 且分母非零等特殊情况才相同。要保持叶值不变，应把惩罚也乘2。

这解释了为什么“两个库的lambda都填1”并不足以建立公平对照。还要检查它们使用损失之和还是平均、Hessian是否带权、正则项如何定义，以及分裂分数是否包含二分之一。对齐算法语义先于对齐参数拼写。

3 父叶只有一个正则项

分裂前只有一个叶子参数 w_P ，它对应的惩罚是 $\lambda w_P^2/2$ ，所以父叶二次项为 $(H_L + H_R + \lambda)w_P^2/2$ 。分裂后有两个独立参数，分别各带一个正则项。

增益是在两个不同模型结构的最优目标之间作差，而不是先把子叶分母加起来。若错误使用 $H_L + H_R + 2\lambda$ ，就相当于在分裂前给唯一的父叶加了两份惩罚。四样本例子父叶梯度恰好为0，会掩盖这个错误；因此应另设 $G_L + G_R \neq 0$ 的例子测试公式。

例如 $G_L = 1, G_R = 0, H_L = H_R = 1/2, \lambda = 1$ ，正确增益为 $\frac{1}{2}(1/1.5 - 1/2) = 1/12$ 。错把父分母写3会得到1/6，把分裂收益夸大一倍。

4 类别重编号的影响

普通数值树只能沿编码排序选阈值。编码0、1、2允许把{0}与{1,2}分开，也允许把{0,1}与{2}分开。重新编码成20、10、30后，排序变了，单次阈值允许的类别集合也跟着改变。因此即使类别语义完全没变，模型搜索空间也可能变化。

一种解决方法是显式类别标记，让支持类别的估计器把它视为无序集合；另一种是one-hot。两种处理仍有不同容量与代价。高基数下one-hot很宽，原生类别有自身限制，不能断言哪一种总最好。

本讲NumPy数组没有pandas category类型，因此采用明确布尔掩码。未知类别9的探针输出与NaN类别相同，这是实际运行验证的特定版本行为，不是所有算法和编码器的共同契约。部署代码应保存训练词表与未知类别策略。

5 外部验证与validation_fraction

validation_fraction控制的是从传给fit的训练数据中内部划出验证部分的比例。若显式传入X_val和y_val，1.8.0会使用这些外部数据，比例参数不再决定验证来源。因此设置None不矛盾，也没有把早停偷偷切回训练损失。

本讲核对了对应版本官方API、实际fit签名以及保存的验证曲线。不能只检查代码有没有传一个叫validation的变量；还需要知道该接口是否真的使用它。旧版本不支持外部参数时应更新到要求版本，而不是删掉参数继续宣称同一协议。

还需注意early_stopping='auto'的条件会随版本改变。本讲直接设True，降低对隐式默认值的依赖。get_params审计保留默认值，正式配置则另行明确记录，二者不可混淆。

6 数据权限的逐项答案

插补均值、StandardScaler均值方差、one-hot词表以及提升树分桶规则由train拟合。树结构和叶值也由train学习。stop标签只用于每个树候选的停止判断，tune标签只用于比较候选的调参log-loss。

calibration标签只用于已选提升树分数上的固定sigmoid拟合。test标签只用于所有选择结束后的性能估计、冻结图表与重现验证。测试程序重新计算test指标是核验已锁定结果，不是依据结果更换模型。

读取CSV的字节、检查摘要或检查ID是否重复，不等于依据测试表现调参。不过这种区别不应成为偷看测试的借口。真实实验中，最好在配置冻结前不展示测试标签与指标，并保存带时间的配置记录。

如果后续决定把train和stop合并重训，基模型会改变，校准器输入分数分布也可能改变。需要重新规定校准策略，而不能直接复用旧校准器后称整个系统完全等价。

7 候选次数相等只是一个预算维度

四个候选对四个候选控制了“尝试多少个设置”这个维度，但没有控制每次训练时间、树数、内存、处理器线程或每个候选的模型容量。提升树最多训练600轮总和，逻辑回归的内部优化迭代和单轮成本另有含义。

公平报告至少应列数据划分、候选清单、选择指标、停止规则、线程数、硬件环境和实际耗时。若研究问题是固定时间内哪种方法更好，应预先锁定墙钟预算，并设计能在预算内运行的搜索，而不是事后把两个耗时不等的结果称作等算力。

本讲fit耗时是真实perf_counter测量，只包括该模型fit，不包括画图、PDF或Notebook。不同硬件上的数值不可直接当算法理论复杂度，单次测量也不应夸大微小差异。

8 可靠性桶的计算与不确定性

设某桶里预测概率为0.62、0.70、0.78、0.74，标签为1、0、1、1。均值预测是 $(0.62 + 0.70 + 0.78 + 0.74)/4 = 0.71$ ，正例比例是 $3/4 = 0.75$ 。这个桶在图上对应横坐标0.71、纵坐标0.75。

只有4个样本时，改动一个标签会把纵坐标移动0.25，因此不能凭0.04的偏差声称校准很好或很坏。增加桶数虽让图更细，却让每桶样本更少；分箱方式本身也会影响视觉印象。应同时报告样本量与proper scoring rule，而不是只挑好看的图。

空桶不能凭空填0或连成一个“真实观测点”。本讲保存count=0和空均值，画图时跳过空桶；右侧样本量图仍然显示它的零计数。

9 校准变差之后该怎么说

本次固定测试中，校准使log-loss从0.588754变成0.591923，差约0.003169；Brier也略差。这支持一句有限结论：这个预先指定的校准流程在这一次封存样本上没有改善这两个指标。它不支持“校准总是有害”，也不说明差异在统计上显著。

看完测试后选择未校准版本，作为后续实践决策可以另行讨论，但不能再把同一测试对该选择的表现说成完全独立、未参与选择的无偏评估。下一步可预注册校准样本量和方法的比较，用新的测试或嵌套设计评估。

AUC没有变化并不奇怪。sigmoid的 a 在本次拟合为正，映射单调递增，样本排序因此保持。若拟合 a 为负或映射形成大量相同值，排序结论就要重新检查，不能把本次现象误写成任意校准都保AUC。

10 一份合格的后续研究方案

问题示例：在一个按时间到达的设备故障表格任务中，原生缺失处理是否比均值插补加缺失指示更稳健？先明确一行是一台设备在一个预测时点的记录，标签是未来固定窗口内是否故障；任何预测后才出现的字段都排除。

使用过去时间训练、其后时间早停/调参，再留更晚且未查看结果的数据作封存测试。按设备分组防止同一台设备跨角色泄漏。候选数量、最大训练时间、主指标、校准方法和缺失机制分析都在打开最终标签前锁定。

报告总体log-loss、关键缺失子组表现、实际耗时和不确定性。若缺失机制随时间变化，应单独解释，不能把它归咎于算法名字。若看到测试不足以回答问题，承认边界并设计下一轮数据收集，而非无限反复使用同一测试集。

11 实验报告判读与评分要点

运行部分应有正常模式与-O模式通过记录、已执行Notebook、六张可重建图以及完整数据摘要。概念部分要能区分叶值与概率、L2与学习率、类别与顺序、候选预算与算力、验证与测试。解释部分应保留校准稍差这一事实。

出现以下情况不能算完整验收：只贴测试准确率；没有逐候选记录；Notebook输出为空；CSV被改却没有更新实验协议；把测试集传给X_val；看完测试后换模型却仍称预先锁定；报告所有库同名参数天然等价。修复时应修正实验设计并重新执行，不是只改一句描述。