

第065讲 对偶与核技巧

1 为什么要换一组未知量

上一讲在参数 w 、偏置 b 和松弛 ξ_i 上求软间隔解。现在想象每个样本有上百万维特征：如果目标与预测只需要某种内积，我们能否跳过显式构造这些维度？回答这个问题之前，必须先知道为什么最优 w 能够由训练样本表示，以及换变量之后是否仍在解同一个优化问题。

本讲从拉格朗日乘子出发，按顺序推弱对偶、强对偶的条件、SVM对偶、KKT条件和偏置恢复，最后才进入核技巧。直接先修是第010、012、016、064讲。重点不是背一张乘子公式表，而是能从约束符号逐步推到可核验的数值结果。

实验包含三个层次：两个点的解析解；所有乘子都到上界时的偏置区间；二维异或型数据上，显式三维特征与对应二次核的四条实现路线。数据均为原创合成， C 和核预先固定，测试只用于实现等价性和一次预测评估，不进行调参。

2 把约束写成统一方向

上一讲的原始问题为：

$$P^* = \min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_i \xi_i$$

$$\text{s.t. } 1 - \xi_i - y_i(w^T x_i + b) \leq 0, \quad -\xi_i \leq 0.$$

统一写成“小于等于0”，是为了明确乘子的符号。给第一组约束乘子 $\alpha_i \geq 0$ ，第二组乘子 $\mu_i \geq 0$ ，构造拉格朗日函数：

$$L = \frac{1}{2} \|w\|^2 + C \sum_i \xi_i + \sum_i \alpha_i [1 - \xi_i - y_i(w^T x_i + b)] - \sum_i \mu_i \xi_i.$$

这里不是给原问题随意加上一个罚函数。乘子暂时固定，随后我们会对原变量取下确界，得到原最优值的下界；再挑选最紧的这种下界。这个方向关系决定了为什么对偶是最大化，也决定了误写一个负号会破坏什么。

3 弱对偶是一个简单的不等式链

对任何原始可行的 w, b, ξ ，每个约束函数都小于等于0；乘子非负，所以乘子项之和也小于等于0。因此固定乘子时，有 $L(w, b, \xi, \alpha, \mu) \leq P(w, b, \xi)$ 。

再令 $q(\alpha, \mu) = \inf_{w, b, \xi} L$ ，则下确界不会大于任何一次具体取值，于是：

$$q(\alpha, \mu) \leq L(w, b, \xi, \alpha, \mu) \leq P(w, b, \xi).$$

这对每一个原始可行点都成立，故 $q(\alpha, \mu) \leq P^*$ 。在合法乘子中最大化 q ，得到对偶最优值 $D^* \leq P^*$ ，称为弱对偶。它不要求原问题凸，也不声称两个最优值必然相等。

一个原始可行解提供上界，一个对偶可行解提供下界。若两者相差很小，最优值只能夹在狭窄区间里。这比“两个求解器都说成功”更直接地解释了对偶间隙为何能用于验收。但必须先检查可行性，两个任意数相减很小没有意义。

4 逐个消去原变量

先把 L 按变量整理。与 w 有关的是 $\|w\|^2/2 - w^T \sum_i \alpha_i y_i x_i$ ，对 w 求导并令0，得到：

$$w = \sum_i \alpha_i y_i x_i.$$

这一步给出关键表示：最优法向量位于训练向量的线性张成空间。它不是预先假设，而是拉格朗日函数驻点条件的结果。对 b 而言， L 中的线性系数为 $-\sum_i \alpha_i y_i$ 。若该系数非零， b 可沿某个方向趋向无穷，让 L 趋向负无穷。要得到有意义的有限下界，必须有：

$$\sum_i \alpha_i y_i = 0.$$

同样，在已经把非负约束放进 L 之后，对 x_i 取下确界时把它作为无约束实变量。其线性系数为 $C - \alpha_i - \mu_i$ ，有限下界要求 $C - \alpha_i - \mu_i = 0$ 。结合 $\alpha_i, \mu_i \geq 0$ ，得到 $0 \leq \alpha_i \leq C$ 。

最后把 w 的最优值代回，二次项与线性项合并成负的一半范数平方：

$$D(\alpha) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^T x_j.$$

因此对偶问题是最大化 D ，约束为 $0 \leq \alpha_i \leq C$ 和 $y^T \alpha = 0$ 。它有 n 个主要未知量，而原问题有 $d+n+1$ 个未知量；但 n 也可能很大，所以换到对偶不是免费加速的保证。

5 为什么这次可以得到强对偶

只说“问题是凸的”还不够谨慎。一般凸问题若缺少适当的约束资格条件，强对偶也可能失败。一个常用充分条件是Slater条件：凸问题存在满足所有非仿射不等式严格不等号、并满足仿射等式的合适内部点。对本讲更简单地检查所有不等式严格成立就足够。

在有限训练数据、 $C>0$ 的软间隔问题中，取 $w=0$ 、 $b=0$ 、每个 $x_i=2$ ，则第一组约束为 $1-2=-1<0$ ，第二组为 $-2<0$ 。目标是凸二次加线性，约束仿射，存在这个严格可行点；因此强对偶成立，最优原始值与最优对偶值相等。

这段论证不依赖数据线性可分。软间隔允许松弛，正是严格可行点容易构造的原因。硬间隔要另查可行性与条件，不能拿这里的 $x_i=2$ 去证明一个根本不允许 x_i 的模型。 C 也必须按本讲假设为正有限数。

在本设置中，KKT条件既是最优解应满足的条件，也足以核验全局最优性。我们不把它推广成“任何非凸问题满足KKT就全局最优”的错误口号。

6 KKT把代数与支持向量接起来

本问题的条件可以分四组阅读。第一组是原始可行性： ξ_i 非负，且 $m_i + \xi_i \geq 1$ 。第二组是对偶可行性： α 和 μ 非负。第三组是刚才的驻点关系： w 为带标签训练向量的加权和， $y^T \alpha = 0$ ，且 $\mu_i = C - \alpha_i$ 。

第四组是互补松弛：

$$\alpha_i(m_i - 1 + \xi_i) = 0, \quad (C - \alpha_i)\xi_i = 0.$$

乘积为0意味着相关乘子和约束余量不能同时严格为正。由它们可读出三种情况：若 $\alpha=0$ ，则在最优解中 $\xi=0$ ，因而 $m \geq 1$ ；若 $0 < \alpha < C$ ，则 $\xi=0$ 且 $m=1$ ；若 $\alpha=C$ ，则 $m=1-\xi \leq 1$ 。最后一种包括在间隔内的正确点、边界点、错分点，也可能恰好在 $m=1$ 上。

不要把逆命题随意加强。 $m=1$ 的点在退化问题中可能具有 $\alpha=0$ ，也可能处于上界；不是每个画在边缘线上的点都必须有严格内部乘子。本讲用 α 大于数值容差来定义实现中的支持向量，其对预测函数有非零贡献。




图1 真正求得的乘子与函数间隔。灰色为近零系数，蓝色为严格内部系数，橙色为接近C的系数。内部系数的点落在规范间隔上；数值容差用于区分边界状态。

7 两个点让整个对偶变成抛物线

令 $x_1 = -1, y_1 = -1, x_2 = 1, y_2 = 1, C=1$ 。等式约束为 $-\alpha_1 + \alpha_2 = 0$ ，因此两者都等于 a 。 w 恢复公式给出 $w = a(-1)(-1) + a(1)(1) = 2a$ 。

代入对偶目标，得到 $D(a) = 2a - 2a^2$ ，约束 $0 \leq a \leq 1$ 。求导为 $2-4a$ ，令0得到 $a=1/2$ ；二阶导数为负4，确为最大值。于是 $w=1$ ，任选一个内部支持向量可得 $b=0$ 。对偶值为 $1/2$ ，原始值也为 $1/2$ ，两个点的松弛都是0。




图2 两点问题的凹抛物线。绿色点是C足够大时的最优a等于1/2；橙色区域表示C等于0.1时的可行范围，最优点被上界截住。

一般C下， $a^* = \min(C, 1/2)$ 。因此C很小时两个样本都成为上界支持向量，即使它们仍然被正确分类，也会处在规范间隔内部。这个例子把C、支持向量状态和软间隔代价连在一起，避免只凭散点图猜测。

8 偏置恢复有一个不能跳过的边界情况

通常先算不含偏置的 $g_i = \sum_j \alpha_j y_j K_{ij}$ 。若存在 $0 < \alpha_i < C$ 的支持向量，KKT给出 $m_i = y_i(g_i + b) = 1$ ，因此 $b = y_i - g_i$ 。实践中对多个内部支持向量的候选b取平均，并报告离散程度，以检查数值误差。

如果所有alpha都在0或C上，不能对一个空集合求平均，也不能随便挑一个上界支持向量硬套 $m=1$ 。应根据不等式形成b的允许区间： $\alpha=0$ 的正类要求 $b \geq 1-g$ ，负类要求 $b \leq -1-g$ ； $\alpha=C$ 的正类要求 $b \leq 1-g$ ，负类要求 $b \geq -1-g$ 。

把所有下界取最大、所有上界取最小，就得到合法区间。若区间为空且超过数值容差，应怀疑乘子还不够准确或实现有错。有限非空区间可选中点；区间中的多个b可能对应同样的最优目标，这不是程序失效，而是解的非唯一性。

两点例取 $C=0.1$ 时， $\alpha=(0.1, 0.1)$ 、 $w=0.2$ ，不含偏置的 $g=(-0.2, 0.2)$ 。负类上界点要求 $b \geq -0.8$ ，正类上界点要求 $b \leq 0.8$ ，所以 $b \in [-0.8, 0.8]$ 。取 $b=0$ ，两行函数间隔均0.2，松弛均0.8，原始值为 $0.5 \times 0.2^2 + 0.1 \times 1.6 = 0.18$ ，对偶值也是0.18。

随包代码专门包含这个无内部支持向量的实验。数值测试还检查区间内不同b的原始目标相同。只在“恰好总有内部点”的数据上通过测试，无法发现这一类偏置恢复错误。

9 内积换成核之前先检查合法性

对偶只通过 $x_i^T x_j$ 使用输入。若某个特征映射phi把x送到更高维空间，我们可以在那个空间解同样的线性SVM；对偶中只需 $\phi(x_i)^T \phi(x_j)$ 。定义 $k(x, z) = \langle \phi(x), \phi(z) \rangle$ ，这个直接返回内积的函数叫核。

训练Gram矩阵为 $K_{ij} = k(x_i, x_j)$ 。若它来自真实内积，就必须对称，而且对任意实向量 c 都有：

$$c^T K c = \left\| \sum_i c_i \phi(x_i) \right\|^2 \geq 0.$$

这就是半正定性，简称PSD。正定比半正定更强，本讲无需每个特征方向都独立。重复样本、有限维特征或线性依赖都可能产生零特征值，只要没有真实的负二次型即可。

一个函数要在整个定义域上成为这种合法核，需要对任意有限样本集合都产生对称PSD Gram矩阵。只对当前训练集算一次特征值非负，不能证明它在所有输入上合法；不过找到一个负特征值的反例，就足以否定这个候选函数的普遍PSD性。

例如矩阵 $\begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$ 对称、元素都正，却有特征值3和负1。取 $c=(1,-1)$ ，二次型是负2，不可能等于某个向量范数平方。因此“越相似数越大”的直觉不足以保证它是合法核。

10 一个能逐项展开的二次核

对二维输入 $x = (x_1, x_2)$ ，选 $k(x, z) = (x^T z)^2$ 。展开：

$$(x_1 z_1 + x_2 z_2)^2 = x_1^2 z_1^2 + 2x_1 x_2 z_1 z_2 + x_2^2 z_2^2.$$

令 $\phi(x) = (x_1^2, \sqrt{2}x_1 x_2, x_2^2)$ ，则恰有 $k(x, z) = \phi(x)^T \phi(z)$ 。中间的sqrt2不能漏掉，否则内积的交叉项系数会从2变成1，得到的是另一个核。

这个显式映射也直接证明核合法，而不是仅凭某次特征值检查。Gram的秩最多为3，样本数超过3时出现近零特征值非常正常。浮点计算中零附近可能出现极小负数，应结合矩阵尺度设容差，不能把每个-1e-15都当成严重非法核，也不能把-1随手裁成0冒充原方法。




图3 本讲16行训练样本的二次Gram矩阵与特征值。显式映射只有三维，所以最多三个非零特征方向。

异或型数据中，两坐标同号为负类，异号为正类。原平面中的两类分布在交错象限，单条直线无法按这个总体规则分开；特征 $x_1 x_2$ 直接表达了符号交互。核技巧没有创造新的标签，它把一个预设的非线性表征嵌入内积计算。




图4 左图是输入空间的交错类别，右图是三维显式特征的二维投影。横坐标 $\sqrt{2}x_1$ 已经暴露类别交互；右图并不冒充完整三维空间。

11 核SVM的预测还需要训练样本

求得 α 和 b 后，新点 z 的预测分数为：

$$f(z) = \sum_i \alpha_i y_i k(x_i, z) + b.$$

α 为0的项不贡献分数，因此预测可以只保留支持向量。要注意库可能直接保存 $\alpha_i y_i$ ，而不是裸 α ；再次乘 y 会把标签乘两遍。scikit-learn二分类SVC的`dual_coef_`带符号，阅读实现时必须查清约定。

训练时预计算核矩阵形状是 $n_{\text{train}} \times n_{\text{train}}$ ；预测时形状是 $n_{\text{new}} \times n_{\text{train}}$ ，列顺序必须与拟合时的训练样本顺序一致。把测试与测试之间的核矩阵传给`predict`，可能维度碰巧相同却语义完全错误。

核化也没有消除计算代价。完整Gram需要二次存储，通用二次规划可能很贵；测试预测还需与支持向量计算核。下一讲比较核、尺度与近似方法的实际预算。本讲只用16行训练样本，是为了把所有矩阵、条件和数值都公开核验。




图5 真正训练得到的核边界。实线为零分数，虚线为正负1，圆环为支持向量；所有几何坐标按相同比例绘制。

12 四条实现路线怎样互相检查

第一条路线用SLSQP直接最大化核对称，再用KKT恢复偏置。第二条路线对显式 ϕ 用原始松弛问题求解。第三条路线在显式 ϕ 上用线性SVC。第四条路线用预计算Gram的SVC，并额外核对原生poly核，设置degree=2、gamma=1、coef0=0，确保恰好对应齐次二次核。

所有路线固定C=2，不进行选择；训练16行、validation24行、test80行。验证与测试用于确认分数等价，不用于挑选哪个映射更漂亮。若修改gamma或coef0，必须重新写出相应 ϕ 或明确这已是不同实验。

实际运行中，自写对偶的原始值约1.061602211689，对偶值约1.061602211689，间隙约1.69e-14；另行原始求解与对偶目标差约1.02e-13。显式SVC与预计算核SVC在测试分数上的最大差约1.78e-15，自写对偶与显式SVC差约8.96e-8。测试准确率1.0，但这只是本讲有意构造的简单无噪声交互任务，不能用来宣称现实泛化已经解决。




图6 左图逐个比较封存测试样本的两套分数，落在对角线说明数值一致；右图展示一个对称但非PSD的相似度矩阵反例。

检查程序独立重算对偶目标、重构 w 、检查等式与盒约束、两组互补乘积、原始可行性和完整新运行。若只有准确率一致，仍可能藏着偏置、缩放或核系数错误；分数级一致性是更严格的验证。

13 练习与下一步

1. 用一句不等式链解释为什么合法乘子给原始最优值提供下界。
2. 逐项推导 b 与 x_i 的有限下确界条件，说明 α 上界 C 从哪里来。
3. 为软间隔原始问题构造严格可行点，并说清强对偶还用到了什么假设。
4. 两点问题在 $C=0.25$ 时求 α 、 w 、偏置区间、原始与对偶目标。
5. 为什么不能从 $\alpha=C$ 直接断言该点一定被分错？
6. 若没有内部支持向量，如何从四种标签/边界组合恢复 b ？
7. 手算 $x=(1,2)$ 、 $z=(3,4)$ 的二次核，并用 ϕ 内积重算。
8. 用 $c=(1,-1)$ 证明 $[[1,2],[2,1]]$ 不能是内积Gram。
9. $n_{\text{train}}=16$ 、 $n_{\text{test}}=80$ 时，训练和预测的预计算核形状各是多少？列顺序为什么重要？
10. 一个核在本次样本上的Gram为PSD，是否已经证明它在整个输入空间合法？

本讲完成的是从原始约束到对偶证据，再到合法内积替换的完整逻辑。下一讲将选择不同核、尺度和正则化，同时正视存储与预测代价。

一级资料与阅读边界

Boyd与Vandenberghe的Convex Optimization第五章用于核对弱/强对偶、Slater与KKT条件；LIBSVM原始论文用于C-SVC对偶与实现背景；scikit-learn1.8.0文档用于SVC参数和预计算核接口；Cornell机器学习课程讲义用于核的PSD判据背景。所有推导、例子、代码与图由本课程独立组织，完整URL与实际核验日期见sources.md。