

第066讲 核方法的选择与代价

1 一条弯曲边界到底花了什么

假设一组点围成大圆，另一组点围成小圆。我们想根据位置判断一个新点属于哪一组。直线不能把内环和外环分开，而距离中心的平方可以：把二维坐标变成包含平方项的新特征后，一条平面就能表达圆形边界。第065讲介绍的核技巧，使我们不必先列出所有新特征，也能计算那个空间里的内积。

但“省掉显式展开”不等于“省掉所有计算”。输入单位改变会改变距离，带宽会改变两个点的影响范围，正则化会决定模型多愿意追随训练样本。训练时还可能要处理一个样本数平方规模的核矩阵，预测时可能要保留很多训练样本。核、尺度、正则化和资源预算必须一起决定。

本讲直接先修第039、051、053至054、065讲。读完后，你应能算出一个小核岭回归模型，说明RBF与多项式核表达了什么假设，设计同等验证预算的比较，并区分核矩阵大小、模型数组大小、序列化大小与实际内存峰值。本文数据全部为原创合成数据，不涉及真实个人信息。

2 先把对象的形状写清楚

设训练输入为 $X \in \mathbb{R}^{n \times d}$ 。这里 n 是样本数， d 是每条样本的原始特征数。第 i 行是向量 x_i 。核函数 $k(x, z)$ 接收两个输入，输出一个标量。核矩阵或Gram矩阵则是把全部两两核值放在一起：

$$K_{ij} = k(x_i, x_j), \quad K \in \mathbb{R}^{n \times n}.$$

若有 q 个待预测输入，交叉核矩阵 K_{*X} 有 q 行、 n 列。不要因为训练矩阵是方阵，就把测试时的矩阵也写成方阵。代码中的许多“能运行但答案错了”的问题，都来自转置方向没有按对象含义核对。

一个合法的实值核应使任意有限输入集合得到对称半正定矩阵。半正定表示任意系数向量 c 都满足 $c^\top K c \geq 0$ 。它保证这些数可以解释为某个特征空间里的内积。这里“相似度”只是直觉；合法核不要求每个元素都在0到1之间，也不要求每个元素非负。

本讲提供从零RBF、多项式核和核岭求解器。测试除了对照库，还检查对称性、特征值和手算数值。有限几个矩阵通过检查不能证明一个任意新函数总是合法核；本讲使用已有理论保证的核族，数值检查负责发现实现错误。

3 RBF核把距离变成影响范围

RBF是径向基函数核的常用简称。我们使用高斯形式：

$$k(x, z) = \exp(-\gamma \|x - z\|^2) = \exp\left(-\frac{\|x - z\|^2}{2\ell^2}\right), \quad \gamma = \frac{1}{2\ell^2}.$$

γ 和 ℓ 表达同一件事，但方向相反： γ 越大，长度尺度 ℓ 越小。距离不为零时，较大的 γ 让相似度更快衰减，因此一个样本只强烈影响附近很小的区域。较小的 γ 使更远的点仍相似。距离为0时，任何正 γ 下核值都等于1。

用一个可心算的例子理解带宽。若两点距离为1， $\gamma = \log 2$ 时核值为1/2；若距离翻倍为2，平方距离变成4，核值成为1/16，并不是1/4。指数里面是平方距离，这一点比背诵“越远越不相似”更有用。

当 γ 极小，很多不同点都非常相似，核矩阵接近全1矩阵，模型可能难以区分局部结构；当 γ 极大，不同训练点近乎互不相似，核矩阵接近单位阵，模型可以形成非常局部的响应。是否过拟合仍取决于正则化和数据分布，不能只凭 γ 一个数下结论。




图1 左图横轴为欧氏距离 r ，纵轴为RBF核值；曲线越快落到零，影响范围越局部。右图横轴为内积，纵轴为多项式核值；核值可以大于1，所以不同核族不能只按数值范围比较。

4 输入尺度是模型假设的一部分

若第一维用米，第二维用毫米，直接计算欧氏距离会让毫米这一维的数值变化更占优势。把同一物理量从米换成厘米，相差100倍的坐标会在平方距离中放大为10000倍。数据的几何关系是否合理，必须先于调参讨论。

标准化用训练集均值 μ_j 和标准差 s_j 把特征变成 $\tilde{x}_j = (x_j - \mu_j)/s_j$ 。这并不是纯粹“方便计算”的无害操作，而是重新定义各方向的距离权重：

$$\|\tilde{x} - \tilde{z}\|^2 = \sum_{j=1}^d \frac{(x_j - z_j)^2}{s_j^2}.$$

如果某维波动主要是噪声，自动缩放到单位方差也不一定合适；业务量纲、测量误差和领域知识可能要求不同权重。我们先用标准化作为可复现基线，再通过严格的验证比较其他选择。

本讲双环数据故意把第一维乘3、第二维乘0.25。同一组已选RBF参数，使用标准化管线的测试准确率为1.0000，不标准化的预先规定诊断对照为0.7667。这个结果说明输入单位有实际影响，不能推出“标准化对所有任务都有益”。该诊断没有额外调参，不参加三个模型族的公平搜索排名。

验证阶段，均值与标准差只能用训练集拟合。即使标准化不看标签，也不能提前把验证或测试输入分布加入拟合。最终参数选好后，可以按预先协议在训练加验证集上重新拟合整条管线，但测试数据始终不参与。

5 多项式核表达全局交互

多项式核采用：

$$k(x, z) = (\gamma x^\top z + c_0)^p.$$

本讲要求正整数次数 p 、非负 γ 和 c_0 ，以使用标准的半正定构造。若 $p = 2$ 、 $\gamma = 1$ 、 $c_0 = 0$ ，对二维输入展开：

$$(x_1 z_1 + x_2 z_2)^2 = x_1^2 z_1^2 + 2x_1 x_2 z_1 z_2 + x_2^2 z_2^2.$$

因此可取特征映射 $\phi(x) = (x_1^2, \sqrt{2}x_1 x_2, x_2^2)$ 。中间的 $\sqrt{2}$ 不是装饰：两个特征内积相乘时，必须恢复系数2。若 $c_0 > 0$ ，展开还会包含较低阶项；齐次核与非齐次核所含的特征不同。

RBF强调局部距离，多项式核强调坐标的乘积与全局交互。高次数可能在远处急剧放大，即使训练区域边界看起来很好，也应检查域外行为、数值范围与稳定性。我们实现里检测核值溢出；“模型输出一个数”不代表该数在训练范围外有可靠含义。




图2 三幅图保持 C 等于1，仅改变标准化空间中的 γ 。黑线是决策分数为零的位置，背景颜色是分数，点是训练样本。此处小 γ 的边界仍可成环，但分数变化较弱；很大的 γ 产生局部小结构。点与背景均用红表示类别0或负分数、蓝表示类别1或正分数。图只用于机制观察，不用于从测试表现追加选参。

6 正则化与核带宽必须共同选择

核SVM的决策函数可以写成 $f(x) = \sum_{i \in SV} \alpha_i y_i k(x_i, x) + b$ 。集合 SV 包含支持向量， C 控制对间隔违例的惩罚强度。较大的 C 通常更不愿容忍训练违例，但它并不独立决定曲线有多弯，因为核本身决定可表达的相似关系。

想象把每个样本的影响范围缩小后，仍使用很强的正则化。模型也许没有足够自由度把每个训练点包起来。反过来，即使 C 很大，极宽的RBF核也未必能分开复杂结构。因此应比较 (C, γ) 组合，而不是先用全数据定一个“最佳带宽”，然后只报告 C 的验证结果。

不同库或不同目标的正则化参数不能按名称直接互换。SVM中的 C 越大通常正则化越弱；核岭回归中的 α 越大正则化越强。即便都叫alpha，目标是否除以样本数也会改变参数数值。本讲下一节专门固定这个约定。

7 从岭回归推到核岭回归

核岭回归KRR仍然预测连续值。设特征空间中的函数为 $f(x) = \langle w, \phi(x) \rangle$ ，暂不另设截距，优化未平均的平方误差与范数惩罚：

$$J(w) = \sum_{i=1}^n (y_i - f(x_i))^2 + \alpha \|w\|^2, \quad \alpha > 0.$$

为什么答案只需训练点对应的特征向量？把 w 拆成训练特征张成空间中的分量与其正交分量。正交分量和每个 $\phi(x_i)$ 的内积都为0，所以不能改善任何训练预测，却会增加范数惩罚。一个最优解不需要它。这就是本讲所需的有限样本表示思想。

令 $w = \sum_i a_i \phi(x_i)$ ，训练预测是 Ka ，范数平方是 $a^\top Ka$ ，得到：

$$J(a) = (y - Ka)^\top (y - Ka) + \alpha a^\top Ka.$$

求导为 $2K(Ka - y) + 2\alpha Ka$ 。取满足下面线性方程的 a ，导数一定为0：

$$(K + \alpha I)a = y, \quad \hat{f}(X_*) = K_* X a.$$

若 K 奇异，不能从导数方程中随意“约掉 K ”。但 $K + \alpha I$ 在 $\alpha > 0$ 时正定，以上解仍给出有效最优函数；不同系数表示若只相差 K 的零空间分量，不改变函数在相关特征空间中的表现。代码用Cholesky分解和线性方程求解，不显式求逆。

若另一份教材使用 $(1/n) \sum_i (y_i - f_i)^2 + \lambda \|w\|^2$ ，两边乘 n 后才可对照，故本讲 $\alpha = n\lambda$ 。忘记这个 n ，会在改变样本量时无意改变正则化含义。scikit-learn的KernelRidge接口与本讲未平均目标的alpha约定对齐；我们用实际数值对照验证。[KernelRidge 1.8.0接口](#)

一个完整的二点手算

取 $x_1 = -0.5$ 、 $x_2 = 0.5$ ，目标 $y = (1, -1)^\top$ ，RBF参数 $\gamma = \log 2$ ，正则化 $\alpha = 0.5$ 。由于两点距离为1：

$$K = \begin{pmatrix} 1 & 1/2 \\ 1/2 & 1 \end{pmatrix}, \quad K + \alpha I = \begin{pmatrix} 3/2 & 1/2 \\ 1/2 & 3/2 \end{pmatrix}.$$

把 $a = (1, -1)^\top$ 代入，左边第一行为 $1.5 - 0.5 = 1$ ，第二行为 $0.5 - 1.5 = -1$ ，正好等于目标。因此系数就是 $(1, -1)$ 。训练点的预测却是 $Ka = (0.5, -0.5)^\top$ ，并不等于原目标。正则化主动牺牲一部分拟合来限制函数范数。

中点 $\mathbf{x}_* = \mathbf{0}$ 到两个训练点距离相同，所以两项核值相同，乘上相反系数后恰好抵消，预测为0。实际从零程序与KernelRidge都输出 $[0.5, 0, -0.5]$ 。这个例子同时展示了核矩阵、正则化、求解和新点预测，不能只检查最后一个均方误差。

8 同等验证预算究竟怎样执行

实验固定三份互不重叠数据：训练240条、验证120条、测试120条，类别各占一半。三个模型族各有9个候选，每个候选只拟合一次训练集并评估同一个验证集。线性基线使用LinearSVC；RBF和多项式使用SVC。前者和后者的损失与求解实现不同，因此这是实用模型族比较，不声称实验只改变核而固定了其余一切。[SVC接口](#)

- 线性： $C = 10^{-4}, 10^{-3}, \dots, 10^4$ ，共9个候选。
- RBF： $C \in \{0.1, 1, 10\}$ 与 $\gamma \in \{0.1, 1, 10\}$ ，共9个组合。
- 多项式： $C \in \{0.1, 1, 10\}$ 与 $p \in \{2, 3, 4\}$ ，固定 $\gamma = 0.5, c_0 = 1$ ，共9个组合。

选出每族验证准确率最高的候选，同分时取预先枚举的第一个。计时和测试表现不参与同分处理。之后每族在训练加验证的360条上重训一次，再评估封存测试集。每族9次验证拟合加1次最终拟合，完整候选结果保存在JSON中。

“同等预算”在这里精确定义为相同候选数、相同划分与评价次数，不是相同墙钟时间，也不保证三个搜索空间同样容易找到好参数。若业务约束是每个模型只能训练十分钟，应该另设时间预算实验。固定一次划分也无法估计所有数据抽样不确定性；严肃模型选择应根据任务使用重复划分或嵌套交叉验证。

模型族	验证选中配置	验证准确率	最终测试准确率	支持向量
LinearSVC	C等于0.0001	0.5333	0.5000	不适用
RBF SVC	C等于1 gamma等于0.1	1.0000	1.0000	100
多项式SVC	C等于0.1 degree等于2	1.0000	1.0000	95




图3 三个模型族都获得9次验证机会后再重训。背景与黑线来自最终模型，展示范围超过主要训练区域。RBF和二次多项式在这组圆环上都有效，不能把一次100%的测试准确率解释为未来永不出错。

9 预测开销不能只看特征维数

显式线性模型保存一个 d 维权重向量和截距。一次预测主要是向量内积。核SVM要与支持向量计算核值，常见成本约随 $n_{sv}d$ 增长，此外还有核函数本身的计算。支持向量很少时推理可能较快；若大部分训练点成为支持向量，模型保存量和预测开销都会增加。

核岭回归一般不是稀疏表示，通常要保留所有训练输入与 n 个系数。它具有容易写出的线性求解公式，不意味着每个任务上都更快，更不意味着部署时无需训练数据。库文档对KRR与SVR的比较也强调了稀疏性的区别；本讲不复制其特定机器的倍数结论。[核岭回归说明](#)

我们对每个模型先预热3次，再分别测单样本和120样本批次各15次，记录全部观测、中央值和四分位数。BLAS线程限制为1，但宿主机可能有其他负载。因此冻结结果中的批预测中央值约为线性0.093毫秒、RBF 0.408毫秒、多项式0.405毫秒，只是本次环境的观测，不能当作跨设备性能保证。单样本延迟与批平均每条成本不是同一个量。

数组计数只包含选定的预测相关ndarray：标准化均值与尺度，以及模型权重或支持向量、对偶系数、支持索引与截距。本次分别是56、2840、2700字节。序列化整个管线约1015、5150、4971字节。两者都不是进程峰值内存，忽略了Python对象开销、求解器工作区、其他数组和库本身。明确标注口径比给出一个没有定义的“内存大小”更重要。




图4 左图是120条批预测的15次测量中央值，误差线为四分位区间；中图仅为选定预测数组的KiB；右图是支持向量数。LinearSVC没有对应支持向量属性，记作不适用，不能伪造为零来制造优势。

10 为什么完整核矩阵会成为瓶颈

若保存一个float64的 $n \times n$ 矩阵，每个元素8字节，总共 $8n^2$ 字节。样本数增加10倍，矩阵元素数量增加100倍。十万样本对应约74.51GiB，仅这一个矩阵就超过许多机器的内存。GiB的换算使用 2^{30} 字节，不能和十进制GB混写。

这是完整稠密矩阵的存储估算，不等于每个核算法都一定一次分配整个矩阵。SVC通常使用缓存和分解策略，缓存可设上限；本讲指定64MiB缓存。KRR的稠密精确解则常需要矩阵分解，标准Cholesky时间随 n^3 增长。具体算法、稀疏结构与迭代求解会改变实现成本，不能把一个公式当成所有核方法的精确运行时间。




图5 横纵坐标均为对数尺度。蓝线是完整float64核矩阵，橙线是64维显式特征矩阵。虚线是8GiB参考线，只比较单个数组，不代表总训练内存。低维近似降低存储阶数，但也引入近似误差和额外变换参数。

11 用近似特征换取规模

Nyström方法先挑 m 个代表输入作为landmarks。令 $C = K(X, Z)$ 是 $n \times m$ 矩阵， $W = K(Z, Z)$ 是 $m \times m$ 矩阵，近似写为 $K \approx CW^\dagger C^\top$ 。符号 $\dagger$ 表示伪逆。通过分解 W 可以构造显式特征，使这些特征的内积近似原核；代表点的选择与小特征值处理会影响误差和稳定性。

随机傅里叶特征RFF对平移不变RBF核使用随机频率。对 $k(x, z) = \exp(-\gamma\|x - z\|^2)$ ，取 $\omega_j \sim \mathcal{N}(0, 2\gamma I)$ 、 b_j 在 $[0, 2\pi]$ 均匀分布，并定义：

$$\phi_j(x) = \sqrt{\frac{2}{m}} \cos(\omega_j^\top x + b_j).$$

对随机抽样取期望时， $\phi(x)^\top \phi(z)$ 对应目标核；有限 m 时有近似误差。此后可以在 m 维特征上训练线性模型。RFF频率不依赖训练坐标的具体取值，Nyström的landmarks来自训练输入。若在交叉验证中使用Nyström，代表点也必须在每折训练部分选取。[官方核近似说明](#)

本实验只比较训练集前160条的固定RBF Gram矩阵，不用测试标签。每种近似、每个 m 运行5个随机种子，报告相对Frobenius误差 $\|K - \Phi\Phi^\top\|_F / \|K\|_F$ 。Frobenius范数就是所有元素平方求和再开方，因而该量衡量矩阵整体相对偏差，而非分类错误率。

当 $m = 8$ 时，Nyström平均误差约0.4494，RFF约1.0378；到 $m = 64$ 时分别约0.0033与0.3908。在这个低维、小样本、特定尺度的问题里，Nyström更精确。这不证明它在相同时间预算下必胜，因为相同特征数并不代表相同变换成本，而且更低的核近似误差未必转化为更低的任务误差。五个种子的误差线是样本标准差，不是置信区间。




图6 横轴为近似特征数 m ，纵轴为相对Gram误差；点为5个随机种子的均值，误差线为样本标准差。总体改善不保证每个种子单调改善。图也不把随机近似当成免费且精确的替代品。

12 怎样形成一个可审查的选择结论

从一个合理的线性基线开始，先检查特征单位和训练管线。再给核模型明示的验证预算，同时选核参数和正则化。选择之后才打开测试评估，并把预测延迟与存储口径放在同一份报告中。若资源成本成为瓶颈，尝试近似特征时也要重新验证任务指标，不只是检查漂亮的核矩阵热图。

本次证据支持的结论很具体：在给定双环数据、固定搜索范围和相同9次验证预算下，核模型有效表达了非线性结构，而线性基线未能做到；核模型保留更多预测状态，批预测也更慢。结论不覆盖高维稀疏文本、分布变化、不同硬件和未经试验的样本规模。

继续学习Gaussian过程时，你会再次遇见 $K + \text{对角项}$ ，但用途会增加：除了预测均值，还要表达对未知函数的概率分布。相似的矩阵代数不等于完全相同的建模解释。本讲先把核选择和成本说清楚，下一讲再研究不确定性从哪里来、又不能保证什么。

练习

1. 两点距离由1变为2, RBF核值原为 $1/2$, 新的核值是多少? 写出 γ 。
2. 把所有坐标同时乘10, 怎样改 γ 可保持RBF核不变? 只放大一维又如何?
3. 取 $\gamma = 1, c_0 = 0$, 展开二维齐次二次核, 并写出含正确缩放系数的显式特征。
4. 用本讲二点例子验证核岭系数与三个查询点预测, 并解释训练误差为什么不为零。
5. 若目标采用平均平方误差, 样本数为200、 λ 为0.01, 应向本讲求解器传入多大 α ?
6. 50000样本的一个float64完整Gram矩阵是多少GiB? 64维特征矩阵呢?
7. 每族候选数相同为什么仍不等于所有意义上的公平? 至少给出三种预算口径。
8. 为什么支持向量数不能代替真实延迟? 为什么序列化文件大小不能写成峰值内存?
9. 近似核误差更低是否保证测试准确率更高? 给出检查流程。
10. 假设你看完测试集后增加了一个 γ 候选, 新的最佳测试分数还能当封存评估吗? 设计补救方案。

资料与复核

教材公式与原创手算使用标准线性代数推导; 代码接口按scikit-learn 1.8.0冻结, 2026年10月7日重新检索一级资料并实际对照。Nyström的原始工作为Williams与Seeger的[论文记录](#), RFF原始工作为Rahimi与Recht的[论文](#)。本讲图表、数据、实验结果及文字解释均为重新制作, 未复用来源图表。完整检索范围见sources.md与source-checks.json。