

第067讲 Gaussian过程回归

1 预测一条曲线也要说明哪里不确定

有12次带噪测量，我们想预测尚未测量位置的数值。一条平滑曲线可以给出答案，但不能单凭曲线形状知道它在哪些地方可信。如果训练点之间有一段空白，或者查询点远离所有观测，模型应怎样表达自己的不确定性？Gaussian过程回归从“对未知函数的可能形状建立分布”开始回答。

Gaussian即高斯，也称正态。Gaussian过程简称GP。本讲不是让你一次想象无穷多个随机变量，而是从有限几个输入点的联合高斯分布出发：先规定这些位置上的函数值如何一起变化，再在观测到部分带噪数值后计算剩余位置的条件分布。

本讲直接先修为第012、021、024至025、029、065讲。我们会重新解释均值、协方差、条件分布及矩阵维度，完整手算二点GP，并用从零Cholesky实现逐个比较库的均值、完整协方差和边际似然。你还会看到：一个模型给出很窄的区间，并不表示它考虑了所有可能的错误。

2 从一个随机数到一组相关随机数

一维高斯分布 $z \sim \mathcal{N}(\mu, \sigma^2)$ 用均值描述中心，用方差描述不确定程度。二维时，除了各自方差，还要说明两个量怎样一起偏离均值。协方差为正表示倾向于同向变化，为负表示倾向于反向变化，为零表示不相关；一般情况下，不相关不一定独立，但联合高斯变量满足这一特殊性质。

对 n 个位置 $x_1, \dots, x_n$ ，把未知函数值堆成向量 $f = (f(x_1), \dots, f(x_n))^T$ 。GP要求任意有限位置集合对应一个联合高斯：

$$f \sim \mathcal{N}(m_X, K_{XX}), \quad (m_X)_i = m(x_i), \quad (K_{XX})_{ij} = k(x_i, x_j).$$

$m(x)$ 是先验均值函数， $k(x, z)$ 是协方差核。GP不是把每个点独立地套一个正态分布；非对角协方差让一个位置的信息可以影响另一个位置。核还必须保证任意有限Gram矩阵半正定，否则就可能出现“某个线性组合的方差为负”的矛盾。

我们主要采用零均值 $m(x) = 0$ 和信号方差为1的RBF核。零均值不表示真实函数永远为零，而是没有数据影响的位置将回到这个先验中心。若问题存在明确趋势，应考虑非零均值、趋势核或其他结构；本讲故意使用带趋势真函数，观察简单假设外推时的限制。

3 核就是对函数形状的假设

RBF协方差写成：

$$k(x, z) = \sigma_f^2 \exp\left(-\frac{\|x - z\|^2}{2\ell^2}\right).$$

σ_f^2 控制函数值的先验方差， ℓ 控制距离多远仍保持相关。本讲固定 $\sigma_f^2 = 1$ 以便把长度尺度和噪声作用分开。小 ℓ 允许函数较快变化，大 ℓ 偏好缓慢变化。它们是函数分布的假设，不能仅凭“曲线越光滑越科学”选择。

给出一组有限输入后，先计算 K ，再从 $\mathcal{N}(0, K)$ 抽样，就得到这组位置上的随机函数值。把相邻点连起来可画出样本曲线，但计算对象仍是有限向量。图1每个面板用相同数量的网格点和三次随机样本，不表示只有三条可能函数。




图1 三组先验样本。横轴是输入 x ，纵轴是函数值；蓝橙紫分别是三次随机抽样。长度尺度从0.3增加到3后，曲线在相邻位置上更一致。图中未使用任何训练观测，展示的是模型在看数据之前允许哪些变化。

4 观测值与潜在函数值不是同一个量

传感器测到的 y_i 通常并非无噪声真值。我们假设：

$$y_i = f(x_i) + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma_n^2),$$

并假设各次测量噪声独立，也独立于潜在函数。于是训练观测向量的协方差是：

$$C = K_{XX} + \sigma_n^2 I.$$

为什么只加在对角？因为不同测量的噪声独立，协方差为0；每个观测自己的噪声方差为 σ_n^2 。如果同一输入位置被重复测量，两次读数也具有不同的独立噪声。因此这里的白噪声指示符应按观测索引理解，不能把“坐标相同”直接当成“同一次噪声实现”。

本讲生成器使用噪声标准差0.18，因此方差为 $0.18^2 = 0.0324$ 。把0.18直接传给期望方差的参数，会把噪声水平设得过大。标准差和方差的单位也不同：前者与目标值同单位，后者是目标单位的平方。

5 联合分布里有哪些矩阵

现在有 q 个待预测输入 X_* 。训练观测 y 和这些位置的潜在函数值 f_* 组成联合向量：

$$\begin{pmatrix} y \\ f_* \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} m_X \\ m_* \end{pmatrix}, \begin{pmatrix} C & K_{X*} \\ K_{*X} & K_{**} \end{pmatrix} \right).$$

C 为 $n \times n$ ， K_{X*} 为 $n \times q$ ， $K_{*X} = K_{X*}^\top$ 为 $q \times n$ ， K_{**} 为 $q \times q$ 。交叉块里不加测量噪声，因为训练噪声与待预测的潜在函数独立。 K_{**} 里也暂不加测试测量噪声，因为此处求的是 f_* 。

设 $\tilde{y} = y - m_X$ 。条件分布公式给出：

$$\begin{aligned} f_* | X, y, X_* &\sim \mathcal{N}(\mu_*, \Sigma_*), \\ \mu_* &= m_* + K_{*X} C^{-1} \tilde{y}, \\ \Sigma_* &= K_{**} - K_{*X} C^{-1} K_{X*}. \end{aligned}$$

均值是先验中心加上由观测推动的修正，修正量通过交叉协方差传播。协方差是先验不确定性减去观测提供的信息。矩阵乘法也可作维度验算： $q \times n$ 乘 $n \times n$ 再乘 $n \times q$ ，最终一定是 $q \times q$ 。

不死记公式的一种推法

在零均值情形，定义 $u = f_* - K_{*X} C^{-1} y$ 。计算它和 y 的协方差：

$\text{Cov}(u, y) = K_{*X} - K_{*X} C^{-1} C = 0$ 。因为 u 与 y 仍联合高斯，所以二者独立。

因此给定 y 后， u 的分布保持原样，而 $f_* = K_{*X} C^{-1} y + u$ 。第一项已是确定向量，成为条件均值；直接展开 u 的协方差便得到上式的 Σ_* 。这个推导说明了为什么“减去信息项”合理，也说明联合高斯假设在何处被真正使用。公式可对照 GPML 第2章式2.22至2.24。[GPML回归章节](#)

6 二点GP的完整手算

取训练输入 $x_1 = -1, x_2 = 1$ ，观测 $y = (1, -1)^\top$ 。选择 $\ell = \sqrt{2/\log 2} \approx 1.6986436$ 、信号方差1、噪声方差1/4。两训练点距离为2，核值正好为1/2：

$$K = \begin{pmatrix} 1 & 1/2 \\ 1/2 & 1 \end{pmatrix}, \quad C = \begin{pmatrix} 5/4 & 1/2 \\ 1/2 & 5/4 \end{pmatrix}.$$

行列式为 $25/16 - 1/4 = 21/16$ ，于是：

$$C^{-1} = \frac{16}{21} \begin{pmatrix} 5/4 & -1/2 \\ -1/2 & 5/4 \end{pmatrix}, \quad C^{-1} y = \begin{pmatrix} 4/3 \\ -4/3 \end{pmatrix}.$$

对点 $x_* = 0$ ，与每个训练点的核值均为 $a = 2^{-1/4} \approx 0.8408964$ 。于是均值为 $a(4/3) + a(-4/3) = 0$ 。这不是“没学到东西”，而是两侧观测在对称假设下正好抵消。

向量 $(1, 1)^\top$ 是 C 的特征向量，对应特征值 $7/4$ 。所以 $C^{-1}(a, a)^\top = (4a/7, 4a/7)^\top$ ，潜在方差为：

$$v_* = 1 - \frac{8a^2}{7} = 1 - \frac{8}{7\sqrt{2}} \approx 0.1918779644.$$

若问题是预测中点下一次带噪测量，则 $y_* = f_* + \varepsilon_*$ ，需要再加一次独立物理噪声方差，得到 **0.4418779644**。两者均值相同，方差不同。实际从零实现与 sklearn 的潜在均值、方差逐项一致；程序只因浮点舍入输出约 2.7×10^{-17} 的均值。

这个例子最值得检查的不是小数位数，而是三个决定：训练对角加了噪声，交叉核没有加噪声，预测潜在函数时没有再加噪声。多数“我与库差一个固定数”的问题就藏在这里。

7 Cholesky让公式变成可靠代码

公式写 C^{-1} ，实现不应真的先形成完整逆矩阵。对正定 C 做Cholesky分解 $C = LL^T$ ， L 为下三角矩阵。先解 $La = y$ ，再解 $L^T\alpha = a$ ，得到 $\alpha = C^{-1}y$ 。预测均值为 $K_{*X}\alpha$ 。

再解 $LV = K_{X*}$ ，后验协方差写成 $K_{**} - V^TV$ 。这样复用同一个分解，数值与计算效率都更合适。本讲实现保留完整协方差与库比较，图上的阴影只使用其对角元素。只比较标准差向量会漏掉查询点之间相关结构的错误。

噪声与jitter的目的不同

重复输入、极长长度尺度或浮点舍入可能让矩阵难以分解。jitter是在训练协方差对角加上的很小数值项 δI ，用于稳定求解。噪声方差描述物理观测的不确定性；jitter描述实现为稳定而做的扰动。本讲标准实验使用 $\delta = 10^{-10}$ ，手算用 $\delta = 0$ 以保留精确分数。

训练时实际分解 $K + (\sigma_n^2 + \delta)I$ ，但预测下一次测量时只加物理噪声 σ_n^2 ，不再把数值jitter解释为新测量误差。若必须把jitter加到很大才可运行，应检查输入、核参数和条件数，而不是悄悄把它当成已知噪声。

三条输入 $[0, 0, 1]$ 在零噪声、零jitter时产生严格奇异核矩阵，本次Cholesky确实失败。显式加 10^{-10} 后得到有限解。程序不自动增加jitter，也不吞掉异常，因此实验记录能说明它实际解了哪个问题。

后验对角有时会出现舍入级负数。代码仅允许尺度相关的 10^{-10} 容差内负值截为0，更大的负值立即报错。不能把任何负方差都截断为0，再声称模型非常自信。

8 图上的两条区间带分别回答什么

对一个固定查询点，若模型与超参数固定，潜在函数的条件标准差为 $s_f = \sqrt{v_*}$ 。常用的约95%点态区间为 $\mu_* \pm 1.96s_f$ 。下一次观测的标准差是 $s_y = \sqrt{v_* + \sigma_n^2}$ ，所以观测区间更宽。

“点态”指每个单独位置的条件概率，不等于整条连续曲线同时落在所有阴影内的概率。若画241个点，也不能直接说“整条函数有95%概率在带内”。若长度尺度和噪声是从数据估计出来的，通常的插入式区间还没有积分掉超参数不确定性。




图2 蓝线为后验均值，蓝色阴影是潜在函数点态区间，橙色外层是下一次观测点态区间，黑点为训练观测，虚线为仅用于评估的真函数。中间训练缺口附近不确定性增加；域外均值逐渐回到零先验。阴影不是任何模型错误都能覆盖的保证。

对于固定输入、核超参数与噪声，后验协方差公式不含观测值 y 。把所有目标都乘100而不改变这些假设，后验均值会改变，方差却不变。若代码重新优化超参数，方差可间接变化；这与固定超参数公式是不同的问题。该性质说明：GP方差衡量模型内的不确定性，未自动识别所有偏离模型假设的信号。

9 长度尺度和噪声怎样改变结论

原创训练数据共有12个输入，范围为 $[-3, 3]$ ，中间 $(-0.8, 0.7)$ 没有观测。生成函数是 $\sin(1.35x) + 0.18x$ ，噪声标准差0.18。该真函数只供评估与作图，拟合代码只读取训练的 x 和 y 。插值评估用 $[-3, 3]$ 的121点，外推评估用 $[3.2, 6]$ 的121点。

固定噪声方差0.0324，比较长度尺度0.25、1、3。短尺度允许快速变化，但训练缺口处难以从远处借信息；长尺度把明显曲折解释得过于平滑，可能输出既错误又很窄的区间。




图3 三幅图仅改变长度尺度，虚线标记训练区间边界，阴影只表示潜在函数点态区间。右图的长尺度在训练范围内就可能漏掉变化，越过边界后也不会自动识别真实的正弦加趋势机制。

固定长度尺度1，再把噪声方差改为0.0001、0.0324、0.36。很小的噪声要求函数几乎穿过每个观测，可能把测量扰动解释成函数起伏，并给出过窄区间。大噪声让模型愿意忽略一些目标差异，但也能抹掉真实结构。不能单纯因为某条曲线最贴黑点就认为其噪声估计最好。




图4 三幅图仅改变假定物理噪声方差。左图低估了生成噪声，训练点附近可能过度自信，部分域外预测超出统一的负3至3纵轴范围；中图使用已知生成噪声作为教学参照；右图的较强平滑伴随更宽的潜在不确定性。真实任务通常不知道生成噪声，需要额外证据或模型估计。

10 边际似然为什么不等于训练误差

GP把潜在训练函数值积分掉后，训练观测服从 $\mathcal{N}(0, C)$ 。对数边际似然为：

$$\log p(y | X, \theta) = -\frac{1}{2} y^\top C^{-1} y - \frac{1}{2} \log |C| - \frac{n}{2} \log(2\pi).$$

θ 表示长度尺度、信号方差、噪声等超参数。第一项考察当前协方差下观测向量有多难解释；第二项来自概率密度归一化，与允许的数据变化体积有关；第三项是固定样本量下的常数。第二项常被称为复杂度项，但它本身可正可负，不能误读为永远非负、随某个参数严格单调的普通正则化惩罚。

如果只追求训练插值，容易把噪声压得很小，得到极尖锐的拟合。边际似然同时考虑整个观测向量在模型分布下的密度，而不只是残差。然而最大化边际似然仍是模型内选择，不证明核族正确，也不保证找到了全局最优。[GPML超参数章节](#)

利用 $C = LL^\top$ ，有 $\log |C| = 2 \sum_i \log L_{ii}$ ，因此无需显式求行列式或逆。二点手算中，数据项为 $-4/3$ ，行列式项为 $-\frac{1}{2} \log(21/16)$ ，常数为 $-\log(2\pi)$ ，合计约 -3.3071772575 。从零程序与库一致。

实验绘制46个长度尺度与35个噪声方差组成的训练边际似然网格，再单独固定物理噪声0.0324，只优化长度尺度。sklearn从预设起点及两个额外随机起点搜索，得到长度尺度约1.28243、LML约-6.16236。网格仅作解释，优化结果与评估标签无关；多起点也不构成全局最优证明。




图5 左图横轴长度尺度、纵轴噪声方差，颜色为仅用训练数据计算的LML；为可读性，显示色值低于负100处截断，原始JSON保留未截断值。右图固定噪声后分开画数据项、行列式项与总值，竖虚线标记优化出的长度尺度。

11 与sklearn对照时必须对齐的约定

本讲固定normalize_y为False、零均值、RBF信号方差1。手算与五组机制实验都设optimizer为None，不允许库偷偷改变你刚手算的核参数。训练对角的alpha设为物理噪声方差加jitter。实际241个查询点完整比较中，均值最大差约 1.16×10^{-11} 、协方差最大差约 1.15×10^{-13} 、LML最大差约 5.94×10^{-10} ，验收容差统一为 10^{-8} 。

alpha与WhiteKernel的区别尤其重要。仅使用RBF并把训练噪声传入alpha时，predict返回的是该核对应潜在过程的协方差，不会自动给新点加训练alpha。若用RBF加WhiteKernel作为核，返回的测试对角包含WhiteKernel噪声。两种方式可给出相同训练协方差与预测均值，却有不同测试方差。

GaussianProcessRegressor 1.8.0接口

本次对照用RBF加alpha等于0.0324加jitter，与RBF加固定WhiteKernel等于0.0324且alpha仅为jitter比较。预测均值差为0，测试方差差恒为0.0324。不要先使用含WhiteKernel的预测标准差，再无条件加一次噪声，那会重复计算。同样，训练时同时把同一份物理噪声放进alpha和WhiteKernel也会重复计算。

12 外推和区间可信度的诚实报告

固定长度尺度	插值真函数RMSE	外推真函数RMSE	外推网格真值落入潜在95%带的比例
0.25	0.1623	1.1996	0.8512
1	0.0870	1.2243	0.8430
3	0.3149	2.8105	0.1736

这张表中的比例是一次确定真函数、固定网格的点态区间包含率。网格相邻点相关，真函数也不是从前GP先验随机抽来的，因此不能把它当成独立伯努利试验、给出普通二项置信区间，或声称已验证频率学95%覆盖。它适合暴露失配，不适合证明普遍覆盖定理。




图6 左图比较插值与外推的真函数RMSE，右图比较固定网格真值落入潜在点态带的比例。灰虚线只是0.95参照。长尺度外推表现差且区间包含率低，提醒我们不确定性始终依赖先验与核假设。

在零均值RBF模型里，远离所有训练点时交叉核趋近0，预测均值趋近0，潜在方差趋近先验方差1。真实函数若含持续增长趋势，回到0可能越来越错。方差回到1只说明模型回到了自己的先验，不说明它已经为一切未知机制留出足够空间。

若要检验覆盖性质，应设计重复数据生成、明确目标是潜在函数还是未来观测，并在模型正确与失配两种条件下报告。若要改进外推，应先讨论领域结构，再比较均值函数、周期核、趋势项或其他候选，不能看完同一外推集后反复修改模型，再把它叫作未见评估。

13 稠密精确GP的计算边界

标准稠密GP需要存储多个 $n \times n$ 相关数组，单个float64矩阵就是 $8n^2$ 字节。Cholesky主要运算量约 $n^3/3$ ，所以样本数翻倍，主要分解量约变8倍。一次超参数优化通常要重复分解许多次，成本不止最后一次拟合。

若已有分解，计算一个查询点的均值需要交叉核与系数相乘；方差还涉及三角求解，通常比只给均值更贵。计算 q 个点的完整协方差还要形成 $q \times q$ 输出，因此查询网格也可能造成显著内存压力。图7画的是理论数组大小与运算量，不是伪装成实测的时间曲线。




图7 左图是一个float64训练协方差矩阵的GiB，右图是Cholesky主导运算数量 n 的三次方除以3。两者都使用对数坐标。完整训练需要不止一个数组，实际速度还依赖硬件、实现与超参数优化次数。

大样本问题常需稀疏、诱导点、结构化核或其他近似。引入近似后既要看均值误差，也要检查方差是否仍有你想赋予它的含义。本讲只验证小样本稠密精确回归，不把这一实现包装为大规模GP系统。

练习

1. 三个训练点、两个查询点时，写出联合协方差各块的形状。
2. 为什么训练协方差加噪声而交叉块不加？同一输入的两次测量怎样处理？
3. 重做二点手算的逆矩阵、均值、潜在方差与观测方差。
4. 噪声标准差为0.3时应加多少对角量？数值jitter需要加到未来观测方差吗？
5. 固定核参数时把 y 全部取反，后验均值与协方差怎样变化？若再优化参数呢？
6. 用Cholesky对角写出log determinant，并计算二点例子的LML三项。
7. 为什么含WhiteKernel的预测不能再无条件加一次noise variance？
8. 长度尺度很大且噪声很小，为什么可能错误而自信？用图与数值解释。
9. 一条曲线上95%的网格点落在带内，能推出未来每个个体有95%保证吗？
10. n 由1000增为10000，一个矩阵的存储和主导分解运算分别增加多少倍？
11. 设计一个不泄漏评估集的GP外推比较，写明均值假设、核候选、选择准则与停止条件。

资料与复核

2026年10月7日重新读取GPML作者网站的第2章与第5章，以及scikit-learn官方文档。本讲推导、手算、数据与图均重新制作。当前stable文档可能随版本改变，实验接口冻结在1.8.0；完整来源记录、版本与实际运行证据随单元提供。GP的介绍与核类型可进一步参看[官方用户指南](#)。