

第068讲 练习答案与讨论

1 两个概率指标的完整计算

真实标签依次为1与0，预测概率依次为0.8与0.3。第一个样本为正类，似然取0.8；第二个样本为负类，似然取 $1-0.3=0.7$ 。联合似然为0.56，负对数联合似然为约0.579818；除以两个样本得到平均对数损失0.289909。

Brier分数是 $[(0.8-1)^2+(0.3-0)^2]/2=(0.04+0.09)/2=0.065$ 。它不是先求有符号误差再平方；若那样做，正负误差会抵消。准确率在阈值0.5下等于1，但没有表现出模型对正确事件的信心程度。

若预测改成0.51与0.49，平均对数损失为 $-\ln(0.51)$ ，约0.673345；Brier分数为0.2401。两个样本仍都猜对，所以准确率仍为1。选择概率模型时只优化准确率，可能忽略重要的概率质量变化。

2 常数基线的校准反例

常数模型把所有产品赋予训练集异常率，预测与实际测试总体比例可能相近。由于所有样本落入很少的概率箱，箱平均偏差很小，ECE可接近0。本次ECE约0.004444，但ROC AUC恰为0.5，说明没有把高风险产品排在低风险产品前面。

因此“校准好”与“能区分个体”不是同义词。可靠性图、对数损失或Brier分数和排序指标应围绕任务一起解读。更换箱数还可能改变ECE排名，所以不能对几个小数位的差别过度解释。

3 为什么不把森林改成最终选择

协议规定使用验证对数损失选方案。15近邻验证损失0.554036，小于森林0.580677，因此选择发生时近邻获胜。测试集后来显示森林0.544137低于近邻0.560582，这是新的审计观察。如果据此切换方案并继续把同一测试分数当作该切换流程的无偏评估，测试答案就参与了模型选择。

诚实的做法是保留原选择，报告排名变化，提出有边界的新假设。若业务允许重新选型，需要新的独立评估数据或预先设计的嵌套评估。仅改变量名，把test.csv称为validation2.csv并不会生成新的独立证据。

这并不意味着森林结果必须隐藏。公开完整方法族代表的测试表现有利于理解失败与稳定性，条件是清楚区分“事前选择依据”与“事后探索观察”。

4 配对bootstrap为什么共享索引

考虑两个测试样本，一个很容易、一个很困难。两个模型的损失都受这种样本难度影响。如果独立重采样两组预测，某次可能抽到A的一堆困难样本和B的一堆容易样本，就把原本配对的比较改成了不公平的两批数据。

先计算每行损失差 d_i ，再抽取 d_i 的索引，与同时抽取两组预测的相同索引等价。若两模型输出完全相同，则每个 d_i 严格为0，任何重采样的均值与区间都为0。测试中的这一不变量能发现很多配对实现错误。

本次森林相对逻辑回归的平均差为-0.095529，百分位区间[-0.125021,-0.066213]；近邻相对逻辑回归为-0.079084，区间[-0.120335,-0.038278]。区间条件于这些已拟合模型与当前数据机制，不是重新抽训练集和重新调参后的全流程区间。

5 计算预算相同吗

不完全相同。三次森林拟合与三次逻辑回归拟合的算术量不同，训练样本保留、预测路径和模型大小也不同。本讲可以准确声称“每族获得三个预定配置的相同搜索次数预算”，同时公开实际耗时。不能声称相同CPU时间或相同能耗。

若改用相同墙钟预算，要说明硬件、线程数、终止策略和调度方式。搜索算法也会影响这个预算内能尝试哪些配置。公平不是一个无需定义的标签，而是一组适合当前问题的可审计约束。

6 解释要求和容量限制会怎样改变项目

若部署设备只能保存很小的模型，先明确可接受字节上限、峰值内存与延迟上限。本实验pickle大小仅对应保存文件，不能替代实际设备加载测试。若实时请求一次只来一行，本讲225行批预测中位数也不能直接转成单请求延迟。

若解释要求严格，应明确解释给谁、解释什么。线性系数可以说明在模型内其他标准化输入固定时的对数几率方向；这不提供因果结论，也可能因模型遗漏交互而误导。补充交互特征后需要重新执行预先声明的比较协议。不能因为“线性可解释”就跳过模型失配检查。

7 失败样本为什么不一定是坏数据

case_0266真实标签为1，15近邻预测约0.066667，因此损失约2.708050。生成器真概率为0.160580，说明这个标签是较少见但完全允许的Bernoulli结果。高损失既可能来自模型概率偏低，也可能来自一个本就难预测的随机事件，两者不能仅靠一次标签完全区分。

case_0748真概率约0.472888，近邻预测0.133333，提示局部平均可能没有很好反映该位置的发生率。可以检查其训练邻居、距离构成和无关列，但这是后续诊断，不应把这个样本删除后宣布性能提高。

真实业务没有p_true列时，更要避免把模型错误都归咎于标注。优先核查数据生成、预测时点和业务流程，记录能够验证的原因，而非编造解释。

8 数字复核题

测试集225行，近邻正确154行，所以准确率 $154/225=0.684444$ 。Wilson区间约为 $[0.621056, 0.741640]$ 。森林正确168行，准确率0.746667。两个比例区间发生重叠，不等价于某个配对假设检验的结论；检验对象与配对结构必须另行定义。

常数、逻辑、森林、近邻的Brier分数分别约为0.243259、0.225158、0.181501、0.190163。与主对数损失方向在本例相同，但未来数据不必保持相同排序。不同损失表达不同惩罚，所以必须先选择主指标再看数字。

9 合格结论范例

在固定合成任务、450/225/225拆分和每族三配置预算下，15近邻由验证对数损失选中，测试损失0.560582，准确率0.684444。森林在测试上取得更低损失0.544137，显示单次验证选择存在波动。非线性候选较线性基线的优势与生成器交互结构一致，但不构成跨任务通用排名。

后续应在新的评估设计中考察带交互特征的线性模型、重复拆分稳定性和目标硬件上的成本。当前概率校准图的箱样本量有限，bootstrap区间不涵盖重训与选参变化，因此不能把这些数字写成生产系统可靠性保证。

10 常见错误的定位

若逻辑回归、近邻使用全900行拟合StandardScaler，预处理已接触封存集。即使没有标签，也违反本实验的训练隔离规则。修复时把缩放放进Pipeline，在训练集fit，在其他拆分仅transform。

若近邻概率0导致 $\log(0)$ 异常，应先理解数学上的无穷惩罚，再使用一致的浮点裁剪；不能删掉这种样本。若单类切片AUC报错，不应伪造0.5；报告None并说明未定义。若空校准箱没有样本，不应画成事件率0。

若普通测试通过而-O失败，多半把业务检查藏进assert。参考实现使用显式异常，普通与优化模式均执行63项检查。最后，不要把测试通过理解为模型科学结论已经被证明；它只是保证本教材承诺的计算与记录一致。