

# 第069讲 练习答案与讨论

## 1 四点协方差与主轴

四点各列和均为0。第一列平方和 $4+1+1+4=10$ ，第二列 $1+4+4+1=10$ ，交叉乘积 $2+2+2+2=8$ 。因此样本协方差为 $[[10/3, 8/3], [8/3, 10/3]]$ 。

将(1,1)代入，乘积为(6,6)，归一化方向为 $(1,1)/\sqrt{2}$ ，特征值6。将(1,-1)代入，乘积为 $(2/3, -2/3)$ ，对应特征值 $2/3$ 。总方差为 $20/3$ ，第一方向保留比例为 $6/(20/3)=0.9$ 。

第一和第二点的第一分数均为 $3/\sqrt{2}$ ，后两点均为 $-3/\sqrt{2}$ 。第一点重构(1.5,1.5)，第二点也是同一个位置；原来区分这两点的信息藏在被丢弃的第二分数中。

## 2 特征值与重构误差的分母

协方差使用 $n-1$ 分母，因此特征值度量的是样本方差。总平方残差把所有 $n$ 个样本的残差加起来，等于 $(n-1)$ 乘丢弃特征值之和。本例为 $3 \times 2/3 = 2$ 。若问平均每样本平方距离，再除以 $n=4$ ，得到0.5。

如果有人说误差应是 $2/3$ ，可能把丢弃样本方差误当成平均每样本误差。若有人得到0.25，可能又除以 $d=2$ ，报告的是每个标量元素的MSE。三个量都可有定义，但不能在没有说明分母和单位时互相替换。

## 3 形状核验

$X$ 为 $n \times d$ ，训练均值为长度 $d$ 的向量，中心化矩阵仍为 $n \times d$ 。公式中的 $V_k$ 为 $d \times k$ ，每列一根主轴。 $Z = X - \bar{X}$ ， $V_k$ 为 $n \times k$ 。重构 $Z V_k V_k^T$ 回到 $n \times d$ ，再加训练均值。

NumPy的 $vt$ 为右奇异向量转置，程序 $components = vt[:, k]$ 的形状为 $k \times d$ 。因此transform写 $(X - \text{mean}) @ components.T$ 。把 $T$ 遗漏后，有时维数直接报错；当 $d$ 恰好等于 $k$ 时却可能静默产生错误结果，所以仅靠“代码能运行”不足以验收。

## 4 符号翻转与重复特征值

将一根主轴 $v$ 换为 $-v$ ，同时分数 $z$ 也变为 $-z$ 。重构 $(-z)(-v)^T = zv^T$ 不变。最简单可靠的比较对象是投影矩阵 $V V^T$ 、重构结果与目标值，而不是逐元素要求同号。

若某组特征值相等，该特征子空间中不同的正交基都可能正确。假如截断保留整个重复组，投影矩阵仍可一致；若 $k$ 把这个组切开，最优 $k$ 维子空间也可能不唯一。此时要以目标值与合法最优空间判断，不应强行让一个实现模仿另一个的轴。

符号约定只是使阅读更稳定。它不能给主轴赋予自然界固定的正方向，也不能将某个载荷符号解释为因果作用。

## 5 为什么最大方差就是最小残差

中心化样本可以写成投影分量与正交残差之和。两部分垂直，平方长度相加等于原始平方长度。原始数据固定，所以投影平方长度越大，剩余平方残差越小。

对所有样本求和，投影平方长度为 $(n-1) \times \text{trace}(V^T S V)$ 。当 $V$ 包含 $k$ 根正交方向时，最大值由最大的 $k$ 个特征值之和取得。故训练最小SSE等于 $(n-1)$ 乘所有未保留特征值之和。这个推导依赖欧氏正交投影与平方距离；换成绝对误差或非线性曲面，不能直接照搬。

## 6 测试集为什么不能自中心化

训练PCA定义一个固定坐标系：原点是训练均值，方向是训练主轴。新数据应投到这个同一坐标系，才可比较它与训练分布。每批测试各自减均值，相当于每次移动原点，掩盖样本整体漂移。

本例给测试 $x_0$ 加3后，正确投影的均值约为 $(2.212, -0.974)$ 。测试自中心化则数学上必然把均值变为0，漂亮的零均值不是模型稳健的证据。无标签变换也可能泄漏评估分布；“没有用 $y$ ”并不足以证明隔离正确。

## 7 标准化是否总该使用

不总是。PCA的距离会受测量单位影响，标准化可以让不同量纲的相对变化获得更接近的权重。但如果某一行几乎全部是微小噪声，标准化可能把噪声放大。如果物理单位本来就具有统一含义，例如同一个传感器阵列的同量纲读数，保留原始尺度可能更符合目标。

应先确定要保留绝对能量、相对变化还是预测信息。标准化的均值与标准差只在训练集估计。白化是在主成分空间把分数进一步缩放到单位方差，与原始列标准化不同，也不是本讲实验自动执行的步骤。

## 8 99%以上方差为何仍可预测失败

反例中大方差方向是与标签无关的随机变量，小方差方向决定标签。PCA没有看标签，按照原始单位的平方距离目标保留大方差方向，完全满足自己的数学定义。分类器失去小方差信号后只能接近随机猜测。

本次第一主成分保留比例约0.998431，PC1分类准确率0.48，两输入分类准确率0.99。结果不推翻PCA最优性，而是说明“最小输入重构误差”与“最小预测误差”是两个目标。如果用PCA为监督模型预处理，应在严格隔离的验证流程中检验 $k$ 及缩放方式。

## 9 结果复核

六维数据保留两维的训练SSE为28.221553，训练样本数320。因此平均每样本平方距离为 $28.221553/320=0.088192$ 。丢弃特征值之和约0.088469，再乘319也得到相同SSE。

测试平均平方距离约0.088299，接近但不等于训练值。库投影与特征值误差本次为0，测试重构最大差约 $3.6 \times 10^{-15}$ 。打印出的0是浮点计算结果在当前精度下完全一致，不是宣称所有PCA实现永远逐位相同。

全维重构残差约 $10^{-29}$ ，属于舍入量级。若出现明显非零残差，应检查是否误用了测试均值、是否忘记加回均值、是否把V和 $V^T$ 弄反。若常数数据解释比例是NaN，应明确处理总方差为0，而不是把NaN当成可解释的统计量。

## 10 可接受的实验结论

在原创六维线性低秩数据上，两主成分保留约99.7264%训练方差，测试平均平方重构距离约0.088299，从零SVD、协方差eigh与库输出在数值容差内一致。原始尺度、中心化位置与评价目标会改变结果。高方差反例显示，保留方差比例无法保证保留分类信息。

进一步研究可以改变噪声、离群点或测量单位，但应声明新的数据机制与评价目标。不能仅看到一个二维图很清楚，就把它解释为数据真实只有两个自然类别；后续流形与聚类章节会继续检查这类推断的边界。