

第070讲 练习答案与讨论

1 两种距离为何不同

卷曲表面的两层可以在三维空间里很接近，但沿表面走到对方的位置要绕过较长路径。输入算法使用的欧氏距离允许直线穿过层间空隙，表面内在距离不允许离开表面。两种距离的最近邻集合与全局排序因此可能不同。

本生成器 $x(t,h)=(t \cos t, h, t \sin t)$ ， t 方向速度平方为 $(\cos t - t \sin t)^2 + (\sin t + t \cos t)^2 = 1 + t^2$ 。其平方根积分得到 $s(t)=0.5[t\sqrt{1+t^2} + \operatorname{asinh} t]$ 。 h 方向单位速度且与 t 方向正交，所以 (s,h) 是已知的等距展开坐标。

这项真值来自生成器，真实数据通常只能估计邻域图或测地距离。不能把本例中能画出真实展开图的便利条件，偷偷当作所有流形数据都具备的事实。

2 手算R1与T1

点ID依次0、1、2、3。原位置0、1、3、7给出的最近邻为1、0、1、2。映射位置0、3、1、7给出的最近邻为2、2、0、1。每个点的最近邻均被替换，所以四个交集大小都是0， $R1=0$ 。

每个新增近邻在原空间都排第2。总惩罚为 $4 \times (2-1)=4$ 。 $n=4$ 、 $k=1$ 时归一化分母 $nk(2n-3k-1)=4 \times 1 \times 4=16$ ， $T1=1-8/16=0.5$ 。

因此 $T1=0.5$ 并不表示一半最近邻保留。 T 考虑新近邻到底错得多远， R 只计集合重合。研究报告必须写清指标定义，不能把一个看起来像百分比的数自动解释为准确率。

3 三个参数为什么都不是簇数

t-SNE的perplexity与邻居概率分布的熵有关，可以理解成平滑有效邻居数。它通过每点局部尺度影响哪些关系重要，而不是命令算法分成几个组。

UMAP的 $n_neighbors$ 是构建局部结构时使用的邻居范围，改变局部与较大尺度关系的权衡。 min_dist 控制低维布局允许点靠得多紧，影响紧凑程度。它不是原始空间的最小距离阈值，更不是DBSCAN那样的邻域半径。

即使某参数值刚好等于图中看见的团块数量，也只是巧合，不能据此推断参数在控制真实类别数。要研究聚类，应另有明确目标与验证，不能直接把二维图上看见的岛屿当作标签。

4 高局部可信度与低全局相关不矛盾

t-SNE种子0、perplexity30的T10约0.996195，表示二维新增近邻在原输入空间的排名惩罚很小。它没有要求每一对远距离按同一比例保留，也没有承诺恢复卷曲纸面的内在测地关系。

该配置的10邻域重合比例为0.8325，内在全局距离秩相关约0.2931。三个数回答三件不同的事：新增近邻错得多远；近邻集合重合多少；全体样本对在表面上的距离排序保留得怎样。它们可以同时成立。

若作者只报告最大的一个指标，会隐藏方法的重要限制。更合格的做法是根据研究目标事先选择主诊断，再将其他指标作为边界和机制说明。

5 团块面积和间隔如何解释

不能直接把二维团块面积对应原始方差或样本密度。t-SNE与UMAP使用局部尺度、吸引和排斥，可能让不同密度的区域看起来大小接近，或因参数改变而松散、紧凑。各图自动坐标范围还会进一步改变视觉比例。

图5只将min_dist从0.1改成0.8就改变布局，原始320个样本完全没有变化。由此推断“群体分布更分散了”会把算法参数作用误当成数据变化。应回到原空间计算有意义的方差、密度或距离，再说明选择的尺度。

两个团块之间的远距离也不是普适尺子。若要比群体差异，先定义原始特征和度量，再做适当统计或预测验证；可视化可辅助展示，不能取代这一步。

6 Gaussian负对照证明了什么

负对照从单一六维标准Gaussian生成，没有预设混合类别。有限样本可能出现局部间隙，二维优化会进一步改变点的排列。若仅凭图上出现空白就宣布真实亚群，负对照会暴露这种推断过于宽松。

它不证明一切二维簇都是假象，也不要求每张负对照图必须出现明显分团。负对照的作用是检查某种解释规则是否会对本来没有预设类别的数据也轻易作出同样结论。实际研究仍需原空间检查、标签外部验证和独立样本。

本次两种子负对照T10约0.9139与0.9075，R10约0.4996与0.4850。即便局部排名指标不算很低，也不能凭它创造真实类别标签。

7 exact和固定种子保证什么

t-SNE的exact指定计算路线，没有采用本实现的Barnes-Hut加速近似。它不意味着优化目标是凸的，也不保证全局最优，更不保证二维表示保存了真实几何。

固定种子与单线程有助于在已固定版本中重现随机过程。UMAP第一次执行可能含Numba编译，耗时不可与后续运行直接做速度排名。跨版本、硬件、依赖或并行设置改变后，应重新验证，不应声称所有环境逐位相同。

两个种子只能展示有限敏感性，不能代替更充分的稳定性研究。特别是当最终科学结论随种子改变时，应暂停命名类别，先核查原空间和数据处理流程。

8 样本外映射和泛化

本实验对全部固定点做探索性映射，再计算同一批点的几何指标。没有假装这些是未参与拟合的新点，所以不把T或R称为测试准确率。

scikit-learn本讲使用的TSNE没有一般transform方法，不能简单调用transform给新点坐标。UMAP有样本外变换接口，但本讲未评价它的泛化。若要把新数据嵌入，需在训练数据fit变换，对独立样本评估邻域、任务表现与漂移，并确保预处理也只在训练集学习。

如果二维表示随后用于分类或聚类验证，不能先用全部数据拟合表示，再宣称后面的测试数据完全未见。整个流程都需要纳入隔离设计。

9 为一个新分群结论设计核查

先写清楚每点代表谁、预测或测量发生在何时、哪些列可用。检查缺失值填补、缩放、批次、设备、重复实体和潜在标签泄漏。随后在原空间定义距离和邻域，观察图中同一团的点是否真的互为近邻。

固定一组合理参数与多个种子，保存所有结果，检查拟报告结论是否保持。设计单峰或打乱结构的负对照，判断算法是否在弱结构中也产生同样外观。若确实需要类别结论，增加独立标签、外部机制、重复实验或新的样本支持，避免用同一图既发现又证明。

人群、健康或其他高影响领域尤其不能把可视化自动当成实际分类依据。图可以提示值得调查的关系，不应替代经过验证的测量与决策过程。

10 可接受的总结

在320点连续卷曲表面上，t-SNE与UMAP的参数和种子会改变二维布局。某些配置具有很高的输入邻域可信度，同时真实表面全局距离排序保持较差。Gaussian负对照说明局部空隙不足以证明真实混合类别。所有结论限于当前数据、预设配置和所选距离定义。

后续工作应围绕要回答的具体研究问题，继续核验原空间关系和结论稳定性，而不是简单继续调参直到图像符合预期故事。