

第072课答案与验收说明

1 四点层次手算

对0、1、4、7，第一步合并0与1，高度1。新簇 $A = \{0, 1\}$ 与4的single、complete、average距离为3、4、3.5；与7的距离分别为6、7、6.5。4与7距离3，因此complete和average明确先合并4与7；single出现平局，本课按簇ID选择4与7。

最后 A 与 $B = \{4, 7\}$ 的跨簇距离是4、7、3、6，得到single高度3、complete高度7、average高度5。Z矩阵的前两行均为 $[0, 1, 1, 2]$ 、 $[2, 3, 3, 2]$ ；最后一行的子簇ID是4与5，簇大小4，只有高度因规则不同。

高度3.2切树时，single全部已合并为1组；complete与average仍为2组。single后两次合并都在高度3，没有对应两组的严格高度区间；按明确合并顺序取 $n-K=2$ 次合并仍可得到2组。不能把有平局时的精确组数切分和距离阈值切分混为一谈。

2 Ward推导与数字

A 的大小为2，均值0.5； B 的大小为2，均值5.5。合并均值3。合并前平方误差是 $0.5 + 4.5 = 5$ ，合并后是 $9 + 4 + 1 + 16 = 30$ ，增量25。

公式给出相同结果：

$$\Delta(A, B) = \frac{2 \cdot 2}{2 + 2} (0.5 - 5.5)^2 = 25.$$

SciPy式Ward高度为 $\sqrt{2\Delta} = \sqrt{50} \approx 7.071068$ 。这个数不是complete的7，也不是平方误差增量25。推导中两组样本向合并均值的移动损失分别求和，才能得到大小权重 $ab/(a+b)$ 。

3 六点密度手算

$\text{eps}=0.3$ 、 $m=4$ 时，含自身邻居数依次为4、4、4、5、2、1。前四点核心，0.55边界，1.5噪声。标签可记为 $[0, 0, 0, 0, 0, -1]$ ，噪声比例1/6。

0.55位于核心点0.3邻域中，所以从0.3直接密度可达；0又与0.3同属核心连通分量，故它们最终同簇。 eps 约束局部连接，不约束簇直径。0.3不能从0.55直接密度可达，因为出发点0.55非核心；即使欧氏距离对称，可达关系也不必对称。

若 m 改为5，只有0.3仍是核心。0、0.1、0.2及0.55都位于其半径邻域内，因此成为边界；1.5仍是噪声。簇成员在这一步恰好没变，但核心结构发生变化。只看最终颜色而不检查核心掩码，会漏掉这种重要差异。

4 共享边界答案

两侧四点各自都是核心，左右最近距离2，大于 $\text{eps}=1.05$ ，因此核心图有两个分量。中间0只看到-1、0、1，共3个点，小于 $m=4$ ，不是核心。它同时邻接两个核心分量，是歧义边界；本课输出 `ambiguous_border_indices` 为[8]，并归入编号较小的分量。

如果错误地让非核心点也扩展，0会把两侧相连，算法退化成所有样本半径图连通分量，破坏密度要求。若输入重排，分量编号可能调换，中间点的归属也可能改变，但核心分量的集合关系仍应相同。这是合理的边界歧义，不是两个核心团突然具有了密度连通路经。

5 环形实验的实际结果

方法或参数	簇数	簇大小	噪声比例
K-means K=2	2	149 与151	0
single切2组	2	150 与150	0
complete切2组	2	174 与126	0
average切2组	2	51 与249	0
Ward切2组	2	107 与193	0
DBSCAN $\text{eps}=0.10$	1	150	0.500
DBSCAN $\text{eps}=0.13$	6	150及五个6点簇	0.400
DBSCAN $\text{eps}=0.24$	2	150 与150	0

single与 $\text{eps}=0.24$ 的DBSCAN恢复了完整内外环。其他方法即使同样输出2组，成员关系也不同；K-means两侧各含约一半内环和一半外环。簇大小相似并不证明结构一致。

外环半径大而点数相同，周长更长、平均点距更大。在较小半径内，外环难以积累6个邻居。 $\text{eps}=0.10$ 时外环全部噪声；0.13只留下五个局部6点簇，其余外环120点仍被拒绝。参数0.24使外环形成连贯核心结构，又尚未跨越内外环间距，因而恢复两环。

6 异密度实验的取舍

$\text{eps}=0.13$ 得到4簇，大小100、6、12、10，噪声137/265，约51.70%。全部100个紧密点保留；松散团130点中103个成为噪声。只看保留点的整齐程度，会掩盖算法丢掉了大部分稀疏群体。

$\text{eps}=0.24$ 得到2簇，大小101与112，噪声52/265，约19.62%。其中松散团仍漏掉24点，背景35点中有7点被接纳。虽然簇数恰为2，但这并不代表找到了完美分组。

$\text{eps}=0.40$ 只剩1簇256点，噪声9/265，约3.40%；100个紧密点、128个松散点和28个背景点被连在一起。减少噪声率没有提升区分两团的能力。这三个设置共同展示全局密度门槛在异密度结构上的困难。

如果学生在真实应用中希望保留稀疏小群体，可以提出考虑多尺度密度方法、业务定义的邻域或独立后续验证，但不能在没有额外证据时宣布某方法一定解决。更改距离、特征与参数也都改变了模型假设。

7 桥接噪声与不可撤销合并

single切2组得到大小1与196，第二个大簇已含全部180个主要群体点。稀疏桥产生连续短边，把左右群体串起来；余下的一点只是更晚合并的孤立点。树上“最后切成两组”不能撤销前面已经完成的跨桥合并。

DBSCAN在 $\text{eps}=0.24$ 、 $m=6$ 时得到两个92点簇，噪声13点。左右各90个主体点全部被接纳，每侧另接纳2个桥点。中间桥段不足以成为核心，不可继续传播，因而两个核心分量未合并。这不等于全部17个人工噪声都被剔除，实际有4个桥点被接纳。

complete、average与Ward也可保留大致左右两团，但它们强制为所有观测分组，远处杂点仍进入某簇。各算法对“没有合适归属”的表达能力不同，不能只拿输出簇数比较。

8 最近邻距离图与报告纪律

本课 $m=6$ 对应含自身的第6个点距离，等价于第5个其他邻居的距离。若另一个实现排除自身后取第6个邻居，阈值图会系统变化。应写清口径，而不是看见曲线不同就修改eps直到结果相似。

排序距离图可辅助观察密度尺度，但拐点不是统计显著性的保证。异密度样本可能有多段转折。用已知生成标签查看遗漏和背景接纳可以解释教学反例；在真实无标签数据中没有这份直接答案，应另外设计验证。

9 复杂度答案

完整float64距离矩阵的字节数为 $8n^2$ ；压缩上三角为 $8n(n-1)/2$ 。

样本数n	完整距离矩阵	压缩上三角
1000	8,000,000 B	3,996,000 B
10000	800,000,000 B	399,960,000 B
100000	80,000,000,000 B	39,999,600,000 B

这些是十进制字节量，不包含Python对象、邻居列表、标签和临时数组。广播实现的 n 乘 n 乘 d 差分临时量还乘一个 d ；高维时尤其危险。压缩上三角约减半，但仍是二次增长。

教学DBSCAN约需 $O(n^2d)$ 距离计算和 $O(n^2)$ 邻接扫描。教学凝聚每步重新枚举跨簇距离，总时间约 $O(n^3 + n^2d)$ 。SciPy本课所用linkage实现有相应二次优化，不能把自写版本的时间直接归给库，也不能把有利索引条件下的DBSCAN复杂度说成无条件保证。

10 测试解释与合格结论

冻结普通与-O报告各通过224项显式检查。它们覆盖手算计数、核心与噪声、闭邻域边界、重复点、全噪声、共享边界、库核心/噪声/分区对照、无平局层次记录、精确K切分、实际失败场景、非法输入和数据篡改。检查通过说明这些明确性质在测试范围内得到支持，不证明所有数据和参数都已验证。

一段合格结论可以写成：在本次欧氏距离和指定参数下，single linkage与适当半径的DBSCAN能恢复同心环，但single在稀疏桥上出现链化。DBSCAN在异密度数据上随半径从碎裂和漏检转向合并，并没有一个由算法名称保证正确的全局阈值。树的切分及噪声身份均依赖研究定义，后续还需独立验证分组意义。