

第074课 混合模型与EM算法

1 看见测量值，看不见来源

上一讲讨论怎样验证分组。本讲再往生成机制走一步：假设每个样本由某个来源产生，但来源编号没有被观察到，我们能否只根据测量值估计每个来源的分布？这不是先把点硬切开再拟合，而是允许同一个点对不同来源保留不同程度的不确定性。

设一家工厂的三台仪器测量同一种物理量。每台仪器有不同偏移和噪声，我们只拿到混在一起的读数，没有仪器编号。一个读数靠近第一台的典型输出，就更可能来自第一台；但两台仪器的输出有重叠，无法对每条记录确定无疑。这种“先选来源，再从来源分布抽值”的故事称为混合模型。

本课按大纲承接第016、019、021、023-024、071课，重新解释概率密度、条件概率、对数与期望。实验从一维Gaussian混合开始，便于手算；正文再给出多维协方差形式。全部数据为原创合成测量，无真实业务或个人字段。

蓝色重点：隐变量不是已经知道但故意遮住的答案。真实使用时，我们通常永远无法直接观测每点的来源，只能在模型假设下计算条件分布。

2 从生成故事写出联合分布

用 x 表示一个连续读数， z 表示来源编号，取值1到 K 。每个来源的混合权重为 π_k ，满足 $\pi_k > 0$ 且 $\sum_k \pi_k = 1$ 。先按这些概率抽来源 $z=k$ ，再从均值 μ_k 、方差 v_k 的正态分布抽 x 。

方差表示平方偏离均值的平均程度，单位是读数单位的平方。标准差是方差的平方根，才与读数同单位。一维正态密度为

$$\mathcal{N}(x | \mu, v) = \frac{1}{\sqrt{2\pi v}} \exp \left[-\frac{(x - \mu)^2}{2v} \right].$$

公式中的圆周率 π 与混合权重 π_k 不是同一角色；带下标的是权重。密度不是单点概率。连续变量恰好等于某值的概率为0，区间概率由密度曲线面积给出；密度可以大于1，且其数值随单位改变。

联合分布将“选来源”和“在来源中抽值”相乘：

$$p(x, z = k | \theta) = \pi_k \mathcal{N}(x | \mu_k, v_k).$$

θ 把全部权重、均值、方差打包为参数。我们没观察 z ，所以把可能来源加起来：

$$p(x | \theta) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, v_k).$$

一个混合分布不要求图上一定有K个峰。两个均值很近的成分可形成单峰；一个复杂分布也可能需要多个成分近似同一现象。“成分数”不能不经检验就解释为真实群体数。[1]




图1 训练直方图、各个加权Gaussian成分及其和。每条成分曲线面积等于其混合权重；黑色总密度曲线面积为1。

3 为什么直接求均值行不通

若来源已知，只需分别计算各组均值和方差。来源未知时，每个点究竟进入哪一组也要估计。但如果先凭猜测硬分组，边界附近的不确定性被丢掉，会影响下一轮参数。

独立样本 $x_1, \dots, x_n$ 的观测对数似然为

$$\ell(\theta) = \sum_{i=1}^n \log \left[\sum_{k=1}^K \pi_k \mathcal{N}(x_i | \mu_k, v_k) \right].$$

独立性使联合密度相乘；对数把乘积变为和，避免很小的数相乘造成下溢。难点是“先求和，再取对数”，不同成分参数被绑在一起。不能将它擅自改成各成分对数之和，那会改变模型。

EM把问题拆成两个互相支持的步骤：给定当前参数，用每点来自各成分的概率作为软权重；给定这些软权重，再更新各成分的参数。E是expectation，即条件期望；M是maximization，即最大化。它不是两个神秘按钮，而是一条有目标依据的循环。

4 E步：每点如何分配责任

贝叶斯条件概率给出责任度：

$$r_{ik} = p(z_i = k | x_i, \theta^{(t)}) = \frac{\pi_k^{(t)} \mathcal{N}(x_i | \mu_k^{(t)}, v_k^{(t)})}{\sum_j \pi_j^{(t)} \mathcal{N}(x_i | \mu_j^{(t)}, v_j^{(t)})}.$$

t表示当前迭代次数，i表示样本行，k表示成分列。r是n×K矩阵，每行非负且和为1。数值0.8表示在当前参数和生成假设下，该点属于某成分的后验概率，不是经过外部验证的分类准确率。

责任度同时受均值距离、方差与混合权重影响。离一个宽分布中心较近并不保证更高责任：宽分布把概率质量铺开，峰值也降低。更常见的来源拥有较大先验权重，但特别不符合它的读数仍可能归于少见来源。




图2 沿连续读数变化的三条责任曲线。它们每个横坐标处相加为1；交界区域保留软分配，而不是立刻硬切成类别。

实际程序先计算对数联合密度 a ，再用 logsumexp 计算 $\log \sum_k e^{a_k}$ 。实现可先减去最大 a 以避免指数上溢。最后取 $\exp(a - \text{归一化项})$ 得到责任。极端读数即便普通密度都下溢为0，对数空间仍能给出有限对数似然。

5 M步：把软权重当作分数样本数

有效成分大小为 $N_k = \sum_i r_{ik}$ ，它可以不是整数。权重更新为 $\pi_k^{(t+1)} = N_k/n$ ，平均更新为

$$\mu_k^{(t+1)} = \frac{\sum_i r_{ik} x_i}{N_k}, \quad v_k^{(t+1)} = \frac{\sum_i r_{ik} (x_i - \mu_k^{(t+1)})^2}{N_k}.$$

权重较大的点更能拉动该成分的均值。方差围绕**新均值**计算；若误用旧均值，不再是同一个精确M步。分母是有效计数 N_k ，不是 $N_k - 1$ ，因为这里最大化似然而非构造无偏样本方差估计。

为什么加权均值是解？固定责任度后，与均值有关的目标等价于最小化 $\sum_i r_{ik} (x_i - \mu)^2$ 。对 μ 求导得到 $-2 \sum_i r_{ik} (x_i - \mu)$ ，令其为零得到加权均值。即便暂不熟悉导数，也可像第071课一样做加权平方分解，非负的偏移项在加权均值处最小。

若某 N_k 数值上极接近0，直接除法会不稳定。本课显式报错并要求换初始化，不静默重设成分；重设虽然工程上常见，却不自动继承同一个似然不降证明。

6 三点手算一轮

取 $x = -1, 0, 1$ ，初始两成分权重各0.5，均值-1和1，方差都为1。对 $x = -1$ ，两成分除公共常数外的密度比例是1比 $\exp(-2)$ ，所以第一成分责任为 $1/(1 + e^{-2}) \approx 0.880797$ 。中点 $x = 0$ 对两成分完全对称，各为0.5； $x = 1$ 交换责任。

第一成分有效数为 $0.880797+0.5+0.119203=1.5$ ；加权为 $-0.880797+0+0.119203=-0.761594$ ，因此新均值约 -0.507729 。第二成分对称 0.507729 ；两者新方差都约 0.408877 ，新权重仍 0.5 。

观测对数似然从约 -4.389254 增加到 -3.549215 。负数变得“不那么负”仍然是增加。不能比较似然绝对值大小；如果误把负对数似然当似然，也会把正确更新说成下降。

这一轮的动态心智模型是：两边的点多数支持近成分，中点同时支持两边；中点把两个中心拉向内部；新的方差相应收紧。下一轮的责任又会改变，因而循环继续。EM没有把中点的来源确定下来，而是持续更新不确定性。

7 Jensen下界为何能支撑不下降

对任意正的分布 $q_i(k)$ ，将每点似然改写为

$$\log p(x_i | \theta) = \log \sum_k q_i(k) \frac{p(x_i, z_i = k | \theta)}{q_i(k)}.$$

对数是凹函数：先取加权平均再取对数，不小于先取对数再加权平均。这就是Jensen不等式。相加得到下界

$$\mathcal{F}(q, \theta) = \sum_{i,k} q_i(k) \log p(x_i, z_i = k | \theta) - \sum_{i,k} q_i(k) \log q_i(k) \leq \ell(\theta).$$

第二项是 q 的熵，衡量分布展开程度。约定 $0 \log 0 = 0$ 。更精确的等式为

$$\ell(\theta) = \mathcal{F}(q, \theta) + \sum_i \text{KL}(q_i \| p(z_i | x_i, \theta)).$$

KL是两个分布之间的非负差异量，在二者相同时为0。E步把 q 设为旧参数的真实后验，使下界在旧参数处接触目标。M步固定 q ，选择使下界不降低的新参数。于是

$$\ell(\theta^{(t+1)}) \geq \mathcal{F}(q^{(t)}, \theta^{(t+1)}) \geq \mathcal{F}(q^{(t)}, \theta^{(t)}) = \ell(\theta^{(t)}).$$

这条链清楚标出条件：E步准确计算旧后验；M步至少不降低同一可行域内的下界；目标定义不变；运算足够准确。近似E步、随意重置空成分、另加惩罚后仍检查原始目标，都不能无条件套用这条保证。

[2]

8 从一维方差走向多维协方差

多维 x 是 d 个读数组成的列向量，均值 μ 也是 d 维。协方差矩阵 Σ 的对角线是各列方差，非对角项描述两列共同波动。正定性确保每个非零方向都有正方差，密度合法且可求逆。转置符号 T 把行与列交换； Σ^{-1} 表示逆矩阵，在这里用于按协方差尺度校正距离； $|\Sigma|$ 是行列式，其平方根控制等密度椭球的体积尺度。多维Gaussian密度包含 $|\Sigma|^{-1/2}$ 和二次型 $(x - \mu)^T \Sigma^{-1} (x - \mu)$ 。

M步的协方差更新是

$$\Sigma_k^{(t+1)} = \frac{1}{N_k} \sum_i r_{ik} (x_i - \mu_k^{(t+1)})(x_i - \mu_k^{(t+1)})^T.$$

两个括号外积形成 $d \times d$ 矩阵。full协方差允许椭圆转动，diagonal只保留各轴方差，spherical让各方向方差相同，tied让不同成分共享协方差。这些是不同统计假设，不仅是加速开关。本课代码一维时full、diagonal、spherical都化成每成分一个方差；tied仍要求所有成分共享同一个方差，与本实现不同。因此不能声称实验已经比较多维协方差族。

K均值可以从相等、固定并趋近于0的球形方差与相等权重的混合模型极限理解：责任趋向最近中心的硬分配。一般EM不是“K均值加上概率字样”，因为权重、尺度和重叠都会改变分配与目标。

9 不下降不等于全局最优

似然曲线一直增加，最多告诉我们这条路径朝更好的目标值移动。非凸目标可有不同驻点；有些对称初始化会永远保留对称性。本课一个重启把三个初始均值全设为0，初始方差与权重也相同，因此E步对每个成分给相同责任，M步又给相同参数。三个成分一直重叠成同一个Gaussian。




图3 八种初始均值下的真实观测对数似然。对称初始化停止在较低水平，其他本批重启进入相近高似然解；所有曲线仍满足允许舍入误差下不下降。

训练对数似然约-687.092的解优于约-819.551的对称解，但有限次重启并不能证明已找到全局最优。训练目标选出best_run，再在另生成的audit数据上报告平均对数密度；不能依据audit结果选重启还把它叫未见最终评估。

成分标签也可以整体交换。若把每个成分的权重、均值、方差一起排列，观测密度完全一样。这是同一个解释的重命名，不是两种新科学发现。第075课会把这个现象推广到连续潜因子的旋转自由度。

10 方差塌缩与约束的真实含义

设一个成分均值恰好放在某个观测 x_i ，令其方差 v 趋近0，则该点密度按 $1/\sqrt{v}$ 增长。其他成分仍可给其余观测正密度，于是总对数似然可以无界增长。并非只要似然更高就更有意义。




图4 三点[0,2,4]的两成分模型，其中一个均值固定在0并逐步缩小方差，另一个均值为3、方差1。训练似然沿塌缩路径持续增加；这不是对总体分布的合理恢复。

本课将一维方差限定为 $v_k \geq 10^{-4}$ 。固定责任度与新均值后，无约束最优方差若小于下限，就取下限，即 $\max(\text{加权方差}, \text{下限})$ 。这是一维固定可行域的精确约束M步，旧参数也满足同一约束，因此仍可用前面的不降链。它与任意“更新完统一加一个常数”不是同一个操作。

下限阻止无界塌缩，却引入尺度选择，也不保证成分有物理意义。改变单位要同步改变方差下限；若所有x乘10，方差量纲应乘100。真实应用可使用更明确的先验、惩罚或协方差结构，但此时须重新声明优化的是哪个目标。

11 实验与自测路线

先完成三点手算，再在Notebook运行责任度与M步。随后跑八次重启，检查每步真实似然差、终止条件、方差和权重。最后用固定塌缩路径解释为何实验采用约束。程序包含与scikit-learn独立实现的密度对照，不能把两份代码都不报错当成数学证明。

练习：推导中点责任为0.5的条件；说明加权方差为什么用新均值；写出Jensen不降链每个不等号的理由；解释对称初始化为何无法自行打破对称；构造标签交换并检验密度不变；说明方差下限改变后的声明边界。实验册给步骤，答案册给逐项推理。

来源与继续阅读

[1] [scikit-learn官方Gaussian混合文档](#)，用于核对协方差选项、接口和奇异性风险。[2] [Dempster、Laird、Rubin \(1977\) 原论文出版页](#)，EM的原始研究出处。本课三点推导、约束解释、数据与对照代码为原创教学实现。sources.md区分实际可读来源与仅元数据核验的出处。