

第077课 精确概率推断

本课主线：图与参数已经给定。先定义要保留、要固定、要求和的变量，再把同一批乘加按更省空间的顺序完成。精确指数学目标不变，浮点运算仍有舍入误差。


1 从“表示分布”走到“回答问题”

第076课学会把联合分布拆成局部因子。本课按既定大纲承接第019、021、076课，讨论给定一部分观测后，如何计算其余变量的边缘与后验。推断与学习先分开：推断使用已给定参数回答未知状态的问题；参数学习使用数据调整参数。这里不拟合模型，不用测试集调参，不把算出的后验当成现实设备已经验证过的风险。

延续人工设备的例子， X_0 、 X_1 、 X_2 、 X_3 表示连续四个时刻的状态，每个只取0低负荷、1高负荷。 E 是末端指示器，0表示灭，1表示亮。下标0到3只是时间位置，没有实际秒数单位。我们观测 $E=1$ ，想知道初始状态 $X_0=1$ 的概率，以及其余三个状态的后验。

模型为 $X_0 \rightarrow X_1 \rightarrow X_2 \rightarrow X_3 \rightarrow E$ 。查询变量是最后要保留并报告分布的变量，例如 X_0 ；证据变量已观测，必须固定，例如 $E=1$ ；隐藏变量在这次查询中既未观测也不打算报告，必须对其所有状态求和，例如 X_1 、 X_2 、 X_3 。隐藏在这里是查询角色，不意味着永远不可测。

查询、证据与隐藏变量先分工



相容世界的权重相加 → 得到两种 X_0 的分数 → 除以证据概率

图1 明确三种角色后再运算：查询保留，证据固定，其余状态求和。

2 把概率参数逐格读清楚

先验 $P(X_0=0)=0.6$ 、 $P(X_0=1)=0.4$ 。每个相邻时刻使用同一转移表 T ；行是前一时刻状态，列是后一时刻状态。这里“转移”是模型定义的条件概率，不要求读者已会矩阵乘法。

前一状态	后一状态0	后一状态1	行和
0	0.85	0.15	1
1	0.25	0.75	1

末端 $P(E=1|X_3=0)=0.1$ 、 $P(E=1|X_3=1)=0.9$ 。它们属于不同条件行，不需要加为1。每行的另一个 E 状态由1减去该行数得到。给定末端证据后的两个数 $[0.1, 0.9]$ 是关于 X_3 的似然：不同 X_3 状态对同一证据 $E=1$ 的支持程度。即使这两个数碰巧和为1，也不能因此称它们为 X_3 的后验。

完整联合概率为

$$P(x_0, x_1, x_2, x_3, e) = P(x_0) \prod_{i=1}^3 T(x_{i-1}, x_i) P(e | x_3).$$

乘积符号 Π 读作“把 $i=1, 2, 3$ 对应的三项全部相乘”。例如全部状态为1且 $E=1$ 时，概率为 $0.4 \times 0.75 \times 0.75 \times 0.75 \times 0.9 = 0.151875$ 。一次完整世界包含五个二元值，所以完整表有32行；固定 $E=1$ 后，留下16行相容世界。

3 穷举是可信的起点

先把 $X_0=0$ 的八个相容世界权重相加，得到 $q(0)$ ；把 $X_0=1$ 的另外八个相容世界相加，得到 $q(1)$ 。 q 不是归一化后验，它等于 $P(X_0=x_0, E=1)$ 。两者之和是 $P(E=1)$ ，后验则是 $q(x_0)$ 除以这个共同分母。

本课穷举结果为 $q(0)=0.20112$ ， $q(1)=0.2032$ ，总和0.40432。因此 $P(X_0=1|E=1)=0.2032/0.40432$ ，约0.502572220。这条初始高负荷后验高于先验0.4，但远低于末端高负荷后验，因为中间多次转移削弱了末端证据对早期状态的约束。

穷举能清楚反映定义，也便于发现错误。然而 n 个二元未知状态有 2 的 n 次方个组合。即使局部表很小，重复枚举仍会为大量世界反复计算相同子表达式。下一步的目标是复用这些重复计算，而不是换一个近似目标。[1]


4 变量消元来自小学分配律

分配律 $a \times b + a \times c = a \times (b + c)$ 是变量消元的代数基础。若某个因子不含正在求和的变量，就能移到该求和符号之外。固定 $E=1$ 后，先消 X_3 ，把它涉及的两张表相乘再求和：

$$m_3(x_2) = \sum_{x_3 \in \{0,1\}} T(x_2, x_3) P(E=1 \mid x_3).$$

Σ 读作“对所有列出的状态相加”。 m_3 不是新随机变量，而是一张只剩 X_2 的两行数表。对于 $X_2=0$ ，两个分支是 0.85×0.1 和 0.15×0.9 ，所以 $m_3(0)=0.22$ ；对于 $X_2=1$ ，得到 $0.25 \times 0.1 + 0.75 \times 0.9 = 0.70$ 。

消元 X_3 ：先乘含 X_3 的两张表，再把 X_3 求和



$$\begin{aligned} m(0) &= 0.85 \times 0.1 + 0.15 \times 0.9 = 0.22 \\ m(1) &= 0.25 \times 0.1 + 0.75 \times 0.9 = 0.70 \end{aligned}$$

消息不是 $P(X_2)$ ： $0.22 + 0.70 \neq 1$ ；它描述末端证据对每个 X_2 状态的支持。

图2 消去一个隐藏变量就是把它的两种可能折叠成邻居状态上的一张新表。

接着消 X_2 ： $m_2(0)=0.85 \times 0.22 + 0.15 \times 0.70 = 0.292$ ； $m_2(1)=0.25 \times 0.22 + 0.75 \times 0.70 = 0.58$ 。最后消 X_1 ： $m_1(0)=0.85 \times 0.292 + 0.15 \times 0.58 = 0.3352$ ； $m_1(1)=0.25 \times 0.292 + 0.75 \times 0.58 = 0.508$ 。乘先验得到 $q(0)=0.6 \times 0.3352 = 0.20112$ ， $q(1)=0.4 \times 0.508 = 0.2032$ ，与穷举完全相同。

必须先将所有含当前变量的因子相乘，再对该变量求和。一般来说， $(\sum_x f(x))(\sum_x g(x))$ 不等于 $\sum_x f(x)g(x)$ 。提前把两张表分别求和，会错误组合不同 x 对应的分支。

5 因子的范围比数组外形更重要

因子是把一组状态映射为非负数的函数；范围scope列出它依赖哪些变量。 $T(X_2, X_3)$ 的范围是 (X_2, X_3) ，固定证据后的末端似然范围是 (X_3) ，消去 X_3 后得到 $m_3(X_2)$ 。一个空范围因子是常数，仍可能保存证据质量或归一化常数，不能随便丢掉。

两张表的“第0轴”可能代表不同变量。例如 f 的范围是 (A, B) ， g 的范围是 (B, A) ，它们相乘时必须按变量名对齐。 $f(1, 0)$ 应乘 $g(0, 1)$ ，而不是机械乘同一坐标的 $g(1, 0)$ 。本课用字典实现，每个键按scope顺序存0/1元组；乘法通过变量名读取，速度不追求最快，但每一步都能手审。

一次变量消元按以下循环执行。先收集所有含待消变量 V 的因子，叫作 V 的桶；桶外因子完全不动。将桶中因子相乘，得到临时联合范围；对 V 两种状态求和，产生范围更小的新因子；把它放回工作列表。最后只剩查询变量与常数因子，全部相乘并归一化。

```
bucket = [f for f in work if variable in f.scope] # 收集确实含V的局部表。
combined = multiply(bucket) # 按变量名对齐，把这些表相乘。
reduced = sum_out(combined, variable) # 只对V求和，保留其余轴。
work.append(reduced) # 用新表总结V，不再展开它的历史状态。
```

完整函数还会先移除桶中旧表，验证消元顺序刚好覆盖所有隐藏变量，并拒绝未知查询、非法证据和重复变量。这里摘出四行只为显示主因果过程，不能直接替代完整函数。`eliminate`返回后验、未归一化质量和trace；trace记录每步临时范围与条目数。

默认按变量名排序只是确定性教学约定，并非聪明的优化算法。查询 X_0 时，默认顺序 X_1 、 X_2 、 X_3 会短暂形成三个变量的表；手工顺序 X_3 、 X_2 、 X_1 最多只需两变量表。两者答案相同，但空间不同。`order`参数允许显式比较；不能根据变量名排序就声称选到了最优顺序。

何时归一化？本实现保留原始质量，最后一次归一化，所以能报告 $P(E=1)$ 。若中途把每张消息都归一化，后验可以保持正确，但必须累计被除去的尺度才能恢复证据概率。

6 sum-product把消元结果当作可复用消息

链是一棵树。树上任意两点只有一条路径，因此从一个方向汇来的消息可以总结那一侧的全部信息，而不会从另一条回路把同一证据重复算进来。sum-product中文为和积算法；“积”把独立分解的局部因子组合，“和”消去不再报告的变量。[2]

本课前向量 $\alpha_i(x_i)$ 表示在尚未加入末端证据时，第 i 个状态的边缘概率。 $\alpha_0=[0.6,0.4]$ ；随后每次把上一状态的两种分支相加：

$$\alpha_i(x_i) = \sum_{x_{i-1}} \alpha_{i-1}(x_{i-1}) T(x_{i-1}, x_i).$$

例如 $\alpha_1(1)=0.6 \times 0.15 + 0.4 \times 0.75 = 0.39$ ， $\alpha_1(0)=0.61$ 。再前进两步得到 $\alpha_2=[0.616, 0.384]$ ， $\alpha_3=[0.6196, 0.3804]$ 。由于本例只有末端一个观测，这些前向量恰好归一化；在更一般的逐时观测模型中，未缩放前向量通常不是每步和为1。

后向量 $\beta_i(x_i)$ 表示给定当前状态时，右侧末端证据 $E=1$ 的概率。 $\beta_3=[0.1, 0.9]$ ；往左递推 $\beta_i(x_i) = \sum_{x_{i+1}} T(x_i, x_{i+1}) \beta_{i+1}(x_{i+1})$ 。第4节的 m_3 、 m_2 、 m_1 正是 β_2 、 β_1 、 β_0 ，数值分别为 $[0.22, 0.70]$ 、 $[0.292, 0.58]$ 、 $[0.3352, 0.508]$ 。

链的两遍sum-product：两端信息在查询点相乘




图3 两遍消息分别总结查询点两侧的信息。蓝色向右、橙色向左，最后在每个状态节点汇合。

7 在每个查询点组合两侧信息

前向量已经汇总当前点左侧的状态与先验；后向量已经汇总当前点右侧的证据。两者相乘给出 $P(X_i=x_i, E=1)$ 。因此对每个 i 都有

$$P(X_i = x_i | E = 1) = \frac{\alpha_i(x_i)\beta_i(x_i)}{\sum_{x_i} \alpha_i(x_i)\beta_i(x_i)}.$$

分母在本课未缩放实现中应对所有位置相同，都是0.40432。对于 $X_2=1$ ，分子为 $0.384 \times 0.70 = 0.2688$ ，除以0.40432得0.664819945。对于 $X_3=1$ ，分子为 $0.3804 \times 0.9 = 0.34236$ ，后验约0.846755046。




图4 无末端证据时的边缘与观测E=1后的后验。证据对不同时间位置的影响强弱不同。

为什么不把 X_0 的消元过程完整重复四次？可以，但会重复计算大量相同子问题。前向和后向各跑一遍，就能用每个点两侧的缓存消息得到整条链所有边缘。若 n 个节点各有 k 种状态，链上每步需要枚举 $k \times k$ 种转移，整体约 $O(nk^2)$ 乘加。本课 $k=2$ ，记录全部前后向向量需 $O(nk)$ 空间；只求单个末端边缘时可只保留当前向量。

树上的一般消息表达也遵守相同原则：变量到因子的消息，是其他相邻因子发来消息的乘积；因子到变量的消息，是局部因子乘其余变量来信，再对其余变量求和。空乘积定义为1，对应尚无其他证据的叶子。消息的接收者不能立即被当作发送者自己的输入，否则会把刚收到的同一份信息原路重复记账。

本实验 `chain_sum_product` 是链特例，独立写出前后向递推，不调用变量消元作为捷径。它与穷举、消元三方对照，才有机会发现三种实现之间的错误，而不是同一函数换三个名字互相验证。

8 消元顺序、填边与树宽

看一张星图：中心C连接六个叶子L0至L5，查询L5。中心先验[0.6,0.4]，每条边在中心与叶同态时给权重3、异态时给权重1。它是无向势模型，边势每行和为4，并非概率转移表。

先消L0至L4时，每一步只把一张(C,Li)表折叠为关于C的表，临时最多4项。最后消C，仍只用(C,L5)四项。若先消C，就要把C和六个叶子同时保留在乘积中，临时范围有7个二元变量，含128项；求和C以后剩六个叶子的64项因子。后续逐个叶子消元，再慢慢缩小。

星图先消中心：六个邻居被连成团




图5 两种顺序保持同一个结果，但中心先消会使其邻居在计算图中彼此相连，形成填边。

消元时把当前变量尚未消去的邻居相互连接，这些新增连接叫填边。给定顺序的诱导宽度 w ，是各步仍存活邻居数的最大值；临时乘积最多涉及 $w+1$ 个变量。对每变量最多 k 个状态的普通稠密表运算，主要代价随 k 的 $w+1$ 次方增长，还要乘图规模及实现相关因子。这里测的是表条目数，不是完整程序实际内存字节或精确运行时间。[1]

图的树宽是所有消元顺序诱导宽度的最小值。因此这张树的树宽为1，先消叶的顺序宽度也是1；先消中心的坏顺序宽度为6，但不能因此把原星图的树宽写成6。查询变量保留到最后、证据先固定，均会影响本次具体的消元规模。

两个顺序都得到 $P(L5=1)=0.45$ ， $Z=4096$ 。答案一致并不代表成本相同；变量个数相同也不代表任何图结构的代价相同。链和稠密团在消元时产生的最大范围可能完全不同。

9 精确算法也有清楚的使用边界

树上和积消息两遍完成是精确推断。一般有环因子图直接反复传同样的局部消息，称为loopy belief propagation；它可能不收敛，即使收敛也不保证精确。把有环图变为团树可恢复一种精确计算组织，但较大的团会带来指数增长。这里介绍这个边界，不把链实现冒充通用有环精确消息引擎。[2]

如果证据概率为0，后验的分母就是0，本实现明确报错。若模型给证据极小但非零概率，长串浮点乘积可能下溢为0；本课短链未缩放实现不解决所有此类数值问题。长链需逐步缩放并记录尺度，或转到对数域，用稳定的log-sum-exp求和。把非常小的概率简单替换为任意固定值，会改变模型，不能仍称原模型的精确推断。

相同道理，近似采样误差、模型错误误差和浮点舍入误差是不同来源。三个精确实现结果相符，证明的是本课有限例子的算法交叉一致性，不代表人工转移表在真实设备中准确。是否使用准确模型，仍需另行研究设计与数据验证。

10 练习与完成标准

1. 计算 $P(X_0=1, X_1=0, X_2=0, X_3=1, E=1)$ ，并区分它与 X_0 后验。
2. 手算 m_3 、 m_2 、 m_1 和 q ，说明每次剩下哪个变量。
3. 用 $f(0)=1, f(1)=2, g(0)=3, g(1)=4$ 说明“各自先求和”为什么错。
4. 为什么消息 $[0.22, 0.70]$ 的和不必为1？若把它归一化，怎样保留证据概率所需信息？
5. 从 α_1 与 β_1 重算 $P(X_1=1|E=1)$ ，同时核对分母。
6. 说明星图两种顺序的临时表、结果表、诱导宽度及树宽各是多少。
7. 将任一因子整张乘7，归一化后验和 Z 分别怎样改变？
8. 为什么推断成功不是参数学习成功？为什么有环图消息“收敛”也不是精确性的证明？

完成标准是：能从概率定义独立推出一个手算答案；能画出消元后新表的范围；能用穷举验证所有边缘；能解释至少一种正确失败和一种计算爆炸。本课实验与答案分别放在lab和answers中。

参考

[1] Stanford CS228课程笔记：[Variable Elimination](#)，核对分配律、消元顺序及诱导宽度。

[2] Stanford CS228课程笔记：[Junction Tree Algorithm](#)，核对树消息与精确性边界。教学参数、手算、机制图和代码由本课程原创。