

第080课答案册：不把猜测变成事实

1 伪标签、置信度和阈值的手算

模型给类别1概率 $p=0.81$ 时，硬伪标签为1，置信度 $\max(0.81, 0.19)=0.81$ ，达到0.8阈值，接纳。

$p=0.19$ 时，硬标签为0，置信度仍为0.81，同样接纳。 $p=0.51$ 时，硬标签虽然为1，但置信度0.51低于0.8，不接纳。硬标签与是否接纳是两个不同判断，不能看到 $\arg\max$ 就无条件放入训练。

若 p 恰好为0.8，本实现使用大于等于，因此接纳；若 p 恰好为0.5，硬标签按规则取1，但置信度不够，不会接纳。阈值必须大于0.5且不超过1，权重必须正且有限。边界定义应写入程序和实验报告，否则两个看似相同实现可能在少数样本上产生不同迭代路径。

这些都是模型内部运算，没有使用真实类别。模型置信度0.81并不直接证明此点81%概率预测正确。只有在适当总体上经过概率校准、且选择机制与分布没有改变时，才有进一步解释的基础。真实可靠性要用独立标签审查。

2 标签权重的总量推导

4条人工标签权重均为1，总权重4。120条伪标签各为0.5，总权重60。合计64，伪标签占 $60/64=0.9375$ ，即93.75%，人工标签只占6.25%。因此“半权重”只描述单条相对权重，并没有保证人工监督在整体目标中仍占主导。

本实现损失分母是全部样本权重总和。如果改为人工损失平均值加 α 乘伪标签损失平均值，那么人工与伪标签的相对总影响由 α 控制，不再随接纳数以同样方式改变。两个写法都可以研究，但它们优化不同目标，不能仅凭都写了0.5就声称是相同算法。

当新增伪标签有系统性错误时，大量错误梯度可能压过少量人工监督。即使平均伪标签错误率不高，错误若集中在某个重要少数类或边界区域，也可能对目标任务造成明显损害。总量、错误位置与损失权重应一起报告。

3 为什么高阈值不能保证低错误率

置信度来自当前模型，而当前模型由少量可能错误的标签训练得到。若整个类别含义被翻转，模型可以把错误方向拟合得非常确定。输入远离它自己的决策边界，sigmoid输出就接近0或1，即使这个边界从任务语义上完全错误。阈值只能筛出“模型认为确定”的点，不能独立检验类别语义。

本课压力例正展示这种情况： -1.2 的真实标签应为0却被写成1， 1.2 的真实标签应为1却被写成0。模型学得负权重，在负侧预测1、正侧预测0。未标注池都远离零边界，于是120点全部通过0.8阈值，也全部错误。提高到某个更大阈值可能减少入选数，但不自动翻转错误方向。

此外，筛选本身改变了评价子集。模型整体校准良好不代表在分布外点、某一少数类或极高置信子集都校准。可以用独立验证标签画可靠性图、按类统计接纳准确率，或者调查分布偏移；但不能用未核验的伪标签给自己的置信度作背书。

4 错误自我强化不必等于置信度逐轮增加

冻结压力结果新增错误伪标签120个，原始错误种子2个，合计122个错误训练目标。初始与重训后准确率均为0。错误平均置信度从0.984431689965变为0.962782983519，数值下降约0.02165。正确描述是错误规模扩张、错误方向持续且仍然高置信，不能写成“错误概率越来越高”。

单个误伪标签样本对分数的交叉熵导数为 $p - \hat{y}$ 。例如真实0类却被赋 $\hat{y}=1$ ， $p=0.9$ 时导数-0.1，会推动分数上升；真实标签0时导数0.9，推动相反方向。但是实际训练同时考虑所有点、正则化和权重归一化，所以整轮最终分数的变化不必与某一个样本的局部梯度完全一致。

这个区分体现了机制说明与测量结果之间的关系。机制告诉我们错误如何进入优化目标，数值实验告诉我们在当前设置下净效应有多大、朝哪个方向。若观察与预想不同，应修正描述并解释可能因素，不应删掉不符合故事的数据。

5 实际标签数量、噪声与不可训练配置

名义2%乘240为4.8条，但按两类分别取 $\text{round}(240 \times 0.02/2) = \text{round}(2.4) = 2$ 条，实际合计4条，占1.67%。10%档每类12条，合计24；30%档每类36条，合计72。每类至少2条的限制也应说明。这个方案利用合成真值分层，现实不掌握真值时无法免费照搬。

标签噪声 η 是每条标签独立翻转的概率，实际翻转数服从相应伯努利和，有限样本不必等于 η 乘样本数。四条标签中一次翻转就是25%，两次就是50%，因此名义噪声相同的不同种子可能行为迥异。结果同时提供nominal噪声与actual_noise_fraction，避免混淆。

45个预定配置中有一个噪声后观察标签只剩一类，标记single_observed_class。汇总不偷偷补抽，而在该格注明有效种子数4，其他格5。若要为单类情形设计常数预测器或补标策略，可以另设新的实验分支，但必须把新的方法、预算和评价规则写清楚，不能事后改协议再沿用原结论。

6 全部结果的合格解读

10%标注、无噪声时，监督准确率均值0.882333，伪标签0.877333，平均差-0.005。10%标注、25%噪声时，监督0.784，伪标签0.745，平均差-0.039。30%标注、无噪声时，监督0.895，伪标签0.897667，差约0.002667。它们共同说明当前简化方法在不同条件下可以有小幅正差或负差，不能预设未标注数据必然改善。

2%标注、50%噪声时平均差约+0.05333，但差值样本标准差约0.10790，跨种子很不稳定，而且两个模型平均准确率均偏低。不能拿这个结果推出高标签噪声有利。30%标注、50%噪声时没有点接纳，两个方法相同，伪标签错误率为null，因为没有可作为分母的伪标签。

差值标准差使用样本分母 $n-1$ ，是重复实验离散程度；它不是均值标准误，也不是置信区间。五个种子的平均分可帮助发现机制和敏感性，不能支撑很强的人群或领域外结论。报告完整协议、全部配置和不确定范围，比只保留一个最好分数更重要。

7 弱标签后验对数赔率推导

假设先验 $P(y=1)=\pi$ ，规则 j 在两类上的准确率均为 a_j ，给定 y 后不同规则条件独立，而且弃权不带额外类别信息。贝叶斯公式写为后验赔率=先验赔率 $\times$ 各非弃权规则输出的似然比。规则投1时，似然比 $a_j/(1-a_j)$ ；规则投0时反过来，为 $(1-a_j)/a_j$ 。

取自然对数，把乘积变成和，规则投1加 $\log(a_j/(1-a_j))$ ，投0减同一个数，弃权贡献0。于是得到讲义中的对数赔率公式。概率由sigmoid变换恢复。若准确率随类别而变化，就需要两类各自的条件错误率；若弃权依赖类别，弃权也可能带信息，不能继续简单忽略。

如果 $\pi=0.5$ 、 $a=0.8$ ，先验对数赔率为0，每条正票权重 $\log 4$ ，负票为 $-\log 4$ 。一正一负相抵，概率0.5。两正一负剩 $\log 4$ ，概率 $4/(1+4)=0.8$ 。这只是所写假设下的模型结果，真实概率是否接近0.8需要额外验证。

8 复制规则为何不增加真实证据

把一条正票规则复制后，输出列与原列完全相同，知道原列就知道副本，副本没有独立新信息。条件独立假设要求给定类别后两规则输出仍独立，这里明显不成立。若把原规则准确率当作0.8，复制并不能产生两次独立的0.8准确观察；错误地相乘会虚增证据强度。

本例冲突行上概率从0.5变成0.8，并不代表真实可靠性提高。正确处理可以去除确定副本、对同一来源分组、在标签模型中显式表达依赖，或利用独立金标准估计其有效贡献。部分相关来源也有类似问题，不能只检查逐字相同的代码。

第三条弱规则依赖干扰特征，覆盖率约0.525，覆盖子集准确率约0.5635，接近随机。规则1覆盖子集准确率约0.9568，规则2约0.8681。多数票却把它们等权处理，所以额外规则不必带来改进。规则多、覆盖大、冲突少都不是准确性的替代证明。

9 覆盖、冲突和准确率的分母

多数票聚合覆盖率为非弃权行数除以全部行数，本例约0.816667。覆盖准确率只在聚合器实际输出0或1的行上计算，本例约0.862245。冲突率统计同时出现至少一张0票与一张1票的行，占全部行约0.179167。三个指标回答不同问题，不能互相替代。

对平票返回弃权是保守且明确的规则，不是将其记成错误或正确。若最终系统必须对每个点给预测，可以由下游分类器或补标流程处理弃权，但要单独评估这部分。高覆盖准确率可能通过只覆盖简单样本获得，因此还应比较弃权群体是否集中在关键类别、难例或分布边界。

本课的规则准确率使用隐藏真值作教学审计，概率聚合器的0.8则是预先给定的演示参数。不能拿这些审计数值反向训练聚合器，同时又声称没有使用标签。若有少量独立金标准用来估计规则可靠性，应明确算入监督预算，并与最终测试集分开。

10 不看测试答案的阈值选择方案

一个合格方案是先固定候选阈值，例如0.7、0.8、0.9，以及候选总权重，使用相同训练标签与未标注池训练；在独立验证集上比较预先选定的指标及每类覆盖，选定方案后冻结；最后只在测试集评价一次。验证标签的标注成本应算入总预算，不能省略。

如果验证样本很少，可用严格嵌套交叉验证或增加人工验证预算，但不能反复偷看测试结果。所有预处理、规则设计和模型选择都应仅利用允许数据。如果最终测试不好，应如实报告，并把新一轮修改看作需要新验证的开发过程，而不是覆盖原记录直到得到理想分数。

本冻结实验没有调阈值，而是全部预先固定。训练真值、验证标签和测试标签都没有传进self_train。普通模式与-O各通过10项测试，涵盖输入拒绝、接纳去重、空接纳、隐藏真值接口、弱标签弃权、复制反例和可重复性。这些测试验证本课实现与协议，不能证明所有半监督方法或真实弱监督来源都可靠。