

第080课实验册：标签少、标签错与错误传播

1 实验问题与预先冻结的协议

本实验问的是：在相同人工标签预算、相同分类器和相同正则化下，加入伪标签如何改变测试预测？标注比例与标签噪声分别起什么作用？错误的高置信预测怎样变成新的错误训练目标？此外，弱标签聚合能否区别“新增独立来源”和“复制同一规则”？这些问题都需要同时保留成功、失败和没有新增标签的结果。

预先固定三种名义标注比例2%、10%、30%，三种标签翻转概率0、25%、50%，五个种子7、19、31、43、59，形成45个配置。分类器为带L2正则的逻辑回归， $\lambda=0.05$ ，伪标签阈值0.8，单条伪标签权重0.5，最多5轮。所有设置在查看测试成绩之前写定，本次不以验证集调参；独立验证集保留供你设计后续实验。

请先在报告中写出可被推翻的预期，不要写“半监督一定优于监督”。更合格的预期是：当人工标签较少或含噪声时，模型可能自信地生成错误标签；提高标签预算能否缓解这种问题，需要实测。对于每个条件，监督和伪标签必须共享同一批被抽中的标签与同一套噪声，实现配对比较。

2 文件、环境和可重复运行

Python 3.11或3.12，安装requirements.txt后执行下面命令。实验本身只使用NumPy，不下载数据；绘图需要Matplotlib；Notebook通过新Python进程里的IPython逐单元真实执行，保存文本和内嵌图，当前受限环境不启动socket内核。PDF构建另需本地MathJax和WeasyPrint，并非训练依赖。

```
python generate_data.py --directory outputs/generated-data
python experiment.py --out outputs/result.json
python test_experiment.py --out outputs/tests.json
python -O test_experiment.py --out outputs/tests-optimized.json
python plots.py --directory outputs/figures
python execute_notebook.py --out outputs/experiment.ipynb
```

data目录提供每个种子的features文件和audit文件。前者含训练池输入、验证输入与验证标签、测试输入；后者保存训练池完整隐藏真值与测试标签。默认experiment读取data中的冻结文件，生成到outputs的副本只用于重建对照，不会自动替换默认输入。比对generation.json中每个文件的SHA256，确认版本一致。

3 操作一：画出信息可见性地图

选择种子7。训练池240点，验证100点，测试600点。训练池与测试按类别平衡生成；x1含类别均值偏移，x2只是方差较大的干扰特征。先只画训练池位置，不着色隐藏真值，再把被选中的24个人工标签着色。此时你看到的才是10%标注条件下训练器可用的信息。

然后单独绘制完整真值图，标注“仅用于教学审计”。比较两张图：少量种子可能没有覆盖边界，也可能给干扰方向造成偶然相关。不能在看过右图以后手工调整左图模型，却还声称算法没有使用隐藏答案。图1将两种视图并排，是为了提醒权限边界，而不是提供调参捷径。

检查self_train接口，确认没有y_u或test_y。审计者在训练结束后计算错误率，训练器不接收这些值。再把隐藏审计标签复制并整体翻转，保持传给训练器的L与U不变，确认模型输出不变。这不是对所有可能泄漏的形式化证明，但能验证隐藏标签没有经当前接口直接进入训练。

4 操作二：理解名义预算与实际预算

名义2%对应 $240 \times 0.02 = 4.8$ 条样本，但本实现按类别分层并至少每类2条，使用round后每类2条，实际4条，占1.67%。10%为24条，30%为72条。请把三档实际数量写出来，不要把所有图例的“约2%”改写成精确2%。分层抽样利用合成真值，是受控模拟的便利，现实获取相同抽样结构可能需要额外标注成本。

固定一个种子，确认低预算索引是高预算索引的子集。这样的嵌套预算减少比较中无关的样本变化。再检查噪声生成：每条标签独立决定是否翻转，实际翻转比例会偏离名义概率。小样本尤其容易极端，翻转一次就改变四分之一标签，不能拿大样本期望当作每个配置的保证。

运行后搜索status字段。共有一个配置出现single_observed_class，即噪声后所有观察标签同类。不要重新抽样直到两类都有，那会改变原协议并筛掉失败。原样报告该配置、实际标签数和汇总的有效种子数。如果真实项目确实要补标以覆盖另一类，应作为新的预算与采样策略单独评价。

5 操作三：先单独检查监督优化器

用四个一维点-2、-1、1、2，标签0、0、1、1，调用fit_logistic。确认converged=True、训练准确率为1、loss_trace在数值容差内非增。读代码中的sigmoid实现，说明为何对正负分数分支计算能避免指数溢出。再看logaddexp表达式，确认损失不需要先对接近零的概率取对数。

Newton步通过Hessian求方向，回溯线搜索尝试较小步长，直到目标下降。程序会检查训练集必须有两类，l2必须为正，权重必须有限且为正。目的不是保证泛化，而是先验证基本优化和输入含义。一个稳定优化器如果收到错误标签，仍然可能稳定地学到错误边界，下一步正要观察这个区别。

监督和半监督模型共享l2和拟合函数；每次重训从确定初值开始，避免把前一次优化状态当成额外隐含变量。若你改为温启动，应重新记录并检查收敛，而不能在比较时让一边完全优化、一边只做几步就停止。

6 操作四：逐轮审计伪标签闭环

选一个配置，列出第一轮每个新接纳点的未标注池索引、硬标签和接纳前置信度。检查阈值条件，以及同一个索引是否只出现一次。随后列出累计接纳数与这一轮新错误数。错误数只能在模型训练结束后，通过隐藏真值审计得到，不能用它撤销错误标签再重训并继续声称是同一算法。

本课接受后冻结标签，后续不重标记；已接纳伪标签与人工标签合并再训练。若某轮没有新点，history记录no_new_confident_points并停止。对于完全不接纳的配置，输出模型应与监督基线相同，伪标签错误率应为null。这表示分母为0，不能填0，否则容易误读成生成标签全部正确。

计算总权重而不是只看单条权重。如果4个人工标签加120个伪标签，每条伪标签0.5，总权重64，其中伪标签60。写出它们占比93.75%，说明为什么大量半权重样本仍可能主导目标。再提出一个不同归一化方式，并明确那将是新方法而非原实验的同一设置。

7 操作五：完整汇总45个配置

读取summaries，按标注比例与名义噪声展示监督准确率、伪标签准确率、配对差值及差值跨种子样本标准差。不要从45行中只挑一行成功图。特别比较10%标注、无噪声与25%噪声，前者平均差约-0.005，后者约-0.039。30%无噪声虽有约0.00267提升，也很小，不足以脱离当前实验宣布普遍优势。

标准差描述五个或四个种子之间的离散程度，不是均值标准误，也不是95%置信区间。若要推断更大范围的平均效果，需要足够重复和合适不确定性分析。本实验种子数很少，主要用于暴露对种子、预算与噪声的敏感性，不能用小数点后很多位制造过度确定感。

同时检查Brier分数与对数损失，它们关注概率预测而非仅关注硬分类是否正确。两个模型准确率相同，不代表概率一样；自训练可能把错误预测变得更极端。比较这些指标有助于发现只报准确率会隐藏的问题，但它们仍不能替代按类、按群体或分布偏移的专门检查。

8 操作六：制造一个可解释的失败

运行stress_experiment，检查两个种子输入和故意反向的标签。未标注池有120个点，其真实目标由输入符号决定。初始模型将方向完全学反，随后120个点都通过0.8阈值，并全部得到错误伪标签。记录错误种子数2、新增错误数120、训练目标错误数122，以及两个阶段准确率均为0。

再记录错误平均置信度，初始约0.9844，重训后约0.9628。置信度略降但仍很高，不能为了贴合“强化”一词而宣称它增加。此处强化的可观测含义是错误标签扩张与错误决策维持。模型输出数值不保证反映真实可靠性，置信筛选本身无法识别一套整体反向的语义。

尝试在副本中纠正一个或两个种子标签，比较接纳结果如何变化；若只剩单类观察标签，应正常报错或按另一个明确协议处理。不要在原报告中把不同标签条件混在同一条曲线上。干预的目的应写清楚：研究种子语义正确性，而不是寻找一个漂亮最终分数。

9 操作七：审查弱规则及弃权

构造三列弱标签矩阵，逐行手查规则定义。-1表示弃权，不计入0票或1票；全弃权与平票都返回-1。用四行小矩阵[-1,-1]、[0,1]、[1,1]、[0,-1]验证多数票结果应为-1、-1、1、0。若把弃权误当负类，低覆盖规则会制造大量并不存在的负类证据。

先报告覆盖率与冲突率，再在覆盖子集上报告准确率，并始终注明分母。种子7多数票覆盖约81.67%，覆盖准确率约86.22%，不能把后者当成对全部240点的准确率。被弃权样本可能恰好更难，丢掉它们后得到的准确率往往更乐观。

弱规则3只看干扰特征，因此可以覆盖不少点却几乎没有可靠类别信息。讨论为什么增加这种规则可能降低聚合质量。再找出规则1与规则2共享x1的事实，说明它们并不满足严格条件独立。聚合公式演示给定准确率0.8，不是从这些真值审计准确率反过来调出来的参数。

10 操作八：复制规则的定量反例

设先验0.5，两规则都假定准确率0.8，一条投1、一条投0。手算正负对数赔率相抵，概率0.5。把正票列复制为两份，错误地当作独立来源，再计算得到0.8。确认代码对应输出。你没有新增样本、人工知识或外部来源，只增加一列，因此额外置信度来自错误独立假设。

在真实标签函数矩阵中，找出规则1与规则2同时投票且冲突的行，本冻结数据有9行。比较复制前后平均置信度0.5与0.8，再强调这不证明复制后的预测准确率80%。为了验证概率，需要独立金标准或合理识别假设；标签函数彼此一致不能代替这些依据。

11 提交内容与最后的自检

报告包括数据生成过程、实际标签预算、每个条件的真实翻转比例、训练可见性图、监督基线、逐轮伪标签审计、全部汇总、不可训练条件、压力失败、弱规则覆盖冲突与复制反例。附运行命令、结果JSON、正常与-O测试、真实执行Notebook及图像。请标注Notebook是在新进程内顺序执行，不声称浏览器交互或socket内核已测试。

最后问：我是否把隐藏真值用于选阈值？是否遗漏失败种子？是否把名义噪声当作实际噪声？是否把null写成零错误？是否把高置信度当作高准确率？是否把复制规则当作新证据？只要有一项发生，就先修复实验协议与措辞，再讨论方法优劣。可重复运行只是基础，可审计的信息边界才让结果可信。