

第081课 实验：异常分数必须经过预算审计

实验目标：重建原创合成机制，解释四种评分函数的差异；只用独立正常校准集选择阈值；保留真实正常数字的误报；核验测试异常绝不进入校准。预计分两次学习，每次60至90分钟。先写预测，再运行，再解释与预测不一致之处。

1 提交什么才算完成

交付一份短报告、完整命令日志、生成数据哈希、结果JSON，以及你自己运行的Notebook。报告必须写出正常定义、训练条件、分数方向、校准样本量、报警规则、原始误报计数和异常机制分层召回。不得只交一张AUROC图，也不得删去没有达到5%实测误报的运行。

先检查lecture.md中的符号表述是否能用自己的话复述。你需要能解释m是正常校准样本数， α 是目标边际预算，k是校准排序的位置，t是分数阈值。这里的k与近邻方法中的邻居数同用字母，但语境不同；写报告时建议把近邻数写成k邻居，把秩写成k校准，避免误把两个参数联动调整。

本实验不需要在线接口、账户或付费API。安装requirements.txt后所有计算离线，真实数据由scikit-learn随包提供。若某依赖缺失，先补齐环境并记录版本，不能把没运行的结果写成“预期通过”。程序默认写入outputs，保留讲义目录中随课冻结的结果供独立比较。

2 从文件建立一张职责地图

阅读generate_data.py，找出四种主数据角色：正常训练、正常校准、正常测试与异常测试。再找出额外污染样本。抄下每个集合的数量和来源，画箭头表示它允许进入哪些函数。训练可以进入fit，校准可以进入calibrate，两个测试集合只能进入最终evaluate与事后解释。

阅读anomaly.py的make_models，写出高斯正则强度、邻居数量、LOF的新颖性开关、SVM的核与 ν 。不要运行任何搜索来“改进”当前冻结测试结果。本次比较的研究问题是相同协议下机制如何不同，不是利用测试集挑选冠军。若以后确实要搜索超参数，先设计新的开发集和独立校准集。

检查experiment.py中StandardScaler的位置。它只用合成正常训练样本拟合。Digits像素统一除以16是数据生成时的固定换单位，没有从测试分布估计任何参数。写出这两种预处理的区别，并说明为什么不能把所有分割拼起来再标准化。

3 第一轮：重建数据并核对字节

在本单元目录执行以下命令。命令路径可以按本地解释器调整，但输出应进入新目录。

```
python generate_data.py --directory outputs/my-data
python experiment.py --out outputs/my-result.json
python test_experiment.py --out outputs/my-tests.json
python -0 test_experiment.py --out outputs/my-tests-optimized.json
```

比较outputs/my-data/generation.json与data/generation.json中的SHA256和字节数，再比较dataset.json的原始字节。相同依赖与种子应给相同内容；若只看文件名一致，无法发现数据被编辑。真实数据行号也在JSON里，必须检查训练、校准、测试没有交集。

查看种子81021如何驱动合成正常模式、异常机制及真实划分。不要为了让图更好看换种子后仍沿用讲义数字。一次种子改变会改变多项随机抽样，必须被视为新重复并记录。若你的NumPy或scikit-learn版本不同，先记录差异，再检查数据数组是否仍一致，不能把任何数字差异都直接归因于算法错误。

4 第二轮：手算评分并追到代码

先在纸上完成一维近邻例子：训练点0、2、5，近邻数2，新点1和4的第二近邻距离各是多少？然后调用KNNRadius核对。解释为什么它是新点到参考集的距离，而不是对待测点之间互相寻找邻居。如果把一批异常测试点先合并为一个参考群，问题设定就变了。

再取四个二维点拟合GaussianScore，输出mean_、covariance_、cholesky_。挑一个靠近中心的点与一个远点，检查分数方向。用SciPy的multivariate_normal.logpdf独立核对负对数密度。必须比较完整数值而不是只比较两者排序相同，因为缺少对数行列式也可能保留同模型内排序，却破坏密度解释。

打开test_gaussian_singular_regularization，解释为何全相同训练点仍能得到有限分数。再试regularization=0，程序应显式拒绝。这个拒绝是算法契约，不要为了让脚本继续而删除输入验证。用python -O重跑后验证仍在，才能说明校验没有依赖assert。

5 第三轮：手算阈值与边界情形

对干净分数1、2、3、4、5， α 取0.34，先算ceil(6乘0.66)，得到校准秩，再找阈值。测试分数恰好等于阈值时是否报警？请写清楚使用严格大于的原因，并核对Calibration.alarms。把所有校准分数改为1，检查并列是否导致保守行为。

接着把校准集缩为两点，预算仍为5%。程序返回正无穷阈值是有意设计。解释为什么这比从两个分数的最大值外推一个“95%分位数”更诚实。你可以提出分布假设来估计极尾部，但那会形成另一种方法，必须额外验证假设，不再享有同一条无分布秩论证。

最后阅读test_exact_rank_exchangeability：固定五个不同分数，让每个依次作为未来正常点，其余四个校准，预算20%。数出报警次数。这个小穷举展示秩逻辑，但不能单独证明现实数据可交换。把数学规则与数据条件分开记录，是这一轮的主要验收点。

6 第四轮：合成实验先读计数，再读排名

从输出JSON抄下四方法的false_positives、normal_n、true_positives、anomaly_n。自己重新相除，确认fpr和recall无方向错误。再按bridge与far拆分召回，按正常group拆分误报。任何总指标都要能追到这些分子分母。

应观察到单高斯桥区召回为零而远端为一，LOF对桥区召回显著更高。先用图2解释几何机制，再看AUROC。不可以仅写“LOF更好”作为答案，必须说明它在哪种机制、什么阈值和什么样本量下改善了哪项指标，以及它仍对稀少正常模式产生多少误报。

把实测正常误报率与5%水平线比较。有些值超过5%，不要立刻调阈值消掉超标，也不要宣称理论被反例推翻。查看Wilson区间，重读边际保证的随机性范围。若要研究长期超预算频率，应额外设计多次独立训练与校准重复，并预先规定汇总方式，而不是挑一次符合目标的测试结果。

7 第五轮：把预算翻译成复核人数

使用讲义公式计算每天一万条、基率千分之一、召回90%、正常误报5%的真报警与误报。然后假设团队每天最多复核20条记录，估算原方案是否可用。请注意这是容量诊断，不意味着可以不顾召回直接把报警截成前20个；后者会引入另一个依赖每日流量的决策规则。

在结果中找到scenario_per_10000_at_prevalence_0.001。它用各方法实测fpr和recall作情景推算，不是真实上线日志。将这些数与当前合成测试异常比例40%作对照，解释为何测试集平均精确率不能直接搬进日常报警队列。

写出你希望部署方补充的三个信息：正常流量规模、异常基率范围、单次误报与漏报成本。若无法知道基率，可报告多个明确情景并保留不确定性，不能凭模型分数猜一个概率。课堂的5%只是示范值，你的建议必须回到任务与资源。

8 第六轮：污染只破坏训练假设

比较contaminated_training与主实验。污染占67/667，额外样本集中在桥区。确认这些点由新随机抽样生成，而不是复用测试异常。查看四种评分函数的正常误报与整体召回怎样改变，再解释哪些方法会把污染群当成参考结构。

特别检查污染后是否重新计算干净校准分数。如果模型更新后只保留旧阈值，分数变化与阈值变化就混在一起，无法解释误报预算。当前程序重新打分并校准，使对照主要研究模型如何受污染影响。即便如此，两种训练条件并不享有同样的“训练全部正常”假设，报告要把这个差别放在结果前面。

不要把污染实验写成数据清洗建议。模型自己选出的高分点既可能是坏数据，也可能是稀有正常样式。若盲目删除再重训，会收缩正常定义。一个合理的后续工作是独立人工审核抽样，而不是自动把所有高分标签改成异常。

9 第七轮：真实负例不许被悄悄删除

查看图5与Digits的normal_test行号。挑选高斯分数最高的三个真实0，写出图像中你观察到的笔画位置、倾斜或闭合差异。描述必须停留在图像证据，不得推断作者身份、能力或健康。比较其中哪些越过阈值，哪些虽然高分仍被接纳。

真实测试只有43个正常0。即使某方法零误报，也要报告0/43与区间上界。然后查看181个真实6中的漏报，解释“任务外类别”与“有害样本”的区别。当前任务的正常定义只允许0，所以6被视为新颖；如果业务以后允许所有数字，本课这些报警就不再构成成功。

说明数据来源为UCI原测试部分随scikit-learn分发，而本课重新做了自己的内部划分。原始数据具有书写者背景，但随包行表没有本实验所需的完整个体分组标识，因此随机分割不能支持新书写者泛化承诺。你的报告应明确没有做过哪些外部验证。

10 第八轮：主动做一次泄漏防护测试

阅读test_test_anomalies_cannot_select_threshold。它把两套测试异常整体平移，再重跑实验，要求每个模型阈值完全不变。为什么召回与AUROC可以改变，而阈值不应改变？从数据流回答，不能只说“因为测试集不参与训练”。

这个测试不是所有泄漏的完备证明。它没有阻止研究者看过测试结果后改超参数，也不能识别原始数据中隐藏的重复个体。但它是一条高价值回归测试，能防止后来有人把校准与异常测试拼接选阈值。请提出另一条可实现测试，例如修改正常测试值也不应改变标准化器或阈值。

11 图形与Notebook验收

运行plots.py到新目录，逐张检查中文字形、图例、坐标方向与图注。图2红色为报警区域，不是高概率正常区；图4右侧是情景公式，不是实验曲线；图5上排必须是真实正常保留集。每张图的来源要能追溯至实际数组和代码，不能靠手画一个符合故事的边界。

运行execute_notebook.py，检查代码单元执行计数连续、无错误输出、图像已内嵌。受当前隔离环境内核通信限制，课程使用新Python进程内IPython顺序执行，而不是声称启动了独立网络内核。你在本地有正常Jupyter时可以再执行一次，但要记录真正用过的方式。

12 最终报告结构与停止条件

报告按“问题与正常定义、预声明方案、数据职责、实现验证、合成机制结果、真实负例、预算与局限”七段组织。每段回答一个问题，避免把所有指标堆在开头。引用experiment-result.json中的实际值，保留高斯桥区失败与稀少正常群误报等不利证据。

若数据哈希不一致、测试失败、Notebook存在未执行单元，先停止结论写作并定位原因。若计算全部通过，但现实数据条件不足，就把结论限定在当前教学任务，不用继续寻找一个更响亮的表述。验收的目标是得到可复核证据链，而不是一定选出可上线的异常检测器。