

第082课 参考答案与证据解读

本次结果既包含合成真值较好恢复，也包含合成相关结构复制检查冲突与真实数据重采样不稳定。三者都必须保留。参考答案的作用是示范如何限制结论，而不是把所有指标解释成成功。

1 命题分层与数据职责

实现命题可以写为：独立计算的每行责任度与sklearn公开接口在浮点容差内一致。若最大误差明显超过 $1e-10$ 或行和不为1，命题被反驳。合成命题可以写为：在预声明三高斯机制下，模型恢复的划分与生成Z高度一致，均值经置换匹配后接近真值。真实命题应限制为：对这份历史Wine两特征的保留样本，模型具有所报告的密度预测与稳定性表现。

训练、验证、测试各自职责清楚，才可能把测试作为对选择过程之外数据的评价。标准化只用训练集，候选K按验证平均对数密度选，标签仅在最后算外部ARI。即使训练函数没有标签参数，人先看颜色再选择特征也会泄漏，因此协议不仅约束代码，还约束探索顺序。

固定两列是为了教学透明，不意味着它们是最优特征组合。若用全部13列或另一对列，需要重新定义正则化、样本量与选择方案，不能把本次结论无条件迁移。真实行号互斥仅证明本课行级划分无重叠，不证明所有潜在个体、生产批次或时间依赖都已隔离。

2 责任度手算与标签交换

权重0.4、0.6，高斯密度0.2、0.1时，两个联合支持为0.08与0.06，观测密度0.14。责任度为 $0.08/0.14=4/7$ 与 $0.06/0.14=3/7$ 。虽然第二分量先验更大，当前点的似然更支持第一分量，因此第一责任度更大。

把权重、均值、协方差完整交换编号，观测密度仍为0.14，责任度只是顺序变成 $3/7$ 、 $4/7$ 。分量编号不是可观测事实。若只交换均值而不交换权重和协方差，那通常已经改变模型，不能称为标签交换不变性检验。

合成均值匹配通过最小总平方距离确定一一映射，再计算匹配后的距离。本次估计顺序对应真分量 $[2,0,1]$ ，匹配均方根距离约0.07760，单位是训练标准化坐标。真实Wine没有高斯参数真值，所以不能套这个误差指标；品种标签也不能提供每个高斯均值的真实答案。

3 数值稳定性与输入拒绝

直接计算远尾密度可能把每项都下溢为零，然后归一化得到未定义的0/0。对数域先计算联合对数密度，再减去最大值做logsumexp，使指数项最大为1；责任度由归一化的对数差取指数。这样并不消除所有浮点误差，但明显扩大可稳定计算的范围。

Cholesky分解要求协方差正定。正则化对角线帮助避免退化，但独立函数仍应拒绝不对称、非正定或含NaN的输入。权重必须为正且和为1，维度必须一致。使用显式异常使这些检查在python -O下继续存在，不能依赖assert。

独立实现与库对照支持计算正确性，不能检验现实分布是否属于混合高斯。两条证据需要分开报告：第一条是软件与数学核验，第二条是统计适用性。把第一条通过写成模型已经发现真实结构，是把实现测试越界解释成科学证据。

4 模型选择的实际结果

合成验证选择K=3，平均验证对数密度约-2.072486；K=4约-2.073486，两者仅差约0.001。因为选择依据预先固定为验证密度，选K=3是合格执行结果，但差距小意味着单次选择证据有限。测试平均对数密度约-1.995785，真参数oracle约-1.958635。

Wine验证选择K=4，验证平均对数密度约-2.363118；K=3约-2.394471。训练BIC最低却在K=2，说明有限样本下不同准则可以分歧。正确处理是报告两者并解释本项目只按预声明验证准则选型，而不是临时选择最接近三个已知品种的答案。

无混合负对照选择K=1，符合生成机制。这一项说明当前流程并非不看数据就强制多分，但不证明误选更多分量的概率为零。若要研究该概率，需要很多独立数据重复、预先决定候选范围与选择规则，并保留所有运行。

5 合成恢复与不可约重叠

本次合成测试ARI约0.984553，显示硬划分与生成Z高度一致，但不是完全一致。高斯分量有重叠，某个点即使知道真参数也未必能确定抽到的Z。隐藏来源随机性、参数估计误差与优化误差需要区分，不能把所有错分都归咎于EM。

均值匹配误差约0.07760补充了ARI，但二者也不验证协方差全部正确。似然、责任度、参数距离和划分相似度问的是不同问题。一个模型可以把大多数点分对，同时在权重或协方差上偏一点，导致整体相关或尾部质量不同。

如果候选K不是3，程序不会强制均值一一匹配。这是合理的边界处理。对多出来的分量，可以研究密度逼近、合并后的划分或其他有明确目的的距离，但不能不加说明地删掉分量后继续声称原模型恢复真值。

6 硬q的ELBO缺口推导

令 $a_k = \log p(x, Z=k)$ ，精确对数证据为 $\log \sum \exp(a_k)$ 。选择最大项k星的硬q在该状态概率为1，其余为0，所以期望联合对数密度为 a_{k^*} 星，熵为零，ELBO就等于 a_{k^*} 星。二者相减为 $\log \sum \exp(a_k)$ 减去 a_{k^*} 星。

责任度 $r_{k^*} = \exp(a_{k^*}) / \sum \exp(a_k)$ ，取负对数恰好得到同一个差值。因此缺口 $= -\log$ 最大责任度 $= \text{KL}(q(\text{硬}||r)$ 。若最大责任度0.5，缺口约0.693147；若0.99，缺口约0.010050。最大责任度接近1时硬化损失小，处于边界时损失更明显。

KL方向不能颠倒。精确r若给多个分量正概率，硬q在其中一些位置为零，则 $\text{KL}(r||q)$ 会涉及正概率乘 $\log$ 正数除零，可能无穷。本次报告只使用前向到r的缺口恒等式，没有把不同KL方向混作同一误差。

合成平均缺口约0.009260，Wine约0.075374。它们仅描述给定拟合参数下把软离散后验硬化的损失，不包括参数后验、K选择、模型错设或局部最优。平均值小也不保证每个样本小，所以图3保留逐样本责任度与缺口关系。

7 两种稳定性如何读

重启稳定性固定训练行，只改变初始化，主要暴露优化敏感性。重采样稳定性有放回抽取训练行再拟合，既含数据扰动也含优化扰动。两者都在相同固定测试输入上比较预测ARI，避免比较不同抽样对象的标签。

Wine重启最低ARI约0.731，bootstrap最低约0.635，最高1。合成bootstrap大多接近1。可以说当前Wine两特征、K=4、有限样本下的划分对扰动更敏感；不能说真实隐结构一定不存在，也不能把差异全部归于某一个原因。

稳定性也不是科学真实性的充分条件。一个错误但非常僵硬的模型可能每次都分得一样，得到很高稳定性；一个真实但重叠的分布则可能让边界点在重采样时改变归属。因此稳定性要与预测、真值对照和模型检查结合，不能独自担任最终判决。

8 固定参数预测与完整后验预测

主GMM路线从估计参数 θ 确定的 $p(x_{\text{新}}|\theta)$ 抽样，参数本身不变化。完整贝叶斯后验预测则对 $p(\theta|D)$ 积分，包含不同可能参数带来的预测变化。EM点估计没有构造这个参数后验，所以本项目明确叫固定参数拟合模型复制检查。

bootstrap用经验数据重采样产生估计分布，不能未经额外论证当成某个先验下的参数后验。增加12个bootstrap模型不自动补齐贝叶斯积分，也不自动校正K选择。若要扩展为完整后验预测，需要指定先验、推断算法、参数标签交换处理与近似诊断。

200次复制形成的是统计量的有限模拟分布。2.5%到97.5%分位区间是复制统计量区间，不是参数可信区间；描述性尾部比例不是经过选择校正的正式显著性水平。它们用来发现值得进一步研究的失配，不能证明模型为真。

8.1 共轭预测基准的计算答案

设 θ 先验 $N(0,4)$ ，观测给定 θ 独立服从 $N(\theta,1)$ 。600个训练观测给出后验方差 $v=1/(600+0.25)=0.0016659725$ ，后验均值约-0.02305036。400个新观测的样本均值在给定 θ 时服从 $N(\theta,1/400)$ ，再对 θ 后验积分，得到 $N(m,v+1/400)$ 。

因此完整预测样本均值方差约0.00416597，固定后验均值对照为0.0025，比值约1.666389。5000份复制实际得到约0.00429439和0.00259099，分别与解析值接近。有限蒙特卡洛误差不要求两个数逐位相同；单元测试用明确相对容差核对，并要求完整预测方差显著更大。

完整解析95%区间约[-0.14955,0.10345]，固定参数区间约[-0.12105,0.07495]，测试样本均值约-0.00329360。两者此次都覆盖，不能因此说遗漏参数不确定性没有后果；区别体现在重复预测分布的宽度，而不只是一份测试的覆盖与否。

每份复制共享一次 θ 是关键。若每行单独抽一个 θ ，均值方差会变成 $(v+1)/400$ ，错误地把共同参数不确定性平均掉。该基准的已知噪声来自合成真机制，只针对单高斯负对照第一维；它没有给Wine或GMM参数构造后验，所以报告始终保持分离。

9 合成相关检查冲突如何解释

合成测试相关系数约0.370913，固定参数复制95%区间约[0.139217,0.314486]，观测在区间外；描述性尾部比例约0.004975。尾部比例观测0.0225在复制区间[0.01,0.0425]内。我们应分别报告，而不是因为ARI很高就忽略相关差异。

相关系数取决于分量权重、均值位置、协方差及测试抽样组成。大部分标签分对，并不迫使这些量都足够准确。有限训练估计、有限测试抽样与未计入参数不确定性都可能贡献冲突；当前一次实验不足以唯一归因。

合格后续是预声明多个独立数据重复，分别用真参数与拟合参数生成复制数据，比较统计量差异出现频率。若只更换种子直到红线落回区间，再把新图作为唯一结果，就破坏了验证意义。保留一个不符合简单成功叙事的结果，正是本项目的重要训练目标。

10 Wine的漂亮ARI与真实边界

Wine选 $K=4$ ，但36个测试样本的硬分量计数为11、0、10、15；一个分量没有赢得任何测试点的最大责任度。因此测试硬划分实际上只占用三个组，可以与三个品种标签完全一致，ARI达到1。这并不矛盾，也不能推出每个拟合分量都对应一种品种。

软密度仍包含未占用分量的贡献；训练与验证的占用也可能不同。品种标签是外部来源类别，不是高斯生成分量真值。ARI1只说明当前36点分组一致，不能推广为全体历史酒样、未来地区或真实化学机制的唯一结构。

真实复制检查两项观测都落在区间中，但Wine只有36个测试点，复制区间较宽。没有看见冲突可能因为辨别能力不足。再结合bootstrap最低ARI约0.635，合理结论是当前模型提供有一定外部一致性的探索表示，但结构解释与外部泛化仍需更多数据支持。

11 合格的扩展研究与停止条件

可以把新的合成机制改成三组重尾分布，并事先固定训练规模、异常尾部强度、候选集合、评价统计与重复次数。保留单高斯或无结构负对照，使用独立新数据，分别研究密度拟合和标签恢复。若有些重复选错K或复制检查失败，应视为待解释结果而非自动删除项。

停止条件应围绕研究问题：预声明实验全部完成，输入与数值测试通过，结果能重建，支持与反证都保留，未解决的机制已经界定。不是“所有图都漂亮”才停止，也不是遇到一个不利结果就放弃。无法确认数据来源或实现核验失败时，则暂停科学结论并先修复证据链。

本课交付的可信内容是可重复研究流程、合成恢复、真实边界与计算近似的明确分层。没有交付葡萄酒因果机制发现、完整参数后验、全球最优证明或跨地区部署保证。把这些限制写清楚不会削弱研究，反而使下一步需要什么证据变得可执行。