

第082课 实验：隐结构的证据链

最终交付是一份小型研究报告：同一GMM流程在已知合成真值、真实Wine与无混合负对照上完整运行。你必须同时报告成功、冲突和不能判断的内容。预计三次学习，每次60至90分钟；所有计算离线，无付费接口。

1 先写一页预声明方案

在运行前用自己的话写出主问题：给定二维观测，有限高斯混合在多大程度上提供可重复的密度与分量解释？然后分别写实现、合成恢复、真实预测与稳定性四项检验。每项写一个失败条件，例如独立责任度不一致、均值匹配误差较大、测试密度低于简单基线或重采样划分变化明显。

固定候选K为1至4、全协方差、正则0.03、训练拟合与验证选择，以及标准化只用训练集。不得先查看品种标签图再修改特征。Wine本实验已经固定使用列0酒精与列6黄酮，这使你可以集中理解研究链条，而不把特征挑选变成没有记录的额外优化。

你的报告不必提出新的算法贡献，但必须说明每个结果支持哪个命题。若你发现“高ARI”和“复制检查冲突”同时出现，应保留二者并解释，不要立即更换统计量或随机种子。科研训练的一部分正是学会容纳不同证据层面的分歧。

2 环境与数据来源验收

安装requirements.txt后，从本单元目录执行数据生成、实验和两种解释器模式的测试。

```
python generate_data.py --directory outputs/my-data
python experiment.py --out outputs/my-result.json
python test_experiment.py --out outputs/my-tests.json
python -O test_experiment.py --out outputs/my-tests-optimized.json
```

generation.json应给出确定的字节数与SHA256。比较新数据与data/dataset.json，确认真实行号没有重复跨集合。Wine总行数178，训练106、验证36、测试36；合成与负对照各为600、200、400。合成真值包含权重、均值、协方差以及每个观测抽到的Z，真实数据没有高斯分量真值。

来源说明不能只写“sklearn数据”。补充Wine原始作者、UCI链接、CC BY 4.0许可与本课程的变换：从13列选两列、保存原行号、内部随机划分、训练标准化。这里酒精与黄酮是化学测量字段，不应把未明确给出的全部单位凭常识补成确定事实。真实数据是历史有限样本，不能代替外部部署验证。

3 手算一个责任度例子

设两个分量的权重为0.4和0.6，对当前点给出的高斯密度分别为0.2和0.1。先计算联合支持0.08与0.06，再求观测密度0.14，最后得到责任度4/7与3/7。注意权重更大的第二分量并不一定有更大的后验，因为当前观测更受第一分量支持。

把两个分量完整交换编号，检查观测密度是否变化、责任度顺序怎样变化。用这个例子说明为什么直接比较两次运行的“第0类准确率”可能错误。对于真实Wine，分量编号没有固定科学名称，不应把每个编号直接写成一个已知品种。

阅读latent_project.py的log_joint与responsibilities，对照公式逐行定位：权重对数、Cholesky分解、对数行列式、平方马氏距离、logsumexp和归一化。挑一个远离均值的点，比较直接指数计算与对数域计算，记录哪一步可能发生下溢。

4 独立验证不是复制同一条计算路径

测试将独立实现与SciPy的多元高斯密度、sklearn公开接口相比较。查看test_independent_density，确认它不是调用responsibilities两次。单分量手算、标签置换、极端尾部与非法协方差测试提供不同角度，减少两个实现共享同一错误的风险。

尝试把协方差改成不对称、负定或包含NaN，程序应拒绝而不是返回一个颜色标签。尝试错误维数、权重不归一化或负权重，检查显式ValueError。优化解释器模式同样应保留这些校验，所以不能用assert替代它们。

通过数值测试只能支持给定模型的实现正确性，不能证明GMM适合Wine。把“实现层测试通过”和“统计模型足够好”写成两个独立段落。若你对两者区别说不清楚，先暂停后续模型解释，回到研究问题分层。

5 比较所有候选，而不是只展示赢家

从结果JSON整理每个K的训练与验证平均对数密度、BIC、迭代次数与收敛状态。图2应同时保留K=1到4。观察训练目标随K大致改善，但验证不一定继续改善；如果某候选未收敛，本实现会报错，不把不完整结果当正常候选继续比较。

在合成世界找出验证最优K，并计算它与次优候选的验证差距。差距很小意味着你应谨慎描述模型选择的确定性，不能因为选中真K就推断选择器总是正确。负对照选K=1是支持性的有限证据，如果换独立种子后选到K=2，也应保留并讨论验证噪声。

在Wine上比较验证选K与训练BIC偏好的K。不要临时决定“哪个更接近已知品种数就用哪个”。若想比较选择准则，另开一项预声明的重复研究，保持评估数据独立。当前实验的准则已经固定，报告应解释分歧而非隐藏它。

6 合成真值恢复与标签匹配

取测试预测分量与真实Z计算ARI。再查看估计均值与真均值，如果编号顺序不同，先通过match_means求最小距离的一一匹配。抄下匹配映射和匹配后均方根距离，并说明误差在训练标准化坐标中计算。

若未来扩展选出K不等于3，不可强行把多余分量删除后再报“恢复很好”。应把“分量数不同，不能一一匹配”作为有效结果，再分别评价密度预测与划分。模型可以密度拟合不错而参数解释不同，这正是阶段项目要展示的辨析。

比较拟合模型与真参数模型的测试平均对数密度。真参数并不是用测试集估计，所以它是合成世界的oracle对照。一次有限测试中真参数分数并不必然高于任何拟合参数，但其生成意义清楚。不要把它当作真实数据也可以获得的参考答案。

7 量化硬分配的近似误差

使用每行联合对数密度，分别计算 $\log\text{sumexp}$ 与最大值，二者相减就是硬q的证据下界缺口。再独立计算负对数最大责任度，要求两条路径数值一致。对责任度0.5、0.5的例子，缺口应为 $\log 2$ ；对0.99、0.01，缺口约0.01005。

这项实验把近似误差限定在给定拟合参数下的离散隐藏变量。请列出没有覆盖的误差：参数估计、参数后验近似、模型错设、模型选择以及优化停在局部解。不能因为硬q缺口小就说完整贝叶斯推断准确，也不能把EM多次重启当成参数后验采样。

打开图3，找出最大责任度最低的真实测试点，观察它的责任度是否分散。不得在看见这些点之后修改主要统计量使近似显得更好。你可以把它们作为后续诊断案例，但要标明属于事后探索。

8 分开理解两种稳定性

先固定训练数据，用12个种子各进行单次初始化，记录固定测试点上的ARI与密度。再对训练行有放回重采样，保持评价点完全相同，重新拟合并记录。图4应该有完整的两条曲线，没有删除低一致性的重复。

解释为什么不能把不同bootstrap训练样本的标签逐行相比较。抽样顺序与对象不同，直接对齐标签没有统计意义。当前使用同一组测试输入，只把模型变化带来的预测变化拿来比较；测试标签没有参与稳定性计算。

稳定性诊断使用测试输入并不等于允许根据它选赢家。当前没有使用这些曲线回头选初始化或K。若你依据稳定性调整设计，原测试集就转为开发信息，新的最终性能需要另留评价数据。把这种信息流写出来比使用“无监督所以不会泄漏”的说法更准确。

9 复制检查必须保留观测与模拟规模

使用冻结参数生成200份复制数据，每份大小等于对应测试集：合成400、Wine36。按预声明方式计算相关系数和尾部比例。核对图5的直方图来自复制数组，而红线来自保留测试数据；不能把训练统计量误放为测试观测。

记录复制95%区间、观测值是否越界及描述性尾部比例。合成相关系数会出现明显冲突，而Wine两项都落在较宽区间中。请先解释这两种结果的证据强度，不要仅按“通过/失败”二元打分。36行真实测试的区间宽，可能只是辨别能力有限。

写出固定参数预测与完整后验预测的数学区别。完整方法需要对参数后验积分，本项目只有一个EM点估计。即使进行了bootstrap，也不能未经论证把其模型集合称为后验样本。你的图注和报告标题必须保持这一边界，不使用“完整后验预测已经验证”的表述。

9.1 补做解析可验的完整后验预测

读取negative原始第一维，使用训练600行、测试400行。模型规定观测方差1已知、均值 θ 先验 $N(0,4)$ 。手算后验方差 $1/600.25$ ，再算后验均值。不要在这里使用训练标准化后的方差冒充已知噪声1，程序故意读取原始合成坐标。

查看conjugate_predictive_check，每一份复制数据先抽一个 θ ，然后把它广播给该份400个观测。解释为什么每行独立重新抽 θ 会破坏共同参数结构。用全方差公式推导样本均值预测方差：完整版本为 v 后验加 $1/400$ ，固定后验均值版本为 $1/400$ 。

比较5000份真实复制的均值方差与解析值，误差应在蒙特卡洛波动范围内。再比较95%区间与保留测试均值。本项是真正对标量参数后验积分的基准；请明确它与主GMM固定参数复制是两项不同实验，不能替主项目补上一项没有做过的GMM贝叶斯推断。

10 真实数据边界分析是必交项

Wine测试外部ARI为1，同时选 $K=4$ 、一个分量在测试硬分配中未被占用、bootstrap ARI最低约0.635。解释为什么这三项并不矛盾。请从“密度分量”“硬划分”“已知品种标签”“36个保留样本”四个对象分别说明，避免把它们统称成类别。

报告只有两个测量特征，未研究另外十一列；没有时间或生产批次外部测试；历史数据范围有限；随机行划分不能证明跨产区泛化。不得用已有标签的一致性声称已经发现化学因果机制。可以把结果写成有希望的探索线索，但下一步需要什么新证据应明确列出。

如果你觉得当前任务太容易，提出一个新的真实数据外部验证方案即可，不必为了增加难度盲目引入更多库或在线数据。阶段项目验收重点是完整证据链。任何新增数据都要重新核对来源、许可与划分，不把未经执行的计划写成结果。

11 Notebook、图形与复现验收

执行plots.py到新目录，确认五张图都能重建且没有中文字缺失、坐标截断或错误图例。图1颜色编号不同不表示恢复失败；图2的不同数据集密度不作跨数据集排名；图5的复制区间是统计量分布区间，不是参数可信区间。每张图附上一句它能支持和不能支持的结论。

执行execute_notebook.py并检查全部代码单元的连续执行计数、真实文本与内嵌图像输出。当前隔离环境采用新Python进程内IPython顺序执行，记录实际方式，不声称浏览器交互或网络内核已被测试。代码单元出现错误应停止交付，不能保留旧输出伪装本轮成功。

12 最终研究报告模板

用“问题与预声明、来源与职责、模型与数值核验、合成恢复、真实边界、近似与稳定性、预测复制、结论与下一步”组织报告。主要表格引用冻结JSON，原始重复结果作为附件保留。最强结论与最大局限都放在开头，让读者不用翻到最后才发现只有36个真实测试样本。

合格的停止条件是全部实现验收完成、预声明实验已经跑完、支持与冲突结果都有解释、未识别部分明确列出。继续修改直到“每张图都通过”并不是完成条件。如果新问题值得研究，把它写成下一项有独立数据与停止条件的实验，而不是无期限改写当前故事。