

第084课 参考答案：从局部规则追溯每一个梯度

以下实测来自Python 3.12.14，完整浮点数保存在experiment-result.json。解析整数结果可精确验证；含sin和exp的值应按适当容差比较。实验只求导，不执行优化器更新。

1 实验A：加法、乘法与种子

a=2、b=3时，加法输出5，梯度分别为1、1；乘法输出6，梯度分别为3、2。把反向种子设为2，前向输出仍为5或6，梯度变为2、2或6、4。种子对应最终输出在某个标量组合中的系数，不会修改之前已经计算的数值。

对于 $x=3$ 、 $z=x*x$ ，乘法左右两个输入槽位各贡献3，合计6。虽然两个槽位指向同一对象，但对 x 变化引起的两份作用都存在。若把父节点集合去重后只保留一项局部导数，程序会错误给3。

2 实验B：共享图完整账本

前向： $x=2$ ， $y=3$ ， $t=6$ ， $q=36$ ， $z=42$ 。反向开始所有节点为0， z 种子设1。

1. 处理 $z=q+t$ ： $q.grad$ 加1， $t.grad$ 加1。
2. 处理 $q=t*t$ ：左槽向 t 加6，右槽再加6，所以 $t.grad$ 从1成为13。
3. 处理 $t=x*y$ ： $x.grad$ 加13乘3，得到39； $y.grad$ 加13乘2，得到26。
4. x 与 y 是叶节点，无父边，结束。

图有5个节点、6条输入边： t 的两个输入， q 的两个槽位， z 的两个输入。两个来自同一 t 的槽位不能当作一条未加权边。正确拓扑排列之一为 x,y,t,q,z ，反向按相反次序处理。

如果把累加改为覆盖，最终结果依赖遍历边的顺序，可能只剩最后一次贡献。不同实现可能显示不同错误数值，因此不应记“错误程序一定输出某个固定值”，而应检查它是否丢失了路径贡献。独立展开 $z = x^2y^2 + xy$ ，得到39与26，排除了只靠图实现自证的循环。

3 实验C：重复调用的实际语义

$x=3$ 、 $z=x*x+x$ 时， $z=12$ 。seed依次为1、1、2、0， $x.grad$ 依次为7、7、14、0； $z.data$ 始终12。每次调用都会清空当前可达图的所有grad，所以不会保留上一调用结果。

这并不是所有自动微分器都必须采用的规则。PyTorch的叶子.grad通常累积本次反向贡献，需要在适当时机清零；重复使用同一已执行图还要注意图保留或重建。本课没有模仿这些完整生命周期语义，文档明确差异比表面使用同一个方法名更重要。

4 实验D：平滑函数四路结果

$f = (xy + \sin x)e^y$ ，解析偏导为

$$f_x = (y + \cos x)e^y, \quad f_y = (x + xy + \sin x)e^y.$$

在(0.7,-1.2)，函数值为-0.05896849939879192。反向与前向得到 x 偏导-0.13106701445828614、 y 偏导0.15186744893974957，与本点解析式一致。中心差分 $h=10^{-5}$ 得到约-0.13106701446212454、0.15186744895014093，最大绝对差 1.0391×10^{-11} 。

五个预声明点的差分最大绝对差不超过 1.30×10^{-10} 。这支持当前实现对这些平滑案例正确，不等于对所有可能输入的形式化证明。单算子、共享图和域测试各自补上不同风险，不能只保留这项综合误差指标。

5 实验E：误差扫描与拐点

本次 h 从 10^{-1} 到 10^{-15} 扫描，误差最小的已试点为 10^{-5} ，约 1.04×10^{-11} 。 h 为 10^{-1} 时误差约 9.57×10^{-4} ； h 为 10^{-15} 时误差反而约0.0131。这不是自动微分突然变差，而是差分的小步长浮点消减占了主导。

ReLU在0处左右数值为ReLU(h)= h 和ReLU($-h$)=0，所以中心差分恒为 $h/(2h) = 0.5$ 。右导数1，左导数0，因此普通导数不存在。实现选择0是一个约定，不应把0.5称为更精确的真实导数。

若测试 $x=1$ ，选择 $h=0.01$ 等使 $x-h$ 与 $x+h$ 都严格为正，则函数在该局部是恒等映射，中心差分应接近1。在负区间同理应为0。核验测试首先要满足可微前提，之后再讨论精度。

6 实验F：Jacobian乘积

$f_1 = xy$ 给第一行(3,2)， $f_2 = x^2 + y$ 给第二行(4,1)，所以 $J = \begin{pmatrix} 3 & 2 \\ 4 & 1 \end{pmatrix}$ 。输入方向 $v=(1,-1)$ 得到 $Jv=(1,3)$ ，说明沿该输入方向移动时两个输出分别以1和3的一阶速率变化。

输出权重 $u=(2,-1)$ 定义 $L = 2f_1 - f_2$ ，反向梯度为 $J^\top u = (2, 3)$ 。如果使用行向量约定，则写 $u^\top J = (2, 3)$ ，内容相同。 v 长度由输入维数决定， u 长度由输出维数决定；碰巧本题都是2不意味着可以任意混用。

要用反向模式恢复 J ，先以输出权重(1,0)得到第一行，再以(0,1)得到第二行。每次按本课API会清零，因此需分别保存结果，不能期待第二次调用后同时保留两次结果。

7 实验G：单神经元结果

预激活 $a = 0.4 \times 2 + (-0.8) \times (-1) + 0.1 = 1.7$ ，预测1.7，误差0.7，半平方损失0.245。损失对预测导数0.7，ReLU在正区间局部导数1，因此对预激活导数也为0.7。

三个参数梯度依次为 $w_1 : 1.4$ 、 $w_2 : -0.7$ 、 $b : 0.7$ 。实跑显示1.4000000000000004等极小尾差，是二进制浮点表示而非新的理论结果。若把损失写成没有二分之一的平方，梯度会全部变为两倍，所以核验前必须对齐损失定义。

8 习题1：重复槽位和直接路径

$z = x^*x + x$ ， $x=3$ 时 $z=9+3=12$ 。平方路径包含两个乘法输入槽位，各贡献3；直接加法路径贡献1，因此总梯度7。解析求导 $2x + 1$ 也得到7。

如果平方只保留一份贡献，则再加直接路径得到4。若最后用赋值覆盖，错误值还可能只剩1或3。准确诊断应检查边列表和累加顺序，而不是用另一个错误常数补偿结果。补偿只会掩盖结构缺陷。

9 习题2：两种推导交叉验证

图推导见第2节。独立展开为 $z = x^2y^2 + xy$ ，所以 $z_x = 2xy^2 + y$ 、 $z_y = 2x^2y + x$ 。代入(2,3)为39与26。中间量导数 $z_t = 2t + 1 = 13$ 则给出另一条检查路线：13乘 $y=39$ ，13乘 $x=26$ 。

注意 z_t 是把 t 当作中间独立坐标时的敏感度，而 x 与 y 还通过 t 关联到输出。不能把13直接当成所有参数的梯度；还必须通过 t 的局部Jacobian继续传播。

10 习题3：相同数值不等于相同节点

令 $a = \text{Value}(2)$ ， $b = \text{Value}(2)$ ， $z = a + 3*b$ 。两叶节点数值相同，但代表不同独立输入，正确梯度 $a.\text{grad}=1$ 、 $b.\text{grad}=3$ 。如果按data去重，程序可能错误地把它们视为一个变量，既混淆依赖也无法表达这两个不同敏感度。

对象身份去重表示同一中间结果被复用时只处理一次。它不意味着每条边也去重：同一个对象在乘法左右槽位出现两次，要保留两项局部导数，或显式先把它们相加成等价的合并边。本课选择保留原始边，最易与算子规则对应。

11 习题4：清零、累加与种子

本课每次backward先清空当前可达节点，所以两次调用互相独立。 $\text{seed}=2$ 相当于计算 $2z$ 对输入的梯度，或对输出 z 施加上游敏感度2；它不是执行两次前向，不是把参数乘2，也不是学习率。

PyTorch默认把一次反向得到的贡献加到叶子已有.grad，训练循环需要合适的zero_grad或设为None等清理方式。但这属于调用之间的存储语义。单次反向中共享节点的贡献都必须相加，两种API在这一数学要求上相同。

12 习题5：复合函数完整求导

对 x , y 视作常数, 内层 xy 导数 y , $\sin x$ 导数 $\cos x$, 指数因子不变, 得到 $(y + \cos x)e^y$ 。对 y , 第一因子导数 x , 第二因子导数 e^y ; 乘积法则两项为 xe^y 与 $(xy + \sin x)e^y$ 。

常见错误只保留 xe^y , 遗漏指数随 y 变化; 另一个错误把 $\sin x$ 对 y 也求出 $\cos x$, 这是没有遵守偏导时其他独立变量固定的约定。两种错误都可能在某些特殊点被数值抵消, 所以核验应覆盖多个点。

13 习题6：解释两个空间

结果为 $J = \begin{bmatrix} 3 & 2 \\ 4 & 1 \end{bmatrix}$, $Jv = (1, 3)$, $J^T u = (2, 3)$ 。前向种子位于输入空间, 回答“若输入沿 v 变化, 输出怎样变”; 反向种子位于输出空间的对偶表示, 回答“若关注 u 加权的输出, 输入各坐标有多敏感”。

若只有一个输入而三个输出, v 只有1项、 u 有3项。此时维数不同可以直观阻止二者混用。把它们都叫“梯度向量”而省略参照对象, 会让后续多输出网络的代码变得难以审计。

14 习题7：差分不能创造导数

中心差分0.5是左右两种线性行为的平均效果, 而导数存在要求所有趋近方式得到同一个极限。ReLU在0的左右导数分别0与1, 条件失败。因此0、0.5、1都不能被称为该点唯一普通导数。

可在 $x=1$ 且 $0 < h < 1$ 时测试正分支, 左右点都为正, 差分为 $[(1+h)-(1-h)]/(2h)=1$ 。负点选择不跨0的 h 则得到0。对不可微边界, 单元测试应检查实现声明的约定, 而平滑差分检查应远离边界。

15 习题8：模式选择依据

一百万输入参数、一个标量损失时, 反向模式一次种子1可得到全部参数偏导; 朴素逐基方向前向需一百万个方向传播。若一个输入映射到很多输出, 前向模式只播种这个输入方向一次, 就能得到所有输出对它的导数; 反向逐输出恢复完整Jacobian则需多个种子。

这是一阶计算工作量的通常比较, 不等于任何程序中绝对的运行时间预测。内存、并行批处理、稀疏结构、只需要某个方向而非完整Jacobian等因素会改变实际选择。若只要一个方向导数, 不能因为参数多就断言一定用反向。

16 习题9：负区间情形

本课正区间答案见第7节。若预激活严格为负, ReLU输出0且局部导数0; 同样目标1、半平方损失给0.5, 但经过ReLU回到 a 的梯度为0, 三个参数本样本贡献都为0。

这说明损失不为0不保证每个参数都有非零梯度。某条路径的局部导数为0即可阻断一阶传播。它也不意味着网络永远无法改善: 其他样本、其他路径或后续参数变化可能改变激活状态。单个样本的局部结论不能扩大成所有训练过程的结论。

17 习题10：两类核验风险

旧图保存的是旧前向值和旧局部导数，直接改输入后不重建图，会混合不同参数点的量。正确流程是先确定新参数，再创建新Value、重新执行函数、最后反向。正常data属性禁止直接赋值，但故意修改内部字段仍可破坏约定，测试不应依赖这种用法。

极小h可能让左右函数值在浮点中几乎相同，差值舍入后再除以h放大噪声。正确流程是在可微点固定随机性，按变量尺度扫描多个合理步长，比较误差趋势，并用解析小例子及前向模式提供额外证据。看到最小步长差异很大，应先诊断数值消减，而非立刻宣布自动微分错误。

18 最终验收与没有证明的部分

19项测试在普通与优化解释器下均通过；共享图梯度为39、26；JVP为(1,3)、VJP为(2,3)；五点差分最大绝对差约 1.29×10^{-10} ；长2500步图没有依赖递归深度。这些是明确的已验事实。

尚未提供张量广播、GPU、高阶导数、动态图内存释放策略、原地修改版本追踪或全部异常数值下的稳定性。当前实现适合教学和小标量核验，不应替代生产框架。能正确写出这些限制，也是本课完成的一部分。