

第085课答案与冻结实验核对

请先完成实验手册。下面的答案不仅给结果，也说明每一步为什么成立，以及哪些错误不能通过修改学习率来掩盖。

1 形状与参数量

输入X为 5×2 ；W1为 2×3 ，b1为3；Z和A为 5×3 ；W2为 3×4 ，b2为4；S、P和独热标签矩阵E为 5×4 ；每样本损失为5项，平均损失为标量。反向G_S为 5×4 ，G_A与G_Z为 5×3 ，G_W2为 3×4 ，G_b2为4，G_W1为 2×3 ，G_b1为3；若继续求输入梯度G_X，则为 5×2 。

参数量为 $2 \times 3 + 3 + 3 \times 4 + 4 = 25$ 。批量大小不进入参数量，因为一批样本共享参数。把b1写成 5×3 虽然能加到Z，却会为每条样本引入不同偏置，已经不是题目所述模型。

2 完整纸笔例

前向结果：Z=[[2,1.5],[-0.5,2.5]]，A=[[2,1.5],[0,2.5]]，S=[[0.05,0.20],[-0.65,0.80]]。第一条概率为[0.462570155,0.537429845]，第二条为[0.190001566,0.809998434]。两条损失分别为0.770957048、0.210722965，平均为0.490840006。

分数梯度为

$$G_S = \begin{bmatrix} -0.268714923 & 0.268714923 \\ 0.095000783 & -0.095000783 \end{bmatrix}.$$

把A转置后左乘得到

$$G_{W_2} = \begin{bmatrix} -0.537429845 & 0.537429845 \\ -0.165570426 & 0.165570426 \end{bmatrix}, \quad G_{b_2} = (-0.173714140, 0.173714140).$$

例如第二行第一列为 $1.5(-0.268714923) + 2.5(0.095000783) = -0.165570426$ 。这一项显式累加两个样本贡献，不能只取第一条或者再平均一次。

G_A 为[[-0.080614477,0.188100446],[0.028500235,-0.066500548]]。ReLU掩码为[[1,1],[0,1]]，故G_Z第二行第一项变0，其他不变。第一层结果为

$$G_{W_1} = \begin{bmatrix} -0.080614477 & 0.254600994 \\ -0.161228954 & 0.309700344 \end{bmatrix}, \quad G_{b_1} = (-0.080614477, 0.121599898).$$

学习率0.1时

$$W_1^{new} = \begin{bmatrix} 1.008061448 & -1.025460099 \\ 0.516122895 & 0.969029966 \end{bmatrix}, \quad b_2^{new} = (0.117371414, -0.217371414).$$

第一层某些权重变大、另一些变小，不能从单个预测错误直觉指定全部权重方向。所有变化必须由同一点的梯度共同决定。

3 广播与偏置归约

因为 S_{ic} 中都含同一 $(b_2)_c$ ，且 $\partial S_{ic}/\partial (b_2)_c = 1$ ，链式法则把所有i的贡献相加：

$\partial L/\partial (b_2)_c = \sum_i (G_S)_{ic}$ 。保持类别c，沿样本i求和，所以NumPy为axis=0，结果C项。

沿类别求和会得到B项，语义变成每条样本的类别梯度之和；普通softmax交叉熵中这一行和恰好接近0，却不是偏置梯度。若B=C，形状甚至恰好相同，错误更难从运行报错发现，因此必须解释索引含义。

4 三种归约修改

当前B=3，sum梯度是3g；复制整批两次后仍mean，梯度仍是g。若仅在已经含1/B的G_S起点之外，对偏置再取一次mean，则偏置梯度小三倍，而按正确公式计算的权重梯度不变。它不是全体参数统一缩放，因此无法用一个全局学习率抵消。

如果每层都在回传表示梯度上再除B，越靠前的层会积累更多错误因子，情况更糟。应先写清每个中间量是否已经对全目标求导，不要在看到“batch”时条件反射地除样本数。

5 ReLU零点的中心差分

对任意正epsilon，中心差分为 $[\text{ReLU}(\epsilon) - \text{ReLU}(-\epsilon)]/(2\epsilon) = 1/2$ 。但ReLU在0不可微，左导数0、右导数1，没有唯一普通导数。代码选择0是约定，中心差分1/2是跨两侧的对称斜率，所以两者不一致不足以判错。

应在远离零点且扰动不跨折点的位置核验，或者换光滑激活检查整个链条。同时还要检查代码在负侧导数为0、正侧为1。不要为了让零点差分通过就把所有ReLU导数改为1/2。

6 更新顺序

G_A的公式含W2。若先把W2改成W2-new，而G_S仍来自旧参数前向，那么所得G_A混合两个参数点，不是L在旧参数点的导数，也通常不是L在新点的完整导数。正确顺序为：旧参数完成前向；缓存中间值；完整计算G_S、G_W2、G_b2、G_A、G_Z、G_W1、G_b1；最后统一更新。

如果你确实想采用交替优化，必须把它定义成一个新的算法，每次参数块更新后重新计算相关前向和目标，而不能把混用新旧参数的错误称为标准反向传播。

7 差分步长诊断

误差先下降再上升符合截断误差与舍入误差竞争。1e-3到1e-5的改善支持中心差分的局部逼近，1e-8变差说明浮点相减开始不稳定。后续应检查是否float64、函数是否确定、是否存在ReLU折点、参数扰动后是否恢复，并对多个参数点重复检查。

本次17参数分块最大绝对误差为W1约6.24e-12、b1约6.52e-12、W2约8.63e-12、b2约1.79e-12。可用最大绝对误差1e-8作为本例宽松验收，但不能把同一阈值无条件用于任意深度和尺度。

8 正则项

目标为 $L_{data} + \lambda(\|W_1\|_F^2 + \|W_2\|_F^2)/2$ 时，权重梯度变成原数据梯度加 λW_1 或 λW_2 ，偏置梯度保持不变。系数1/2抵消平方求导的2。

如果错误写成 $[\sum_i \ell_i + \lambda R]/B$ ，相对通常的平均数据损失加lambda R，正则被缩小B倍；改变批量又改变正则强度。先明确目标，再写梯度，才可以比较超参数。

冻结训练与测试记录

数据种子85086，训练/验证/测试分别323/157/160。主训练种子8501、隐藏宽度8、学习率0.15、1200次全批量更新。初始训练损失0.938143063，最终0.008241463；验证损失0.017509568、准确率0.987261146；测试损失0.012261032、准确率1.0。这里不按验证选择检查点，测试仅结束时评价。

普通与-O模式各运行10项真正的unittest，全部通过。复制批量的平均梯度最大差约2.78e-17，sum与3倍mean的最大差约6.94e-17，遗漏batch因子的负对照被检出。这支持实现和归约约定的一致性；只有一个合成任务、一个数据种子，不支持现实安全系统效果或全局最优声明。