

第087课 练习答案与冻结实验解释

本答案的数值来自experiment-result.json。理论值与实验估计分别注明；保留小数只是方便复核，并不表示结论有同样多位有效精度。正常与优化模式的14项unittest均实际运行通过。

1 四点例子的完整计算

预激活为 $[-3, -1, 1, 3]$ ，ReLU输出为 $[0, 0, 1, 3]$ 。先算均值： $(0 + 0 + 1 + 3)/4 = 1$ 。平方和为 $0 + 0 + 1 + 9 = 10$ ，二阶矩 $q = 10/4 = 2.5$ 。方差有两种一致算法：围绕均值的平方偏差为 $[1, 1, 0, 4]$ ，平均是1.5；也可用 $q - \mu^2 = 2.5 - 1 = 1.5$ 。RMS为 $\sqrt{2.5} \approx 1.581139$ ，标准差为 $\sqrt{1.5} \approx 1.224745$ 。

输入均值为0，二阶矩和方差都为 $(9 + 1 + 1 + 9)/4 = 5$ 。输出二阶矩是输入二阶矩的一半，但输出方差1.5不是输入方差5的一半。原因是ReLU产生了非零均值，方差还要减去均值平方。只写“ReLU让方差减半”会混淆不同量。

这里的对半不是依赖样本数趋近无穷的近似。四个输入严格成正负配对，正值保留的平方和恰好占全部平方和一半；若输入集合不对称，这个有限样本结论不必成立。

2 逐项展开线性组合

令 $Z = \sum_{i=1}^n W_i H_i$ ，偏置为0。要求本层不同权重相互独立、每个权重均值为0、方差为 σ_w^2 ，权重向量与输入向量独立。输入每个坐标的二阶矩相同，为 q 。这里不必强求输入各坐标独立，独立零均值权重已经能够消除不同坐标对应的交叉项。

先算 $E[Z] = \sum_i E[W_i]E[H_i] = 0$ 。随后

$$E[Z^2] = \sum_i E[W_i^2]E[H_i^2] + \sum_{i \neq j} E[W_i W_j]E[H_i H_j].$$

不同权重独立且均值为0，故 $E[W_i W_j] = 0$ ；同一个权重的 $E[W_i^2] = \sigma_w^2$ 。于是 $E[Z^2] = n\sigma_w^2 q$ 。由于 $E[Z] = 0$ ，这也等于 $\text{Var}(Z)$ 。

若输入均值为 μ 、方差为 v ，则 $q = v + \mu^2$ ，正确结果为 $n\sigma_w^2(v + \mu^2)$ 。漏掉均值项会低估非零均值激活产生的预激活尺度。理论期望对输入和初始化共同平均；给定一个固定权重矩阵沿样本统计，不会逐项严格等于这个总体等式。

训练后权重可能与输入表示形成依赖，零均值及同分布近似也可能失效。因此推导首先是一种初始化尺度分析，不是对整个训练过程的不变量证明。

3 64→32层的Xavier尺度

$n_{in} = 64$, $n_{out} = 32$ 。Xavier方差为 $2/(64 + 32) = 1/48 \approx 0.0208333$ ，标准差为 $1/\sqrt{48} \approx 0.144338$ 。若使用 $U[-a, a]$ ，要求 $a^2/3 = 1/48$ ，故 $a = 1/4 = 0.25$ 。

在线性近似下，前向每坐标二阶矩乘子是 $64/48 = 4/3$ ，反向是 $32/48 = 2/3$ 。它们平均为1，但两者都不是1。这个结果直观地显示，宽度改变时，一个方差一般无法同时精确保留两个方向的每坐标尺度。

错误做法是把 $1/64$ 和 $1/32$ 直接平均，得到 $3/128 \approx 0.0234375$ 。这与 $1/48$ 不同。Xavier是在前后向传播倍率之间取折中，不能凭一句“平均一下”就忽略究竟平均哪个量。

还有两个常见错误：把方差0.0208333传作正态抽样的标准差；把批大小128放进fan_in。前者令尺度再平方，后者把样本数误当连接数，都会改变预期传播。

4 ReLU、Leaky ReLU与24层预测

对称预激活 Z 经过ReLU后， $E[A^2] = E[Z^2]/2$ 。一层线性加ReLU的二阶矩倍率为 $n_{in}\sigma_w^2/2$ ，令它等于1得到 $\sigma_w^2 = 2/n_{in}$ 。

负斜率为 a 的Leaky ReLU在正半轴保留 Z ，负半轴变为 aZ 。两半平方期望原本相等，所以

$$E[A^2] = \frac{1+a^2}{2} E[Z^2], \quad \sigma_w^2 = \frac{2}{(1+a^2)n_{in}}.$$

取 $a = 0.1$ 、 $n_{in} = 64$ ，方差为 $2/(1.01 \times 64) \approx 0.0309406$ ，标准差约0.175899。ReLU的对应方差为0.03125，标准差约0.176777。负半轴不再完全归零，因此所需补偿略少。

等宽Xavier给出 $\sigma_w^2 = 1/64$ ，ReLU每层二阶矩倍率约1/2。若输入二阶矩约1，24层预测 $2^{-24} = 5.96046 \times 10^{-8}$ 。冻结实验三个种子中位数为 5.91216×10^{-8} ，数量级与预测一致。输入梯度RMS比中位数为 3.85794×10^{-4} ，不要把RMS比与二阶矩比直接当同一数字。

5 范数、RMS与损失平均

矩阵有 $M = 128 \times 64 = 8192$ 个元素。 $\|G\|_F = \text{RMS}(G)\sqrt{M}$ ，所以范数为 $0.02\sqrt{8192} \approx 1.810193$ 。如果另一矩阵有更多元素，即使每个元素典型大小不变，Frobenius范数也会增长。

假设原损失为 B 个逐样本损失的平均，改成求和后，损失变为原来的 B 倍，梯度、RMS和Frobenius范数也都变为 B 倍。本题 $B = 128$ ，RMS成为2.56，范数约231.70475。若梯度的均值不为0，方差也会乘 B^2 ，这再次说明平方量与一阶尺度不能混用。

本课探针是 $S = \sum H \odot U$ ，特意没有按批量平均，以便末层梯度就是固定 U 。真实分类损失却是逐样本交叉熵的平均。因此二者绝对范数不能直接排名；探针主要看相对于上游的比例，训练日志主要看同一损失约定内的变化。

6 饱和与梯度的两个反例

24层sigmoid/Xavier：末层激活二阶矩中位数约0.248300，数值完全没有趋近零；末层导数绝对值小于0.01的比例中位数为0；输入梯度RMS比却约 6.93979×10^{-16} 。原因是sigmoid导数至多1/4，不需要达到非常极端的饱和，就能在多层链式乘法中产生巨大衰减。激活绝对值并不能代表输入敏感度。

24层tanh/large：末层小导数比例中位数约69.47%，输入梯度RMS比中位数却约 4.67021×10^7 。大量局部门很小，剩余路径仍可能受很大的权重倍率影响。总梯度是路径相加与矩阵方向传播的结果，不能只凭末层一个比例判断。

这两组数字的正确结论是“需要联合看权重、导数与端到端梯度”。不应推广成“sigmoid永远不能训练”或“tanh饱和会导致爆炸”。本课指定了结构、深度、宽度、初始化和种子；换条件之后可能出现不同现象。

7 残差恒等项不能提供无条件下界

一维残差块 $h_{l+1} = h_l + F(h_l)$ 的导数为 $1 + F'(h_l)$ 。若 $F(h) = -h$ ，输出恒为0，一块导数就是0，更多块也为0。若 $F(h) = h$ ，一块导数2，两块导数4，24块为 $2^{24} = 16777216$ 。因此“包含一个1”不代表总和至少为1，更不代表多块乘积稳定。

一般向量形式为 $J_l = I + \alpha J_{F_l}$ 。它提供直接路径，但分支路径可以与直接路径在某些方向相互抵消，也可以共同放大。若相加后还有激活 ψ ，实际雅可比是 $D_\psi(I + \alpha J_F)$ ；若跳连是投影 P ，则是 $P + \alpha J_F$ 。讨论严格恒等路径时，必须核对这些条件。

前向二阶矩是

$$E[(H + \alpha F)^2] = E[H^2] + 2\alpha E[HF] + \alpha^2 E[F^2].$$

即使 $E[HF]$ 近似为0，残差分支仍可能逐层累积平方质量。若输入与分支均值不为0， $E[HF]$ 也不等于协方差本身。不能因为“随机权重均值零”就在训练过程中永久删除这个相关项。

本课简化tanh残差探针在24块时，未缩放末层二阶矩中位数17.4577，梯度RMS比10.5709；按 $1/\sqrt{24}$ 缩放后为1.43845与1.24156。这支持本配置中的改善，没有提供对所有残差架构的稳定性定理。

8 高硬准确率为何没有通过记忆验收

预声明门槛有两个条件：准确率100%以及平均交叉熵小于0.02。93.3%不满足第一个条件，约1.0986更远不满足第二个条件。因此small配置失败，不存在“接近通过”的含糊改写。

概率 $[0.33333334, 0.33333333, 0.33333333]$ 会把第一类选为预测，若第一类是真实类就得到一个正确硬预测；但它的负对数概率仍接近 $\log 3$ 。全数据上有很多微小排序正确，也不能说明模型已产生有意义的概率间隔。

small三个种子的最终准确率为83.3%、93.3%、70.0%，交叉熵都在1.09861227附近。He三个种子均为100%，交叉熵分别约0.000137209、0.000118559、0.000151649。Xavier也均为100%，交叉熵约0.000516460、0.000209915、0.000222428。应该写“在固定预算下，He与Xavier都通过记忆验收，small没有通过”，不能为突出He而隐去Xavier的成功。

这些训练概率也没有经过独立校准测试；小训练损失不意味着对现实新样本的置信度可信。

9 数据来源、预处理与后续泛化设计

数据来源是UCI Wine，官方说明178个样本、13项化学特征、三个品种，许可CC BY 4.0。课程从scikit-learn随包副本取出每类原始行号最前的10条，保存30行全部13特征与原标签。运行实验只读取本地JSON，因此不需要scikit-learn或联网。来源链接、许可、修改和哈希均在data目录中说明。

标准化只用这30条训练记录得到均值与标准差，适合当前刻意记忆任务。这里重复在训练数据上评价是任务设计的一部分，并不“偷偷用了测试集”，因为没有声明存在独立测试集。错误在于把这种结果误称泛化成绩。

后续泛化实验可重新使用完整178条数据，事先确定训练、验证、测试划分或嵌套交叉验证规则；标准化仅用每个训练折拟合；网络宽度、正则化与早停只由训练/验证决定；最终测试只用于一次冻结评估。因为数据很小，应报告不确定性与分割敏感性，不能凭一次高分宣称适用于新产区或新年份。

现在已经看过这些30条样本的结果，因此若重新分割把它们放入测试集，需要承认探索历史可能影响模型选择。更干净的外部验证使用未参与开发的新批次数据，并记录测量单位、采样来源和分布差异。

10 为什么巨大统一学习率不是合理补救

第一，层间梯度尺度差异可能很大。把全局学习率乘100000会同时放大输出层和其他正常层，容易使损失震荡、溢出或激活模式剧变。第二，若某些门给出精确零梯度，有限学习率乘零仍为零。第三，如果梯度已被数值误差或病态方向主导，单纯放大无法恢复丢失的信息。

合理顺序是先检查数据标准化与标签对应、损失平均方式和有限差分；确认参数确实更新；记录初始化的逐层激活与梯度；检查激活关闭或饱和；再在匹配激活的初始化上做小规模学习率试验。所有试验保留控制变量与预算，不能同时增加深度、改变优化器、改数据而只把成功归因于学习率。

梯度裁剪可以限制爆炸更新，但不修复消失；逐层学习率可能帮助某些尺度问题，却也需要先确认实现与方向可信。本课只要求提出有证据的下一步，不要求发明一个万能超参数。

11 完整复核记录应如何写

一个合格结论示例：在float64、宽度64、深度24、三组配对权重种子的随机输入探针中，ReLU/He末层二阶矩中位数约0.992，输入/输出梯度RMS比约1.58；同条件ReLU/Xavier的二阶矩约 5.91×10^{-8} 。这些结果与二阶矩传播数量级分析相符，但未检验全部雅可比方向。另在固定30条Wine训练集上，六层48宽ReLU网络用普通全批量SGD训练1200步，He和Xavier都通过双门槛记忆验收。没有独立泛化结论。

其中每一句都能找到对应配置与原始数值。失败、边界与成功共同构成报告，不是成功后另外附加的免责声明。