

第087课 激活初始化与梯度传播

本课问题：一个网络还没有学到任何东西，为什么就可能已经难以训练？我们把“输出看起来正常”“梯度能传回来”“参数真的在学习”和“能够拟合一小批数据”分开检查。核心不是背两条初始化公式，而是知道公式控制了什么平均量、依赖哪些假设，以及什么时候应该相信实际测量。

直接先修：015、021、034、083、085至086。需要会向量、矩阵、期望与方差、链式法则，以及前向传播和反向传播。本课的实验只用NumPy，不需要GPU，也不依赖在线数据服务。读完应能独立推导Xavier与He的尺度、解释二阶矩和方差的差别、读懂逐层诊断图，并用真实小数据完成一次训练链路验收。

1 从一个具体故障开始

假设你用葡萄酒的13项化学测量预测三个品种，先搭六个隐藏层，每层48个神经元。运行1200步，屏幕上准确率偶尔已经超过90%，但交叉熵一直约为1.0986。你会说模型已经学会了吗？本课真实实验出现了这个现象：过小权重能让三类概率只发生极微小的排序变化，硬分类却看起来进步明显。

另一方面，换成较合适的初始化后，同样数据、网络、训练步数和学习率，在三个种子上都能达到100%训练准确率，交叉熵降到千分之一以下。这说明该结构至少有能力拟合这30条记录，也说明原来的训练配置确实有问题。但它不证明这个网络能预测新酒样，更不证明深度网络是这个表格任务的最佳选择。

我们先在完全可控的随机输入上隔离传播机制，再做有真实标签的训练。第一部分没有优化器干预；第二部分检验完整训练链路。两个实验回答的问题不同，不能互相代替。

2 符号不是装饰：每个量都要有形状

设第 l 层输入宽度为 n_{l-1} ，输出宽度为 n_l 。对一个样本， $h^{(l-1)}$ 是长度 n_{l-1} 的列向量； $W^{(l)}$ 是 $n_l \times n_{l-1}$ 矩阵； $b^{(l)}$ 是长度 n_l 的偏置； $z^{(l)}$ 叫预激活， $h^{(l)}$ 叫激活。

$$z^{(l)} = W^{(l)}h^{(l-1)} + b^{(l)}, \quad h^{(l)} = \phi(z^{(l)}).$$

第 j 个神经元做的是

$$z_j^{(l)} = \sum_{i=1}^{n_{l-1}} W_{ji}^{(l)} h_i^{(l-1)} + b_j^{(l)}.$$

求和表示这个神经元收集所有输入的加权贡献。 ϕ 逐元素作用，不会混合不同神经元。本课代码为了让一行对应一个样本，保存批量矩阵 $H \in \mathbb{R}^{B \times n_{l-1}}$ 以及权重 $W \in \mathbb{R}^{n_{l-1} \times n_l}$ ，所以代码写成 $Z = HW + b$ 。这是转置后的存储约定，数学机制不变。矩阵前后顺序写错常常比初始化选择更早造成问题。

B 是批大小； L 是隐藏层数； σ_w^2 是某层单个权重的初始化方差。不要把网络宽度、输入特征数和样本数混为一谈。fan_in是一个输出单元收到多少输入，fan_out是一个输入单元向多少输出连接，二者都不是批大小。

3 局部导数如何变成长链

令 $\mathcal{L}$ 为标量损失， $g^{(l)} = \partial \mathcal{L} / \partial h^{(l)}$ 。先经过激活，再经过线性层，链式法则给出

$$\delta^{(l)} = g^{(l)} \odot \phi'(z^{(l)}), \quad g^{(l-1)} = (W^{(l)})^T \delta^{(l)}.$$

符号 $\odot$ 表示对应位置相乘； δ 是对预激活的梯度；转置矩阵把输出方向的敏感度送回输入。对权重的梯度是

$$\frac{\partial \mathcal{L}}{\partial W^{(l)}} = \delta^{(l)} (h^{(l-1)})^T.$$

所以权重梯度小可能来自反传信号小，也可能来自前向激活小，两者不能只凭最终梯度范数区分。一个通道在输入方向几乎常数，即使后方梯度不小，这个通道也很难贡献有效更新。

若每层雅可比为 $J_l = \partial h^{(l)} / \partial h^{(l-1)}$ ，整体雅可比是 $J_L J_{L-1} \cdots J_1$ 。标量直觉是 $0.8^{24} \approx 0.00472$ ， $1.2^{24} \approx 79.5$ ；反复乘略小或略大的数，最终差距很大。矩阵还有方向旋转，因此“平均大小合适”仍不保证每个方向都合适。


4 三种激活的导数，逐步看明白

Sigmoid定义为 $\sigma(z) = 1/(1 + e^{-z})$ 。对分母取导并整理，可得 $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$ 。当 $z = 0$ 时，输出是1/2，导数为1/4；离开零点，导数更小。正负极大输入使输出贴近1或0，这时激活处于饱和区域，输入再变化很多，输出也只变一点。

Tanh定义为 $(e^z - e^{-z})/(e^z + e^{-z})$ ，导数为 $1 - \tanh^2(z)$ 。在零点导数为1，正负两端趋近0。它以零为中心，但“中心对称”并不意味着永远不会饱和；若权重过大，预激活也会很大。

ReLU定义为 $\max(0, z)$ 。正半轴导数是1，负半轴导数是0；零点不可微，代码必须选定约定，本实验取0。连续随机初始化下恰好位于零点的概率通常为零，但浮点运算、零输入或全零偏置可能制造精确的零，所以约定仍需要说明。

ReLU的正半轴不饱和，并不意味着它处处传梯度。负半轴被关闭；一个单元在整个训练批上都关闭时，当前批不能通过这个单元的ReLU更新其输入权重。偶尔一半样本关闭是普通门控，不等于永久“死亡”。要宣称死单元，需要跨样本、跨时间检查，不能把一次输出为零当成死亡证明。



原创图1：三种激活、导数及ReLU二阶矩

图1前三幅曲线用解析公式生成。右下角是标准正态输入经过ReLU后的理论均值、二阶矩和方差，它们刻意不相等。图中“点质量”指概率集中在一个准确值上，不是一个很窄但连续的峰。

5 最容易写错的一步：二阶矩不等于方差

随机变量 A 的均值是 $\mu = E[A]$ ；二阶矩是 $q = E[A^2]$ ；方差是 $v = E[(A - \mu)^2]$ 。展开平方后

$$v = E[A^2] - 2\mu E[A] + \mu^2 = q - \mu^2.$$

因此 $q = v + \mu^2$ 。只有均值为零时，两者相等。代码里`mean(xx)`是二阶矩，`var(x)`是方差，`sqrt(mean(xx))`是均方根RMS。RMS衡量相对于零的典型大小；标准差衡量围绕均值的波动。它们服务于不同问题。

举个无需概率积分的例子：四个激活值是 $[0, 0, 1, 3]$ 。均值为1，二阶矩为 $10/4 = 2.5$ ，方差为 $2.5 - 1 = 1.5$ 。若直接把二阶矩2.5写成方差，就漏掉了非零均值的贡献。这个错误在ReLU中尤其常见，因为负值被截掉后均值通常变成正数。

再看标准正态 Z 经过ReLU得到 A 。正态分布关于零对称，平方是偶函数，因此正半轴恰好贡献一半平方期望： $E[A^2] = E[Z^2]/2 = 1/2$ 。同时正半轴的一阶积分得到 $E[A] = 1/\sqrt{2\pi}$ 。所以

$$\text{Var}(A) = \frac{1}{2} - \frac{1}{2\pi} \approx 0.340845.$$

“ReLU保留ReLU后的方差，所以ReLU后方差还是1”并不是这个推导。我们要追踪的主要量是二阶矩。即使预激活是零均值，激活也可以不是零均值。

6 一层线性组合的传播式从哪里来

先省略层号，考虑 $Z = \sum_{i=1}^n W_i H_i$ ，偏置先置零。假设本层权重独立、均值为零、每个权重方差都是 σ_w^2 ，并与进入本层的激活独立。期望的随机性同时包含初始化与输入抽样。

均值先算： $E[W_i H_i] = E[W_i]E[H_i] = 0$ ，因此 $E[Z] = 0$ 。平方展开成对角项与交叉项：

$$E[Z^2] = \sum_i E[W_i^2 H_i^2] + \sum_{i \neq j} E[W_i W_j H_i H_j].$$

独立零均值权重使交叉项为零；每个对角项等于 $E[W_i^2]E[H_i^2] = \sigma_w^2 E[H_i^2]$ 。若输入各坐标有相同二阶矩 q ，得到

$$\text{Var}(Z) = E[Z^2] = n\sigma_w^2 q.$$

注意这里允许 H_i 有非零均值；关键是权重为零均值。因此正确右侧是输入二阶矩，而不是一律用输入方差。这也是非线性激活后继续计算时必须小心的地方。

有限网络中“在一个已经抽好的权重矩阵上，沿样本算统计量”，与“把输入和权重都当随机变量求总体期望”不是同一个统计操作。理论总体均值为零，不保证一次固定网络的每个神经元样本均值恰好为零。实验会把批量与神经元展开统计，并通过三个种子展示浮动；这些是诊断量，不是理论等式的逐层精确验证。

7 Xavier：先满足近线性的理想要求

若激活在零点附近接近恒等函数，例如小预激活的 $\tanh$ ，有 $\phi(z) \approx z$ 与 $\phi'(z) \approx 1$ 。前向保持每坐标尺度，要求 $n_{in}\sigma_w^2 \approx 1$ 。反向在梯度与权重近似独立、坐标二阶矩相近时，要求 $n_{out}\sigma_w^2 \approx 1$ 。

当输入和输出宽度相同，两个条件可以同时满足。宽度不相同，一般无法用一个标量方差同时精确满足。Xavier采用折中

$$\sigma_w^2 = \frac{2}{n_{in} + n_{out}}.$$

这个式子等价于让前向乘子与反向乘子的算术平均为1。它不是两个理想方差 $1/n_{in}$ 与 $1/n_{out}$ 的算术平均。若 $64 \rightarrow 32$ ，方差为 $2/96 = 1/48$ ，前向乘子为 $4/3$ ，反向乘子为 $2/3$ ，平均为1。[1]

本课用正态版：先抽 $G \sim \mathcal{N}(0, 1)$ ，再令 $W = G\sqrt{2/(n_{in} + n_{out})}$ 。传给正态抽样器的是标准差而非方差。若使用对称均匀分布 $U[-a, a]$ ，它的方差为 $a^2/3$ ，所以对应边界为 $a = \sqrt{6/(n_{in} + n_{out})}$ 。两个分布方差相同，不表示有限样本的尾部或谱性质完全相同。

Xavier不是“任何激活都自动稳定”的保证。Sigmoid零点导数只有1/4，ReLU会删除负半边平方质量，这些都偏离近恒等条件。对 $\tanh$ 而言，若预激活本身较大，近线性近似也会失效。

8 He：把ReLU丢掉的一半平方质量补回来

设预激活 Z 关于零对称，且 $A = \max(0, Z)$ 。无需假设 Z 严格为正态，对称性已经足够保证 $E[A^2] = E[Z^2]/2$ 。结合上一节的一层传播式：

$$q_l = E[(H^{(l)})^2] \approx \frac{1}{2} n_{l-1} \sigma_{w,l}^2 q_{l-1}.$$

希望乘子为1，就令

$$\sigma_{w,l}^2 = \frac{2}{n_{l-1}}, \quad \text{std}(W) = \sqrt{\frac{2}{n_{l-1}}}.$$

这就是fan_in版He初始化的核心尺度。[2] 等宽64时，标准差为 $\sqrt{2/64} \approx 0.176777$ 。Xavier在同样宽度下标准差为0.125；固定标准差0.01会让单层二阶矩乘子约为 $64 \times 0.01^2/2 = 0.0032$ 。

反向分析中，ReLU门的平方仍等于这个门本身，若打开概率约为1/2，并近似忽略门与上游梯度的相关性，反向每坐标二阶矩乘子约为 $n_{out} \sigma_w^2/2$ 。fan_out版He因此用 $2/n_{out}$ 。输入输出宽度相等时，两者一致；宽度变化很大时，要知道自己更想优先保持哪个方向的每坐标量。

Leaky ReLU把负半轴斜率设为 a ，对称预激活下二阶矩保留比例变成 $(1 + a^2)/2$ ，相应fan_in尺度是 $2/[(1 + a^2)n_{in}]$ 。这里 a 是负斜率，不是激活值，也不是均匀分布的边界。一个符号在不同文献里可能有不同含义，复现前要重新标注。

9 别把边界层机械当成内部隐藏层

输入层前面没有ReLU，因此推导中“先线性，再ReLU”的组合需要与实际结构对齐。若第一层使用He，标准化输入二阶矩约为1，预激活二阶矩约为2，再经ReLU回到约1，这个约定是自洽的。

输出层通常直接产生logits，后面接softmax和交叉熵，并没有需要补偿的ReLU。对输出层沿用He不一定导致失败，但不能援用“补回半边”的理由。本课真实训练把所有配置的最后线性层固定为Xavier，使初始化干预只发生在隐藏层。这样观察到的差异更容易解释。

零偏置是控制实验的起点。把所有权重初始化为零通常会保留神经元之间的对称性，阻碍它们学到不同特征；零偏置却很常见，因为独立随机权重已经破坏了这种对称。两句话并不冲突。偏置很大还会把tanh、sigmoid推入饱和或把ReLU整体推到一侧，使零均值与半开门假设不再适用。

10 梯度范数要先说明“对谁求导”

本课传播实验不接一个任意的分类损失，而是在最后激活上放置一个独立的随机上游矩阵 U ，定义探针标量 $S = \sum_{ij} H_{ij}^{(L)} U_{ij}$ 。于是对最后激活的梯度恰好是 U 。这相当于给网络一个固定的反向测试信号，再看输入端收到多少。

U 和输入、权重各用独立随机流。不同深度和初始化共享相同输入、相同形状的 U ，同种子下还共享标准正态权重底稿，只改变缩放。这样比“每次随便重抽一切”更容易归因。

若矩阵 G 有 M 个元素，Frobenius范数为 $\|G\|_F = \sqrt{\sum G_{ij}^2}$ ，RMS为 $\|G\|_F/\sqrt{M}$ 。本实验主要报告输入梯度RMS与输出梯度RMS之比。等宽时它也等于Frobenius范数比；不等宽时就不一定相同。平均损失和总损失的梯度还差批大小倍数，所以跨代码比较绝对范数之前必须核对损失的reduction。


上游探针只能测试初始化处的一个随机方向。它不是训练损失梯度，更不是全部奇异值。若某些方向被大幅放大、另一些被压扁，一个平均RMS可能掩盖二者；需要更强诊断时，应查看雅可比谱或多个独立方向，但本课不把一个探针伪称完整谱分析。

11 预先固定实验，才不容易挑结果

传播实验统一使用float64、批量128、宽度64，隐藏深度为2、8、24。输入种子8700，上游梯度种子8799，权重种子8701、8702、8703。每个深度都测试ReLU的small、Xavier、He、large四个初始化；另测试tanh和sigmoid的Xavier与large。small标准差0.01，large标准差1，这两个刻意的反例不是推荐设置。

每层记录预激活和激活的均值、方差、二阶矩、RMS、零值比例，以及对激活和预激活的梯度。还记录导数绝对值小于0.01的比例。对tanh、sigmoid可把它当作一个操作性饱和指标；对ReLU，它主要表示关闭门比例，不能解释成与sigmoid相同的饱和机制。

三种种子中位数用于概括，最小至最大用于展示有限重复的跨度。这不是置信区间，也不足以估计全部初始化风险。默认脚本保存所有原始逐层结果，不只保存最漂亮的一条。



原创图2：固定宽度与配对种子的深度传播

图2对数纵轴让许多数量级可以同时出现。阴影只代表三个种子的范围；不能把阴影窄理解为统计上已经确定。右下角层号仍从输入到输出，反向传播的计算顺序则相反。

12 先用理论数量级预测，再读实测

等宽ReLU配Xavier时，理想二阶矩每层约乘1/2，因此24层末端应约为 $2^{-24} \approx 5.96 \times 10^{-8}$ 。实测三个种子的中位数为 5.912×10^{-8} ，很接近这个数量级。对应输入/输出梯度RMS比约 3.858×10^{-4} 。RMS是平方量的平方根，因此不要误把二阶矩倍率直接当作RMS倍率。

small的末层二阶矩中位数为 1.318×10^{-60} ，梯度RMS比为 1.822×10^{-30} ；large分别达到 1.318×10^{36} 和 1.822×10^{18} 。它们展示的是初始化处的强烈缩小与放大，还不是“训练已经数值溢出”的证据。本实验float64仍可表示这些数，但实际更新很容易因尺度失衡而困难。


He的24层末层二阶矩中位数约0.992，梯度RMS比约1.580。它保持在合理数量级，并没有做到每层每个方向精确等于1。有限宽度、门控和方向相关性都会造成偏离。不能因为1.58不是1就宣布理论被推翻，也不能因为中位数好看就宣布任意更深网络一定稳定。

同样，Xavier在六层真实训练中能够很好拟合，和它在24层ReLU传播中逐渐缩小并不矛盾。初始化是训练起点，深度和后续更新会改变现象；“相对更难”不等于“绝对不能训练”。

13 看分布，才能发现平均量藏住的事

每层只有一个均值会隐藏大量细节。全为0与一半为-100、一半为100的均值都为0，但表达与梯度行为完全不同。方差、二阶矩、分位数、零点质量需要联合看。

图3绘制激活非零部分的 $\log_{10} |a|$ 和输入梯度非零部分的 $\log_{10} |g|$ 。负30表示原始绝对值约 10^{-30} ，不是“梯度值等于-30”。激活在零点的概率质量单独标出，因为对零取对数没有有限结果。图中直方图是给定非零条件下的密度，不可把曲线面积误认为所有样本的概率都在其中。



原创图3：不同深度的激活与梯度分布

同一种子下，三种正缩放的ReLU网络有相同门控模式，因为零偏置和ReLU的正齐次性：

$\text{ReLU}(cx) = c \text{ReLU}(x)$ ，其中 $c > 0$ 。所以相同深度的零值比例一致，而非零分布整体移动。这个细节是控制实验的可解释性优势，并非绘图误把同一组数据画了三次。若加入非零偏置、换成tanh或开始训练，这个精确关系通常就不再成立。

14 饱和不等于所有梯度一定同时消失

24层sigmoid配Xavier时，末层激活二阶矩约0.248，输出看起来完全不接近全零，但输入梯度RMS比只有 6.94×10^{-16} 。末层导数小于0.01的比例中位数还是0。这说明即便没有大量“极端饱和”单元，反复乘最大只有1/4的局部导数也能导致强烈衰减。把梯度问题只归结为输出贴边，诊断会漏掉这一类情况。

反方向也值得注意：large初始化的tanh在24层末端约69.5%的导数小于0.01，但输入梯度RMS比中位数却约 4.67×10^7 。多数单元饱和不代表剩余路径不能被大权重强烈放大。必须同时看导数、权重、方向及最终范数，不能只数饱和单元就宣布整体梯度消失。

“爆炸”与“消失”甚至可以在同一网络的不同方向、不同样本或不同层同时发生。平均RMS大可能来自少数异常分量。因此真正排查训练时，还应看最大绝对值、非有限值比例、按样本的分布，并记录是激活梯度还是参数梯度。

15 残差路径为什么有帮助

普通层是 $h_{l+1} = F_l(h_l)$ 。简化残差块是 $h_{l+1} = h_l + \alpha F_l(h_l)$ ，其中 α 是残差分支缩放。对输入求导：

$$J_l = I + \alpha J_{F_l}, \quad g_l = g_{l+1} + \alpha J_{F_l}^T g_{l+1}.$$

I 是恒等矩阵；它把同一方向直接传过来。即使残差分支导数较小，仍有一条加法路径。多块展开会出现不经过某些残差变换的项，这有助于理解深网络为何可以从接近恒等映射的状态开始调整。[3]

但“有 I ”不等于“最终梯度必定至少和原来一样大”。两条路径可能抵消。标量反例：若 $F'(h) = -1$ 、 $\alpha = 1$ ，总导数 $1 + F' = 0$ ；若 $F' = 1$ ，24块总导数是 $2^{24} = 16777216$ 。恒等项存在，梯度仍可消失或爆炸。

还有结构边界。若加法之后再接ReLU，雅可比外面又乘一个门，恒等路径也可能被关闭；若用投影矩阵调整维度，跳连不再是严格的 I ；若跳连上有缩放、归一化或门控，也必须把它们纳入导数。残差论文的严格传播式有明确结构条件，不能直接搬给所有名叫“残差”的模块。

16 残差前向尺度也要计算

对标量坐标，有

$$E[(H + \alpha F)^2] = E[H^2] + 2\alpha E[HF] + \alpha^2 E[F^2].$$

中间项是相关项，不能未经说明就扔掉。如果二者均值不为零，还不能直接把 $E[HF]$ 叫协方差；协方差还需要减去均值乘积。即使相关项近似为零，分支每次增加的二阶矩也会随深度累积。

本课残差探针使用 $h \leftarrow h + \alpha \tanh(hW)$ ，不是完整ResNet复现。宽度64，三个种子，比较 $\alpha = 1$ 与 $\alpha = 1/\sqrt{L}$ 。24块时未缩放的末层二阶矩中位数约17.458，梯度RMS比约10.571；缩放后的对应值约1.438与1.242。这个实验说明分支缩放在本配置中控制了增长，不说明它是所有残差网络的最优规则，也没有替代归一化或深度专门初始化的完整分析。

17 真实小数据：为什么故意追求过拟合

在准备大规模训练之前，先问一个很朴素的问题：模型能不能把30条已经看过的真实记录记住？如果容量明显足够却做不到，应该优先怀疑标签对应、预处理、前向、梯度、更新和初始化，而不是立刻增加数据或算力。这是一项训练链路的烟雾测试。

本课从UCI Wine的随包副本冻结每类原始行号最前面的10条，共30条，保留全部13特征和原标签；顺序在训练前确定，不按照拟合表现挑行。Wine数据来自真实化学测量，原库共有178条、三个品种，使用CC BY 4.0许可。[4] 交付包已包含这30条原始值，运行实验不需要scikit-learn，也不需要下载。


标准化参数只由这30条训练记录计算。每列减去其均值，再除以总体标准差，代码采用ddof=0。这里没有验证集和测试集，因为目标明确是刻意记忆这30条样本。不能给训练成绩改名叫测试成绩。将来若评价泛化，必须另建分割并重新规定预处理和模型选择职责。

18 训练协议与验收门槛

模型是13→48→48→48→48→48→48→3，六个ReLU隐藏层，最后一层为线性logits。偏置初始为零。所有配置使用相同原始标准正态权重底稿，隐藏层分别使用small、Xavier、He，输出层始终Xavier。优化器为全批量普通梯度下降，学习率0.05，固定1200步，无动量、权重衰减、归一化或梯度裁剪。

记忆成功预先同时要求训练准确率等于100%且平均交叉熵小于0.02。前者要求所有硬预测正确；后者排除“只是以极微小差距碰巧排对”的情况。损失阈值并不是概率校准证明，只是这一诊断任务清楚可复核的验收标准。

交叉熵使用稳定的log-softmax：每行logits减去最大值，再计算指数和的对数。对真实类别的负对数概率求均值。反向梯度为 $(P - Y)/B$ ，其中 P 是预测概率矩阵， Y 是真实类别的one-hot矩阵。除以 B 只做一次；若在每层再除一次，深层梯度会被人为压小。



原创图4：真实训练与残差缩放

图4上半部分是三种种子训练曲线，下半部分是独立的残差传播诊断。两组图共用一个版面，但不是同一个模型，也不能用下半部分解释上半部分的全部差异。

19 冻结结果：允许好结果和反例一起存在

He三种子的最终交叉熵分别约为0.000137、0.000119、0.000152，训练准确率都是100%。Xavier对应约0.000516、0.000210、0.000222，也全部通过验收。这个实验支持“两个配置在当前网络与预算下都能训练”，不能写成“只有He能训练”。

small的交叉熵分别约为1.098612265、1.098612270、1.098612277，和均匀三分类的

$\log 3 \approx 1.098612289$ 极其接近，但硬准确率分别达到83.3%、93.3%、70.0%。比如预测概率是 $[0.33333334, 0.33333333, 0.33333333]$ 时，第一类被选中，然而并没有形成明显的概率偏好。微小变化足以改变argmax，损失却揭示模型几乎仍停在均匀预测。

种子8701的初始首层权重梯度范数，small约 1.89×10^{-7} ，Xavier约0.114，He约0.546。这些值还受到输出层和实际标签的影响，不能直接和无监督传播探针的RMS比混算。它们共同说明，真实训练里也出现了尺度差异。

20 为什么增大学习率不能包治百病

参数更新是 $\Delta W = -\eta \nabla_W \mathcal{L}$ 。当某层梯度特别小，提高全局学习率 η 的确可能增加该层步长，但它也会同时放大其他层，导致原本正常的层震荡或发散。如果梯度精确为零，任何有限学习率乘零仍然为零。

更严重时，小梯度反映的是方向信息已经丢失或严重失真。把一个几乎没有有效信号的数乘大，不等于恢复正确方向。初始化控制信号尺度，学习率控制沿当前梯度走多远，二者相关却不是同一旋钮。

梯度裁剪主要限制过大更新，不能使已经消失的梯度自动回来；归一化会改变传播条件，但仍需要检查位置和训练/评价状态。本课不把这些手段混入主实验，是为了让初始化比较有清楚解释。下一课再系统讨论优化实践。

21 一份可以照做的诊断顺序

先检查数据和损失：特征单位是否悬殊，标签是否是正确整数，样本与标签是否对齐，损失有没有重复平均，是否出现NaN或无穷。再用小网络和有限差分核对梯度，确保问题不是实现错误。

然后固定一批输入，记录初始化处逐层激活和梯度；同时保留均值、方差、二阶矩、RMS以及零值比例。观察异常首次出现在哪层，而不是只看最后输出。改变初始化时，保持宽度、输入、随机底稿和上游探针一致，避免一次修改五个因素。

接着关闭不必要的正则化和随机增强，用极小真实样本尝试记忆，固定成功门槛与训练预算。若过不了，逐项排查：更新是否真正写回参数，梯度方向是否正确，激活是否关闭，隐藏层是否得到学习信号。若过得了，再恢复验证协议和正则化；通过记忆测试只是进入下一阶段的许可证。

最后记录失败。一个种子失败是信息，不应无声换种子直到得到好图。要改实验，就说明改了什么、为何改、哪些结果属于旧协议。科学判断依赖可追溯的对照，不依赖一张美观曲线。

22 本课代码如何对应推导

activate与derivative对应激活及局部导数；weight_std只负责返回标准差；moments同时保存均值、方差、二阶矩与RMS，避免读者把名字相近的统计量混用。forward返回全部中间激活和预激活，因为反向过程需要知道当时的门控状态。

input_vjp沿反向次序把上游矩阵乘激活导数，再乘权重转置。probe建立控制实验；probe_samples为分布图重建固定种子的真实样本值。residual_vjp把直接路径和分支路径相加，并用有限差分单独验证。

loss_and_grad实现稳定交叉熵及全部权重、偏置梯度；train_tiny真的执行1200次参数更新，保存损失、准确率和首末层梯度范数。run返回完整JSON字典；plots读取冻结结果并画图。测试使用unittest，不依赖会被python -O删除的裸assert，正常与优化解释器都已运行。

23 结论的边界，也是下一步的入口

Xavier和He给出的是在特定近似条件下保持平均尺度的起点。实际网络中的有限宽度、数据相关性、参数训练后的依赖、非零偏置、归一化、共享权重与特殊结构都会改变传播。不要把两条公式当作整个优化理论。

本课提供三层证据：公式给出数量级预测；受控实验展示初始化处的传播；真实小数据检验完整训练链路。三者互相补充，却不互相越权。我们没有做完整雅可比谱分析、没有估计泛化误差、没有复现大型ResNet，也没有比较所有可能初始化。

最值得保留的习惯是：每当看到一个“稳定”结论，都问它稳定的是均值、方差、二阶矩、范数还是所有方向；每当看到一个“学会了”结论，都问它来自训练损失、硬准确率还是未见数据。说清楚量与边界，才能把直觉变成可复核的判断。

来源与复核

[1] Glorot与Bengio, 2010, 原论文第4.2节及公式10-12: [PMLR原文](#)。

[2] He等, 2015, 第2.2节、公式7-10与反向讨论: [作者原论文](#)。

[3] He等, 2016, 第2节传播推导及第3至4节结构条件: [Identity Mappings原文](#)。

[4] Aeberhard与Forina, Wine数据与CC BY 4.0许可: [UCI官方页](#)。

逐项核验范围见sources.md。所有图均由本课plots.py原创生成，理论图、初始化探针与真实训练结果已分别标明。