第088讲 练习答案与验收解释

1 更新与曝光预算

batch32每轮1280/32=40次更新，10轮400次；batch128每轮10次更新，10轮100次。两者曝光量均1280×10=12800。匹配epoch只匹配这一例的曝光，不匹配更新或墙钟。若丢弃最后不足一批、采样有放回或数据增强成本不同，还要重新核算。

2 不等长梯度累积

总数19，三个mean loss权重为8/19、8/19、3/19。因为整体目标是每条样本权重1/19，短批中每条样本在其mean loss里权重1/3，乘3/19才还原1/19。若每批都乘1/3，最后三条各占1/9，前面每条各占1/24，已经改变样本权重。

实现时组开始zero_grad，各段加权backward，组结束clip和step。不能在每段step，因为参数点变了；不能每段清空，因为前面梯度会丢。BN训练统计依赖微批，故即使权重正确也未必与大batch等价。

3 裁剪计算与边界

(6,8)范数10，乘5/10得到(3,4)。普通SGD若不含其他更新项，更新范数是eta×5。Adam还进行自适应缩放，不能据此得到同一个上界。weight decay也是独立参数变化来源，应在讨论实际位移时包含。

4 只丢scheduler的恢复对照

保持模型、优化器、随机数、数据游标和保存位置相同；一组恢复scheduler state或使用正确全局step，另一组从新scheduler初始状态开始。分别记录恢复后每一步lr、loss和参数差。首个lr分歧是直接证据。若使用本讲rate(t)显式函数，step已经决定计划，没有额外scheduler对象可丢，此时应故意重置t来构造相同问题。

5 加入BatchNorm后为何不能等价

大batch统计由37条共同计算，微批分别由16、16、5条计算，所以同一条样本的归一化激活不同，loss函数在分批前后已改变。梯度线性加权只对同一函数的样本项适用，不会抵消这种变化。可冻结BN为eval再测，隔离批统计效应；但这改变了训练算法，不能默默替换。

6 固定30分钟方案

预先设定同一机器线程、数据划分与评价频率，每组独占运行30分钟，记录时间起点是否含数据预处理/编译，定期记录验证指标、更新量、曝光量和内存。给各配置相同调参预算。最终比较30分钟时的预定指标，同时报告实际完成工作量。短任务有启动开销，墙钟受噪声影响，应重复并报告变异。本讲固定120步只回答相同更新预算问题，不能替代该时间预算。

数值验收与解释模板

正确累积误差小于1e-6；完整恢复误差小于1e-7；仅权重恢复差异应显著大于1e-6。具体实测数值以outputs/results.json为准。通过意味着这台机器、该版本、该模型和更新边界的状态足够，并非跨硬件通用保证。三种配置验证loss的高低应按全部种子呈现，不从一次结果推广普遍排名。