# 第089讲 实验手册

## 运行准备：每一步都有检查点

建议Python 3.12，CPU即可。先在终端进入本讲目录，创建独立虚拟环境，再按README安装依赖。运行python experiment.py会生成outputs/results.json和figures中的图；运行python -m unittest -v test_experiment.py会执行数值测试。首次安装PyTorch可能需要下载较大CPU轮子，训练本身不需要联网。

请先确认python -c "import torch; print(torch.**version**)"成功，再运行实验。若提示找不到模块，通常是安装包的Python与运行脚本的Python不是同一个，不要反复混用pip和pip3。使用python -m pip能明确安装目标。

实验默认CPU单线程、固定随机种子。结果数值可随版本产生细微变化，耗时会随机器负载明显变化。验收依据是数学容差与机制，不要求你的毫秒数和本包完全一致。不要删除失败对照，它们是本讲证据的一部分。

已执行experiment.ipynb含实际IPython执行输出和图像，可先阅读再重跑。Notebook与脚本使用同一实验函数，避免维护两套相互漂移的实现。运行会覆盖本讲outputs和figures中生成的同名文件，请先备份自己修改后的结果。

## 实验A：不用训练，先辨认统计轴

运行axis_probe，固定第一条anchor，把另外7条同伴从0换成20。记录BN train、LN、BN eval三种最大输出差。预计BN train变化明显；LN和冻结BN eval不随同伴变化。再检查统一加10的输入平移：LN输出近似不变，冻结BN通常明显改变。

在纸上画8×4矩阵：BN沿列向下收集8个数，LN沿行收集4个数。若换成(B,T,D)，写清LayerNorm(D)到底覆盖哪些轴。通过标准是你能在计算前预测哪些样本相互影响。

## 实验B：验证dropout的一阶与二阶矩

打开dropout_probe：20万个输入都等于3，p=0.25。训练输出只能是0或4，理论均值3、方差3。检查样本统计在合理容差内；再切eval，输出应精确恢复输入。把p改为0.5，先手算理论值再运行。

不要把期望相等写成每次输出相等，也不要把样本方差的微小偏差当实现错误。若输入是随机变量，本讲的条件方差推导不能直接不加条件地套用；要使用全方差公式重新计算。

## 实验C：2×2消融而不是一次堆叠

四组分别改变LN与dropout有无，每组三种子。读01_factorial.png训练与验证曲线，核对记录loss时处于eval模式。比较仅dropout与baseline，再比较LN+dropout与LN；两次差异是否方向一致？若不一致，这是交互迹象，不能用单一“dropout提高多少”概括。

本基线训练64条、验证256条、60轮、batch16，共240次更新。BN batch探针是单独探索，batch4/16/64分别960/240/60次更新。明确写下这个混杂因素，不要把曲线差异全归因于批统计。

## 实验D：补全真正的early stopping

基线仅记录验证最优epoch。请另写扩展：patience=5，改善阈值1e-4，最大60轮；改善时深拷贝state_dict，连续5轮无改善则停止，最后恢复最佳权重。报告停止epoch与最佳epoch，两者通常不同。

本包没有独立测试集，故最终仍叫验证结果。若你自行增加测试集，先冻结所有选择规则，最后只评价一次。禁止用测试结果反过来改变patience。

## 提交与验收

提交三图、四组逐种子指标、BN batch预算表、dropout矩核验与early stopping伪代码。必须区分统计轴、训练/推理状态、正则机制与选择规则。无需证明某模块总是更好，能解释不改善的结果同样合格。