第098讲 参考答案与验收解释

1 单步手算

保留项0.9×0.8=0.72，写入项0.2×(−0.5)=−0.10，因此c=0.62；h=0.7×tanh(0.62)≈0.3858。输出门控制可见状态，不能据h的绝对值较小就认为c中记忆已消失。

2 两种门控的区别

LSTM分别维护c和h，有遗忘、输入、输出三个sigmoid门及候选内容。GRU只有隐藏状态，重置门控制候选的旧信息贡献，更新门混合旧状态与候选。按PyTorch定义，z越大越保留旧状态。先重置再线性映射与先线性映射再重置一般不同，因为矩阵与逐元素门不交换。

3 真实基线结果

本次CPU实测，RNN、GRU、LSTM在3个初始化、3个测试长度上的27条准确率全部为1.0000；每个模型每个长度的种子间标准差都是0。该结果不支持“门控网络在本任务明显胜过RNN”。正确结论是：在噪声0.10、训练长度12、宽度12和200次更新的这个简单首位符号任务中，三种结构都学会了足以覆盖测试长度48的策略。

训练后长度12交叉熵按种子0/1/2分别为：RNN约0.00008479、0.00007244、0.00005559；GRU约0.00003483、0.00003738、0.00001687；LSTM约0.00011002、0.00002715、0.00009376。交叉熵仍有差别，但准确率已到上限；不能把更低置信损失直接等同于所有分布上更强记忆。

> 没有观察到架构优劣也是有效实验结果。简单任务达到天花板时，应保留原结果，设计更难且预先定义的干扰或预算实验，而不是改数据直到出现想要的排名。

4 参数量与公平性

核心基数12×1+12×12+2×12=180，输出头为12×2+2=26。RNN共206，GRU共566，LSTM共746。控制了数据、状态宽度、更新次数、优化器和学习率；没有控制参数量、FLOPs，也没有为各结构单独调参。所以只能描述这组设置，不能声称全面比较了最优架构。

5 数值验证

手写LSTMCell与框架最大绝对误差为0。有效token损失为1.2796443436030598，追加3列padding后为1.2796443436030596，相差2.22×10^−16，是浮点求和量级。正确有效状态读出变化为0，错误统一最后位置读出变化约0.02200475。后者是结构性错误的证据，不能用“padding只是零”搪塞。

6 错误平均造成什么后果

原张量有2×4=8个位置，其中有效5个。若错误地直接mean，得到正确有效平均的5/8。追加3列后张量有2×7=14个位置，错误值变成正确平均的5/14。于是同一有效内容只因padding变长，错误损失又缩成原来的8/14。这个变化不是学习进步，梯度也被相同因子缩小。

7 梯度通路能说明多少

固定门且不写入时，f=0.9的50步直接保留系数约0.005154，f=0.99约0.605006。这里控制门为常量，目的仅为说明连乘敏感性。真实LSTM门受旧h影响，完整梯度还包含间接路径；不能把这两个数当训练模型实测记忆长度。

8 双向网络的适用范围

若预测整段已经观察到的句子中每个词的标签，使用左右上下文可能合理。若在实时t时刻预测t+1事件，右侧真实数据不可见，双向分支会泄漏未来。即使训练损失更低，部署条件也不成立。单向有效索引的padding不变性不能替代双向打包验证。

9 单测通过仍然不保证什么

7项单测覆盖单步参考、损失padding、有效状态padding、错误末端反例、空mask拒绝、数据复现和有限梯度。它们不证明模型在任意分布上泛化，不证明代码不存在其他错误，也没有测量GPU速度。性能结论应来自真实记录，不能把准确率阈值硬编码成机制测试。

10 扩展研究如何评分

合格记录包含一个明确改动、事前假说、完整种子结果、控制变量与失败案例。提高噪声可能改变排名，也可能仍全部成功；两种结果都可接受。若更改训练长度，还应重新报告总输入token预算，因为同样200次更新不再对应相同序列计算量。