第099讲 参考答案与实测审计

1 三token第一行

分数为[0.707107,0,0.707107]，权重约[0.401112,0.197776,0.401112]。输出为这三个V的加权和，约(6.016681,5.961077)。点积判断读取份额，V提供被读取内容；若直接拿K当输出，将改变题目定义。

因果mask下第一行只有第一个位置可读，权重为[1,0,0]，输出(10,0)。第二行只保留前两个分数，归一化约[0.330238,0.669762,0]，输出约(3.302385,13.395231)。第三行不受因果mask影响，因为它已经可以看到全部三个位置。

2 手写梯度

给定G=dL/dO，dV=A转置G，dA=GV转置。每行dS=A⊙(dA−sum(A⊙dA))。然后dQ=dS K/sqrt(d_k)，dK=dS转置 Q/sqrt(d_k)。广播时减去的是该行标量，sum保持最后一维长度1，避免错误地跨查询聚合。

若Q/K/V都由X产生，dX是三个投影支路贡献之和。若只是独立给定的Q/K/V测试，代码只需要报告各自梯度，不必凭空添加不存在的共享X节点。

3 实际误差

手写前向对框架最大误差3.89×10^−16；Q、K、V手写梯度误差分别约1.11×10^−16、1.11×10^−16、0。中心有限差分单坐标误差约9.78×10^−11。前向与自动微分的差异接近float64舍入量级，有限差分还包含步长截断与相消误差，因此其容许阈值较宽。

单坐标有限差分不是全梯度证明；配合Q/K/V全张量解析梯度对齐才构成本讲较完整的验证。代码通过不代表任意扩展代码都正确。

4 信息边界反例

把最后一个位置的K增加30、V减少20，正确因果mask下前3个输出变化为0；去掉mask时最大变化约20.062714。这直接表明未屏蔽版本能读取被改动的未来内容。

padding追加测试变化为0；被屏蔽权重最大值为0；每行权重和误差约2.22×10^−16。全屏蔽查询被明确拒绝，避免未定义归一化。有效键屏蔽不自动处理无效查询的损失，完整任务还需要有效token mask。

> 这些是机制验收结果，不是语言能力成绩。实验未训练模型，也未测翻译、推理或真实问答表现。

5 复杂度

4头、长度16/32/64/128的分数矩阵元素数依次为1024/4096/16384/65536，float32字节数为4096/16384/65536/262144。长度翻倍，元素数乘4。它只是显式分数矩阵大小，不包含训练内存全部来源；高效内核可改变实际物化和访存方式。

6 多头与交叉注意力

B=2、H=4、L=8、d=3时，Q是[2,4,8,3]，权重[2,4,8,8]。查询长度5、键长度7、值维4时，输出[2,4,5,4]。多头不是把8个位置切成4组每组2个，而是4套读取视角各自处理所有允许位置。

7 不能据热图声称什么

高权重不等于最终预测中最高因果作用。值向量大小、投影、残差和后续非线性都可能改变贡献。热图首先适合检查mask与归一化，因果问题需要定义干预并测输出变化，也应考虑干预造成分布外输入。

8 验收结果

9项测试覆盖框架前向、解析梯度、有限差分、未来不变性、无mask反例、padding不变性、概率约束、全屏蔽拒绝、交叉注意力形状。数值阈值针对CPU float64；更换精度或实现时需说明误差变化，不能默默调宽阈值掩盖逻辑错误。