第099讲 注意力实验手册

1 实验目标

不用封装模型，完成三token前向手算、注意力手写反向、框架对齐、因果与padding反例。预计60–90分钟。最终提交数值对照和一段信息边界说明，不能以热图“看上去合理”代替测试。

2 运行

在本讲目录安装requirements.txt后依次运行python experiment.py、python -m unittest -v test_experiment.py、python execute_notebook.py。所有输入本地生成，不联网。Notebook可逐格执行；发布版本由IPython真实执行并保存。PDF重建见build-requirements.txt与package.json，安装构建依赖后运行python build_pdf.py。

> 先验证小矩阵再考虑训练。一个mask方向错误的模型也可能降低训练损失，因为它偷看了答案。

3 手算任务

写出Q、K、V形状和完整分数矩阵。计算第一行未屏蔽权重与输出，保留6位小数。再加入下三角允许mask，算第一行与第二行；解释为什么第一行输出恰好等于V的第一行。

观察outputs/results.json的hand_example，不要先照抄。核对你算的是每行softmax而非每列；每行权重和为1。比较float64结果时使用绝对误差1e−6，不要求四舍五入文本与二进制浮点完全相同。

4 梯度任务

对O=AV写出dV和dA，再推导单行softmax的dS，最后写dQ与dK。打开backward对照形状：dQ与Q相同，dK与K相同，dV与V相同。

实验构造固定上游dy，并使用L=sum(O*dy)形成标量。为什么有限差分两侧必须使用同一个dy？如果每次重新采样dy，差值同时包含目标变化，不能估计原目标的导数。

5 因果反例

修改最后位置K/V，比较前3个查询输出。保留正确mask时误差应低于1e−12；去掉mask应出现明显变化。记录两种值，解释这项检查覆盖的是注意力核心而非整个数据管道。

额外把下三角换成上三角，再测早期输出。这个破坏性实验应失败；恢复正确实现后提交。不要把失败阈值改大来通过。

6 padding与空行

追加两列随机K/V，新增列标为False。有效输出应不变。把mask整行改False，必须明确报错。讨论另一种生产策略：跳过无效查询并在损失端排除；不要让NaN悄悄混入训练。

7 多头形状练习

给定B=2、H=4、L=8、每头维度3，写出Q形状与权重形状。再设交叉注意力查询5个、键7个、值维4，输出应为[B,H,5,4]。本讲单测含一个无头维的批次交叉注意力实例，验证查询与键长度不必相等。

8 复杂度审计

读取results中complexity。长度16、32、64、128时，H=4的分数张量元素数应为1024、4096、16384、65536。以float32每元素4字节换算。指出这不是峰值训练内存，也不是直接测得的运行时间。

9 验收清单

- 3token前向计算与手写梯度推导完整
- 9项单测通过，包含两项反例和全屏蔽拒绝
- Notebook无错误输出且图来自本次代码执行
- 明确mask中True的语义，并说明其他API可能相反
- 不把注意力权重等同因果解释