第100讲 参考答案与实测结果

1 两条残差

Pre-LN先对X归一化送入注意力，注意力输出加X得到Y；再对Y归一化送入FFN，FFN输出加Y得到Z。第二次不能仍加X。归一化范围为每个token最后的8个特征，不跨batch或位置。

2 完整形状链

输入[2,4,8]，QKV打包输出[2,4,24]，每个Q/K/V为[2,4,8]，拆头后[2,2,4,4]，权重[2,2,4,4]。聚合后转回[2,4,8]，输出投影保持该形状。FFN内部[2,4,16]，最后投回[2,4,8]。

同样数字4同时出现在序列长度和每头特征维，不能仅凭张量数字相同判断轴正确。换一个长度或宽度再测试能揭示偶然掩盖的轴交换错误。

3 参考实现结果

CPU float64实测前向最大误差2.22×10^−16，输入梯度误差2.22×10^−16，全部参数梯度最大误差1.33×10^−15。比较包含qkv与输出投影、两个FFN线性层和两个LN的权重与偏置，共12组参数。

相同随机种子不等于相同参数，因为初始化调用顺序可以不同；显式复制参数才能保证比较的是同一个函数。Pre-LN、GELU、dropout=0和mask语义也必须一致。

4 位置对称性结果

无位置块置换等变误差6.66×10^−16，平均池化不变误差2.22×10^−16。加入固定位置编码后，仅交换内容使平均池化结果变化约0.08991861。若内容和位置向量一起重排，输入整体只是置换，不能用这个测试证明模型区分固定位置上的内容交换。

未来特征扰动在因果mask下对前三位置输出影响为0。若给所有特征加同一个常数，LN可能消除该变化；本实验使用不同特征不同扰动幅度，避免缺乏鉴别力的反例设计。

5 顺序任务

无位置版三个初始化准确率均0.5，交叉熵约ln2=0.693147；有正弦位置版三个初始化准确率均1.0，记录的float32交叉熵均为0.0。

记录为0不是证明数学概率精确等于1，而是大logit间隔下有限精度交叉熵舍入到0。这个任务仅有两种完整枚举模式，结果说明当前结构与训练能区分它们，不证明未见句子、长序列或真实语言的泛化能力。

> 无位置失败来自明确的对称性条件：全连接共享自注意力、逐位置层、无位置编码和平均池化。改成首位置读出或因果mask后条件改变，不能沿用同一句“不可能区分”的结论。

6 参数量

QKV为216，输出投影72，两个LN合计32，FFN为144+136=280，总计600。公式$4d^2+2df+9d+f$同样得到600。f从16增到32时增加272，块总数变872。embedding、分类头和最终LN如果存在，需要另计。

7 复杂度

注意力投影量级Ld^2，注意力两次矩阵乘法量级L^2d，FFN量级Ldf。固定参数模型处理更长序列，参数数目不变，但计算与激活内存增加。头数改变不必改变投影参数总数，前提是模型总宽度固定。

8 验收与边界

10项测试通过：前向参考、输入梯度、参数梯度、等变性、池化不变性、位置破坏对称性、因果未来不变性、参数量、位置形状及有限值、全屏蔽拒绝。实验没有测GPU性能，也没有训练完整语言模型。后续分词和标签移位需另行验证，不能继承这些测试作为数据管道正确性的证明。