第100讲 Transformer块实验手册

1 目标与环境

预计90分钟。先画出Pre-LN两条残差，再阅读Block.forward，完成参考对齐、位置对称性和顺序分类。依赖见requirements.txt，默认CPU单线程，不需下载数据或模型。

运行python experiment.py、python -m unittest -v test_experiment.py、python execute_notebook.py。Notebook保存真实代码输出；可用Jupyter逐格重跑。PDF构建需额外安装build-requirements.txt和package.json依赖，再运行python build_pdf.py。

2 逐行形状审计

给定输入[2,4,8]，写出LN后、QKV打包后、拆头后、权重矩阵、拼头后和FFN内部的形状。注意head维在序列维之前。检查两个残差加法前后的宽度都为8。

> 验证顺序：先复制同一组参数、对齐同一个函数，再比较训练。仅仅相同随机种子不保证两种模块参数相同。

3 参考实现对齐

在reference中逐项核对qkv、proj、fc1、fc2、norm1、norm2的映射。确认参考参数norm_first=True、activation='gelu'、dropout=0、batch_first=True。allowed在自写实现为允许矩阵，参考src_mask为屏蔽矩阵，因此取反。

报告前向、输入梯度、全部参数梯度最大误差。破坏性测试：将参考改为Post-LN或ReLU，应不再对齐。恢复后再继续。不要放宽误差阈值来容忍结构不同。

4 置换对称性

运行默认permutation=[2,0,3,1]，比较F(PX)与PF(X)，然后比较两者平均池化。解释等变和不变差别。添加固定PE后，只交换内容、不交换位置向量，检查全局表示变化。

再尝试把内容和PE一起置换，解释为何这次依然只是把完整输入向量重排。这项分析比简单背“Transformer需要位置编码”更精确。

5 因果测试

将最后位置的不同特征加入不同幅度扰动，检查前三位置输出。为什么不能只对全部特征加同一个常数作为唯一测试？LayerNorm可能消除共同平移，使某些错误测试不敏感。本讲使用随特征索引变化的扰动，提高测试鉴别力。

6 顺序分类诊断

数据仅有[A,B]与[B,A]，每种重复32条。无位置版与有位置版各3个初始化、150次更新，保存全部学习曲线。报告训练准确率，并明确没有独立泛化测试。

预先写下结构预测：无位置+无mask+平均池化无法区分两类；位置向量可以打破这种对称性，但优化是否成功仍需实测。不要把“理论可表示”直接当“训练必然成功”。

7 参数预算

手算d=8、f=16时单块参数。再把f改为32，预测参数增量2d×16+16=272，然后用sum(p.numel())核验。分类器还包含embedding与head，应分开计数，不混进600参数块基线。

8 研究扩展

任选：平均池化换为首位置读出；无位置但加入因果mask；或比较学习式位置表与正弦PE。每次说明哪个信息通道打破对称性，并保留原基线。扩展结果不可冒充当前发布默认实验。

9 验收

- 画出两条正确残差与逐位置LN范围
- 10项单测通过，包括全部参数梯度与未来不变性
- 三种误差、参数量和六次训练记录可查
- 解释无位置结论的条件与当前任务无泛化评估
- 保留失败/天花板结果，不筛选种子