第101讲 答案与结果解读

1. A：正确的输入标签

完整s=[BOS,a,b,EOS]。输入x=[BOS,a,b]，标签y=[a,b,EOS]，有效目标数为3。BOS用于启动条件，自己没有被预测；EOS要被预测，因此模型学到何时结束。若把标签改成[BOS,a,b]，每个位置都可以复制当前符号，任务已经改变。

2. B：PAD为什么必须排除

补齐只是批量存储技术，与文本内容无关。如果PAD进入损失，较短句子带来更多容易预测的PAD，平均损失可能因为补齐比例高而下降。更换批量组成就改变指标，会让模型比较失真。正确方法是对非PAD目标求NLL总和，再除有效目标数。仅把PAD对应logit清零而仍把它计入分母，同样错误。

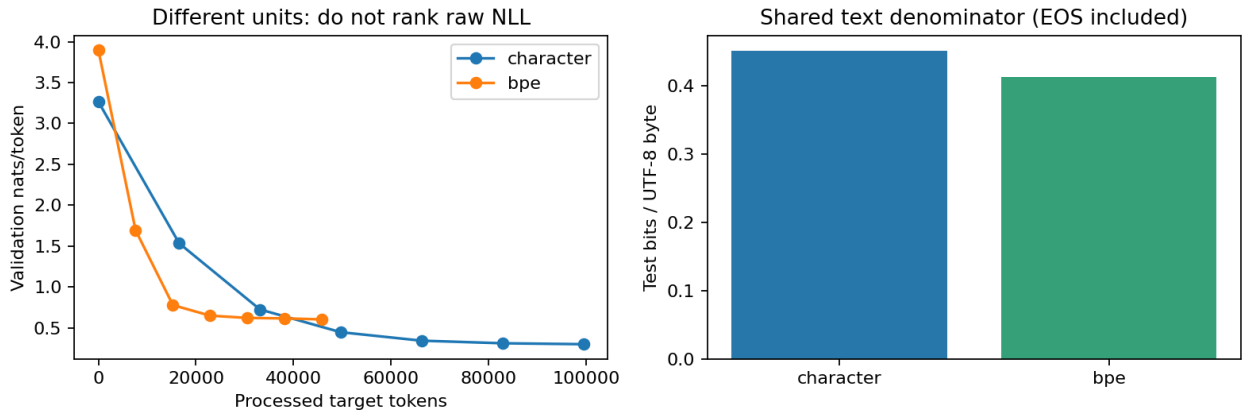
3. C：增加合并数改变了什么

每次BPE合并可能增加词表符号，同时降低一些文本的token数量。输出层和嵌入层参数增加，序列递推步数可能减少，子词频率也改变。相同训练120步并不意味着相同处理token或者同计算预算。应同时报告这些量，不仅报告PPL。遇到新字符，本课UNK机制会丢失原符号；生产级字节回退是另一种设计，本实验没有实现。

4. 实际结果：一个会误导人的排序

> 真实CPU运行：字符模型测试困惑度1.3550，BPE为1.8292；若直接按PPL排序，字符模型看似更好。但按共同文本的bits/UTF-8-byte评分，字符为0.4513，BPE为0.4125。两种排序不一致正好说明：单位不同的PPL不能直接排名。

字符模型测试NLL的分母是字符token数，BPE模型分母是子词token数。一个子词可能包含多个字符，单步信息量不同。BPB把两个模型对同一测试文本的总NLL放到共同字节分母上，才具备本课约定下的可比性。它仍没有控制参数量、处理token和计算预算，因此不能归纳“BPE总是更优”。



由实际训练结果绘制的比较图。

5. D与E：共同分母还需要共同边界

左图nats/token对应不同token事件，所以不可直接比较线条高度。若一份评分包含EOS、另一份不包含，即使分母都叫原始字节数，分子也已经不同。本课全部计EOS且不计BOS/PAD，以文档为评分单位。

不能先求每个batch的PPL再简单平均，因为exp(a+b)与exp(a)+exp(b)不同。应先累加所有目标的负对数概率，除以总目标数，然后取指数。短文档、长文档的权重由目标数决定。

6. 因果性与teacher forcing

未来修改检查的实际最大差值为0，符合单向GRU结构。训练时给模型真实历史并不泄漏当前目标，因为当前位置只看到BOS和之前token。生成时历史由模型自己产生，错误会改变后续条件，这是训练与自由生成不同之处。当前检查不覆盖数据污染，所以仍须独立检查分区。

7. F：为什么不能推广到自然文本

实验只包含4个形容词、8个名词、3个动词组成的2976篇短句。训练与测试共享模板和词表，只检查未见过的组合。没有中文、事实问答、长程依赖、域外文体或对抗输入证据。测试良好最多说明该教学分布内的下一token预测学到了规则。

8. 评分参考

满分10分：对齐及有效位置2分；分区和tokenizer拟合边界2分；PPL/BPB重算2分；因果性解释2分；预算与推广限制2分。只贴最后数字而没有口径说明，不能视为完成。

扩展正确方向：固定总计算预算对比不同切分；实现字节级回退并测试多语言；构造模板外测试集合。它们都需要新的实验，不能用本课现成结果代替。